ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Día 1 — Regresión Lineal y Limpieza de Datos



Módulo 3: Machine Learning Aplicado

13-10-2026 · Jonathan Rosero Soto

Edificio Aulas y Relación con el Medio Externo, Av. Toledo N23-55 y Madrid
Telf.: +593 2 2525766 - Ext: 102 / 125 / 143 / 120 / 127 - www.cec-epn.edu.ec

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

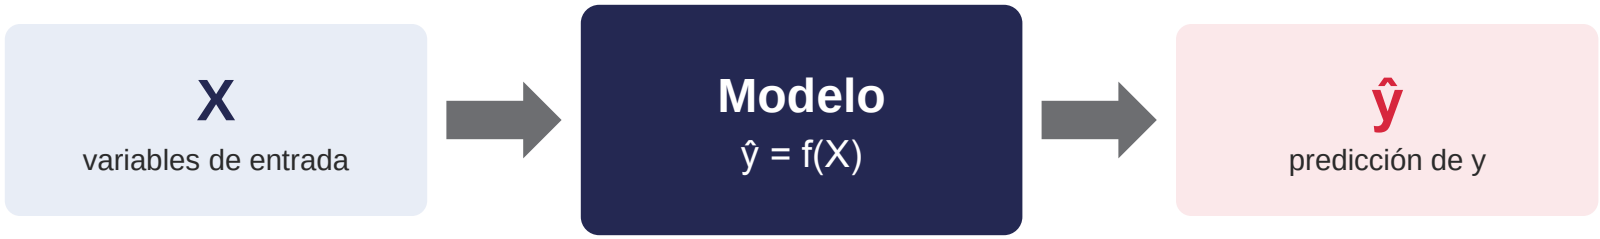
cec·epn U.C.C. Unidad de Capacitación y Certificación

Ruta de la jornada

1	**Regresión lineal simple**	La recta que mejor resume los datos, calculada a mano
2	**¿Qué tan buena es la recta?**	Residuos, MAE, MSE, RMSE, Bias, R^2 y correlación
3	**Datos nuevos**	Train, Validation y Test: aprender vs memorizar
4	**Limpieza de datos**	Duplicados, valores imposibles, atípicos y faltantes
5	**Más de una variable**	Regresión múltiple y variables categóricas

Regla del día: *primero entender a mano, luego dejar que la computadora lo repita.*

Estadística y ML: mismo problema, otro vocabulario



Aprendizaje supervisado: **aprendemos f con ejemplos donde conocemos X y también la respuesta real y**

En estadística decimos…	En Machine Learning decimos…
Variable dependiente / respuesta	Target, variable objetivo (y)
Variables independientes / regresoras	Features, predictores (X)
Observación / unidad muestral	Fila, ejemplo, instancia
Estimar los parámetros	Entrenar o ajustar el modelo
Valor ajustado / pronóstico	Predicción
Muestra de estimación	Conjunto de entrenamiento (Train)
Validación fuera de muestra	Validation y Test

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

1

Regresión lineal simple

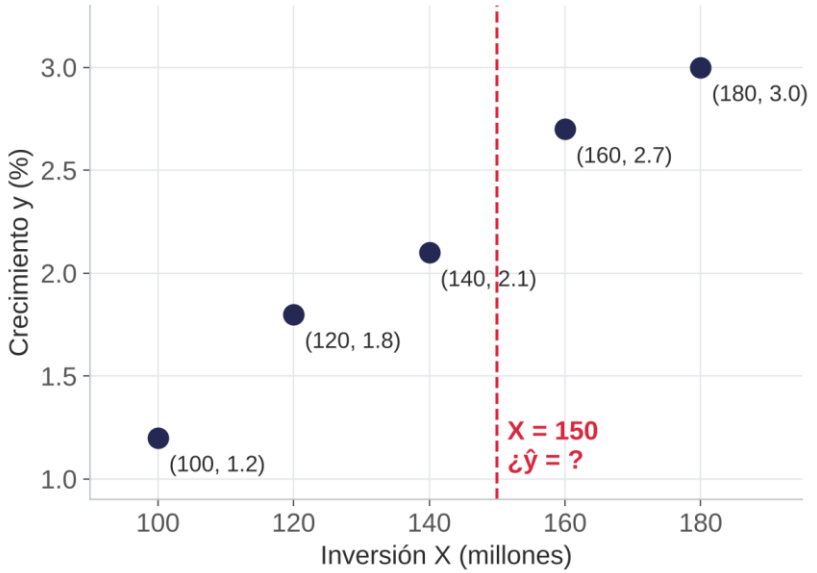
Una variable de entrada, una recta, y el criterio para elegir la mejor: todo calculado a mano

En esta sección

- El problema
- La recta
- Residuos y SSE
- Cálculo de b_0 y b_1

El problema: ¿cuánto crecerá la actividad?

Obs.	Inversión X (millones)	Crecimiento y (%)
1	100	1.2
2	120	1.8
3	140	2.1
4	160	2.7
5	180	3.0



Lo que observamos

Cuando la inversión sube, el crecimiento también tiende a subir, casi en línea recta.

Pregunta

Si X = 150 millones, ¿qué crecimiento predecimos?

Paso 0: graficar antes de calcular

¿Sube o baja?

Dirección de la relación (positiva o negativa)

¿Recta o curva?

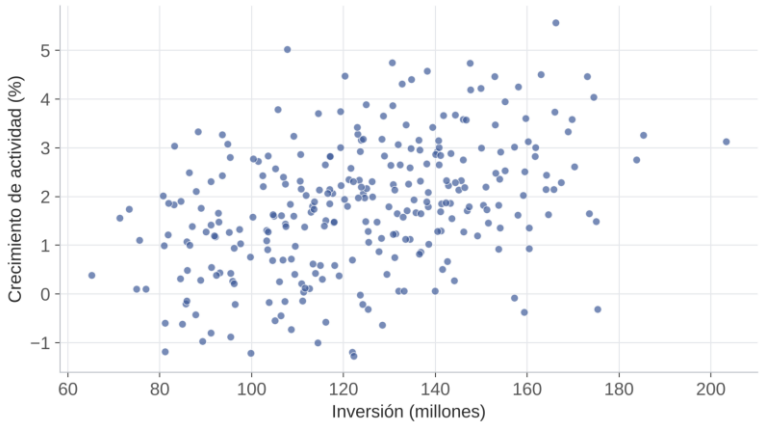
Si es curva, una recta no la representa bien

¿Muy dispersa?

Mucha dispersión = predicciones menos precisas

¿Puntos aislados?

Pueden ser errores o casos especiales

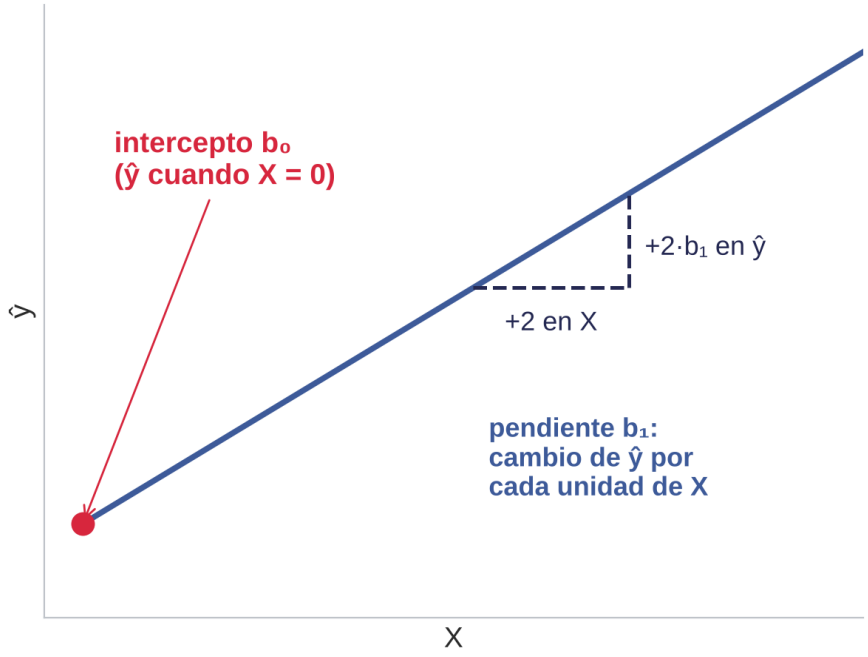


Datos reales del curso: 287 meses-región-sector

La nube real sube suavemente, pero con **mucha dispersión**.

Nuestros 5 puntos forman casi una recta: por eso son ideales para aprender el cálculo.

La ecuación de una recta

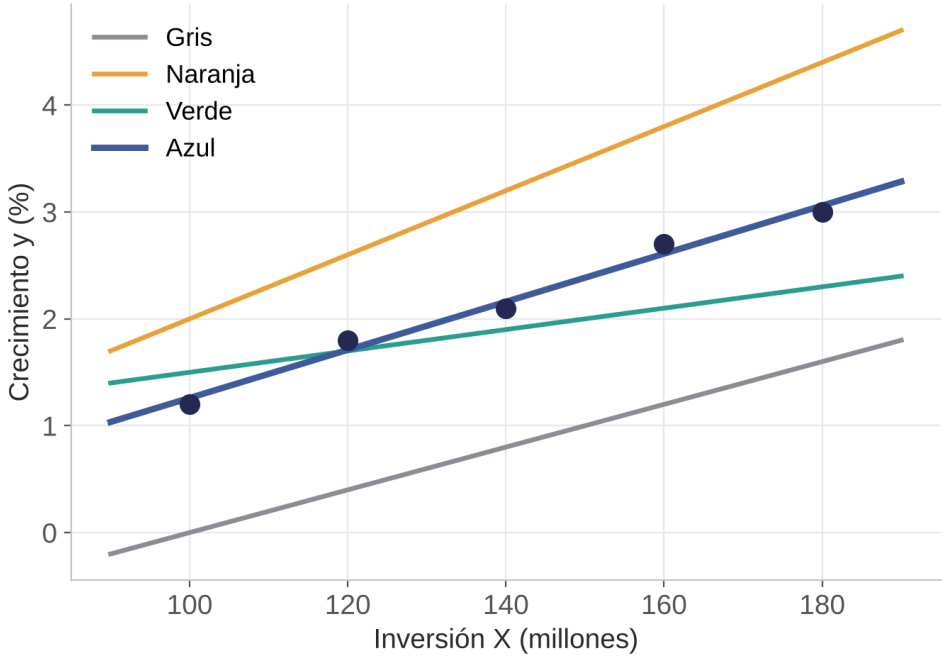


$$\hat{y} = b_0 + b_1 \cdot X$$

$\hat{y}$	valor predicho de y (crecimiento %)
b_0	intercepto: ŷ cuando X = 0
b_1	pendiente: cambio de ŷ por cada unidad de X
X	variable de entrada (inversión, millones)

y ≠ ŷ: y es lo que realmente ocurrió; ŷ es lo que dice la recta. La diferencia entre ambos es el error.

Infinitas rectas posibles: ¿cuál elegimos?



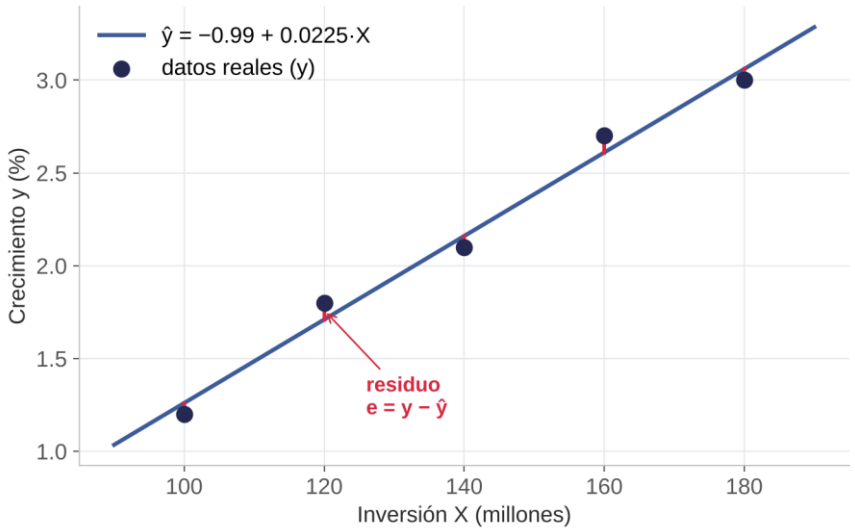
Recta	b_0	b_1
Gris	−2.00	0.0200
Naranja	−1.00	0.0300
Verde	+0.50	0.0100
Azul	−0.99	0.0225

¿Cómo decidimos?

Midiendo la distancia de cada punto a la recta.

Idea clave: la mejor recta es la que, en conjunto, queda más cerca de todos los puntos.

El residuo: la distancia entre lo real y lo predicho



$$e_i = y_i - \hat{y}_i$$

Ejemplo para la observación 1 (X = 100):

Predicción: $\hat{y} = -0.99 + 0.0225 \times 100 = 1.26$

Real: $y = 1.20$

Residuo: $e = 1.20 - 1.26 = -0.06$

e > 0
real mayor que predicho: subestimó

e < 0
real menor que predicho: sobreestimó

SSE: sumar los errores al cuadrado

$$SSE = \Sigma (y_i - \hat{y}_i)^2 = e_1^2 + e_2^2 + \ldots + e_n^2$$

Si solo sumamos

+2 + (−2) = 0

¡parece que no hay error!

Si elevamos al cuadrado

4 + 4 = 8

todo error cuenta

Errores grandes pesan más

$1^2 = 1$ · $3^2 = 9$

triple de error, 9 veces el castigo

Recta	Gris	Naranja	Verde	Azul
SSE	9.30	5.66	0.99	**0.027**

Ganadora: la recta azul (SSE = 0.027). ¿Pero existe otra recta aún mejor?

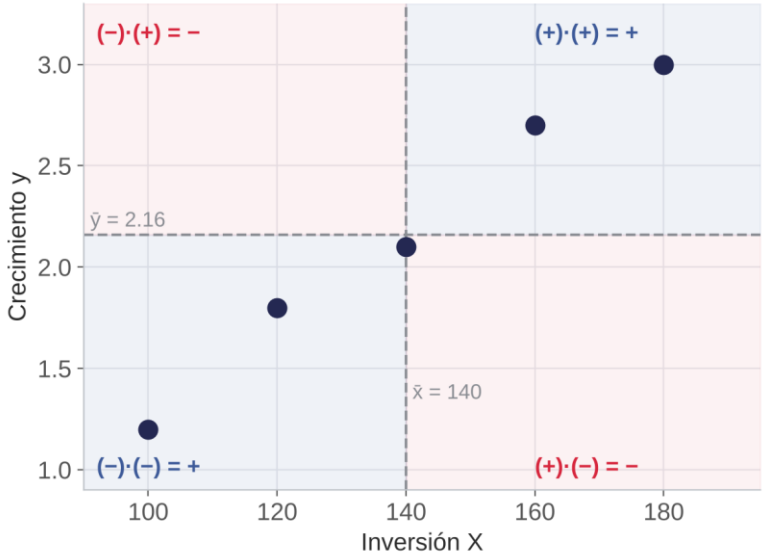
Mínimos cuadrados: la fórmula de la mejor recta

Pendiente

$$b_1 = \Sigma(x_i - \bar{x})(y_i - \bar{y}) \;/\; \Sigma(x_i - \bar{x})^2$$

Intercepto

$$b_0 = \bar{y} - b_1 \cdot \bar{x}$$



¿Qué mide el numerador?

Si X e y están **del mismo lado** de sus medias, el producto es positivo. Si la mayoría de puntos cae en esos cuadrantes, la pendiente es positiva.

Equivalencias

b_1 = Cov(X, y) / Var(X)

La recta siempre pasa por el punto ($\bar{x}$, $\bar{y}$).

Cálculo a mano · Paso 1: las medias

Media de X

$\bar{x} = (100 + 120 + 140 + 160 + 180) / 5$

$= 700 / 5 = 140$

Media de y

$\bar{y} = (1.2 + 1.8 + 2.1 + 2.7 + 3.0) / 5$

$= 10.8 / 5 = 2.16$

Centro de la nube: $(\bar{x}, \bar{y}) = (140, 2.16)$

La mejor recta pasa obligatoriamente por este punto.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cálculo a mano · Paso 2: desviaciones y productos

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
100	1.2	−40	−0.96	38.4	1600
120	1.8	−20	−0.36	7.2	400
140	2.1	0	−0.06	0	0
160	2.7	20	0.54	10.8	400
180	3.0	40	0.84	33.6	1600
			Suma	**90**	**4000**

Ejemplo fila 1

$(100 - 140) = -40$ · $(1.2 - 2.16) = -0.96$

$(-40) \times (-0.96) = 38.4$ · $(-40)^2 = 1600$

Todos los productos son ≥ 0

Los puntos están en los cuadrantes “positivos”: la pendiente será positiva.

Cálculo a mano · Paso 3: pendiente e intercepto

Pendiente

$b_1 = 90 / 4000$

$$\mathbf{b_1 = 0.0225}$$

Intercepto

$b_0 = 2.16 - 0.0225 \times 140$

$b_0 = 2.16 - 3.15$

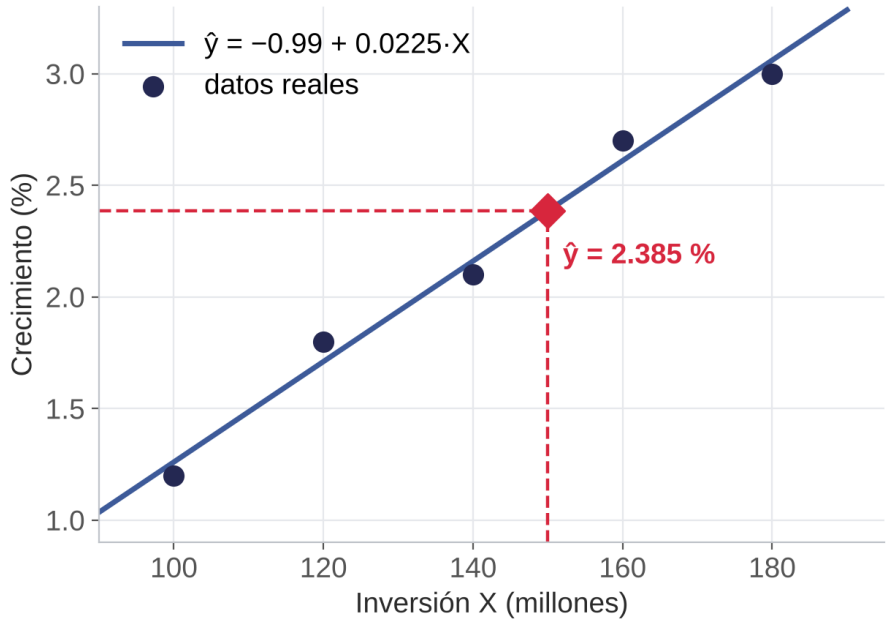
$$\mathbf{b_0 = -0.99}$$

La recta de mínimos cuadrados es

$$\hat{y} = -0.99 + 0.0225 \cdot X$$

Verificación: ninguna otra recta tiene un SSE menor que 0.027 para estos 5 puntos. En el notebook comprobaremos que la computadora da exactamente estos números.

Usar la recta para predecir



Pregunta: X = 150

ŷ = −0.99 + 0.0225 × 150

ŷ = −0.99 + 3.375

ŷ = 2.385 %

X	Cálculo	ŷ
110	−0.99 + 2.475	1.485
150	−0.99 + 3.375	2.385
170	−0.99 + 3.825	2.835

Así funciona todo modelo: primero aprende los parámetros (b_0, b_1) con datos conocidos; después los usa para predecir casos nuevos.

Interpretar la pendiente y el intercepto

Pendiente $b_1 = 0.0225$

Por cada **1 millón más** de inversión, la predicción de crecimiento sube **0.0225 puntos porcentuales**.

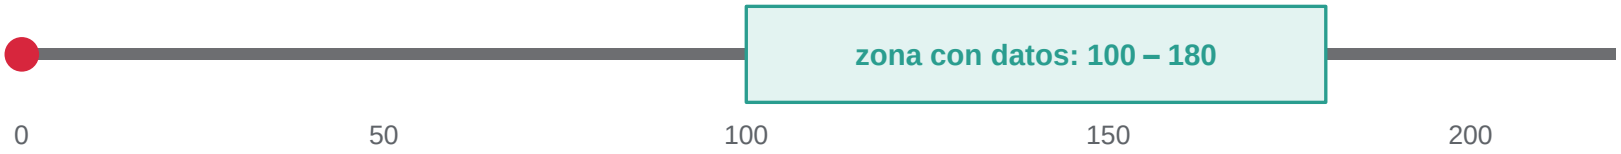
10 millones más → +0.225 pp

Intercepto $b_0 = -0.99$

Valor de ŷ cuando la inversión es **0**.

Nunca observamos inversión 0: aquí no tiene interpretación económica, solo ubica la recta.

Rango de inversión observado en el ejemplo



X = 0 → extrapolación

Asociación ≠ causalidad: la recta describe cómo se mueven juntas las variables; no prueba que invertir cause el crecimiento.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Supuestos del modelo lineal clásico: LINE

L

Linealidad

La relación media entre X e y es una recta.

Revisar: *Residuos sin forma de curva*

I

Independencia

El error de una fila no depende de otra.

Revisar: *Cuidado con datos en el tiempo*

N

Normalidad

Los errores siguen una distribución normal.

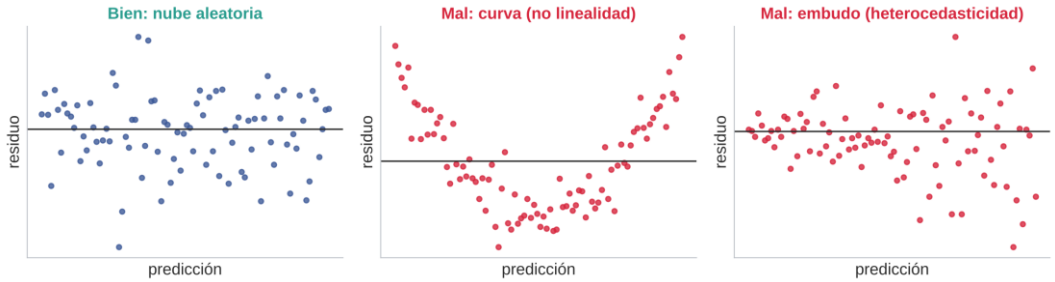
Revisar: *Histograma de residuos en campana*

E

Igual varianza

La dispersión de los errores es constante.

Revisar: *Residuos sin forma de embudo*



ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

2

¿Qué tan buena es la recta?

Medir los errores: cada métrica responde una pregunta distinta, y todas se pueden calcular a mano

En esta sección

- Cinco métricas
- Cálculo a mano
- R^2 y la media
- Correlación r

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cinco métricas, cinco preguntas

MAE	**promedio de |e|**	¿Cuánto me equivoco normalmente?	**ideal = 0** unidades de y
MSE	**promedio de e^2**	Error cuadrático medio	**ideal = 0** unidades^2
RMSE	**√MSE**	¿Qué tan grandes son los errores grandes?	**ideal = 0** unidades de y
Bias	**promedio de $(\hat{y} - y)$**	¿Sobreestimo o subestimo sistemáticamente?	**ideal = 0** + sobre / − sub
R^2	**1 − SSE / SST**	¿Cuánto mejoro frente a predecir siempre la media?	**ideal = 1** sin unidades

Las métricas calculadas a mano

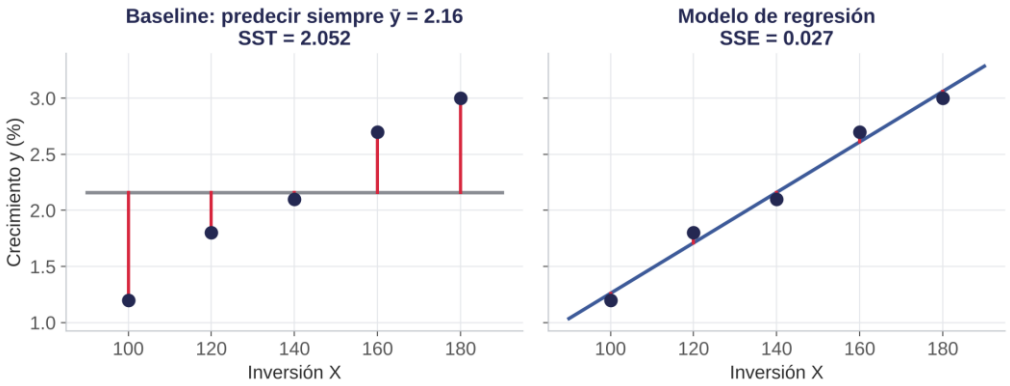
y	ŷ	e = y − ŷ	|e|	e²
1.2	1.26	−0.06	0.06	0.0036
1.8	1.71	+0.09	0.09	0.0081
2.1	2.16	−0.06	0.06	0.0036
2.7	2.61	+0.09	0.09	0.0081
3.0	3.06	−0.06	0.06	0.0036
Suma		**0.00**	**0.36**	**0.027**

MAE	0.36 / 5	**0.072**
MSE	0.027 / 5	**0.0054**
RMSE	√0.0054	**0.073**
Bias	0.00 / 5	**0.000**

Interpretación: en promedio la recta se equivoca 0.07 puntos porcentuales, sin tendencia a pasarse ni a quedarse corta.

Pero… lo medimos con los mismos datos con los que se calculó la recta. ¿Funcionará con datos nuevos?

R^2: ¿cuánto mejora la recta frente a la media?



y	y − ȳ	(y − ȳ)²
1.2	−0.96	0.9216
1.8	−0.36	0.1296
2.1	−0.06	0.0036
2.7	0.54	0.2916
3.0	0.84	0.7056
SST		**2.052**

$R^2 = 1 - SSE / SST$

$= 1 - 0.027 / 2.052 = 0.987$

$R^2 < 0$ es posible

con datos nuevos, si el modelo es peor que la media

Lectura: la recta reduce el error cuadrático en 98.7 % respecto a predecir siempre 2.16 %.

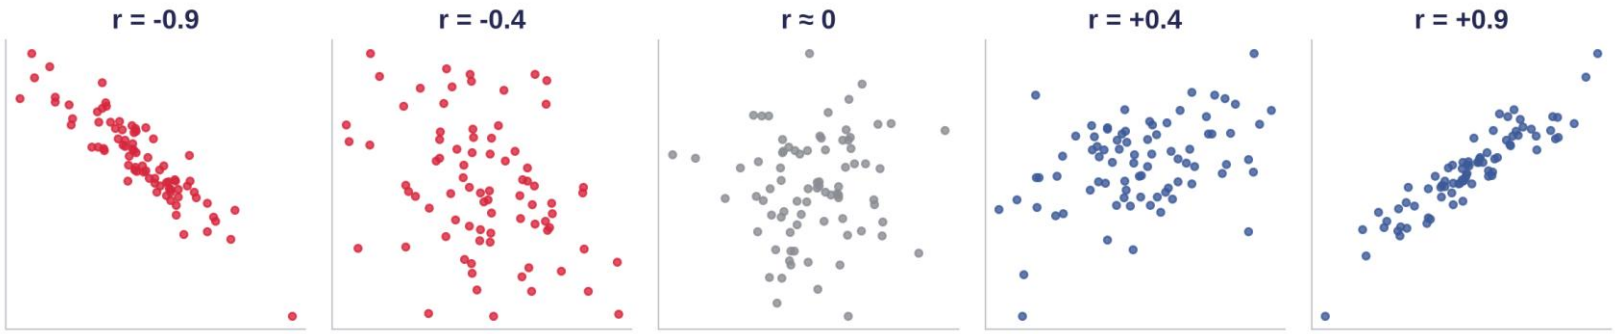
ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Correlación r y su relación con R^2

$$r = \Sigma(x_i - \bar{x})(y_i - \bar{y}) \;/\; \sqrt{[\,\Sigma(x_i - \bar{x})^2 \cdot \Sigma(y_i - \bar{y})^2\,]}$$



Con nuestros 5 puntos

$r = 90 / \sqrt{(4000 \times 2.052)}$

$r = 0.993$

En regresión simple

$R^2 = r^2$

$0.993^2 = 0.987$ (coincide)

ESCUELA POLITÉCNICA NACIONAL

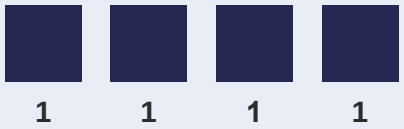
cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

MAE vs RMSE, y la trampa del Bias

Modelo A: errores parejos

|errores| de 4 predicciones:



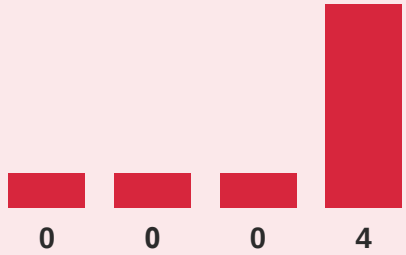
MAE = **1.0**

RMSE = **1.0**

RMSE = √[(1+1+1+1)/4] = 1

Modelo B: un error grande

|errores| de 4 predicciones:



MAE = **1.0**

RMSE = **2.0**

RMSE = √[(0+0+0+16)/4] = 2

La trampa del Bias

errores: **+3 y −3**

Bias = (+3 − 3)/2 = **0**

Bias ≈ 0 no significa modelo bueno.

Solo dice que no hay tendencia sistemática. Acompáñelo siempre de MAE o RMSE.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

3

Datos nuevos: Train, Validation y Test

Una recta que se ajusta bien a los datos con los que se calculó no garantiza que prediga bien casos nuevos

En esta sección

- ¿Por qué dividir?
- Aprender vs memorizar
- Datos reales

¿Por qué separar los datos en tres conjuntos?

Train 70 %	Validation 15 %	Test 15 %
200 filas	43 filas	44 filas

Ejemplo con los 287 registros del dataset del curso, repartidos al azar

Train

Los apuntes con los que se estudia

Con estos datos se calculan b_0 y b_1 (lo que hicimos a mano).

Validation

El examen de práctica

Comparamos modelos y elegimos. Se puede consultar varias veces.

Test

El examen final

Se mira una sola vez, al final, para estimar el error real.

Regla de oro: si usamos Test para decidir, deja de ser un examen final y el error reportado será optimista.

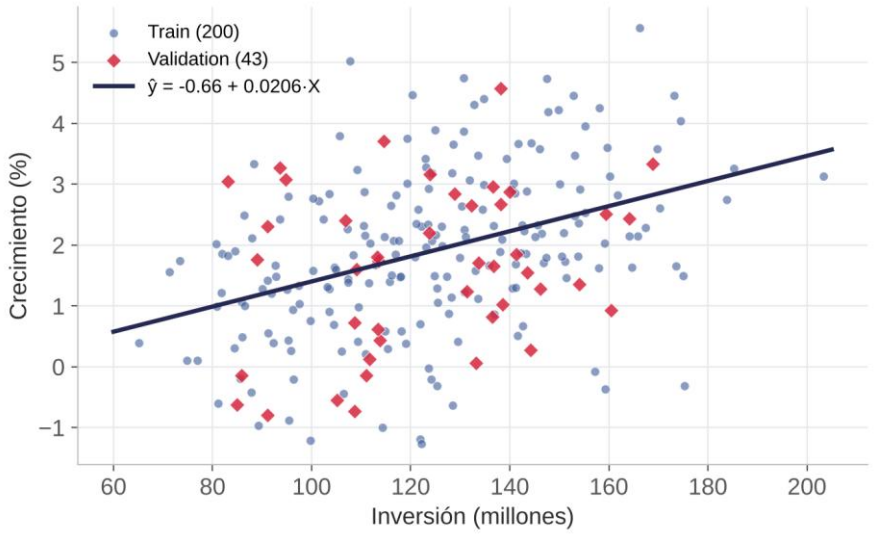
Aprender vs memorizar: subajuste y sobreajuste



	Error en Train	Error en Validation	Diagnóstico
Subajuste	alto	alto	Modelo demasiado simple
Buen ajuste	bajo	bajo y parecido	Generaliza bien
Sobreajuste	muy bajo	alto	Memorizó el ruido

La señal de alerta es la brecha entre Train y Validation.

Con datos reales, la historia cambia



	MAE	RMSE	R^2	Bias
Train	0.947	1.220	0.165	0.000
Validation	1.115	1.305	0.012	+0.262

5 puntos del ejemplo

$R^2 = 0.987$

287 datos reales (Validation): $R^2 = 0.012$

Lo bueno

Train y Validation no son muy distintos: no hay sobreajuste fuerte.

Lo malo

La inversión sola casi no predice datos nuevos.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

4

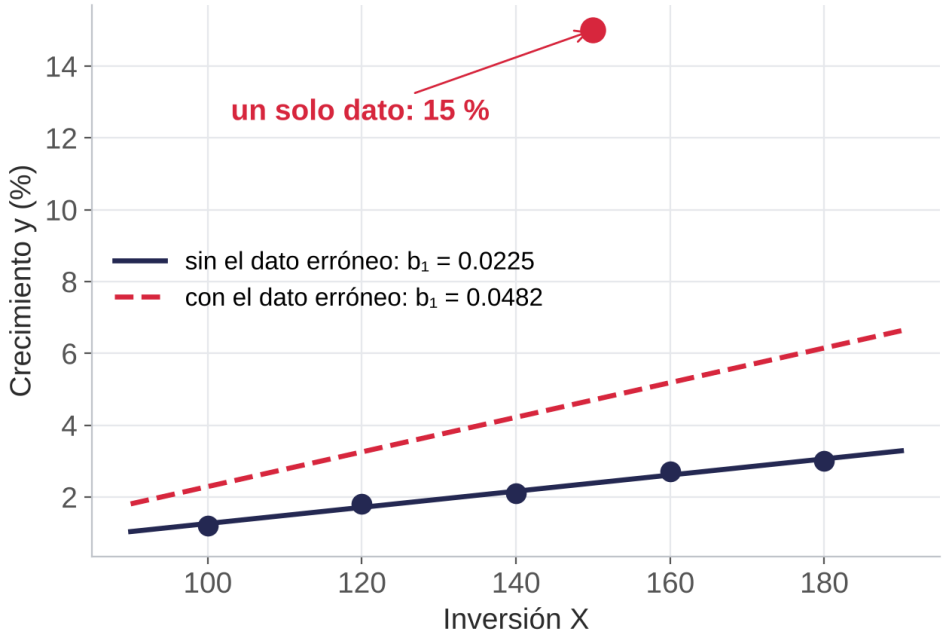
Limpieza de datos

Los datos reales llegan con errores. Si no los corregimos, la recta los aprende. Lo haremos a mano sobre una tabla pequeña

En esta sección

- ¿Por qué limpiar?
- Duplicados y validez
- Atípicos
- Faltantes

¿Por qué limpiar? Un solo dato lo cambia todo



Pendiente con 5 datos limpios

$b_1 = 0.0225$

Con 1 dato erróneo añadido

$b_1 = 0.0482$

¡más del doble!

Basura entra, basura sale: como el SSE eleva al cuadrado, un error de 15 puntos pesa enormemente y “jala” la recta hacia él.

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Las dimensiones de la calidad de datos

C Completitud

¿Faltan valores?

Ejemplo: **celdas vacías**

U Unicidad

¿Hay filas repetidas?

Ejemplo: **la misma fila dos veces**

V Validez

¿Los valores son posibles?

Ejemplo: **desempleo de 150 %**

E Exactitud

¿El valor es real o un error?

Ejemplo: **crecimiento de 15 %**

C Consistencia

¿Formatos y unidades iguales?

Ejemplo: **fechas en distinto formato**

P Pertinencia

¿La columna aporta información?

Ejemplo: **una columna con el mismo valor**

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Una tabla pequeña con todos los problemas

#	Mes	Región	Inversión	Desempleo %	Crecimiento %	Fuente
1	ene	Costa	100	5.1	1.2	SINTÉTICO
2	feb	Costa	120	4.8	1.8	SINTÉTICO
3	mar	Sierra	140		2.1	SINTÉTICO
4	abr	Sierra	160	5.0	2.7	SINTÉTICO
5	may	Costa	180	4.6	3.0	SINTÉTICO
6	may	Costa	180	4.6	3.0	SINTÉTICO
7	jun	Amazonía	130	150	2.0	SINTÉTICO
8	jul	Insular	150	5.3	15.0	SINTÉTICO

Reto: encuentre los 5 problemas antes de seguir

Pista: revise celdas vacías, filas iguales, valores imposibles, valores extremos y columnas que no cambian.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Diagnóstico: los 5 problemas encontrados

#	Mes	Región	Inversión	Desempleo %	Crecimiento %	Fuente
1	ene	Costa	100	5.1	1.2	SINTÉTICO
2	feb	Costa	120	4.8	1.8	SINTÉTICO
3	mar	Sierra	140		2.1	SINTÉTICO
4	abr	Sierra	160	5.0	2.7	SINTÉTICO
5	may	Costa	180	4.6	3.0	SINTÉTICO
6	may	Costa	180	4.6	3.0	SINTÉTICO
7	jun	Amazonía	130	**150**	2.0	SINTÉTICO
8	jul	Insular	150	5.3	**15.0**	SINTÉTICO

1. Faltante
fila 3

2. Duplicado
filas 5 y 6

3. Imposible
fila 7: 150 %

4. Atípico
fila 8: 15 %

5. Sin aporte
col. Fuente

Duplicados y columnas sin información

#	Mes	Región	Inversión	Desempleo %	Crecimiento %	Fuente
5	may	Costa	180	4.6	3.0	SINTÉTICO
6	may	Costa	180	4.6	3.0	SINTÉTICO

Problema
la fila de mayo pesa el doble en el SSE.

Decisión
conservar solo la primera copia (fila 5).

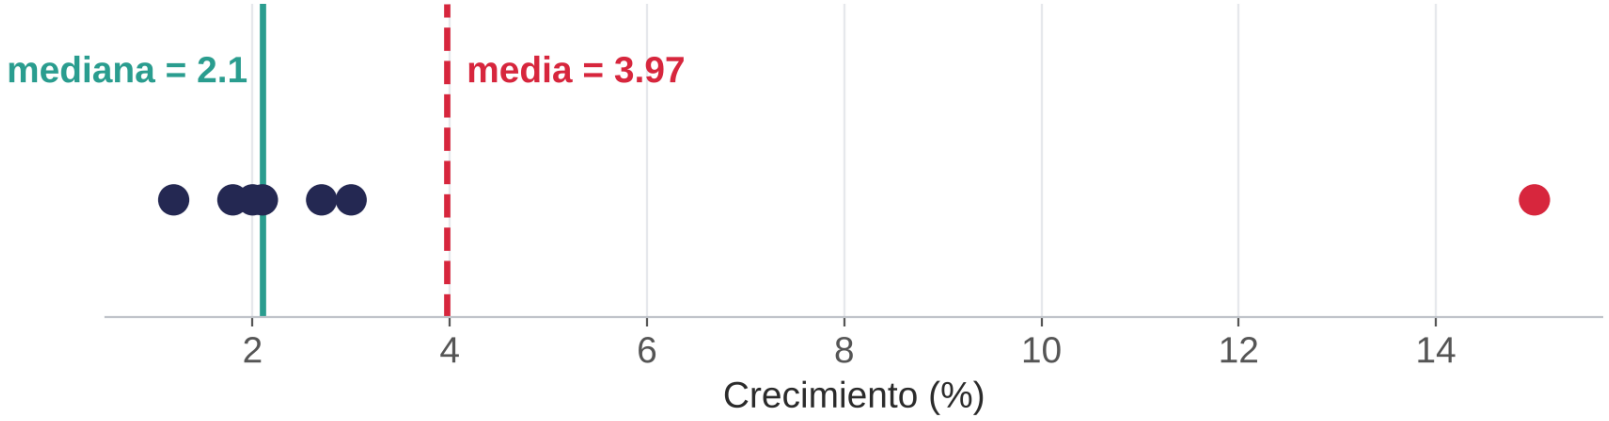
Columna sin aporte: “Fuente” vale SINTÉTICO en todas las filas

SINTÉTICO	SINTÉTICO	SINTÉTICO	SINTÉTICO	SINTÉTICO

Varianza = 0
si nunca cambia, no puede explicar por qué y cambia

Validez (fila 7): un desempleo de 150 % es imposible. No lo inventamos: lo convertimos en faltante y lo tratamos como tal.

Valores atípicos: la media se deja arrastrar



Media con el 15

27.8 / 7 = 3.97

Media sin el 15

12.8 / 6 = 2.13

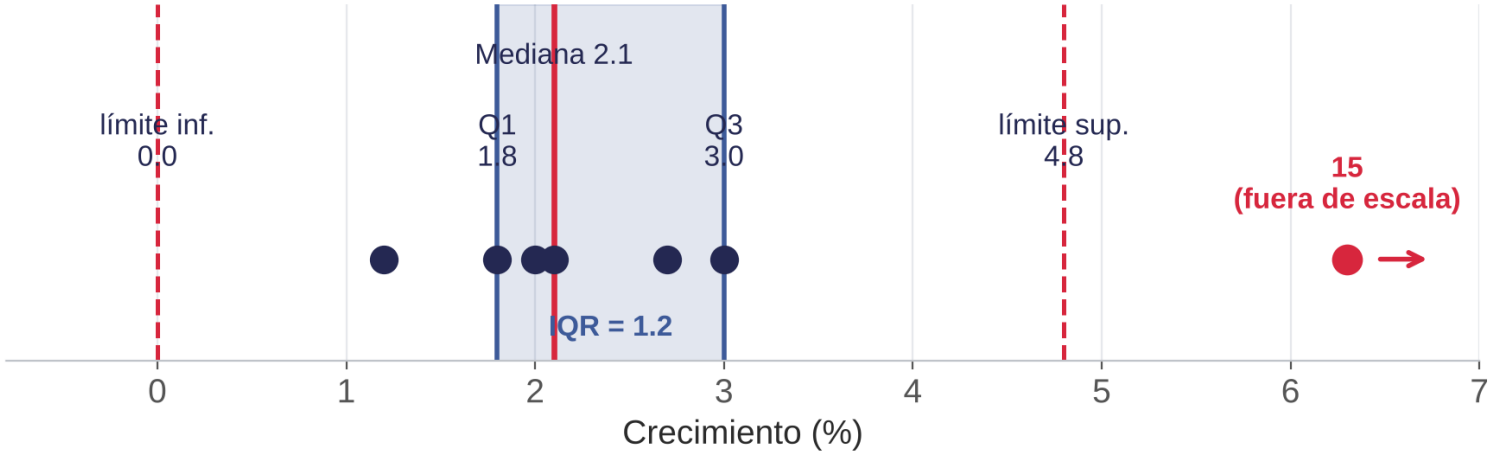
Mediana con el 15

2.1

ordenar y tomar el centro

Por eso: para detectar atípicos y para rellenar faltantes preferimos medidas robustas como la mediana y los cuartiles.

Detectar atípicos a mano: la regla del IQR



1 Ordenar

1.2 · 1.8 · 2.0 · 2.1 · 2.7 · 3.0 · 15

2 Cuartiles

Q1 = 1.8 · Q3 = 3.0
IQR = 3.0 − 1.8 = 1.2

3 Límites

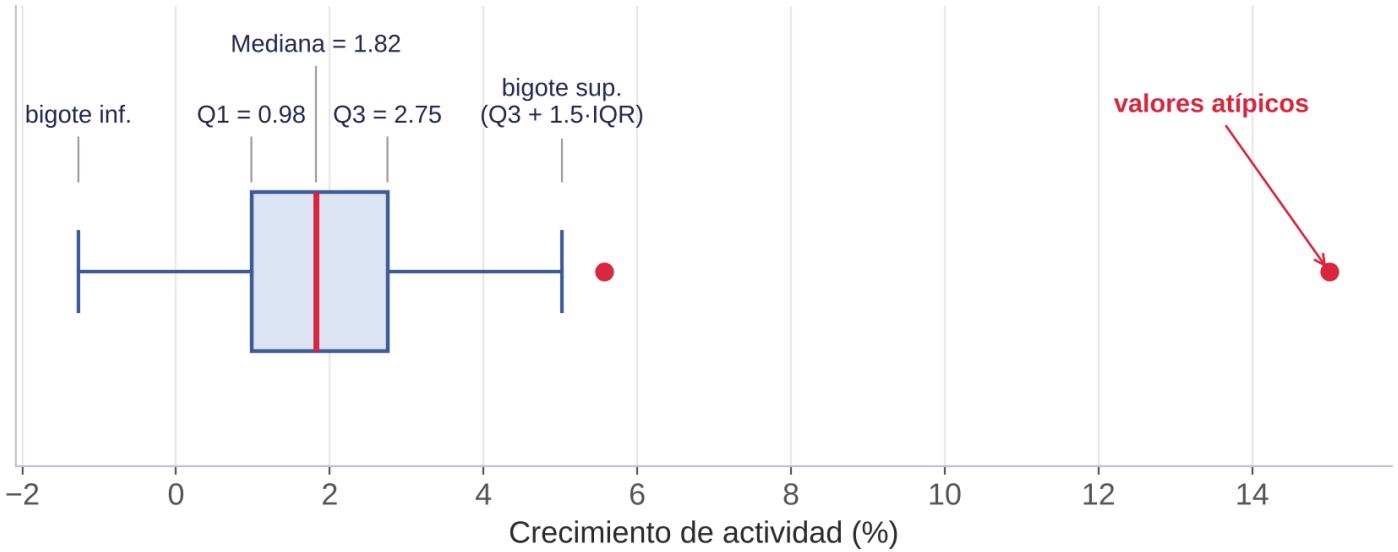
inf: 1.8 − 1.5×1.2 = 0
sup: 3.0 + 1.5×1.2 = 4.8

4 Decidir

15 > 4.8
→ atípico

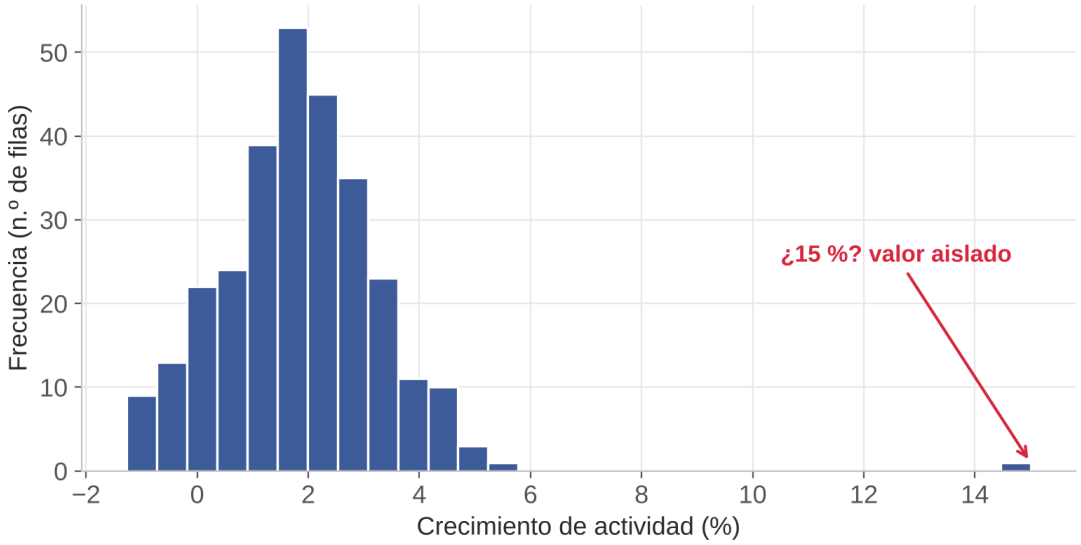
Atípico ≠ error: la regla solo señala. Investigamos: si es un error de captura, se corrige o elimina; si es real, se conserva.

Leer atípicos en un boxplot



Elemento	Valor (datos reales)	Cómo se lee
Caja (Q1 a Q3)	0.98 a 2.75	El 50 % central de los datos
Línea roja	1.82	Mediana: mitad arriba, mitad abajo
Bigote superior	hasta 5.41	Q3 + 1.5 × IQR
Puntos rojos	5.57 y 15.0	Fuera de los bigotes: investigar

Leer atípicos en un histograma



Centro

La mayoría entre 0 % y 4 %

Forma

Aproximadamente simétrica, en campana

Aislados

Un valor de 15 %, lejos del resto

Histograma y boxplot son las dos herramientas visuales básicas para encontrar valores extremos antes de modelar.

Valores faltantes: ¿por qué falta un dato?

MCAR

Completamente al azar

Ej.: *Se perdió una hoja del registro*

MAR

Depende de otra variable observada

Ej.: *Una región reporta menos el desempleo*

MNAR

Depende del propio valor

Ej.: *Las empresas con malos resultados no reportan*

Estrategia	Ventaja	Riesgo
Eliminar la fila	Simple	Perdemos información y podemos sesgar la muestra
Rellenar con la media	Conserva las filas	Sensible a atípicos; reduce la varianza
Rellenar con la mediana	Robusta a atípicos	También reduce la varianza
Estimar con otras variables	Más preciso	Más complejo; riesgo de fuga de datos

Rellenar un faltante se llama imputar.

Imputar a mano con la mediana

orden: **4.6** | **4.8** | **5.0** | **5.1**

Mediana
(4.8 + 5.0) / 2 = 4.9

#	Región	Desempleo antes	Desempleo después
3	Sierra	(vacío)	**4.9**
7	Amazonía	150 (imposible)	**4.9**

¿Por qué la mediana?

Porque no se deja arrastrar por valores extremos, como vimos con el 15 %.

Evitar la fuga de datos

La mediana se calcula **solo con Train** y luego se aplica a Validation y Test.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Resultado: la tabla limpia

8 × 7 original → **7 × 7** sin duplicado → **7 × 7** 150 → vacío → **6 × 7** sin el 15 % → **6 × 7** imputado 4.9 → **6 × 6** sin “Fuente”

#	Mes	Región	Inversión	Desempleo %	Crecimiento %
1	ene	Costa	100	5.1	1.2
2	feb	Costa	120	4.8	1.8
3	mar	Sierra	140	**4.9**	2.1
4	abr	Sierra	160	5.0	2.7
5	may	Costa	180	4.6	3.0
7	jun	Amazonía	130	**4.9**	2.0

Ahora sí: con esta tabla podemos calcular la recta sin que los errores la distorsionen.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

El dataset real del curso tiene los mismos problemas

289	11	72	4 × 4
filas mes · región · sector	**columnas** variables	**meses** 2019 a 2024	**grupos** regiones × sectores

Problema	En la tabla pequeña	En el dataset real	Decisión
Faltantes	1 celda	8 celdas (inflación y confianza)	Imputar con mediana
Duplicados	1 fila	1 fila	Eliminar la copia
Atípico / error	crecimiento 15 %	crecimiento 15 % (fila 33)	Eliminar tras investigar
Sin aporte	columna Fuente	columna tipo_dato	Eliminar la columna

Para investigar: en exportaciones hay un valor de 1300 millones cuando el resto no pasa de 521. ¿Error o dato real?

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

5

Más de una variable

Regresión múltiple y variables categóricas: la misma idea, con más columnas

En esta sección

- De la recta al plano
- Manteniendo lo demás constante
- Categorías a números
- ¿Mejoró?

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

De la recta al plano y al hiperplano

1 X — **Recta** (2D)

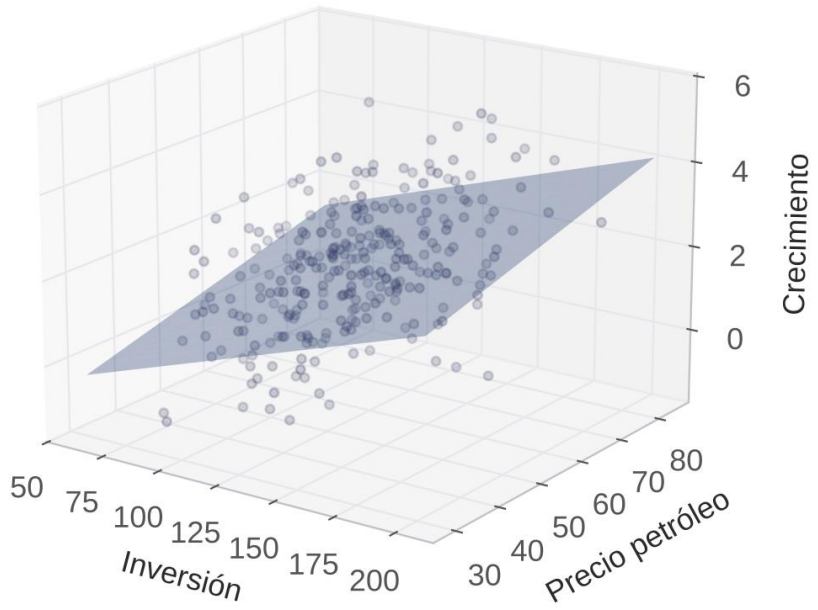
$\hat{y} = b_0 + b_1 x_1$

2 X — **Plano** (3D)

$\hat{y} = b_0 + b_1 x_1 + b_2 x_2$

p X — **Hiperplano** (p+1 D)

$\hat{y} = b_0 + b_1 x_1 + \ldots + b_p x_p$



ŷ = −2.24 + 0.0189·inversión + 0.0300·petróleo

Puntos: datos reales · Plano: predicción

Ceteris paribus: “lo demás constante”

$$\hat{y} = -2.24 + 0.0189 \cdot \text{inversión} + 0.0300 \cdot \text{petróleo}$$

Escenario	Inversión	Petróleo	Cálculo	ŷ
A	150	60	−2.24 + 2.835 + 1.800	2.395
B	**160**	60	−2.24 + 3.024 + 1.800	2.584

B − A = 0.189

= 10 millones × 0.0189, con el petróleo fijo

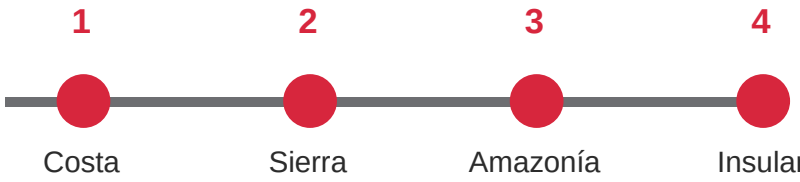
Ojo con las escalas

un coeficiente pequeño no significa variable poco importante si se mide en otra unidad

Multicolinealidad: si dos variables se mueven juntas, el modelo no sabe a cuál atribuir el efecto y los coeficientes se vuelven inestables.

Variables categóricas: el texto no es una magnitud

Codificación con números



Inventa un orden y distancias

¿Sierra está “entre” Costa y Amazonía? ¿Insular vale 4 veces Costa?

One-Hot Encoding (dummies)

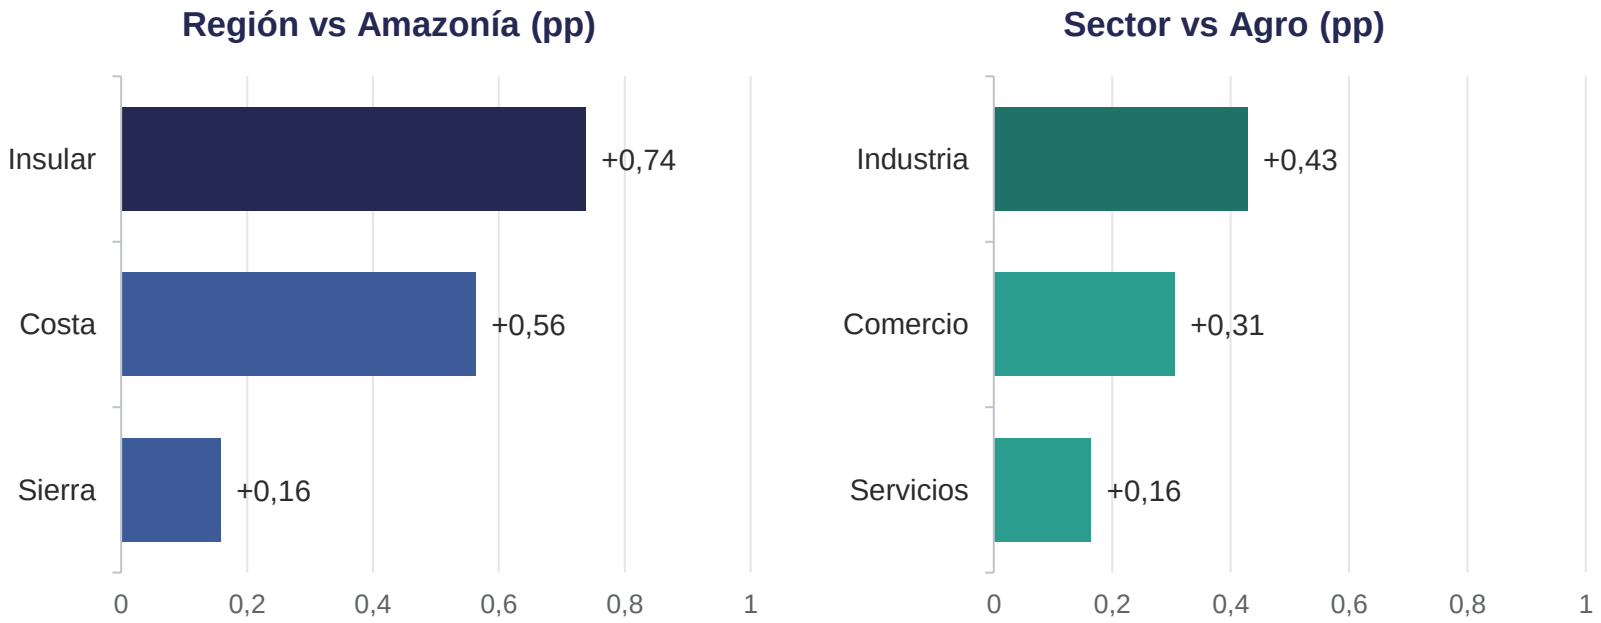
Región	Costa	Insular	Sierra
Amazonía	0	0	0
Costa	1	0	0
Insular	0	1	0
Sierra	0	0	1

Amazonía = categoría de referencia (todo en 0)

¿Por qué dejar una fuera?

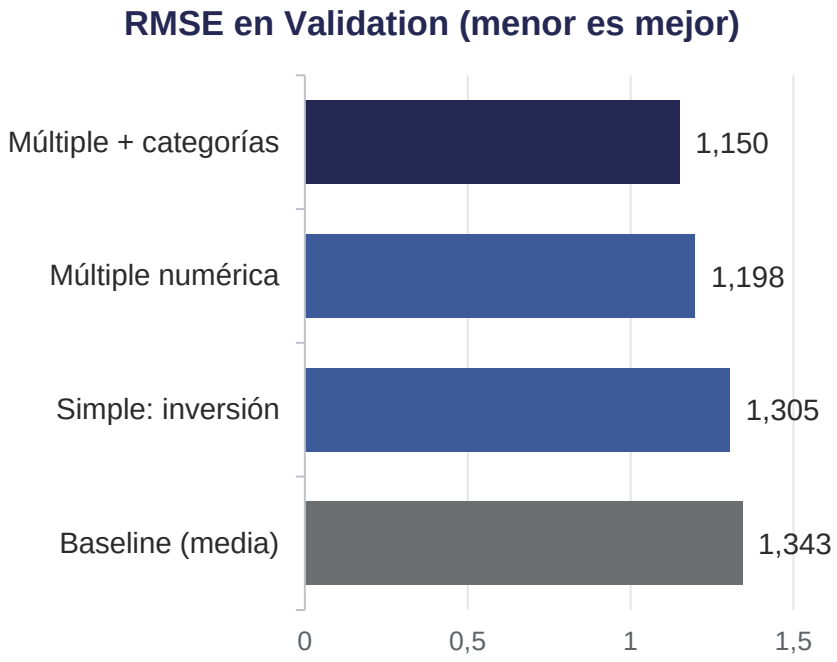
Si incluimos las 4 columnas, en cada fila suman 1 y repiten la información del intercepto (trampa de las dummies). Con k categorías se usan k − 1 columnas.

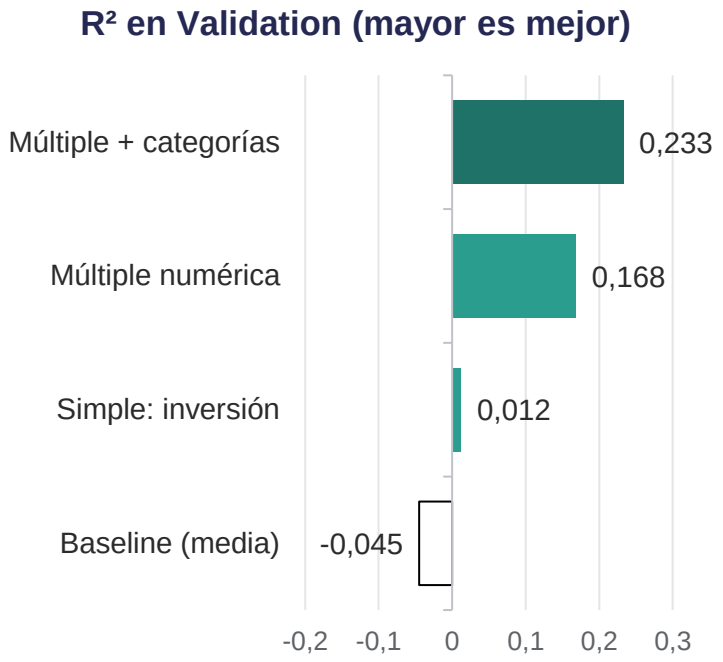
Leer el coeficiente de una dummy



A mano: dos filas idénticas salvo la región: si una es Insular y la otra Amazonía, la predicción difiere en 0.74 puntos porcentuales. Si es Amazonía, todas las dummies valen 0 y no se suma nada.

¿Mejoró el modelo al agregar información?





Resultado final en Test: error típico ≈ 1 punto porcentual

RMSE 0.997 · R^2 0.369 · el modelo explica cerca de un tercio de la variación.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ideas clave del día

1

La recta minimiza el SSE

$b_1 = \Sigma(x-\bar{x})(y-\bar{y}) / \Sigma(x-\bar{x})^2$ y $b_0 = \bar{y} - b_1\bar{x}$

2

Una métrica no basta

MAE, RMSE, Bias y R^2 responden preguntas distintas.

3

Evaluar con datos nuevos

Train aprende, Validation decide, Test se mira una vez.

4

Un modelo aprende los errores

Un solo dato erróneo duplicó la pendiente.

5

La mediana es robusta

Úsela para detectar atípicos e imputar faltantes.

6

Asociación ≠ causalidad

Coeficientes y correlaciones describen, no prueban efectos.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Del papel al notebook

Lo que hicimos a mano	Lo que verán en el notebook	Debe dar…
Medias, desviaciones y sumas	La computadora calcula b_0 y b_1	$b_0 = -0.99 \cdot b_1 = 0.0225$
Residuos, MAE, RMSE, R^2	Funciones de métricas	MAE 0.072 · R^2 0.987
Encontrar los 5 problemas	Revisar nulos, duplicados y rangos	8 faltantes · 1 duplicado
Cuartiles e IQR	Boxplot y estadísticos descriptivos	límite superior ≈ 5.41
Mediana para imputar	Rellenar faltantes	0 faltantes al final
Dummies a mano	Codificación One-Hot	k − 1 columnas por variable

Su rol con el agente de IA

Pidan que explique cada paso y comprueben que los números coincidan con los calculados a mano. Si no coinciden, algo está mal.