ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Día 2 — Árboles de Regresión y Random Forest



Módulo 3: Machine Learning Aplicado

14-10-2026 · Jonathan Rosero Soto

Edificio Aulas y Relación con el Medio Externo, Av. Toledo N23-55 y Madrid
Telf.: +593 2 2525766 - Ext: 102 / 125 / 143 / 120 / 127 - www.cec-epn.edu.ec

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ruta de la jornada

1	**Nuevo dataset y repaso**	Indicadores del Banco Mundial; limpieza y primer modelo lineal
2	**Validación cruzada (K-Fold)**	Evaluar varias veces en lugar de confiar en una sola Validation
3	**Árbol de regresión**	A mano con 8 filas y luego con 10 127 clientes de tarjeta
4	**Controlar la complejidad**	Jugar con max_depth, min_samples_split y min_samples_leaf
5	**Random Forest**	Muchos árboles distintos y un promedio: calculado a mano

Regla del día: *un modelo más complejo no siempre predice mejor.*

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Lo que ya sabemos del Día 1

1

La recta

$\hat{y} = b_0 + b_1X$, elegida para que el SSE sea el menor posible.

2

Las métricas

MAE, MSE, RMSE, Bias y R^2: cada una responde una pregunta distinta.

3

Train / Validation / Test

Aprender con unos datos y medir con otros que el modelo no vio.

4

Sub y sobreajuste

Muy simple falla en todo; muy complejo memoriza Train y falla en datos nuevos.

Hoy: ¿y si la relación no es una recta? Los árboles responden con preguntas en lugar de una ecuación.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

1

Nuevo dataset y repaso

Indicadores macroeconómicos del Banco Mundial: 7 países de América Latina, 2005–2024

En esta sección

- **Qué es una fila**
- **Faltantes**
- **Primer modelo**

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

El dataset: indicadores del Banco Mundial

140
filas
país-año

7
países
América Latina

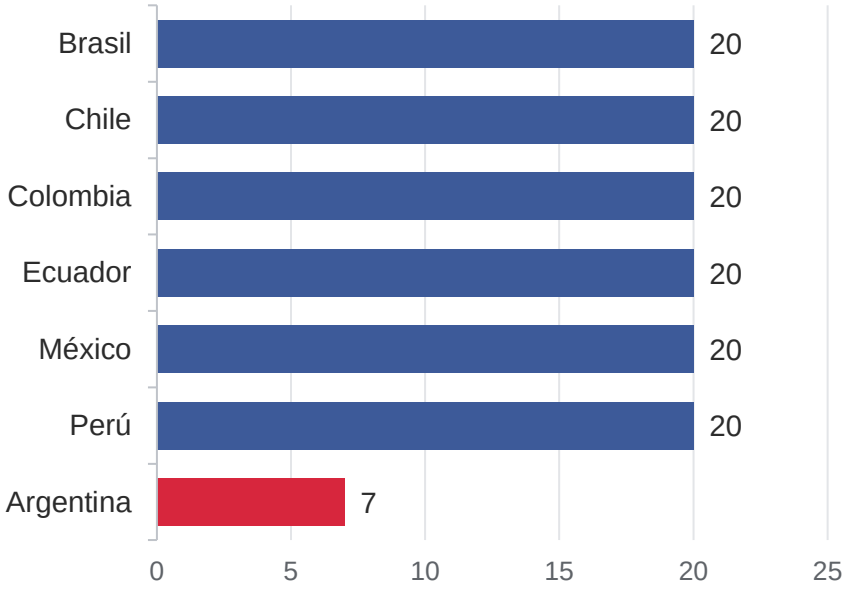
20
años
2005 a 2024

5
predictores
indicadores X

Variable	Significado	Rol
crecimiento_pib_pct	Variación anual del PIB (%)	**Objetivo (y)**
inflacion_pct	Inflación anual (%)	Predictor (X)
desempleo_pct	Desempleo (%)	Predictor (X)
exportaciones_pct_pib	Exportaciones (% del PIB)	Predictor (X)
inversion_pct_pib	Formación bruta de capital (% del PIB)	Predictor (X)
crecimiento_poblacion_pct	Crecimiento de la población (%)	Predictor (X)
país, año	Identifican la fila	No entran al modelo

Limpieza: los faltantes no son ceros

Filas completas por país (127 en total)



13 faltantes

inflación de Argentina, 2005–2017

140 filas → **127 completas**

eliminando las filas con faltantes

¿Imputar con 0? No: inventaría datos

Consecuencia: al eliminar filas cambia la muestra. Siempre hay que reportar cuántas filas se perdieron y de dónde.

Cuidado: los años de un mismo país se parecen



partición aleatoria: años vecinos en ambos lados

Sirve para

Aprender cómo evaluar un modelo.

No sirve para

Afirmar que el modelo pronostica bien el futuro.

Primer intento: regresión lineal múltiple

Train 88	Val 19	Test 20

Modelo	Conjunto	MAE	RMSE	R^2
Baseline (media)	Train	2.91	4.15	0.00
Baseline (media)	Validation	3.54	4.36	−0.12
Regresión lineal	Train	2.74	3.81	0.16
Regresión lineal	Validation	3.39	4.36	−0.12

Casi igual que el baseline

En Validation, la recta se equivoca prácticamente lo mismo que predecir siempre 3.34 %.

Pregunta del día: ¿un modelo que no use una recta, sino reglas por regiones, lo hará mejor? Antes, aprendamos a evaluar con más cuidado.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

2

Validación cruzada (K-Fold)

Una sola Validation puede salir fácil o difícil por azar. K-Fold evalúa varias veces y promedia

En esta sección

El problema	Las 5 vueltas	Resultados

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

El problema de una sola Validation

Validation “fácil”

Cayeron años normales: el error parece pequeño.

Validation “difícil”

Cayeron crisis: el error parece enorme.

Idea de K-Fold: hacer varias “Validations” distintas y promediar.

Analogía: un examen con 5 preguntas mide mejor que uno con una sola, aunque el estudiante sea el mismo.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

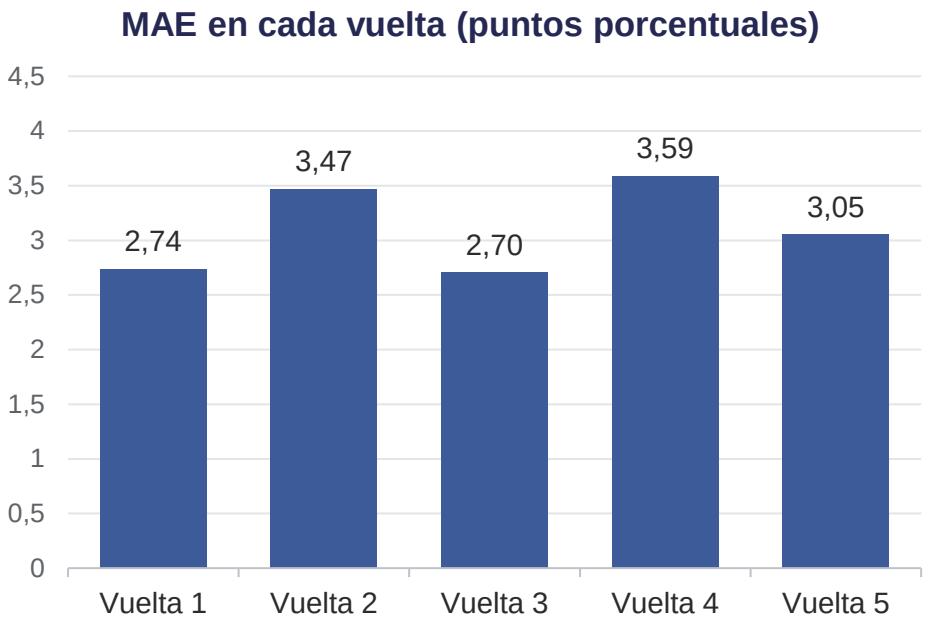
K-Fold paso a paso con 5 bloques

	bloque A	bloque B	bloque C	bloque D	bloque E	
Vuelta 1	Val	Train	Train	Train	Train	→ MAE vuelta 1
Vuelta 2	Train	Val	Train	Train	Train	→ MAE vuelta 2
Vuelta 3	Train	Train	Val	Train	Train	→ MAE vuelta 3
Vuelta 4	Train	Train	Train	Val	Train	→ MAE vuelta 4
Vuelta 5	Train	Train	Train	Train	Val	→ MAE vuelta 5

5 modelos distintos
cada uno entrenado con 85–86 filas

5 mediciones del error
cada una con 21–22 filas nunca vistas

Resultados de K-Fold con la regresión lineal



Promedio de los 5 MAE

3.11

Desviación entre vueltas

± 0.41

A mano: (2.74 + 3.47 + 2.70 + 3.59 + 3.05) / 5 = 15.55 / 5 = 3.11. Con una sola Validation habríamos visto 3.39: ni “la verdad”, ni un error; solo una de muchas posibilidades.

Holdout vs K-Fold, y la prueba final en Test

Evaluación	Filas evaluadas	MAE	RMSE	R^2
Holdout (una Validation)	19	3.39	4.36	−0.12
K-Fold (5 vueltas)	107	3.11	4.15	0.01

Prueba final en Test (20 filas, se mira una sola vez)

Modelo final	Entrenado con	MAE	RMSE	R^2
Holdout	88 filas (Train)	2.45	3.41	−0.24
Reentrenado tras K-Fold	107 filas (desarrollo)	2.35	3.12	−0.04

Lectura: con más datos para aprender el error baja un poco, pero la recta sigue sin superar claramente a la media.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

3

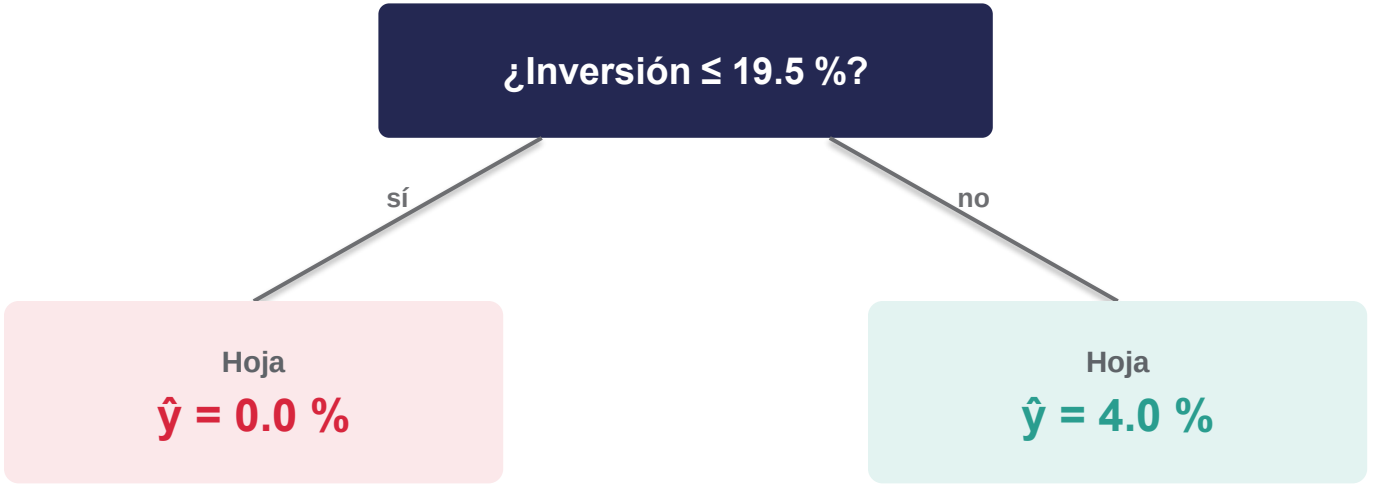
El árbol de regresión

En lugar de una ecuación, una serie de preguntas sí/no. Lo construiremos a mano con 8 observaciones

En esta sección

- La idea
- Elegir el corte
- Crecer el árbol
- Datos reales

La idea: predecir con preguntas sí/no



Raíz
la primera pregunta, con todos los datos

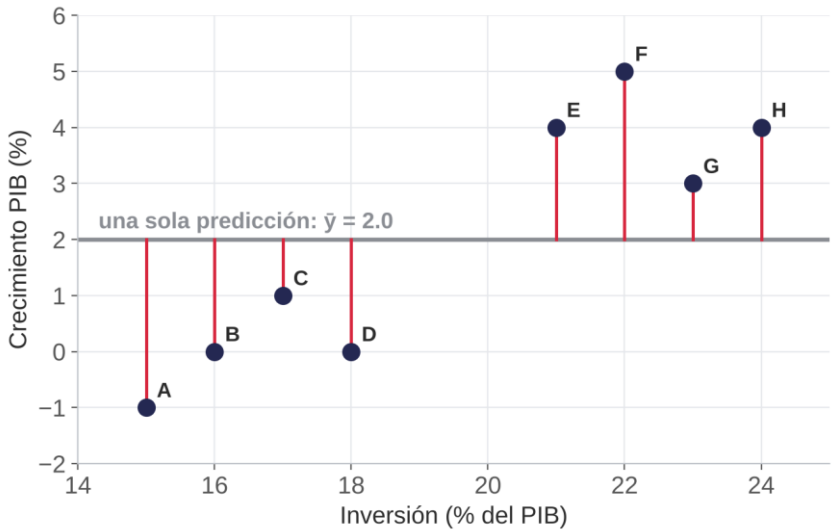
Rama
el camino según la respuesta sí o no

Hoja
el final: devuelve un número, el promedio

Recta vs árbol: la recta usa una sola fórmula para todos; el árbol forma grupos y predice el promedio de cada grupo.

Nuestro ejemplo a mano: 8 países-año

	X: inversión	y: crecim.	$(y - 2)^2$
A	15	-1	9
B	16	0	4
C	17	1	1
D	18	0	4
E	21	4	4
F	22	5	9
G	23	3	1
H	24	4	4
		$\bar{y} = 2.0$	**36**



Sin preguntas: error de partida

SSE = 36

cada pregunta debe reducirlo

¿Cómo se evalúa un corte? El mismo SSE del Día 1

Izquierda: X ≤ 19.5

Fila	y	(y − promedio)²
A	−1	1
B	0	0
C	1	1
D	0	0

promedio = **0** SSE = **2**

Derecha: X > 19.5

Fila	y	(y − promedio)²
E	4	0
F	5	1
G	3	1
H	4	0

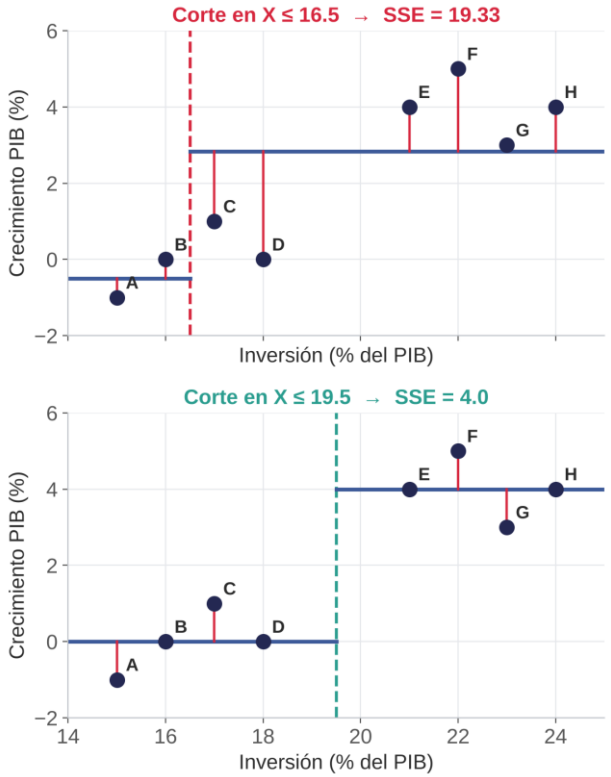
promedio = **4** SSE = **2**

SSE total con el corte = 2 + 2 = **4**

Reducción: de 36 a 4 → 1 − 4/36 = 89 % de la variación explicada

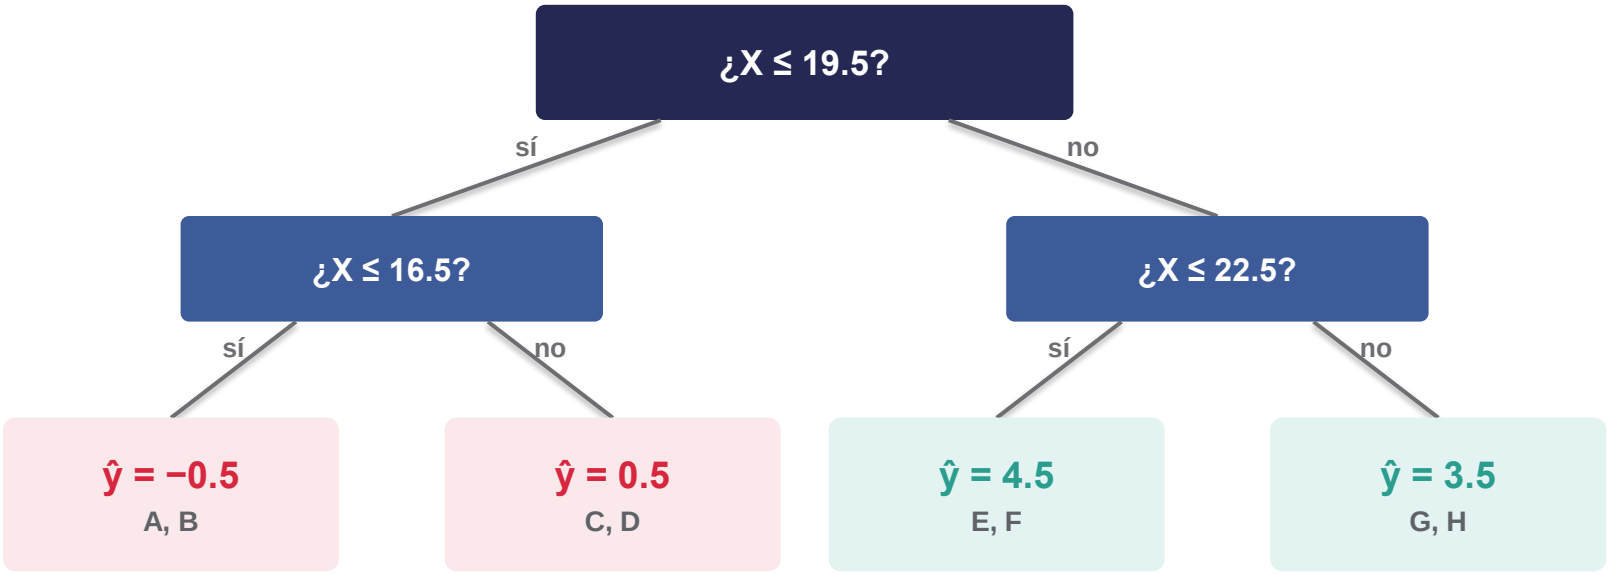
Probar todos los cortes posibles

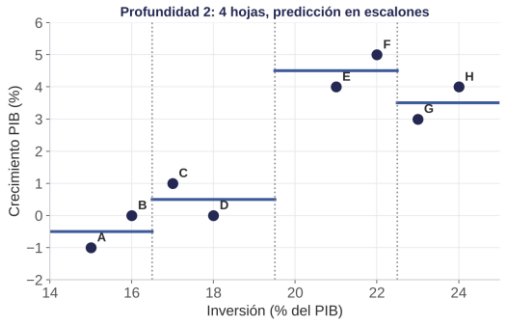
Corte	Izquierda	Promedio izq.	Promedio der.	SSE total
X ≤ 15.5	A	−1.00	2.43	25.7
X ≤ 16.5	A, B	−0.50	2.83	19.3
X ≤ 17.5	A–C	0.00	3.20	16.8
X ≤ 19.5	**A–D**	**0.00**	**4.00**	**4.0**
X ≤ 21.5	A–E	0.80	4.00	16.8
X ≤ 22.5	A–F	1.50	3.50	30.0
X ≤ 23.5	A–G	1.71	4.00	31.4



Gana X ≤ 19.5 (SSE = 4). Así aprende un árbol: busca la pregunta que mejor separa valores altos de bajos.

Seguir preguntando: un árbol de profundidad 2





Profundidad	Hojas	SSE
0	1	36
1	2	4
2	4	2
3	8	0

SSE = 0 no es bueno

cada hoja tiene 1 fila: memorizó, no aprendió

Del ejemplo a datos reales: 10 127 clientes

Variable	Significado	Rol
Total_Trans_Amt	Monto transado en 12 meses (USD)	**Objetivo (y)**
Total_Trans_Ct	Número de transacciones en 12 meses	Predictor (X)
Total_Ct_Chng_Q4_Q1	Cambio de transacciones: Q4 frente a Q1	Predictor (X)
Total_Relationship_Count	Productos que tiene con el banco	Predictor (X)
Customer_Age	Edad	Predictor (X)
Credit_Limit	Límite de crédito (USD)	Predictor (X)

Clientes

10 127

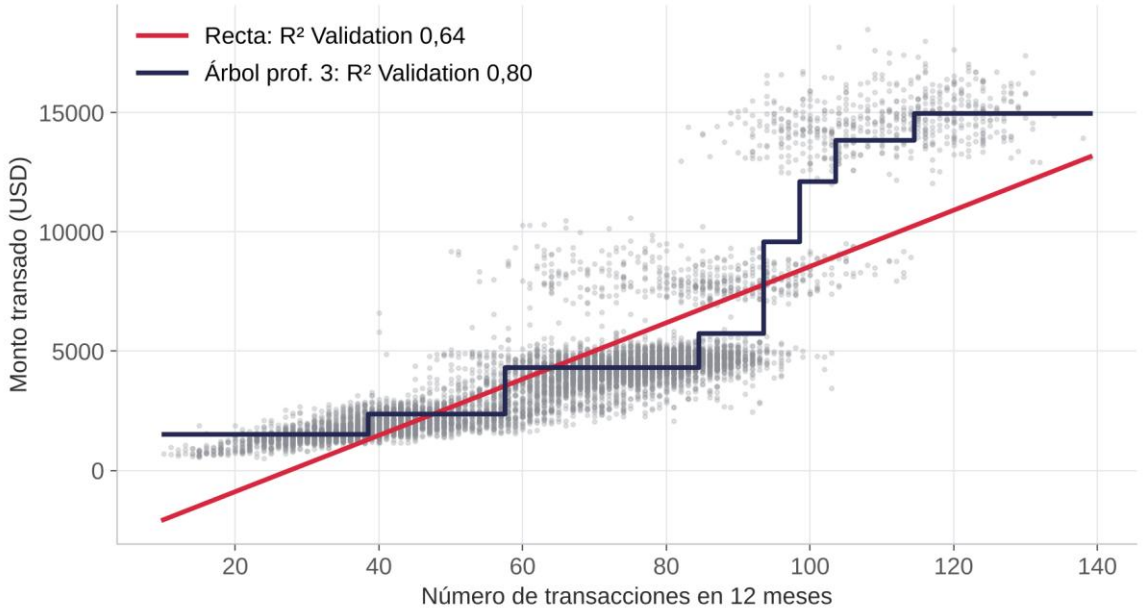
Train / Val / Test

7 088 · 1 519 · 1 520

Fuga: el archivo trae dos columnas Naive_Bayes… que son predicciones de otro modelo y CLIENTNUM, un identificador. Se eliminan.

No es un pronóstico: monto y número de transacciones son del mismo año. Es un ejercicio para ver cómo un árbol aprende una relación que no es recta.

Una recta frente a escalones



Recta

Mismo aumento por cada transacción: 118 USD.

Árbol

Un promedio por grupo: escalones.

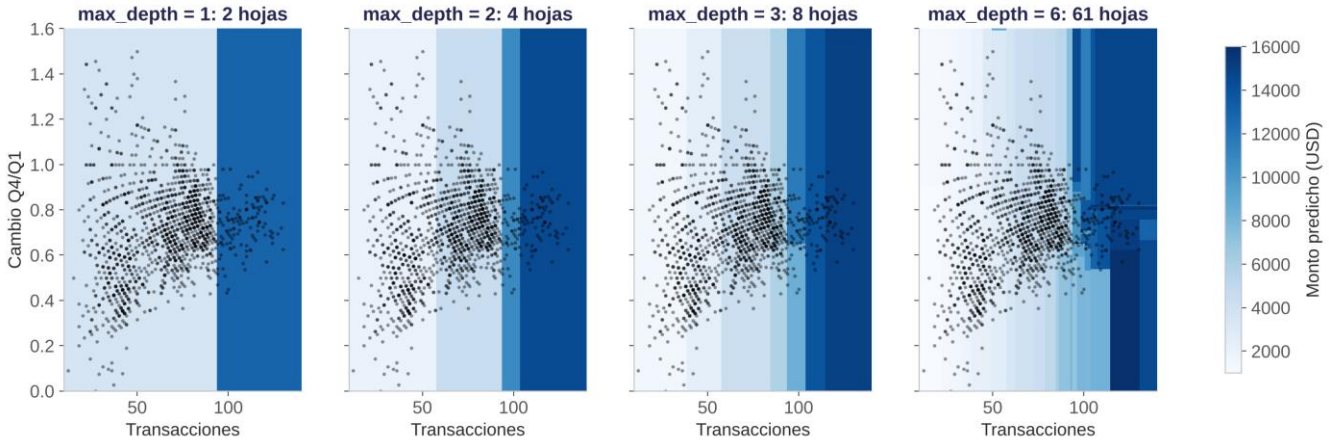
Límite del árbol: no predice más allá del promedio de su última hoja, aunque llegue un cliente con más transacciones que las vistas.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cómo divide el algoritmo: rectángulos



Cada pregunta
una línea paralela a un eje

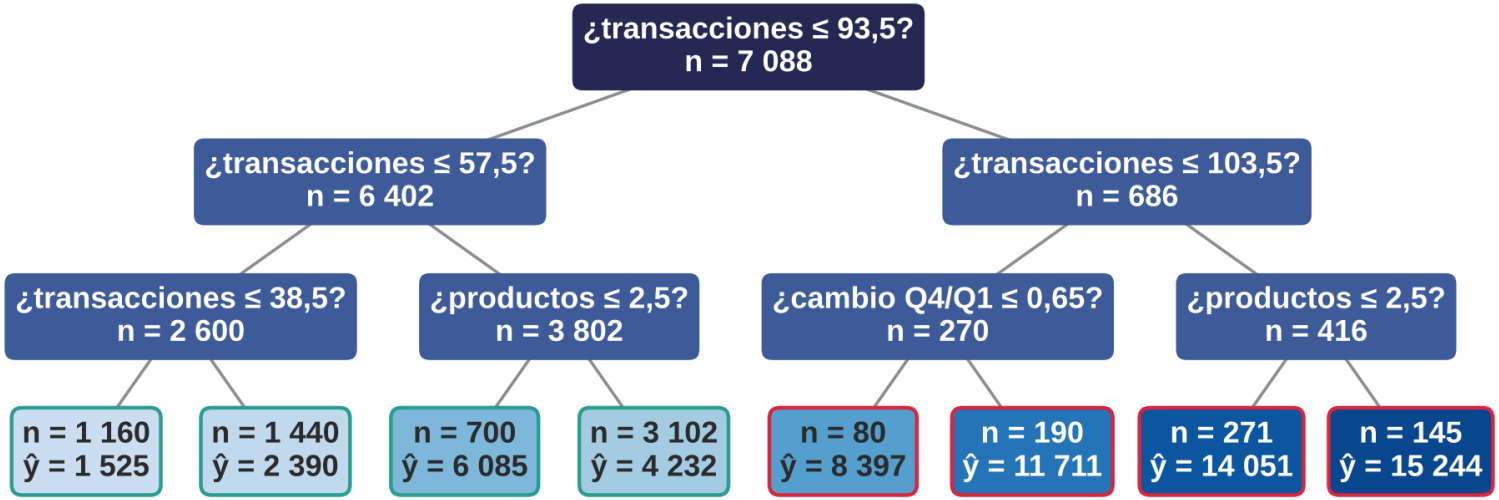
Cada hoja
un rectángulo con su promedio

Más profundidad
rectángulos cada vez más pequeños

Eje horizontal: número de transacciones. Eje vertical: cambio de transacciones Q4/Q1. Color: monto predicho.

El árbol real de profundidad 3

A · max_depth = 3 → 8 hojas · R^2 Validation 0,821



Borde rojo: hojas con menos de 300 clientes (la más pequeña, 80). **Cuidado:** «2 productos o menos → más monto» no significa que vender menos productos haga gastar más.

Train y Validation casi iguales: R^2 0,843 y 0,821. Con 7 088 filas, ocho hojas no alcanzan a memorizar.

Seguir la ruta: una predicción a mano

Cliente de Validation	Valor
Transacciones	34
Cambio Q4/Q1	0,31
Productos	4
Edad	40
Límite (USD)	23 981



Real	Árbol	Recta
1 421	**1 525**	**1 466**

Explicable: sabemos exactamente por qué el árbol predijo 1 525: por la ruta que siguió. Eso no prueba causalidad.

¿Le ganó el árbol a la recta? Esta vez sí

Modelo	Conjunto	MAE (USD)	RMSE (USD)	R^2
Regresión lineal	Train	1 415	1 916	0,692
Regresión lineal	Validation	1 347	1 858	0,678
Árbol prof. 3	Train	831	1 367	0,843
Árbol prof. 3	Validation	840	1 384	0,821

En Validation: mejor
MAE baja de 1 347 a 840 USD

Sin brecha
R^2 0,843 en Train y 0,821 en Validation

Contraste: con el panel del Banco Mundial el árbol perdió frente a la recta. El tamaño y la forma de los datos importan.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

4

Controlar la complejidad

Tres hiperparámetros: cuántas preguntas, cuántas filas para preguntar y cuántas filas por hoja

En esta sección

- Los tres
- Profundidad
- Mín. por hoja
- Mín. para dividir
- Ver el árbol

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Parámetros vs hiperparámetros

max_depth

Profundidad máxima

Cuántas preguntas encadenadas de la raíz a una hoja. Por defecto: sin límite.

min_samples_split

Mínimo para dividir

Cuántas filas necesita un nodo para que se le permita preguntar. Por defecto: 2.

min_samples_leaf

Mínimo por hoja

Cuántas filas debe tener cada hoja que resulta de un corte. Por defecto: 1.

Con los valores por defecto el árbol sigue preguntando hasta que cada hoja tiene clientes con el mismo monto: con 7 088 clientes crea 7 080 hojas. Memoriza Train.

min_samples_split y min_samples_leaf no son lo mismo

min_samples_split = 100



el nodo de 100 sí puede preguntar

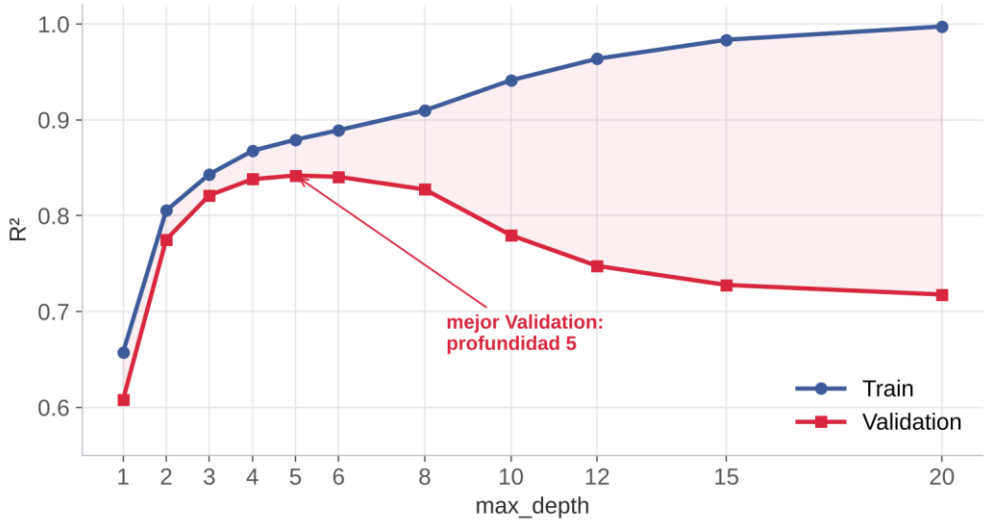
min_samples_leaf = 50



el corte 99 / 1 está prohibido

	Pregunta que responde	Cuándo actúa
min_samples_split	¿este nodo tiene suficientes filas para preguntar?	antes de cortar
min_samples_leaf	¿cada hoja nueva tendrá suficientes filas?	después de cortar

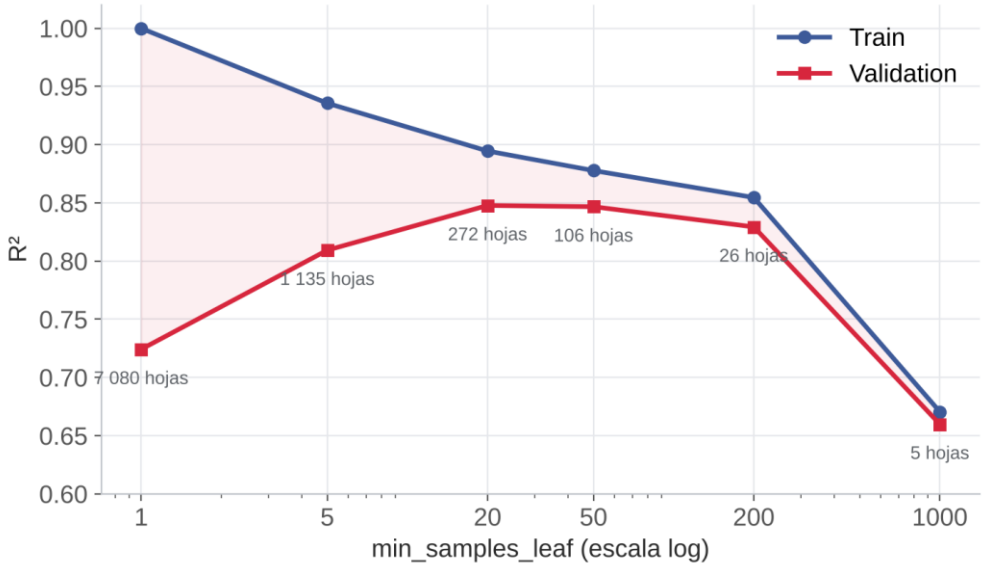
Jugar con max_depth



Prof.	Hojas	R² Train	R² Val
1	2	0,658	0,608
3	8	0,843	0,821
5	32	0,879	**0,842**
10	609	0,941	0,780
20	5 321	0,997	**0,718**

Subajuste con profundidad 1 (malo en ambos). **Sobreajuste** desde profundidad 8: Train sigue subiendo y Validation baja. El punto intermedio está cerca de 5.

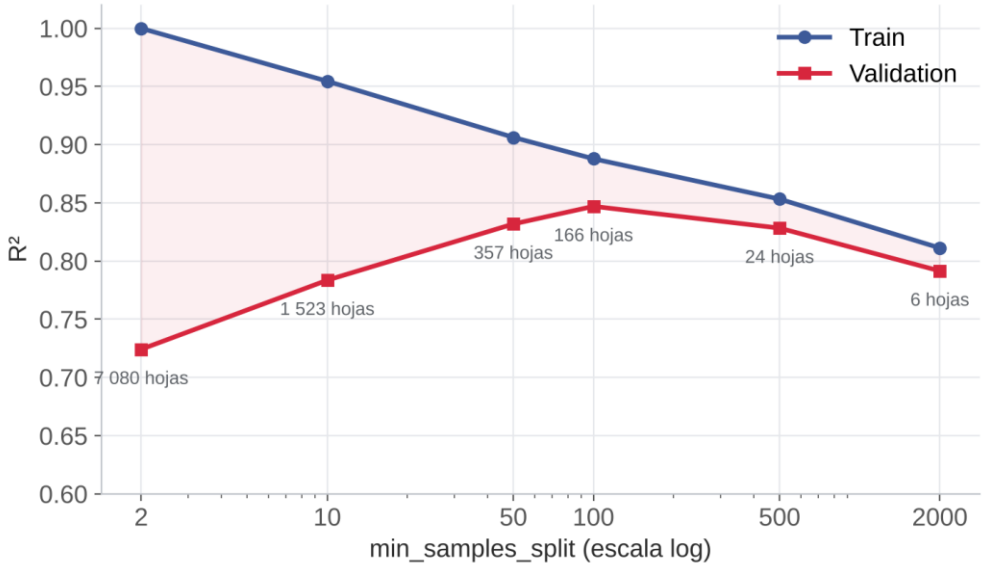
Jugar con min_samples_leaf



mín. por hoja	Hojas	R² Train	R² Val
1	7 080	1,000	**0,724**
5	1 135	0,936	0,809
20	272	0,894	**0,848**
200	26	0,855	0,829
1 000	5	0,670	**0,660**

Lectura: subir el mínimo cierra la brecha entre Train y Validation… hasta que el árbol queda demasiado simple. Ni hojas de un cliente, ni hojas gigantes.

Jugar con min_samples_split

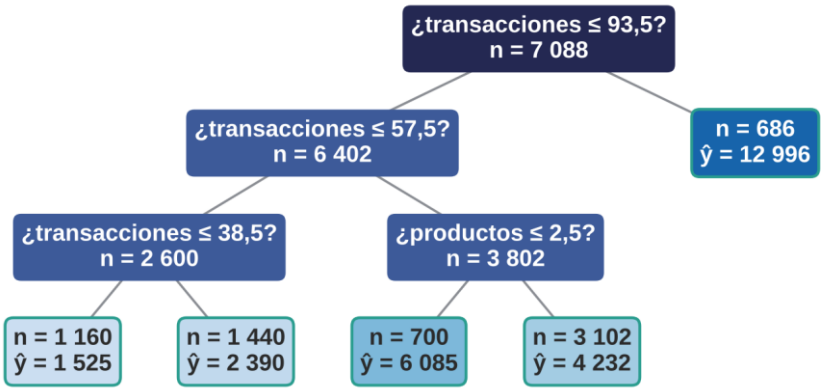


mín. para dividir	Hojas	R^2 Train	R^2 Val
2	7 080	1,000	**0,724**
10	1 523	0,954	0,784
100	166	0,888	**0,847**
500	24	0,853	0,828
2 000	6	0,811	0,791

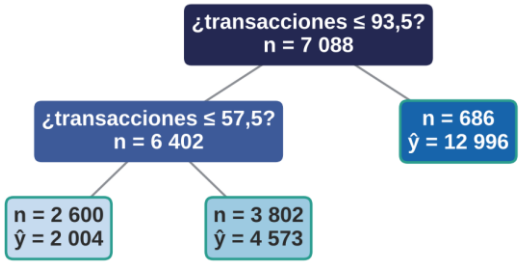
Los tres hiperparámetros tienen el mismo patrón: muy poco control memoriza, demasiado control simplifica. Se elige el punto intermedio en Validation.

El mismo árbol con distintos hiperparámetros

B · + min_samples_leaf = 600 → 5 hojas · R^2 Validation 0,785



C · + min_samples_split = 4 000 → 3 hojas · R^2 Validation 0,750



Árbol	Hiperparámetros	Hojas	Hoja más pequeña	R^2 Validation
A	max_depth = 3	8	80 clientes	0,821
B	+ min_samples_leaf = 600	5	686 clientes	0,785
C	+ min_samples_split = 4 000	3	686 clientes	0,750

Aquí B y C son demasiado estrictos: pierden R^2. En el notebook (9.6) pueden probar sus propios valores y ver el dibujo.

Subajuste y sobreajuste: tres árboles

Árbol	Hojas	MAE Train	MAE Val	R^2 Train	R^2 Val	Brecha R^2
Prof. 1	2	1 515	1 554	0,658	0,608	0,05
Prof. 4	16	739	772	0,868	0,838	0,03
Sin límite	7 080	0,7	962	1,000	0,724	**0,28**

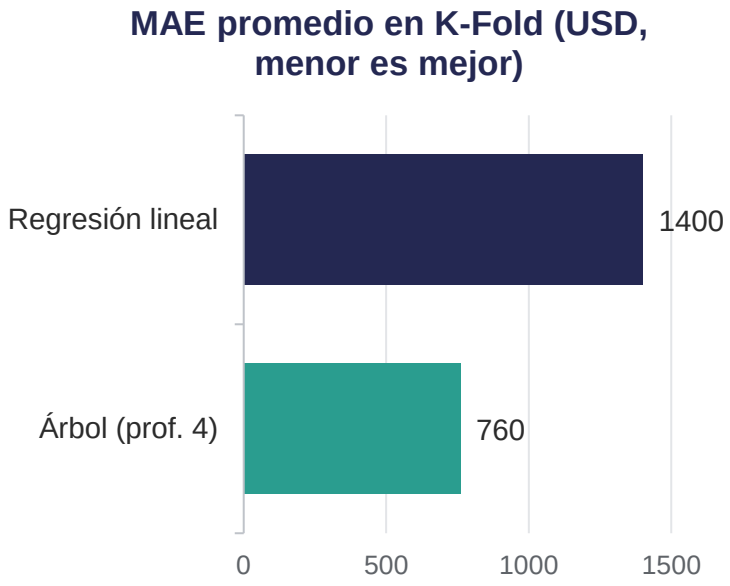
Subajuste
muy simple: falla en todo

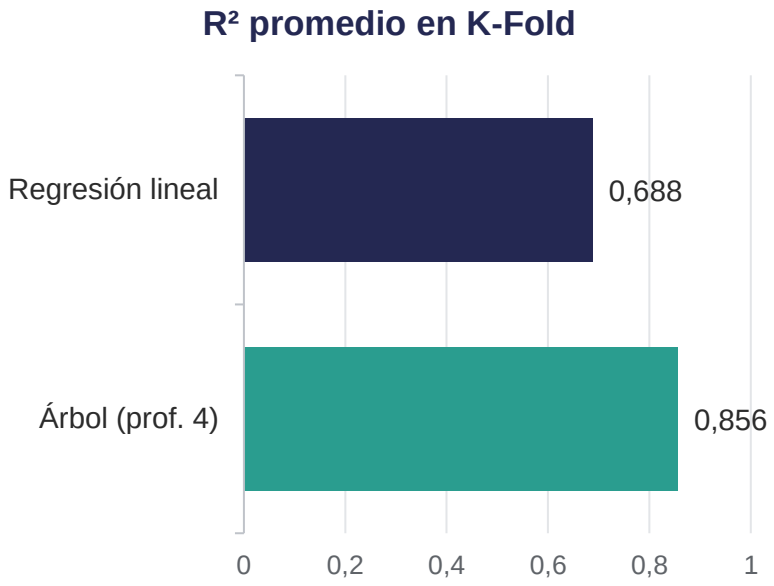
Equilibrio
aprende sin memorizar

Sobreajuste
perfecto en Train, peor en datos nuevos

La señal: no es el valor de Train, sino la distancia entre Train y Validation.

Estabilidad con K-Fold: árbol vs recta





Con miles de filas las cinco vueltas se parecen mucho (desviación ≈ 25 USD). Con 107 filas del Banco Mundial cada vuelta cambiaba bastante.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

5

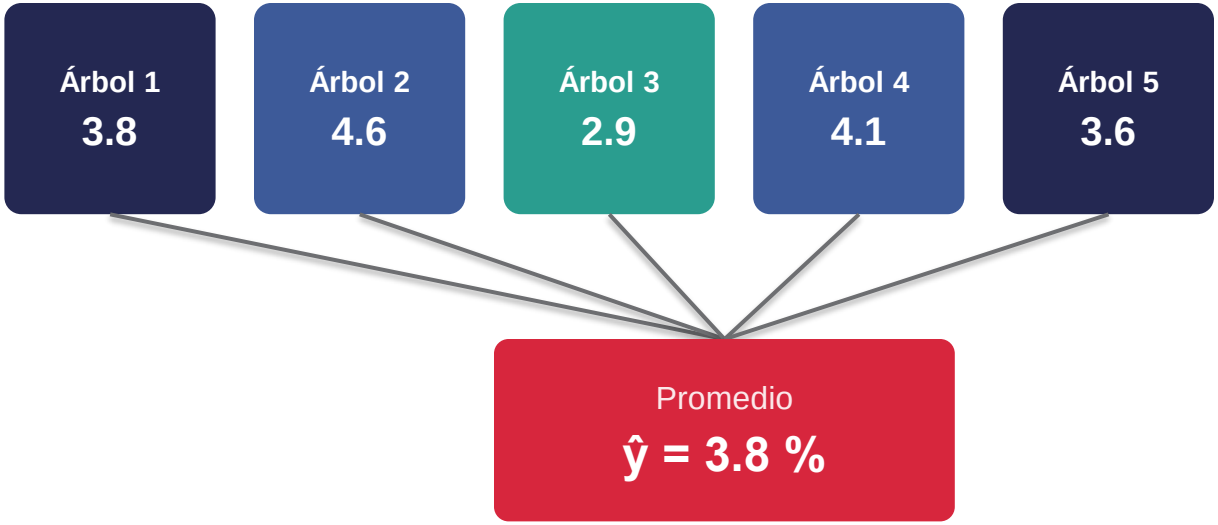
Random Forest

Un árbol solo es inestable. Muchos árboles distintos, promediados, se equivocan menos al azar

En esta sección

- La idea
- Bootstrap a mano
- Promediar
- Resultados

La idea: la sabiduría de la multitud



Cada árbol opina
valores ilustrativos

Random = azar

Cada árbol ve una muestra distinta de filas y de variables.

Forest = bosque

Muchos árboles; la predicción final es el promedio de todos.

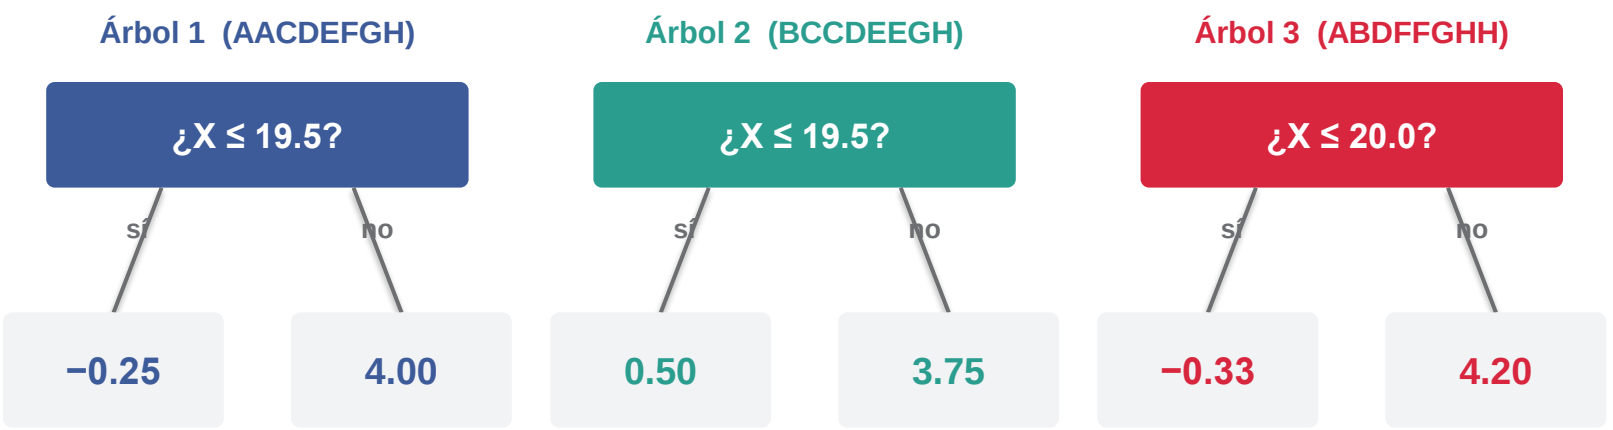
Paso 1: bootstrap, sortear filas con reemplazo

Datos originales	A	B	C	D	E	F	G	H
Árbol 1	A	**A**	C	D	E	F	G	H
fuera (OOB): **B**								
Árbol 2	B	C	**C**	D	E	**E**	G	H
fuera (OOB): **A, F**								
Árbol 3	A	B	D	F	**F**	G	H	**H**
fuera (OOB): **C, E**								

Recuadro rojo
fila repetida en la muestra

Out-of-bag
filas que ese árbol nunca vio

Paso 2: cada muestra produce un árbol distinto

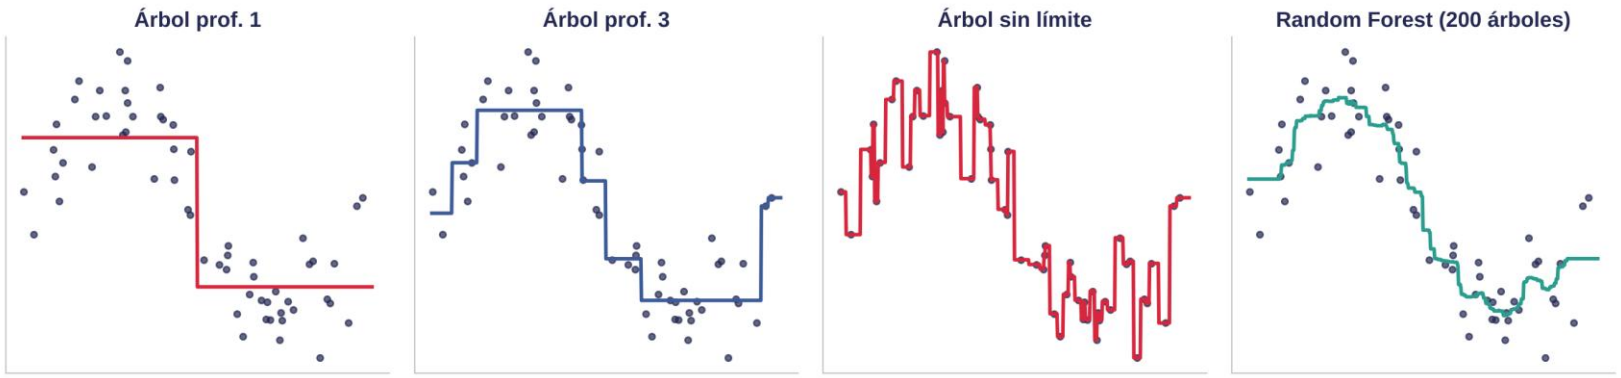


	Árbol 1	Árbol 2	Árbol 3
Corte	19.5	19.5	**20.0**
Hoja izquierda	−0.25	0.50	−0.33
Hoja derecha	4.00	3.75	4.20

Varianza: el mismo algoritmo, con datos casi iguales, da reglas distintas. Random Forest aprovecha esa diversidad.

Paso 3: promediar las predicciones a mano

Nuevo caso	Árbol 1	Árbol 2	Árbol 3	Promedio (bosque)	Árbol original
X = 17	−0.25	0.50	−0.33	**(−0.25 + 0.50 − 0.33) / 3 = −0.03**	0.0
X = 20	4.00	3.75	**−0.33**	**(4.00 + 3.75 − 0.33) / 3 = 2.47**	4.0



En la imagen: un árbol forma escalones bruscos; el bosque de 200 árboles promedia y produce una curva más suave.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Paso 4: azar también en las variables

Árbol 1	**Transacciones**	Cambio Q4/Q1	Productos	**Edad**	Límite
Árbol 2	Transacciones	**Cambio Q4/Q1**	Productos	Edad	**Límite**
Árbol 3	**Transacciones**	Cambio Q4/Q1	**Productos**	Edad	Límite

En color: variables que ese árbol puede usar en su primer corte (ejemplo ilustrativo)

Sin este azar

Todos los árboles se parecerían: promediar copias no ayuda.

Con este azar

Árboles diversos: sus errores se compensan al promediar.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Los hiperparámetros del bosque

n_estimators valor: **100**

Número de árboles

Más árboles: promedio más estable

max_depth valor: **8**

Profundidad de cada árbol

Limita cuántas preguntas hace

min_samples_leaf valor: **5**

Filas mínimas por hoja

Evita hojas de casos aislados

max_features valor: **azar**

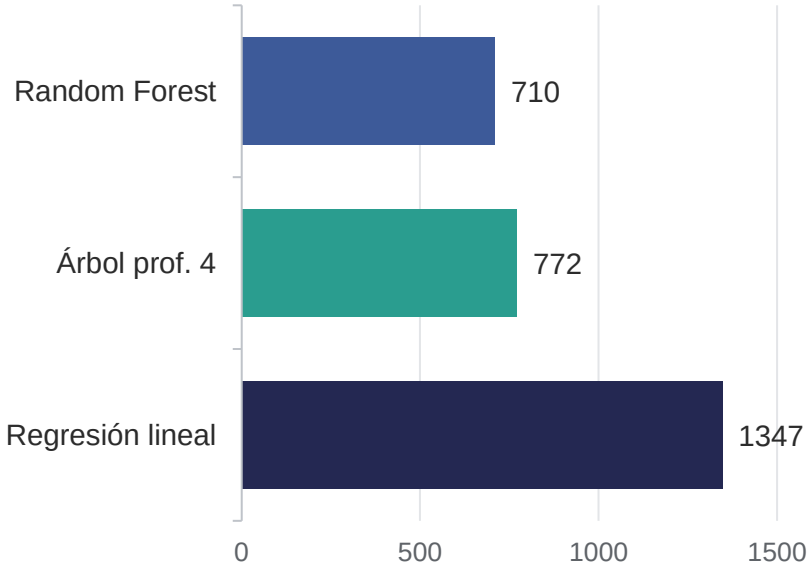
Variables por corte

Hace a los árboles diversos

Igual que antes: se eligen comparando en Validation o con K-Fold, nunca mirando Test.

Resultados: ¿quién predice mejor?

MAE en Validation (USD, menor es mejor)



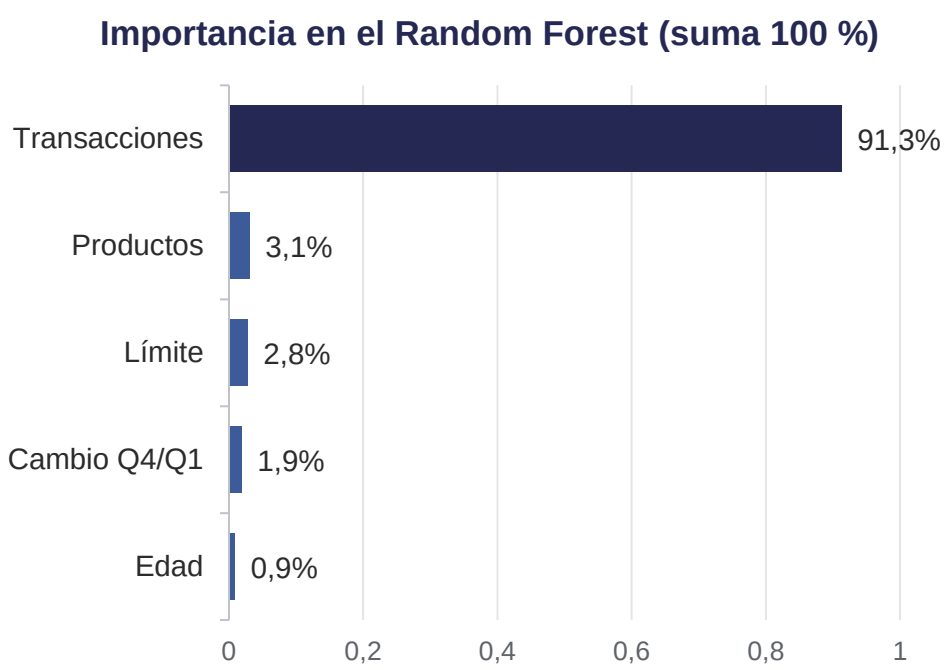
Random Forest	Train	Validation
MAE (USD)	612	710
RMSE (USD)	1 026	1 213
R^2	0,912	0,863
Bias (USD)	−2	−33

Bosque vs árbol solo

MAE baja de 772 a 710 USD

Lección doble: con el Banco Mundial (127 filas) la recta ganó; con 10 127 clientes ganan el árbol y el bosque. Siempre comparar en los mismos datos.

¿Qué variables usa más el bosque?



Cómo se lee

Transacciones aportó 91 % de toda la reducción del error.

Qué NO dice

Ni causa, ni si aumenta o disminuye el monto.

Coherente con el árbol: sus tres primeras preguntas también fueron sobre transacciones.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ideas clave del día

1

K-Fold evalúa mejor

Promedia 5 Validations en lugar de confiar en una.

2

El árbol pregunta

Elige el corte con menor SSE; la hoja predice un promedio.

3

SSE = 0 es memorizar

Hojas de una fila no generalizan.

4

Tres hiperparámetros

max_depth, min_samples_split y min_samples_leaf.

5

El bosque promedia

Bootstrap + azar en variables + promedio = más estable.

6

Depende de los datos

127 filas: ganó la recta. 10 127 clientes: el bosque.

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Del papel al notebook

Lo que hicimos a mano	Lo que verán en el notebook	Debe dar…
Eliminar faltantes	Contar nulos y quedarse con filas completas	140 → 127 filas
Las 5 vueltas A–E	Validación cruzada con 5 bloques	MAE promedio 3.11
SSE de un corte	El ejemplo y = [1, 2, 8, 9]	SSE 50 → 1
Árbol de profundidad 3	plot_tree con BankChurners	raíz: transacciones ≤ 93,5
Los tres hiperparámetros	Tablas de max_depth, leaf y split	mejor R^2 Val. ≈ 0,85
Bootstrap y promedio	Random Forest de 100 árboles	MAE Validation 710 USD

Su rol con el agente de IA

Pidan que explique cada línea y verifiquen los números. Si un resultado no coincide con lo calculado a mano, pregunten por qué.