ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Día 3 — Clasificación: árbol, bosque, KNN y SVM



Módulo 3: Machine Learning Aplicado

Jonathan Rosero Soto

Edificio Aulas y Relación con el Medio Externo, Av. Toledo N23-55 y Madrid
Telf.: +593 2 2525766 - Ext: 102 / 125 / 143 / 120 / 127 - www.cec-epn.edu.ec

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ruta de la jornada

1	**¿Qué es clasificar?**	Clases, regresión vs clasificación, dos errores
2	**Conocer los datos**	PaySim: columnas, fugas y desbalance
3	**Gini**	Cómo elige el árbol cada pregunta
4	**Matriz de confusión y métricas**	Accuracy, Precision, Recall y F1
5	**Desbalance y Random Forest**	Balancear Train y muchos árboles que votan
6	**KNN**	BankChurners: vecinos y normalización
7	**SVM**	Credit Risk: margen, multa C y fronteras curvas
8	**Cierre**	Test una vez y qué modelo usar

Regla del día: *acertar mucho no basta; importa a quién se acierta.*

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Tres datasets, un algoritmo cada uno

Dataset	Pregunta sí/no	Filas	% positivos	Algoritmo
PaySim (muestra)	¿La transacción es fraude?	100 198	8,2 %	Árbol y bosque
BankChurners	¿Abandonó la tarjeta de crédito?	10 127	16,1 %	KNN
Credit Risk	¿El préstamo cayó en impago?	32 581	21,8 %	SVM

Árbol
pregunta por tipo, monto y hora

KNN
busca clientes parecidos

SVM
traza una frontera

Consecuencia: compararemos modelos dentro de cada dataset, nunca entre datasets distintos.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Los tres datasets en pocas palabras

PaySim · fraude

Cada fila es una transacción de dinero móvil simulada: tipo, monto y hora. Queremos saber si es fraude. Con tres variables, el árbol hace preguntas fáciles de leer y la matriz de confusión se entiende como «fraudes detectados frente a falsas alarmas».

BankChurners · abandono

Cada fila es un cliente de tarjeta con su comportamiento del último año: transacciones, gasto, uso del límite, meses inactivo. Queremos saber si abandonó la tarjeta. KNN encaja porque compara al cliente con los clientes que más se le parecen.

Credit Risk · impago

Cada fila es un préstamo aprobado: ingreso, monto, tasa, grado de riesgo e historial. Queremos saber si cayó en impago. SVM encaja porque pagados e impagos se separan bastante bien y se puede dibujar la frontera.

En común: las tres respuestas son sí/no, las tres clases positivas son minoría y ninguno describe clientes del Ecuador.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

1

¿Qué es clasificar?

La respuesta deja de ser un número y pasa a ser una clase: fraude o normal

En esta sección

- El problema
- Clases
- Regresión vs clasificación
- Dos errores

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Nuestro problema: identificar transacciones sospechosas

Operación	Tipo	Monto USD	Saldo anterior USD	¿Fraude? (isFraud)
1	PAYMENT	50	800	No (0)
2	TRANSFER	8 000	8 000	Sí (1)
3	CASH_OUT	100	1 500	No (0)
4	TRANSFER	5 000	5 000	Sí (1)
5	PAYMENT	30	300	No (0)

Características (X)
tipo, monto, saldo: lo que sabemos de la transacción

Variable objetivo (y)
isFraud: 0 = legítima, 1 = fraudulenta

Dos preguntas del día: ¿cómo elige el árbol su primera regla? (Gini) y ¿cómo sabemos si detecta bien los fraudes? (matriz de confusión)

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Qué es clasificar?

Características
tipo, monto, hora…

→

Modelo
reglas aprendidas de casos pasados

→

Clase
fraude o normal

Pagos

¿fraude o normal?

Tarjetas

¿abandona o se queda?

Crédito

¿se paga o cae en impago?

Binaria: dos clases, como hoy. **Multiclase:** tres o más (por ejemplo, segmento de cliente A, B o C).

Aprendizaje supervisado: igual que en regresión, aprendemos de filas donde ya conocemos la respuesta.

¿Qué es una clase?

Columna isFraud

0
1
0
1
0

Clase 0 · negativa
transacción legítima
operaciones 1, 3 y 5

Clase 1 · positiva
transacción fraudulenta
operaciones 2 y 4

Positiva = la que buscamos

No significa «buena»: fraude, abandono, impago.

¿Por qué importa?

Los nombres VP, VN, FP y FN dependen de esta elección.

Hoy: clase positiva = fraude (PaySim), abandono (BankChurners) e impago (Credit Risk).

Regresión y clasificación: qué cambia

	Regresión (Días 1 y 2)	Clasificación (hoy)
Pregunta	¿Cuánto?	¿Cuál clase? ¿sí o no?
Respuesta	un número: 3 109 USD, 2,4 %	una etiqueta: fraude / normal
El error es…	una distancia	un acierto o un fallo
Métricas	MAE, RMSE, R^2	matriz de confusión, Precision, Recall, F1
Hoja del árbol	el promedio de y	la clase más frecuente
Criterio para cortar	reducir el SSE	reducir el índice Gini
Modelo de referencia	predecir el promedio	predecir la clase más frecuente

Pista: si la respuesta se puede promediar con sentido (USD, %), es regresión; si es una etiqueta, es clasificación.

Una clase no es una probabilidad

Datos
tipo, monto, hora…

→

Score
una señal numérica, p. ej. 0,62

→

Umbral
¿0,62 ≥ 0,50?

→

Clase
fraude

Umbral más bajo

Más transacciones se marcan como fraude: encontramos más, pero con más falsas alarmas.

Umbral más alto

Menos alertas y más seguras, pero se escapan más positivos.

Ojo: un score alto no prueba que la transacción sea fraude; es una regla aprendida de datos históricos.

Dos maneras de equivocarse

Falso positivo (FP)

Dijo positivo, era negativo.

Pagos: bloqueamos una transacción legítima.

Crédito: negamos un préstamo que sí se pagaba.

Falso negativo (FN)

Dijo negativo, era positivo.

Pagos: dejamos pasar un fraude.

Crédito: aprobamos un préstamo que no se pagó.

Pregunta antes de modelar: si revisar una alerta cuesta poco y un fraude cuesta mucho, aceptamos más FP para reducir FN.

Hoy: las métricas describen los errores; el costo de cada error lo pone el analista.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

2

Conocer los datos: PaySim

Antes de modelar: qué significa cada columna, cuáles no se pueden usar y por qué el fraude es tan raro

En esta sección

- **Origen**
- **Columnas**
- **Fugas**
- **Desbalance**

PaySim: de dónde vienen los datos

¿Qué es?

Transacciones de dinero móvil (una billetera en el celular) generadas por un simulador a partir de un mes de datos reales. Los datos financieros reales son privados; la simulación permite estudiar el fraude.

Transacciones (30 días)
6 362 620

Fraudes
8 213 · 0,13 %

Cómo ocurre un fraude en la simulación

1. Cuenta de la víctima
el defraudador toma el control

→

2. TRANSFER
envía todo el saldo a otra cuenta

→

3. CASH_OUT
retira el dinero en efectivo

Dataset sintético: sirve para aprender; no describe fraudes reales ni clientes del Ecuador.

Los cinco tipos de transacción (type)

CASH_IN	CASH_OUT	DEBIT	PAYMENT	TRANSFER
Depositar efectivo: cargar saldo a la billetera	Retirar efectivo de la billetera	Pasar dinero de la billetera a una cuenta bancaria	Pagar a un comercio por bienes o servicios	Enviar dinero a otro usuario
normales: 20 051	normales: 32 471	normales: 593	normales: 31 018	normales: 7 852
fraudes: 0	**fraudes: 4 116**	**fraudes: 0**	**fraudes: 0**	**fraudes: 4 097**

El fraude solo usa TRANSFER y CASH_OUT: los dos pasos para vaciar una cuenta. Creamos transfer_o_retiro = 1 si el tipo es uno de esos dos, y 0 si no.

Conteos de la muestra de clase (100 198 transacciones).

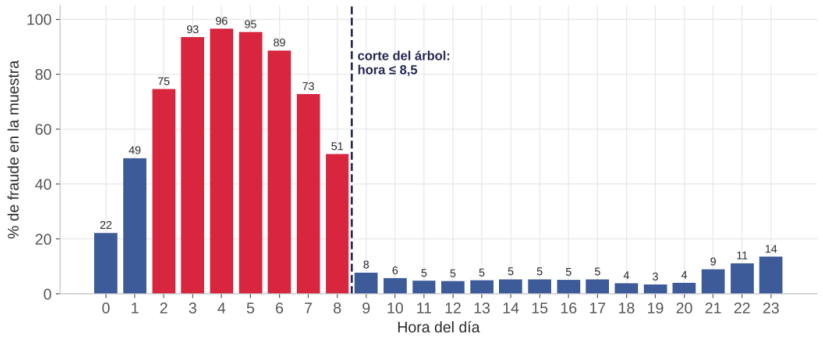
Las columnas, una por una

Columna	Qué es	¿Entra?	Por qué
step	hora de la simulación: 1, 2, … 744	**sí, como hora**	el fraude se concentra de madrugada
type	tipo de transacción (5 tipos)	**sí, resumida**	el fraude solo usa TRANSFER y CASH_OUT
amount	monto de la transacción	**sí**	los fraudes suelen ser montos altos
nameOrig / nameDest	código del cliente que envía / recibe	**no**	es un nombre: no se repite en clientes nuevos
oldbalanceOrg / newbalanceOrig	saldo del que envía, antes / después	**no**	fuga de información
oldbalanceDest / newbalanceDest	saldo del que recibe, antes / después	**no**	fuga de información
isFlaggedFraud	alerta de la regla actual (> 200 000)	**no**	es la respuesta de otro detector: la usamos para comparar
isFraud	¿fue fraude? 0 / 1	**es la y**	lo que queremos predecir

Regla: solo entra al modelo lo que se conoce en el momento de decidir y describe a la transacción.

¿Para qué sirve step? Convertirlo en hora del día

step	Día	Hora del día = resto de step ÷ 24
3	1	3 (madrugada)
27	2	27 − 24 = 3 (madrugada)
50	3	50 − 48 = 2 (madrugada)
110	5	110 − 96 = 14 (tarde)



% de fraude en la muestra según la hora del día

step crudo: número de hora del mes (1 a 744); no se repite en el futuro. **Hora del día:** 0 a 23; se repite todos los días y muestra el patrón de madrugada.

Ingeniería de variables: transformar una columna con conocimiento del negocio para que el modelo la pueda aprovechar.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Por qué quitamos los saldos? Fuga de información

Fuga de información: usar una columna que contiene la respuesta o que se escribió conociéndola.

Analogía

Predecir si un estudiante aprueba usando su «nota final». Acierta siempre, pero no sirve: esa nota solo existe cuando ya se sabe el resultado.

En PaySim

Las transacciones detectadas como fraude se cancelan y la cancelación altera los saldos. Los saldos llevan la huella de la respuesta.

Antes de decidir
tipo, monto, hora

→

La decisión
¿es fraude?

→

Después
cancelación y saldos ajustados

Advertencia del dataset: oldbalanceOrg, newbalanceOrig, oldbalanceDest y newbalanceDest no deben usarse para detectar fraude.

La prueba: demasiado bueno para ser verdad

Fraudes con monto = saldo anterior

97,8 %

Normales con monto = saldo anterior

0,0 %

Mismo árbol (prof. 5) en Validation	Precision	Recall	F1
Sin saldos: tipo, monto y hora	0,806	0,521	**0,633**
Con los cuatro saldos	0,972	0,810	**0,884**

Señal de alarma: cuando una columna hace al modelo casi perfecto, primero hay que preguntarse si esa columna existiría antes de conocer la respuesta.

Decisión: seguimos sin saldos. Un F1 de 0,63 honesto vale más que un 0,88 que no se repetirá.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Por qué no usamos isFlaggedFraud como variable?

¿Qué es isFlaggedFraud?

La alerta de la regla actual: marca todo intento de transferir más de 200 000 en una sola transacción.

Veces que la regla se activó (muestra)

16

Transferencias fraudulentas > 200 000

2 740

No describe la transacción
es la salida de otro detector

Casi nunca avisa
como variable aportaría poco

La usamos como rival
¿le ganamos a la regla actual?

Una regla fija es fácil de explicar, pero no aprende de los datos. Por eso es una buena referencia para comparar.

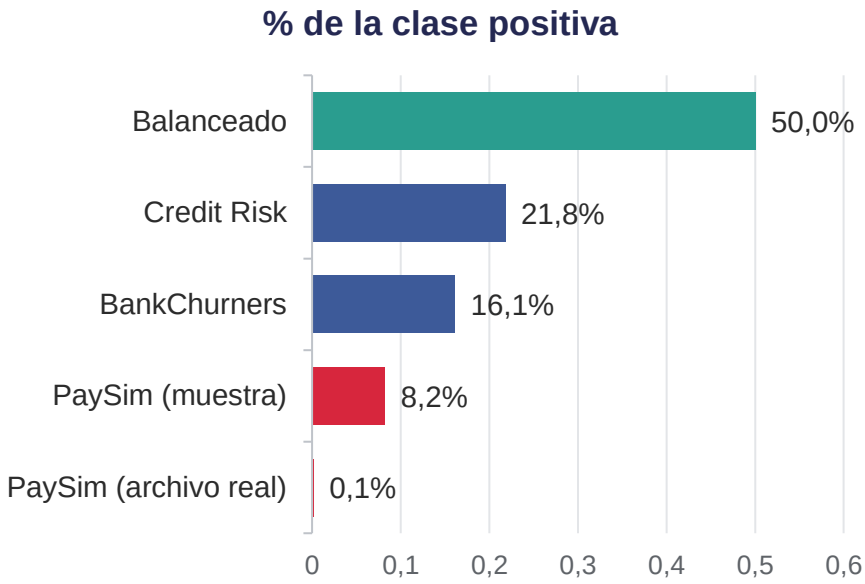
Datasets balanceados y desbalanceados

Balanceado

clases de tamaño parecido. Ejemplo: 500 normales y 500 fraudes.

Desbalanceado

una clase es rara. Ejemplo: 980 normales y 20 fraudes.



El peligro: con 980 normales y 20 fraudes, decir siempre «normal» acierta 98 % y no detecta ningún fraude. El modelo aprende poco de la clase rara, justo la que buscamos.

Los tres datasets de hoy son desbalanceados.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Por qué trabajamos con una muestra?

Archivo completo
6 362 620

→

Nos quedamos con
todos los fraudes (8 213)
+ 91 985 normales al azar

→

Muestra de clase
100 198

	Archivo completo	Muestra de clase
Fraudes	8 213	8 213 (todos)
Normales	6 354 407	91 985 (al azar)
% fraude	0,13 %	8,2 %

Esto ya es balancear: submuestreo de los normales. **Consecuencia:** con la tasa real habría muchas más falsas alarmas; la Precision de hoy sería menor en producción.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cómo trabajar con datos desbalanceados

1 Dividir bien

stratify o por grupos

2 Medir bien

Precision, Recall, F1

3 class_weight

más peso a la clase rara

4 Submuestreo

quitar mayoritarios en Train

5 Sobremuestreo

repetir minoritarios (SMOTE)

6 Umbral

mover el punto de decisión

Regla de oro: se balancea solo Train. Validation y Test deben parecerse a los datos reales.

Más adelante comparamos class_weight, submuestreo y sobremuestreo con el mismo árbol.

Una fuga escondida: cada fraude aparece dos veces

Una operación de fraude = dos filas (ejemplo ilustrativo)

TRANSFER	CASH_OUT
181 000 · hora 1	181 000 · hora 1

División al azar (mal)

Train	Validation
TRANSFER 181 000	CASH_OUT 181 000

el modelo ya vio ese monto

División por operación (bien)

Train	Validation
TRANSFER + CASH_OUT	otras operaciones

no hay montos repetidos

Resultado: Train 70 126 filas (8,2 % fraude) · Validation 15 063 (8,5 %) · Test 15 009 (8,0 %). Ninguna operación compartida.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

3

Árbol de clasificación: cómo elige la pregunta

El índice de Gini mide la mezcla de clases y guía la construcción del árbol

En esta sección

- Construir y evaluar
- Gini
- Ejemplo a mano
- PaySim

Dos momentos distintos: construir y evaluar

Momento 1 · con Train

Construir

Índice de Gini

¿qué pregunta separa mejor las transacciones?

Momento 2 · con Validation

Evaluar

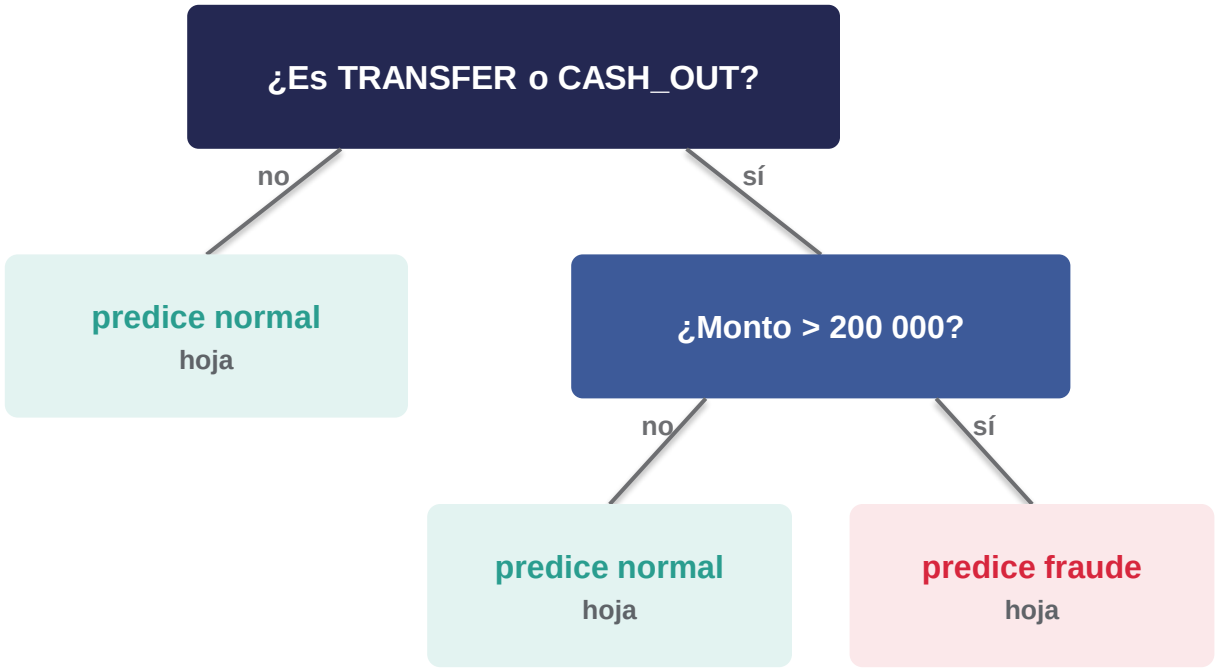
Matriz de confusión

¿detecta correctamente los fraudes?

Gini ayuda a construir el árbol; la matriz de confusión ayuda a evaluar sus predicciones.

Orden de hoy: primero Gini (cómo aprende), luego la matriz y las métricas (cómo lo evaluamos).

¿Qué es un árbol de clasificación?



Nodo

una pregunta

Rama

una respuesta: sí o no

Hoja

da la clase más frecuente

¿Qué pregunta va primero? La que mejor separa normales de fraudes. Para medir «separar bien» usamos el índice de Gini.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Índice de Gini: qué tan mezclado está un nodo

Gini = 1 − (p0² + p1²)

p0 = proporción de normales · p1 = proporción de fraudes

Nodo puro



10 normales · 0 fraudes

1 − (1² + 0²)

0,00

Nodo mixto



8 normales · 2 fraudes

1 − (0,8² + 0,2²)

0,32

Máxima mezcla



5 normales · 5 fraudes

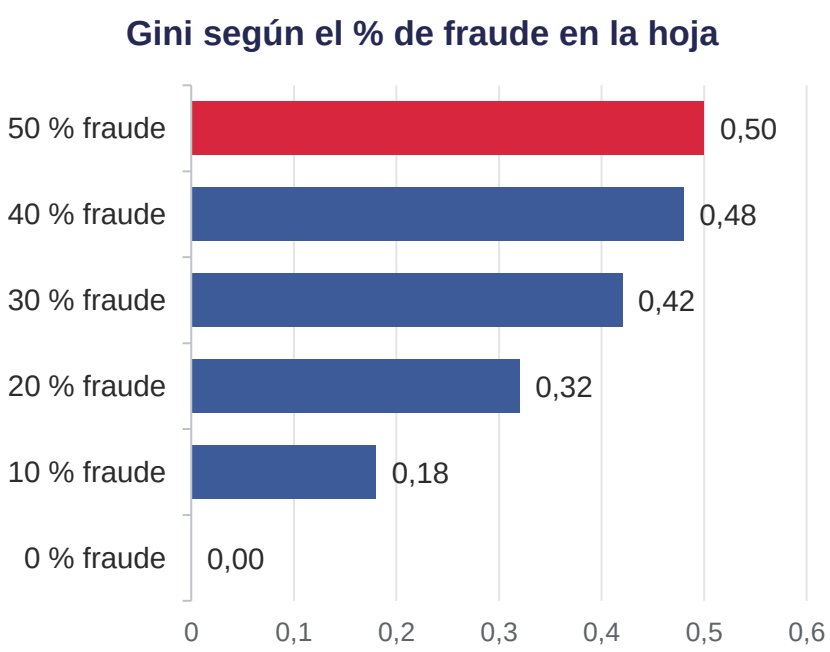
1 − (0,5² + 0,5²)

0,50

● azul = normal ● rojo = fraude

Lectura: 0 = una sola clase (nodo puro). 0,5 = mezcla máxima para dos clases con igual peso.

¿Qué mide Gini? Equivocarse al azar



La fórmula

$G = 1 - p(\text{normal})^2 - p(\text{fraude})^2$

Con 20 % de fraude: $1 - 0{,}8^2 - 0{,}2^2 = 1 - 0{,}64 - 0{,}04 = 0{,}32$

Cómo se lee

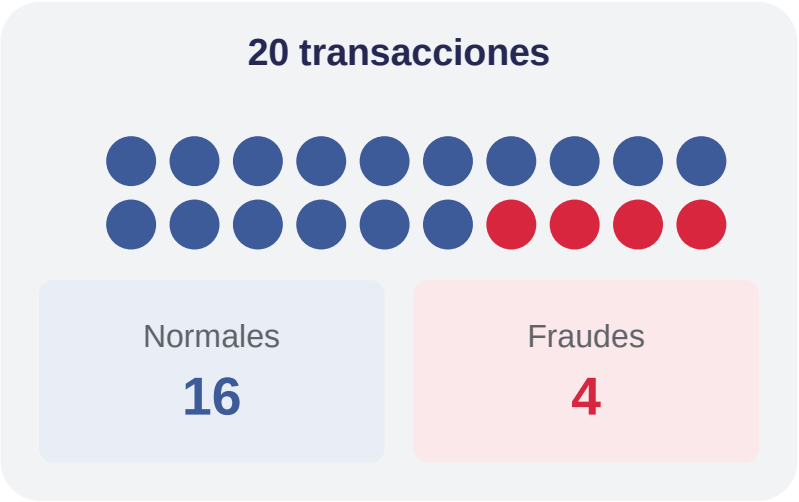
0 = hoja pura, una sola clase.

0,5 = máxima mezcla con dos clases.

Menor Gini = hoja más «segura».

Simétrico: 80 % de fraude da el mismo Gini que 20 %. Gini no dice qué clase domina, solo cuánta mezcla hay; la hoja predice la clase mayoritaria.

Ejemplo a mano: 20 transacciones



Paso	Cálculo
1. Proporción de normales	$p_0 = 16 / 20 = 0{,}8$
2. Proporción de fraudes	$p_1 = 4 / 20 = 0{,}2$
3. Elevar al cuadrado	$0{,}8^2 = 0{,}64 \cdot 0{,}2^2 = 0{,}04$
4. Gini inicial	**$1 - (0{,}64 + 0{,}04) = 0{,}32$**

Siguiente paso: buscar una pregunta que reduzca esa mezcla de 0,32.

Ejemplo inventado para comprender el cálculo; no representa una muestra del dataset PaySim.

Probamos una pregunta: ¿la transacción es TRANSFER?

20 transacciones
16 normales · 4 fraudes · Gini 0,32

¿Es TRANSFER?

sí

6 transacciones



2 normales · 4 fraudes · $1 - (2/6)^2 - (4/6)^2$

Gini = 0,444

no

14 transacciones



14 normales · 0 fraudes · $1 - (14/14)^2$

Gini = 0,000

Rama no: pura, ningún fraude. **Rama sí:** todavía mezclada, pero con mayoría de fraudes.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Gini ponderado: no basta con promediar

Promedio simple (incorrecto)

(0,444 + 0) / 2 = 0,222

Trata igual a una rama de 6 filas y a una de 14.

Gini ponderado (correcto)

6/20 × 0,444 + 14/20 × 0 = 0,133

Cada rama pesa según cuántas filas llegan a ella.

Antes de dividir
0,32

→

Después (ponderado)
0,133

→

Reducción de impureza
0,187

Reducción = Gini antes − Gini ponderado después. Cuanto mayor, mejor separa la pregunta.

¿Por qué ponderar? Una rama pura de 2 filas no vale lo mismo que una de 14: importa a cuántas transacciones ordena bien.

El árbol prueba otras preguntas y elige la mejor

Pregunta	Rama 1: filas · fraudes · Gini	Rama 2: filas · fraudes · Gini	Gini ponderado	Reducción
¿Es TRANSFER?	6 · 4 · 0,444	14 · 0 · 0,000	0,133	**0,187**
¿Monto ≤ 1 000?	12 · 1 · 0,153	8 · 3 · 0,469	0,279	0,041

1 Probar

cada variable y cada umbral

2 Calcular

el Gini ponderado de las ramas

3 Elegir

la mayor reducción de impureza

4 Repetir

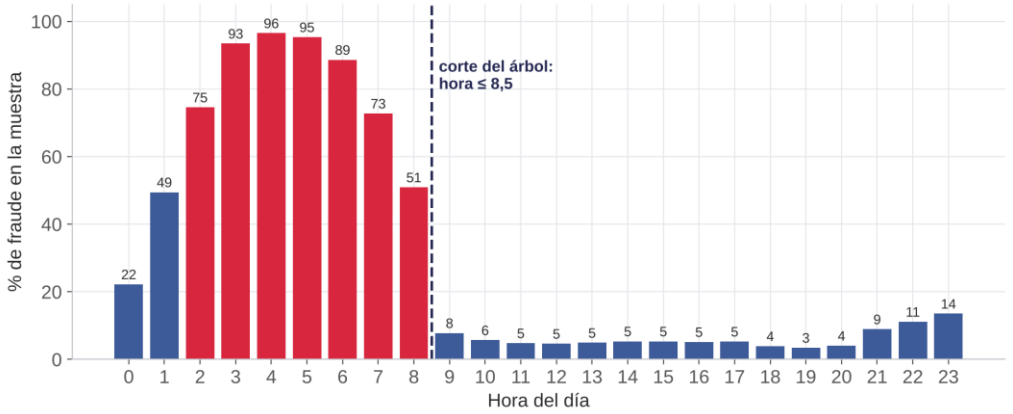
en cada rama hasta parar

Condiciones de parada: el nodo es puro, se alcanzó max_depth o quedarían menos filas que min_samples_leaf (Día 2).

Gini no mide aciertos con transacciones nuevas: solo guía la construcción. Para evaluar está la matriz de confusión.

Ahora con PaySim: ¿dónde está el fraude?

Tipo	Normales	Fraudes
CASH_OUT	32 471	4 116
TRANSFER	7 852	4 097
PAYMENT	31 018	0
CASH_IN	20 051	0
DEBIT	593	0



Tres señales: el tipo (transferencia o retiro), el monto (alto) y la hora (madrugada). El árbol podrá preguntar por las tres.

Cuidado: en un dataset sintético, estas señales reflejan cómo se programó la simulación; no son leyes del fraude real.

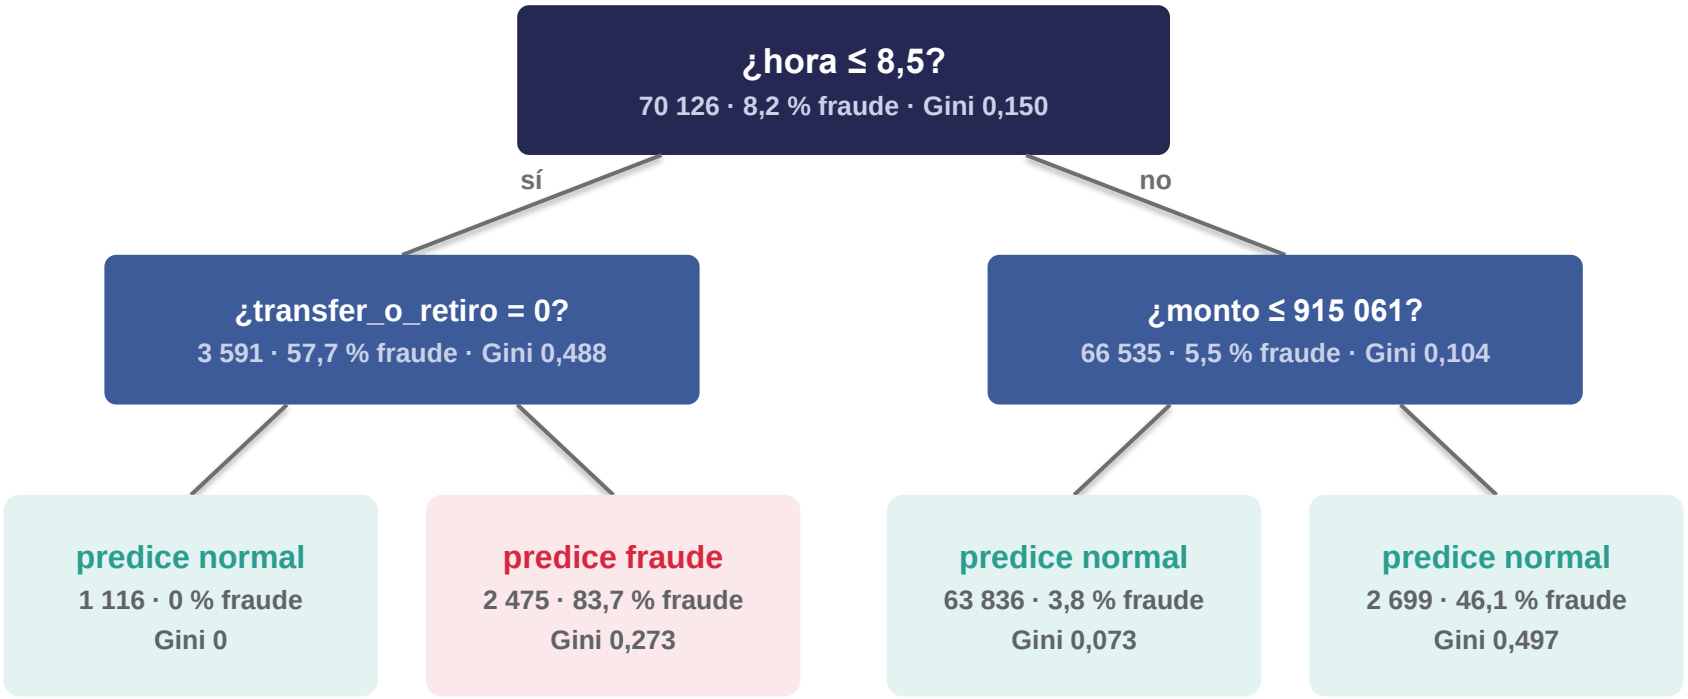
PaySim: comparar preguntas candidatas

Pregunta	Izquierda: filas · fraudes · Gini	Derecha: filas · fraudes · Gini	Gini ponderado
¿hora ≤ 8,5?	3 591 · 2 072 · 0,488	66 535 · 3 663 · 0,104	**0,124**
¿hora ≤ 6,5?	2 762 · 1 591 · 0,488	67 364 · 4 144 · 0,116	0,130
¿transfer_o_retiro = 0?	**36 355 · 0 · 0,000**	33 771 · 5 735 · 0,282	0,136
¿monto ≤ 200 000?	49 488 · 1 905 · 0,074	20 638 · 3 830 · 0,302	0,141

A mano, ¿hora ≤ 8,5?: izquierda p = 2 072 / 3 591 = 0,577 → G = 1 − 0,577² − 0,423² = 0,488. Ponderado = (3 591 × 0,488 + 66 535 × 0,104) / 70 126 = 0,124.

Raíz: 0,150. La mejor pregunta baja la mezcla a 0,124. El algoritmo hace esto con todos los umbrales posibles.

El árbol de dos preguntas que aprendió el algoritmo



Hoja pura: de madrugada, si no es transferencia ni retiro, nunca hubo fraude. **Hoja mixta:** de día con monto alto, casi mitad y mitad.

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

4 Matriz de confusión y métricas

Una vez entrenado, ¿cómo sabemos si el árbol está detectando correctamente los fraudes?

En esta sección

- Matriz
- Leer VP y VN
- Métricas
- F1
- PaySim

Matriz de confusión: 1 000 transacciones

	Predice normal	Predice fraude
Real normal	**950** VN correctos	**30** FP falsas alarmas
Real fraude	**5** FN fraudes omitidos	**15** VP fraudes detectados

Comprobar	
Real normal	950 + 30 = 980
Real fraude	5 + 15 = 20
Alertas emitidas	30 + 15 = 45
Total	1 000

Diagonal = aciertos (VN y VP). **Fuera de la diagonal = errores** (FP y FN). Fraude es la clase positiva.

Nombre: «confusión» porque muestra qué clase confundió el modelo con cuál.

Matriz ilustrativa de un DecisionTreeClassifier evaluado en 1 000 transacciones nuevas.

Cada casilla en un sistema de pagos

Resultado	Qué significa en un sistema de pagos
Verdadero negativo (950)	La operación era normal y el sistema la clasificó correctamente
Falso positivo (30)	La operación era legítima, pero el sistema generó una alerta
Falso negativo (5)	Era fraude, pero el modelo no lo detectó
Verdadero positivo (15)	Era fraude y el modelo lo detectó

Costo de un FN

un fraude que pasa desapercibido: dinero perdido.

Costo de un FP

horas de revisión y un cliente legítimo molesto.

El negocio decide cuál de los dos errores pesa más; las métricas solo los cuentan.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cómo leer VP, VN, FP y FN sin confundirse

1.ª palabra
¿Acertó? verdadero / falso

2.ª palabra
¿Qué dijo? positivo = fraude / negativo = normal

Nombre	¿Acertó?	¿Qué dijo el modelo?	¿Qué era en realidad?	En palabras
VP	sí	fraude	fraude	fraude detectado
VN	sí	normal	normal	normal bien aceptada
FP	no	fraude	normal	falsa alarma
FN	no	normal	fraude	fraude que se escapó

Truco: lee primero la segunda letra (P o N = lo que dijo el modelo) y después la primera (V o F = si acertó).

Métricas nuevas (1): Accuracy

Accuracy usa las cuatro casillas

	pred. normal	pred. fraude
real normal	VN **950**	FP **30**
real fraude	FN **5**	VP **15**

Accuracy = (VP + VN) / total

(950 + 15) / 1 000 = 96,5 %

Qué responde

Porcentaje total de operaciones correctamente clasificadas.

Cuándo sirve: clases equilibradas y errores de costo parecido. Con 98 % de normales, engaña.

Métricas nuevas (2): Precision

Precision mira la columna de alertas

	pred. normal	pred. fraude
real normal	VN **950**	FP **30**
real fraude	FN **5**	VP **15**

Precision = VP / (VP + FP)

15 / (15 + 30) = 33,3 %

Qué responde

¿Mis alertas son confiables? De cada 3 alertas, solo 1 era fraude.

Importa cuando cada alerta es costosa: revisión manual, bloquear la tarjeta de un buen cliente.

Métricas nuevas (3): Recall

Recall mira la fila de fraudes reales

	pred. normal	pred. fraude
real normal	VN **950**	FP **30**
real fraude	FN **5**	VP **15**

Recall = VP / (VP + FN)

15 / (15 + 5) = 75,0 %

Qué responde

¿Se me escapan los fraudes? De cada 4 fraudes, encontró 3.

Importa cuando dejar pasar un positivo cuesta mucho: un fraude, un préstamo grande que no se pagará.

Métricas nuevas (4): F1-score

F1 = 2VP / (2VP + FP + FN)

30 / (30 + 30 + 5) = 46,2 %

Equivale a 2 · P · R / (P + R)

2 · 0,333 · 0,75 / 1,083 = 0,462

	Precision	Recall	Promedio simple	F1
Ejemplo de 1 000	0,333	0,750	0,542	**0,462**
Regla isFlaggedFraud (PaySim)	1,000	0,004	**0,502**	**0,008**

Media armónica: se acerca al valor más bajo. Si una de las dos es casi 0, F1 es casi 0.

Rango: 0 = no detecta nada · 1 = detecta todos los fraudes sin ninguna falsa alarma.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Por qué no podemos confiar solo en Accuracy?

Nuestro árbol		«Todas son normales»	
Accuracy	96,5 %	Accuracy	98,0 %
Fraudes detectados	15 de 20	Fraudes detectados	0 de 20
F1	0,462	F1	0,000

Más Accuracy, cero fraudes. Con clases desbalanceadas, Accuracy premia ignorar la clase rara.

Por eso: en fraude miramos Recall, Precision y F1, además del costo de cada error.

F1: la métrica para todo problema de clasificación

¿Qué es?

Un número de 0 a 1 que resume Precision y Recall. Solo es alto si ambas son altas.

¿Por qué con desbalance?

No usa los VN: las normales bien aceptadas no lo inflan. «Siempre normal» → F1 = 0.

¿Para qué la usaremos?

Elegir hiperparámetros y comparar modelos en Validation: árbol, bosque, KNN y SVM.

F1 = 2VP / (2VP + FP + FN) · no aparece VN

Hoy: PaySim (fraude), BankChurners (abandono) y Credit Risk (impago) se comparan con F1 de la clase positiva.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Qué métrica elegir?

Situación	Error más costoso	Métrica
Fraude, impago de un crédito grande, enfermedad grave	FN: dejar pasar un positivo	**Recall**
Revisión manual costosa, bloquear tarjetas de buenos clientes, spam	FP: falsa alarma	**Precision**
Ambos errores pesan parecido	Los dos	**F1**
Clases ≈ 50 / 50 y errores de costo parecido	Los dos	**Accuracy**

En clase usaremos F1 para elegir modelos. En un banco real habría que traducir cada FP y cada FN a dinero o a tiempo.

PaySim: el árbol completo y sus métricas

Árbol en Validation (15 063 transacciones)

	pred. normal	pred. fraude
real normal	VN **13 619**	FP **161**
real fraude	FN **615**	VP **668**

Métrica	Cálculo	Valor
Accuracy	(668 + 13 619) / 15 063	0,948
Precision	668 / (668 + 161)	0,806
Recall	668 / (668 + 615)	0,521
F1	2·0,806·0,521 / 1,327	0,633

Lectura: detecta la mitad de los fraudes (Recall 0,521) y, cuando avisa, acierta 8 de cada 10 veces (Precision 0,806).

No memoriza: F1 en Train 0,610 y en Validation 0,633: casi iguales. Lo que aprendió también funciona con transacciones nuevas.

PaySim: el árbol frente a las referencias

En Validation (15 063 transacciones)	Alertas	Accuracy	Precision	Recall	F1
Siempre «normal»	0	0,915	—	0,000	**0,000**
Regla isFlaggedFraud	5	0,915	1,000	0,004	**0,008**
Árbol (prof. 5, hoja ≥ 30)	829	0,948	0,806	0,521	**0,633**

Accuracy: 0,915 frente a 0,948, casi igual. **F1:** 0 y 0,008 frente a 0,633, la diferencia salta a la vista.

Le ganamos a la regla actual: encontramos 668 fraudes en lugar de 5, con 161 falsas alarmas.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

5

Desbalance y Random Forest

Cuatro formas de tratar el desbalance y muchos árboles que votan

En esta sección

- class_weight
- Estrategias
- Bosque
- Memorizar

class_weight: dar más peso a los fraudes

Árbol sin pesos

	pred. normal	pred. fraude
real normal	VN 13 619	FP 161
real fraude	FN 615	VP 668

Árbol balanced

	pred. normal	pred. fraude
real normal	VN 11 829	FP 1 951
real fraude	FN 246	VP 1 037

	Alertas	Precision	Recall	F1
Sin pesos	829	0,806	0,521	0,633
Balanced	2 988	0,347	0,808	0,486

El intercambio: encuentra 1 037 fraudes en lugar de 668, a cambio de 1 951 falsas alarmas en lugar de 161. F1 baja, pero si un fraude cuesta mucho más que revisar una alerta, podría convenir.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

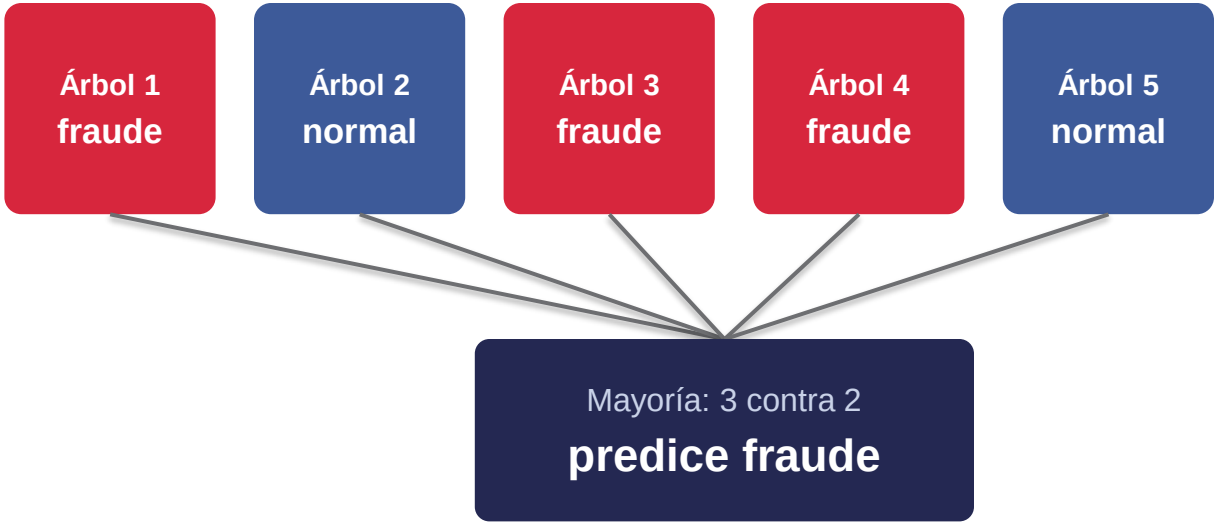
Cuatro estrategias, la misma Validation

Estrategia (solo en Train)	Filas de Train	% fraude en Train	Alertas	Precision	Recall	F1
Sin balancear	70 126	8,2 %	829	0,806	0,521	0,633
class_weight balanced	70 126	8,2 % (con pesos)	2 988	0,347	0,808	0,486
Sobremuestreo	128 782	50 %	3 351	0,317	0,829	0,459
Submuestreo	11 470	50 %	2 247	0,427	0,748	0,544

¿Cuál elegir? Si el costo de un fraude perdido es muy alto, una estrategia con más Recall. Si las alertas se revisan a mano y son caras, sin balancear.

Sobremuestreo repite filas: el modelo puede memorizarlas. Submuestreo es rápido pero descarta información.

Random Forest: muchos árboles que votan



Cada árbol opina
votos ilustrativos

Regresión (Día 2)

Cada árbol da un número; el bosque promedia.

Clasificación (hoy)

Cada árbol da una clase; el bosque cuenta votos.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

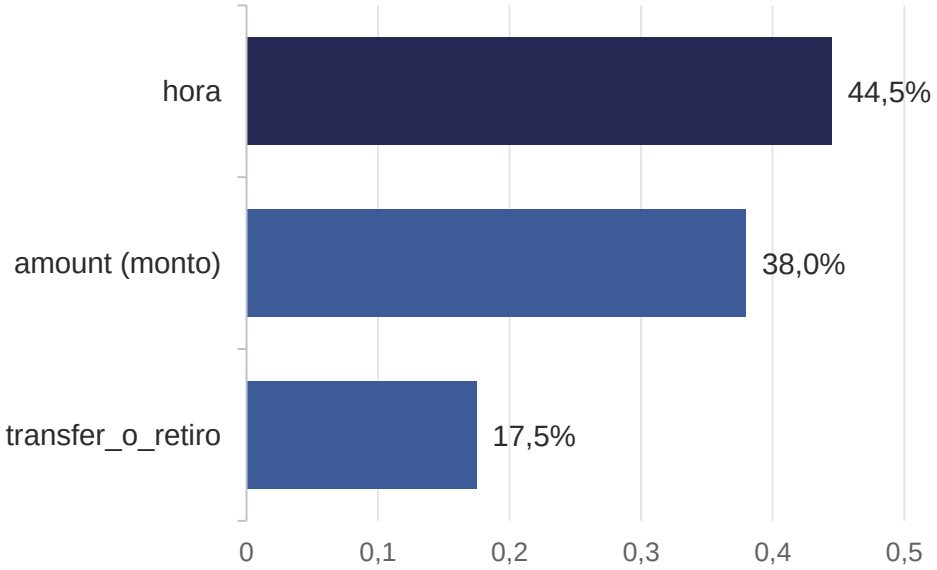
Un árbol que memoriza y uno que no

Modelo	Alertas	Precision	Recall	F1 Train	F1 Validation	Brecha
Árbol (prof. 5, hoja ≥ 30)	829	0,806	0,521	0,610	**0,633**	−0,02
Árbol balanced	2 988	0,347	0,808	0,474	0,486	−0,01
Random Forest	789	0,823	0,506	0,620	0,626	−0,01
Random Forest balanced	3 080	0,339	0,814	0,483	0,479	0,00
Árbol sin límite	953	0,626	0,465	**0,998**	**0,534**	**0,46**

La señal de memorizar: Train casi perfecto y Validation mucho peor. Se corrige limitando el árbol (max_depth, min_samples_leaf), como en el Día 2.

Bosque: si no mejora la métrica que importa, su costo de cálculo y su menor facilidad para explicarse no se justifican.

¿Qué variable usó más el bosque?



Cómo se lee

La hora aportó 44,5 % de toda la reducción de Gini.

Qué NO dice

Ni causa ni dirección: solo qué variable separó mejor.

Coherente con el árbol: su primera pregunta también fue sobre la hora.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

6

KNN: clasificar por parecido

BankChurners: si los clientes que más se le parecen se fueron, es una señal de alerta. Antes, normalizar

En esta sección

- Datos y fuga
- La idea
- Normalizar
- Elegir k

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

BankChurners: clientes que abandonan la tarjeta

Clientes	Abandonaron	Abandonos en Validation
10 127	**16,07 %**	**244 de 1 519**

Usamos 11 variables numéricas de comportamiento

Edad · límite de crédito · saldo que arrastra · monto y número de transacciones

Cambio de monto y de transacciones (Q4 frente a Q1) · uso promedio del límite

Meses inactivo · contactos con el banco · número de productos

Por qué para KNN: tiene comportamiento transaccional y actividad: explica bien cómo se clasifica a un cliente por clientes similares.

Otra fuga: columnas que ya conocen la respuesta

Accuracy de la regla con la columna

100 %

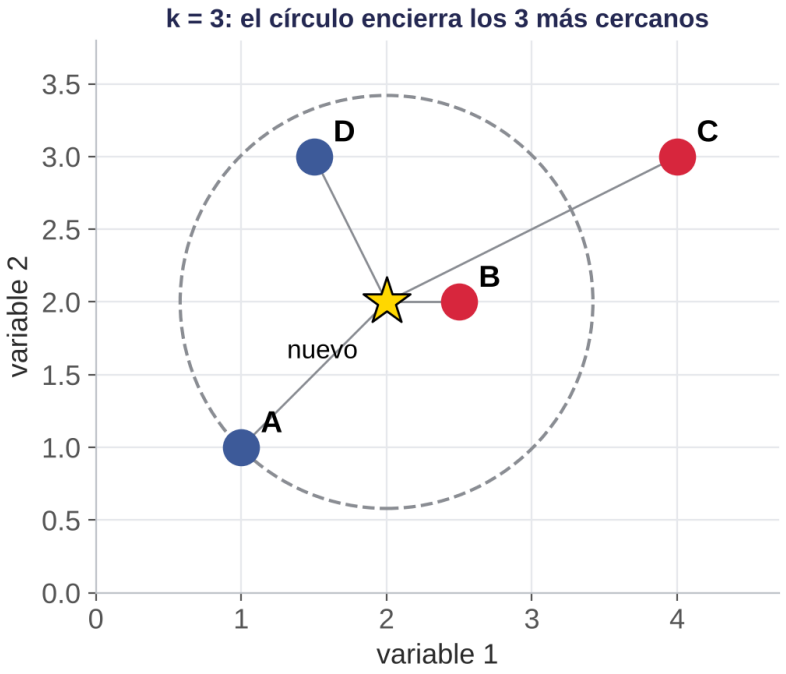
Señal de alarma

Un resultado perfecto casi siempre indica fuga, no un gran modelo.

Columna	Qué hacemos	Por qué
CLIENTNUM	Eliminar	identificador, no describe al cliente
Naive_Bayes… (2)	Eliminar	contienen la respuesta
Attrition_Flag	Target y	Attrited Customer = 1

Pregunta de control: ¿esta columna existiría antes de saber la respuesta?

La idea de KNN: preguntar a los vecinos

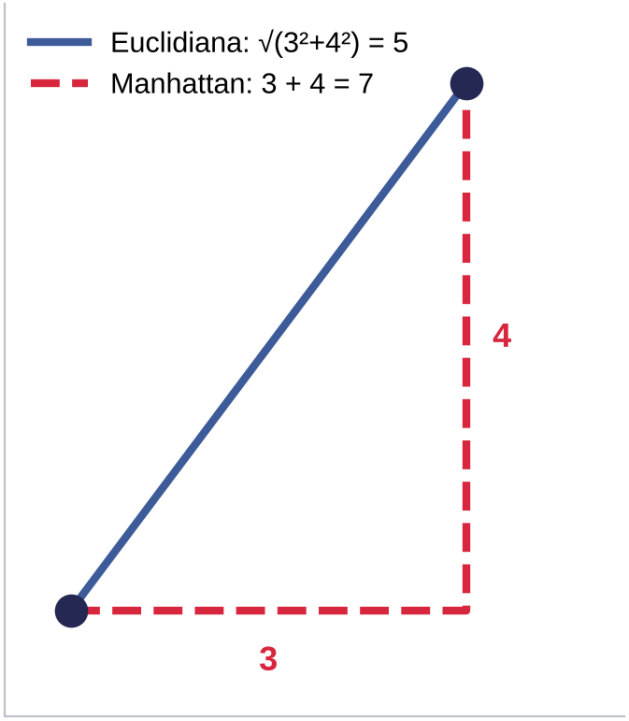


Punto	Distancia	Clase	¿Entre los 3?
B	0,50	yes	sí
D	1,12	no	sí
A	1,41	no	sí
C	2,24	yes	no

Voto: 2 no contra 1 yes
predice no

KNN no aprende reglas: guarda los casos de Train y los consulta cada vez que llega uno nuevo.

¿Qué significa «cercano»? Dos distancias



Euclidiana (p = 2)

$\sqrt{(\Delta_1^2 + \Delta_2^2 + \ldots)}$: la opción por defecto de KNN.

Manhattan (p = 1)

$|\Delta_1| + |\Delta_2| + \ldots$: castiga menos una diferencia grande en una sola variable.

Con 11 variables la idea es la misma: se suman las diferencias de las 11 columnas.

Antes de medir distancias: escalar

	Transacciones	Monto (USD)
Cliente nuevo	48	3 109
Vecino más cercano	49	3 073
Diferencia	1	36
Diferencia escalada	1 / 23,6 = 0,042	36 / 3 391,7 = 0,011

Sin escalar

$\sqrt{(1^2 + 36^2)} = 36{,}0$

manda el monto

Escalado

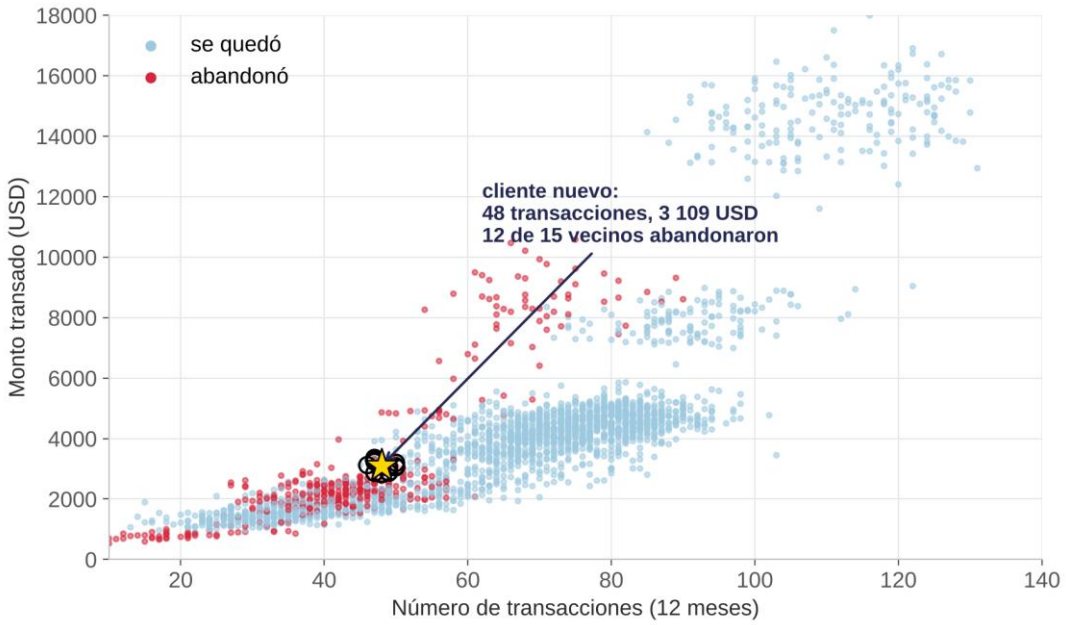
$\sqrt{(0{,}042^2 + 0{,}011^2)} = 0{,}044$

ambas cuentan

z del cliente: (48 − 64,9) / 23,6 = −0,71 y (3 109 − 4 397) / 3 391,7 = −0,38: está algo por debajo del cliente promedio en ambas.

Igual que siempre: la media y la desviación se aprenden solo con Train.

Un cliente real y sus 15 vecinos



Vecinos que abandonaron

12 de 15

Predicción KNN

abandona

Lo que pasó

abandonó

Observa: a partir de unas 85 transacciones casi no hay puntos rojos. KNN no escribió esa regla: la encuentra al consultar a los vecinos.

Las escalas engañan: el vecino equivocado

	Transacciones	Monto (USD)	Distancia sin escalar	Distancia estandarizada
Cliente nuevo	48	3 109	—	—
Cliente A (parecido)	49	3 073	**36,0**	**0,044**
Cliente B (distinto)	79	3 112	**31,1**	**1,312**

Sin escalar

B «gana» porque su monto casi coincide; las 31 transacciones de diferencia casi no pesan.

Estandarizado

Cada variable pesa en desviaciones: A es el vecino correcto.

Por eso, en KNN y en SVM normalizar no es opcional: la distancia depende de las unidades.

Dos formas de normalizar

Estandarización (StandardScaler)

z = (x − media) / desviación

Min-max (MinMaxScaler)

x' = (x − mín) / (máx − mín)

Cliente nuevo	Valor	Estandarizado	Min-max
Transacciones	48	(48 − 64,9) / 23,6 = −0,71	(48 − 10) / (139 − 10) = 0,29
Monto (USD)	3 109	(3 109 − 4 397) / 3 391,7 = −0,38	(3 109 − 530) / (17 995 − 530) = 0,15

Estandarización

La opción habitual; tolera mejor los valores extremos.

Min-max

Fácil de leer (0 a 1); un valor extremo estira todo el rango.

Normalizar cambia los vecinos y el resultado

KNN k = 15	Sin escalar	Estandarizado	Min-max
2 variables · F1	**0,590**	**0,685**	0,682
2 variables · Recall	0,492	0,627	0,623
11 variables · F1	**0,624**	**0,688**	0,675
11 variables · Recall	0,557	0,586	0,574

Vecinos en común

2 de 15

Abandonos entre vecinos

2 frente a 12

Regla: el escalador va dentro del Pipeline: aprende media y desviación (o mínimo y máximo) en Train y las aplica igual a Validation y Test.

Baseline: Accuracy 0,839 y Recall 0. Incluso sin escalar KNN encuentra abandonos, pero se equivoca de vecinos.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Elegir k y la distancia

Configuración	Alertas	VP	FN	FP	Precision	Recall	F1
k = 5	186	153	91	33	0,823	0,627	0,712
k = 15	172	143	101	29	0,831	0,586	0,688
k = 31	156	130	114	26	0,833	0,533	0,650
k = 15, Manhattan	179	152	92	27	0,849	0,623	0,719

k pequeño

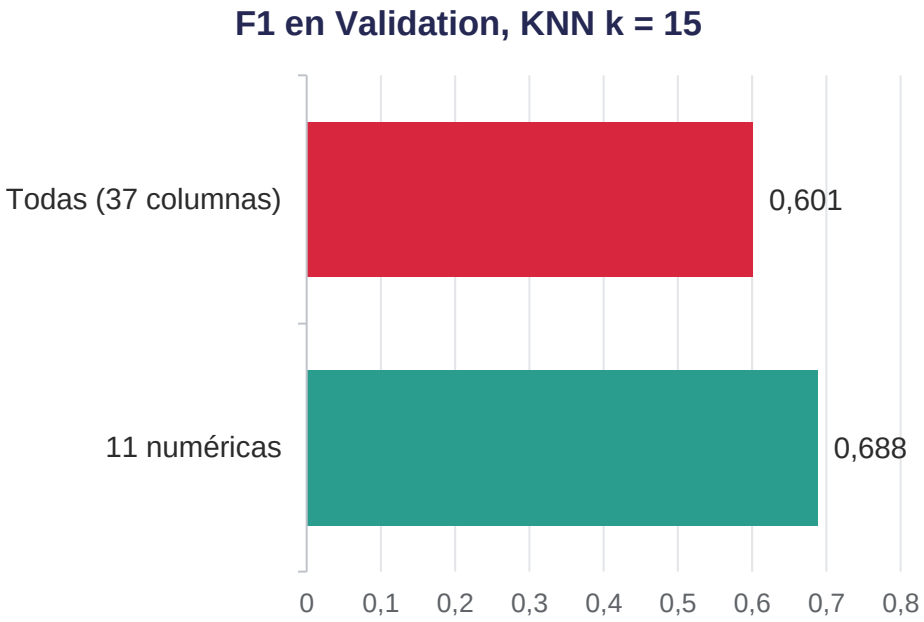
Decide con pocos clientes: más sensible a casos raros.

k grande

Suaviza, pero la clase mayoritaria gana más votos.

De 244 abandonos en Validation, la mejor configuración encontró 152 y emitió solo 27 falsas alarmas.

¿Más columnas siempre ayudan a KNN?



Maldición de la dimensión

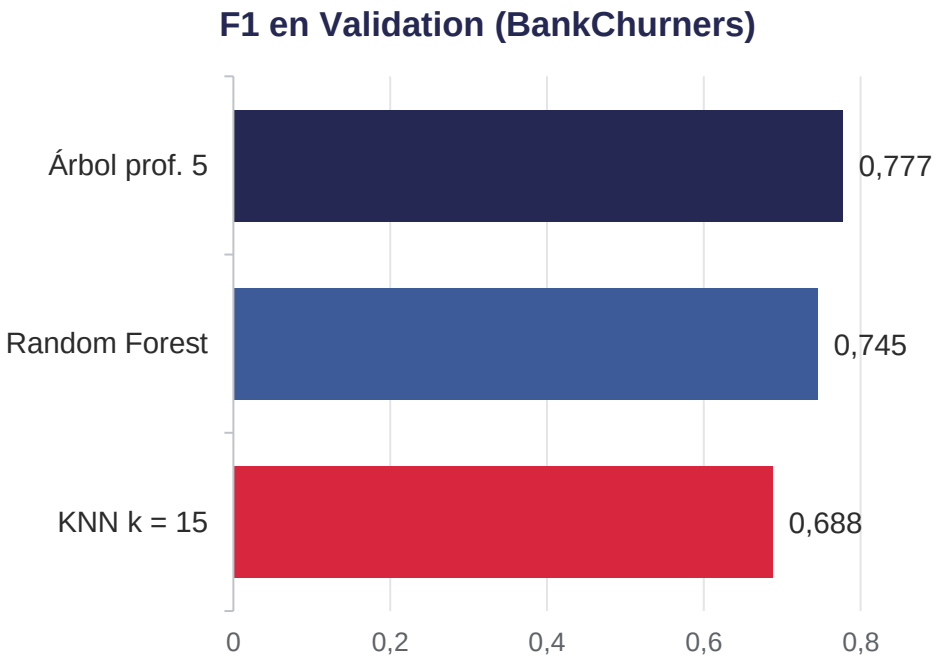
Con muchas columnas, el vecino más cercano deja de ser claramente parecido.

Para KNN

Elegir bien las columnas importa tanto como elegir k.

Recall: 0,586 con 11 numéricas frente a 0,475 con todas las columnas.

¿KNN es el mejor algoritmo para estos clientes?



	Precision	Recall
KNN k = 15	0,831	0,586
Random Forest	0,891	0,639
Árbol	0,768	0,787

Regla de siempre: comparar en las mismas filas antes de elegir un algoritmo.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

7

SVM: una frontera entre préstamos

Credit Risk: separar préstamos pagados de impagos con el mayor margen posible

En esta sección

- Datos
- Margen a mano
- Multa C
- Curvas
- Usos

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Credit Risk: ¿el préstamo caerá en impago?

Variable	Descripción
person_age · person_income	Edad e ingreso anual
person_home_ownership · person_emp_length	Vivienda y antigüedad laboral (años)
loan_intent · loan_grade	Propósito y grado del préstamo (A a G)
loan_amnt · loan_int_rate	Monto y tasa de interés
loan_percent_income	Monto del préstamo / ingreso
cb_person_default_on_file	Impago anterior registrado
cb_person_cred_hist_length	Años de historial crediticio

Préstamos

32 581

Impagos

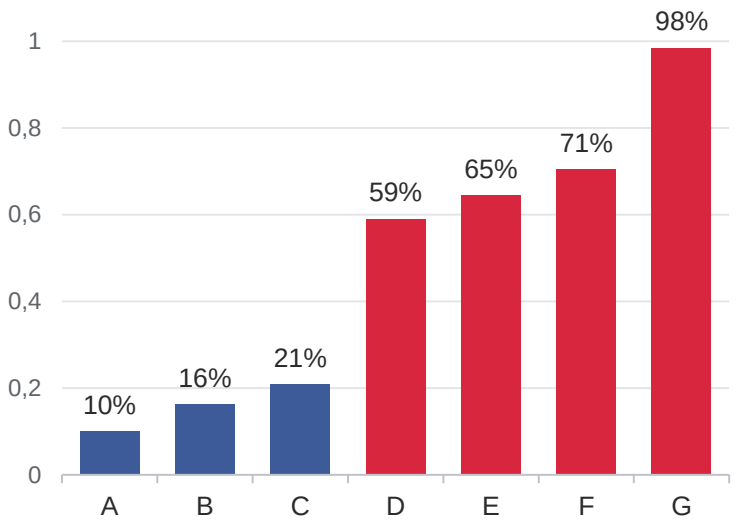
21,8 %

Target: loan_status (0 = sin impago, 1 = impago).

Revisa la licencia en la página de Kaggle antes de usarlo fuera de clase.

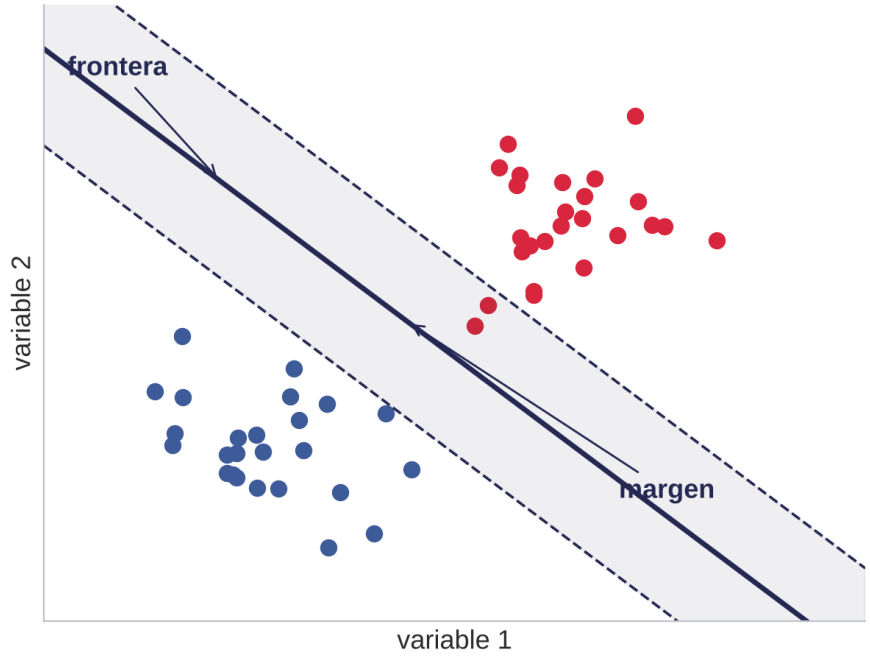
Limpieza mínima y el grado del préstamo

Problema	Filas	Decisión
Edad > 100	5	eliminar
Antigüedad > 60 años	2	eliminar
Duplicados	165	eliminar
Tasa faltante	3 116	mediana de Train
Antigüedad faltante	895	mediana de Train



Grado y tasa son decisiones de la entidad que ya resumen su evaluación del riesgo: se conocen al aprobar (no son fuga), pero explican parte del buen desempeño de cualquier modelo.

La idea de SVM: una frontera con margen



Frontera

la línea (o plano) que decide la clase

Margen

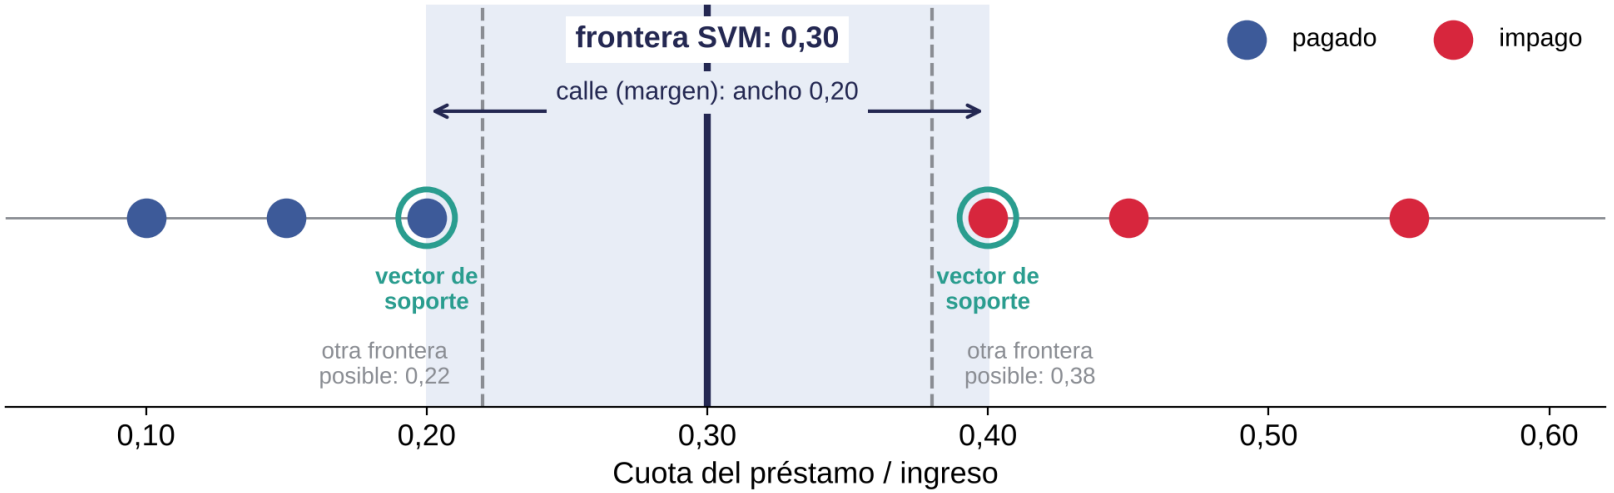
la «calle» vacía a cada lado de la frontera

Vectores de soporte

los puntos que definen dónde va la calle

Frente a KNN: KNN consulta a los vecinos cada vez; SVM aprende la frontera una vez y luego solo mira el lado.

SVM a mano: seis préstamos sobre una recta



Frontera candidata	Distancia al pagado más cercano (0,20)	Distancia al impago más cercano (0,40)	Margen
0,22	0,02	0,18	0,02
0,30 (SVM)	0,10	0,10	**0,10**
0,38	0,18	0,02	0,02

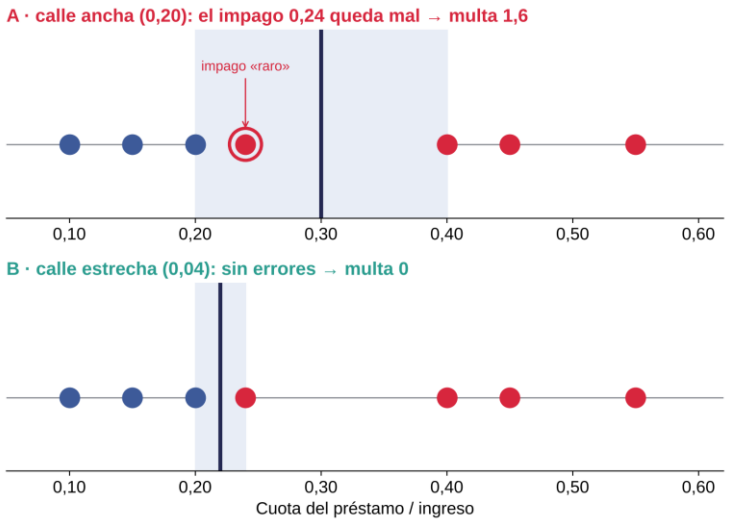
Regla aprendida: cuota / ingreso > 0,30 → impago. Margen = distancia al punto más cercano; SVM busca el mayor.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Qué es la multa C? Un cálculo a mano



	A · ancha	B · estrecha
Ancho de la calle	0,20	0,04
Costo de la calle: 2 / ancho²	50	1 250
Multas (holgura)	1,6	0
C = 1	**51,6 ✓**	1 250
C = 100	**210 ✓**	1 250
C = 1 000	1 650	**1 250 ✓**

Costo total = 2 / ancho² + C × suma de multas

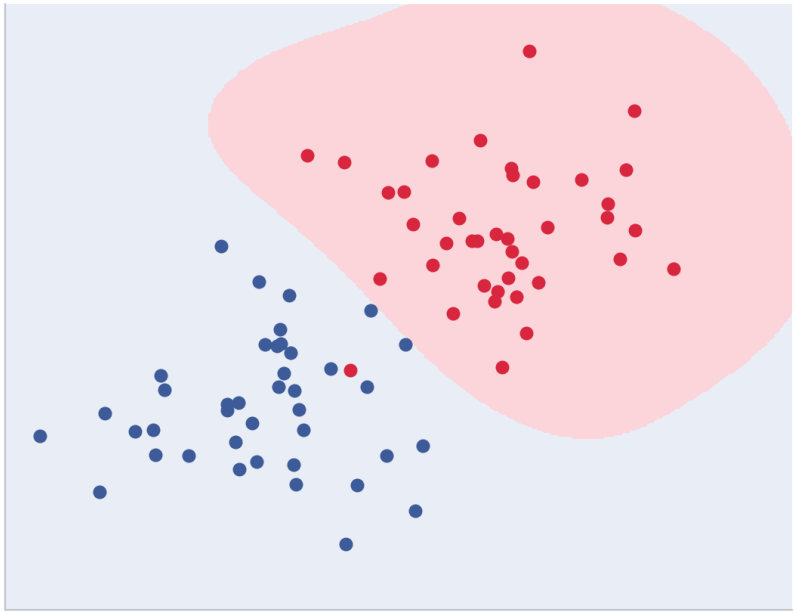
multa de un punto = cuánto invade la calle: 0 si queda fuera, más de 1 si quedó del lado equivocado

C pequeño: las multas son baratas → calle ancha, tolera errores. **C grande:** las multas son caras → calle estrecha, persigue cada punto y puede memorizar.

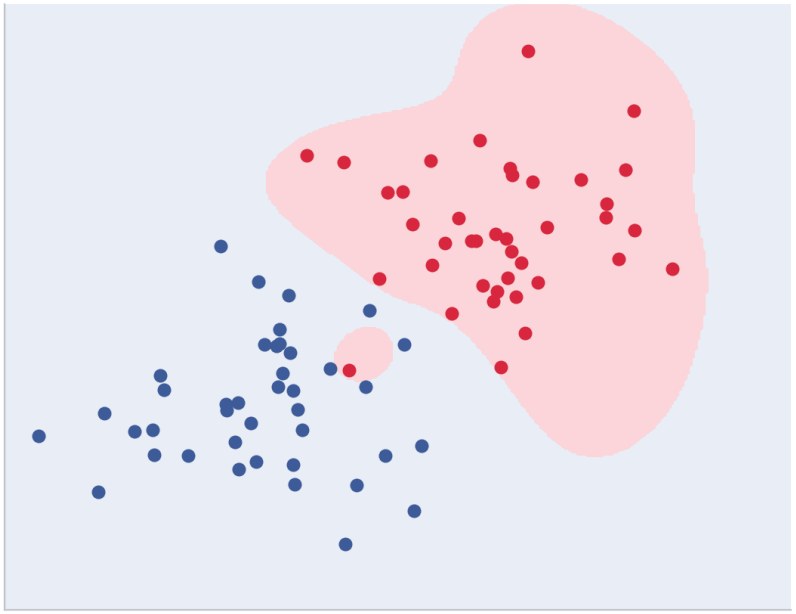
Ejemplo inventado con una variable; con muchas variables el cálculo es el mismo, pero lo hace la computadora.

C: margen ancho o pocos errores

C pequeño: margen ancho, tolera errores

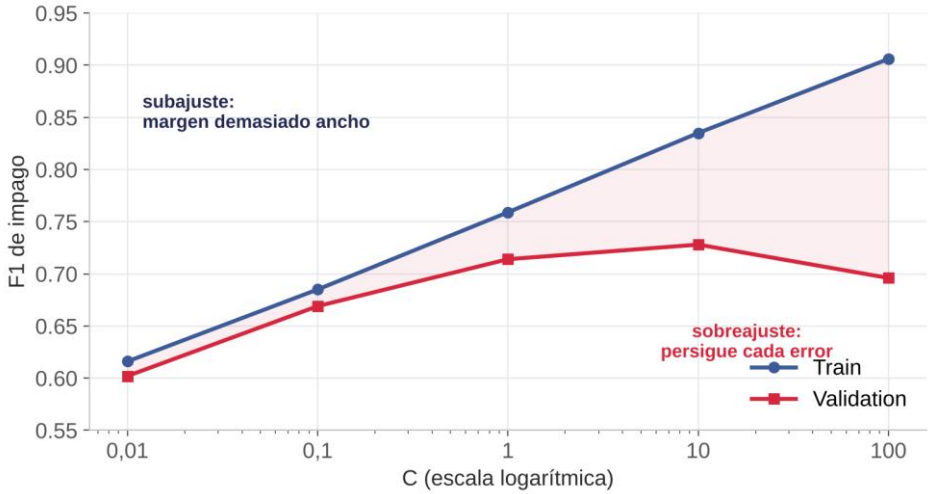


C grande: margen estrecho, persigue cada punto



Ejemplo ilustrativo con puntos inventados: misma nube, dos valores de C. C es un hiperparámetro, como max_depth o k.

Jugar con C: el hiperparámetro más importante de SVM



C	F1 Train	F1 Val.	Vect. soporte
0,01	0,616	0,602	6 192
0,1	0,685	0,669	4 503
1	0,759	0,714	3 698
10	0,835	**0,728**	3 247
100	**0,906**	**0,696**	2 799

C pequeño

multa baja: margen ancho, tolera errores

C intermedio

equilibra margen y errores

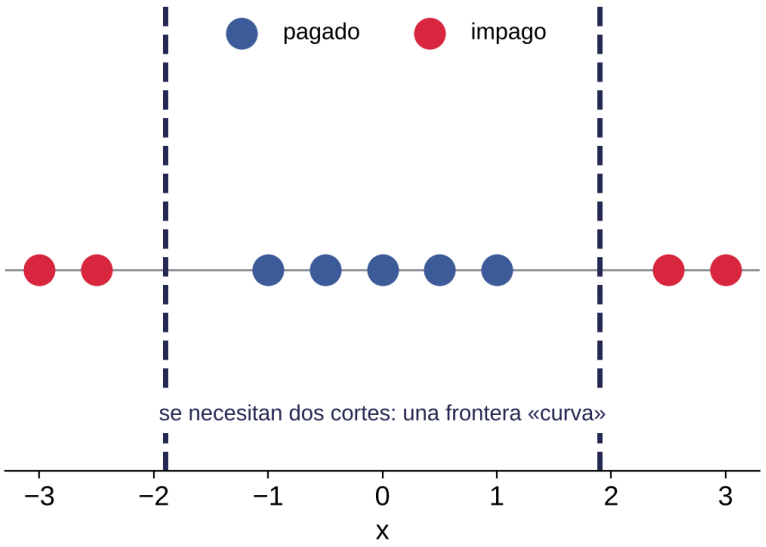
C grande

multa alta: margen estrecho, memoriza

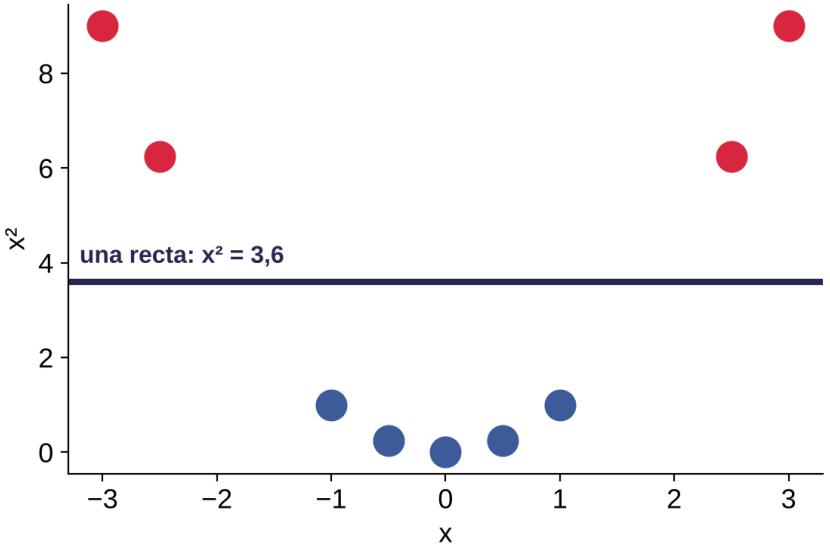
Como max_depth o k: C controla la complejidad y se elige en Validation. Con RBF, gamma actúa junto con C.

¿Cómo se curva la frontera? Un truco a mano

1. Con x sola: un corte no alcanza



2. Agregamos x²: ahora una recta separa



La idea

Agregar x^2 vuelve recta una frontera curva: en x es $|x| > 1{,}9$.

El kernel RBF

Lo hace solo, midiendo parecido entre puntos. gamma = qué tan local es cada punto.

Frontera recta o curva: kernel lineal y RBF



Kernel: una forma matemática de comparar puntos que permite fronteras curvas sin crear columnas nuevas a mano. gamma controla qué tan local es cada punto.

Azul: predice pago · Rojo: predice impago · Puntos: 1 500 préstamos de Train

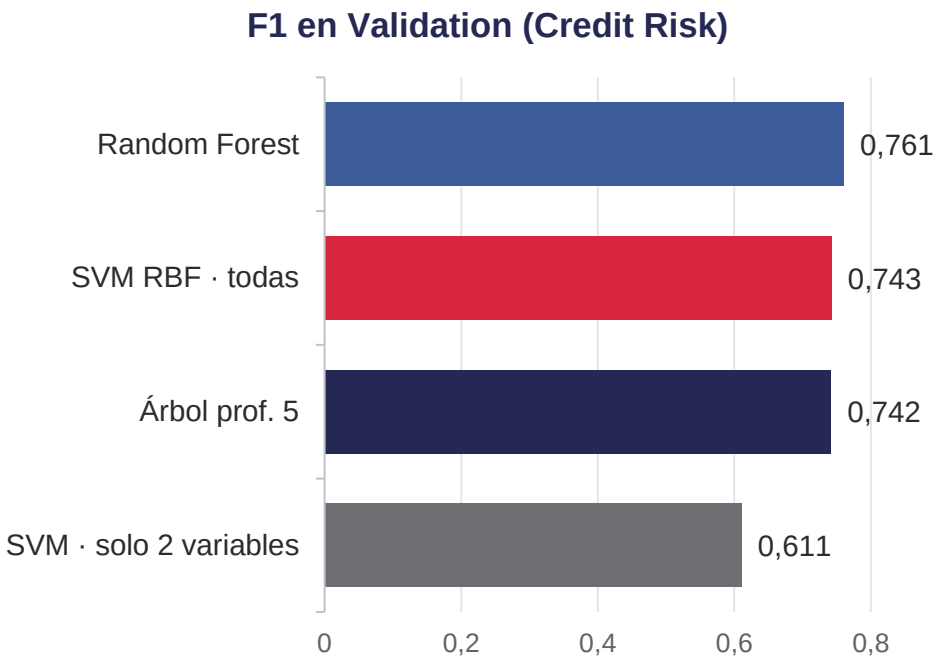
SVM con todas las variables

SVM	Alertas	Precision	Recall	F1 Val.	F1 Train	Vect. soporte
Lineal, C = 1	510	0,559	0,723	0,631	0,648	4 038
RBF, C = 0,5	456	0,656	0,759	0,704	0,736	3 888
RBF, C = 1	438	0,678	0,754	0,714	0,759	3 698
RBF, C = 2	413	0,697	0,731	0,714	0,781	3 539
RBF, C = 1, sin pesos	271	0,911	0,627	0,743	0,785	2 629

Vectores de soporte: miles de los 8 400 préstamos de Train sostienen la frontera: muchos casos quedan cerca del límite.

class_weight: el mismo intercambio que en el árbol: más impagos detectados a cambio de más falsas alarmas.

SVM funciona mucho mejor cuando las clases están bien separadas



Clases mezcladas

con 2 variables: la frontera deja muchos préstamos del lado equivocado

Clases separadas

con todas: la frontera es clara y SVM rinde muy bien

Al leer un notebook público: ¿contra qué baseline se comparó? ¿Con qué otros modelos? ¿Sobre qué filas?

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿En qué otros casos se usa SVM?

Textos

spam, noticias por tema, opiniones positivas o negativas: miles de columnas (palabras)

Imágenes

dígitos en cheques y formularios escaneados

Bioinformática

muchas mediciones (genes) y pocos pacientes

Riesgo y fraude

scoring de crédito y operaciones anómalas con datasets medianos

Documentos

clasificar reclamos o informes regulatorios por su texto

No conviene

millones de filas, explicar con reglas, necesitar probabilidades

Aquí usamos una muestra de 12 000 préstamos porque SVM se vuelve lenta con muchas filas.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

8 Cierre

Tres datasets, una misma forma de evaluar, y Test una sola vez

En esta sección

- Tasas base
- Umbral
- Test
- Qué modelo usar

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Por qué no comparar F1 entre datasets

Dataset	Filas Validation	% positivos	Accuracy del baseline
PaySim (muestra)	15 063	8,5 %	0,915
BankChurners	1 519	16,1 %	0,839
Credit Risk	1 800	21,9 %	0,781

En clasificación desbalanceada, Accuracy sola nunca alcanza: mira Precision, Recall y F1 de la clase que te importa.

Tasa base: con la tasa real de PaySim (0,13 %), aunque el modelo encontrara los mismos fraudes, la gran mayoría de sus alertas serían falsas y la Precision caería.

Mover el umbral: ejemplo a mano

Caso	1	2	3	4	5	6	7	8
Real	0	0	1	1	1	0	1	0
Score	0,10	0,35	0,40	0,55	0,70	0,72	0,88	0,90

Umbral	Alertas	Aciertos	Precision	Recall	F1
0,35	7	4	0,57	1,00	0,73
0,50	5	3	0,60	0,75	0,67
0,75	2	1	0,50	0,25	0,33

Regla: el umbral se decide en Validation y según el costo de cada error; nunca se cambia porque Test salió mal.

Test se abre una sola vez

Dataset	Modelo elegido	F1 Validation	F1 Test	Recall Test
PaySim (muestra)	Árbol (prof. 5, hoja ≥ 30)	0,633	0,647	0,534
BankChurners	KNN k = 15, Manhattan	0,719	0,739	0,639
Credit Risk	SVM RBF, C = 1, sin pesos	0,743	0,739	0,623

Si Test empeora

No se vuelve a elegir: Test se convertiría en otra Validation.

Si Test se parece

La estimación es razonable para estos datos, no para otra población.

Recordatorio: la división es aleatoria; no simula un periodo futuro ni clientes del Ecuador.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Para qué es mejor cada modelo?

Modelo	Fortalezas	Debilidades	Ejemplos en banca y economía
Árbol	Se explica con reglas; no escala; mezcla números y categorías	Inestable; memoriza si no se limita	Reglas de aprobación de crédito, primeras alertas de fraude
Random Forest	Estable y preciso; mide importancia de variables	Menos explicable; más lento	Scoring de riesgo, abandono, fraude con muchas variables
KNN	Intuitivo: casos parecidos; no supone forma de la relación	Obliga a escalar; lento al predecir; sufre con muchas columnas	Clientes similares para ofertas, comparar países o empresas parecidas
SVM	Muchas columnas; clases separadas; frontera curva	Obliga a escalar; lento con muchas filas; difícil de explicar	Clasificar reclamos o documentos por texto, scoring con datasets medianos

Ningún modelo gana siempre: depende de cuántos datos hay, de cómo se separan las clases y de si hay que explicar la decisión.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cómo elegir un modelo: una guía rápida

¿Hay que explicar la decisión?	→	Árbol limitado
¿Importa más acertar, con muchas variables?	→	Random Forest
¿Tiene sentido «casos parecidos» y hay pocas variables?	→	KNN (normalizado)
¿Muchas columnas o clases bien separadas?	→	SVM (normalizado, elegir C)

Siempre: baseline → Validation → métricas de la clase que importa → Test una sola vez.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ideas clave del día

1

Accuracy engaña

El baseline acierta 92 % y no encuentra ningún fraude.

2

Métricas nuevas

VP = dijo fraude y acertó. Precision: alertas. Recall: cobertura.

3

Cuidar las fugas

Los saldos de PaySim y las columnas Naive Bayes contienen la respuesta.

4

Desbalance

Balancear solo Train; class_weight y muestreo suben el Recall.

5

Normalizar

KNN y SVM miden distancias: z = (x − media) / desviación.

6

SVM y C

C pequeño subajusta, C grande memoriza; se elige en Validation.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Del papel al notebook

Lo que hicimos a mano	Lo que verán en el notebook	Debe dar…
Baseline y regla del negocio	DummyClassifier e isFlaggedFraud	Recall 0 y 0,004
Gini de las preguntas candidatas	Tabla de cortes y árbol de prof. 2	0,150 → 0,124
Matriz del árbol completo	confusion_matrix y métricas a mano	13 619 · 161 · 615 · 668
Desbalance	4 estrategias con el mismo árbol	Recall 0,52 → 0,81
Fuga en BankChurners	Regla con la columna Naive Bayes	Accuracy 1,0
Normalizar	Vecinos sin escalar y estandarizados	2 de 15 en común
El hiperparámetro C	SVM RBF con C = 0,01 a 100	mejor C = 10: F1 0,728

Su rol con el agente de IA

Pidan que explique cada línea y verifiquen los números. Si un resultado no coincide con lo calculado a mano, pregunten por qué.