ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación



Día 4 — Clustering: segmentar clientes de tarjeta

Módulo 3: Machine Learning Aplicado

Jonathan Rosero Soto

Edificio Aulas y Relación con el Medio Externo, Av. Toledo N23-55 y Madrid
Telf.: +593 2 2525766 - Ext: 102 / 125 / 143 / 120 / 127 - www.cec-epn.edu.ec

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ruta de la jornada

1	**Supervisado y no supervisado**	Aprender con la respuesta o descubrir sin ella
2	**¿Qué es clustering?**	Grupos de filas parecidas; K-Means y jerárquico
3	**Conocer y preparar los datos**	8 950 clientes de tarjeta: limpieza, logaritmo y escala
4	**K-Means**	Qué es, paso a paso, hiperparámetros y límites
5	**Elegir k y describir grupos**	Codo, Silhouette, tamaños y perfiles
6	**Validar y clustering jerárquico**	Línea base, dendrograma y linkage
7	**Cierre**	Cómo defender un clustering en el proyecto final

Regla del día: *un algoritmo siempre entrega grupos; nuestro trabajo es demostrar que sirven.*

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

1

Supervisado y no supervisado

Las dos grandes familias del Machine Learning: aprender con la respuesta o descubrir sin ella

En esta sección

- Dos formas
- Supervisado
- No supervisado
- Practiquemos

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Dos formas de aprender de los datos

Supervisado

estudiar con ejercicios resueltos

Cada fila trae la respuesta (y).

El modelo aprende la relación entre X e y.

Luego predice y para filas nuevas.

No supervisado

ordenar fotos sin etiquetas

Las filas no traen respuesta.

El algoritmo busca estructura: grupos, patrones.

Nosotros interpretamos lo que encontró.

Días 1 a 3
regresión y clasificación

Hoy (Día 4)
clustering

La pregunta clave: ¿mis datos traen la respuesta que quiero obtener? Si sí, es supervisado; si no, no supervisado.

Supervisado: aprender con la respuesta

Monto	Tipo	Hora	¿Fraude? (y)
8 000	TRANSFER	3	sí
50	PAYMENT	14	no
5 000	TRANSFER	2	sí
100	CASH_OUT	11	no

Modelo
aprende la relación entre X e y

Predice y
para transacciones nuevas

Regresión

y es un número: monto, crecimiento

Clasificación

y es una clase: fraude, abandono, impago

Se evalúa

comparando con la respuesta real: MAE, F1

Lo esencial: hay una respuesta correcta conocida, así que se puede medir el error sin discusión.

No supervisado: descubrir sin respuesta

Saldo	Compras	Avances	Límite
1 865	1 271	159	5 950
84	908	0	4 000
1 528	0	1 272	3 000
127	282	0	1 800

sin columna y: nadie dice a qué grupo pertenece cada cliente

Algoritmo
busca filas parecidas

Grupos
que nosotros interpretamos

Clustering (hoy)

agrupar filas parecidas

Reducir dimensiones

resumir muchas variables en pocas (PCA, Día 5)

Detectar casos raros

filas que no se parecen a ninguna otra

Lo esencial: no hay respuesta correcta; se evalúa coherencia, estabilidad y utilidad.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Supervisado y no supervisado, lado a lado

	Supervisado	No supervisado
¿Los datos traen y?	Sí	**No**
¿Qué aprende?	A predecir y a partir de X	Estructura: grupos o patrones
Tareas	Regresión, clasificación	Clustering, reducción de dimensiones, casos raros
Algoritmos del módulo	Lineal, árboles, bosque, KNN, SVM	K-Means, jerárquico, PCA
Cómo se evalúa	Error frente a la respuesta real (MAE, F1)	Silhouette, estabilidad e interpretación
Riesgo típico	Memorizar Train (sobreajuste)	Grupos sin significado: siempre entrega grupos
Ejemplo bancario	¿Este cliente abandonará la tarjeta?	¿Qué tipos de clientes tenemos?

Cuidado: KNN (supervisado, Día 3) y K-Means (no supervisado, hoy) se parecen en el nombre y en que usan distancias, pero resuelven problemas distintos.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Supervisado o no supervisado? Practiquemos

Estimar el monto de crédito que pedirá un cliente, con historial de montos

→ **Supervisado · regresión**

Detectar fraude con transacciones ya marcadas como fraude o normal

→ **Supervisado · clasificación**

Agrupar provincias según sus indicadores económicos

→ **No supervisado · clustering**

Segmentar clientes de tarjeta sin ninguna etiqueta

→ **No supervisado · clustering**

Predecir si un cliente abandonará, con datos de quienes ya se fueron

→ **Supervisado · clasificación**

Encontrar transacciones raras cuando nadie sabe cuáles son fraude

→ **No supervisado · casos raros**

Truco: busca la columna que quieres obtener. Si existe en los datos históricos, es supervisado.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

2

¿Qué es clustering?

No hay variable objetivo: buscamos grupos de filas que se parecen

En esta sección

- Sin colores
- Tres tipos
- Usos
- Vocabulario
- Dos familias

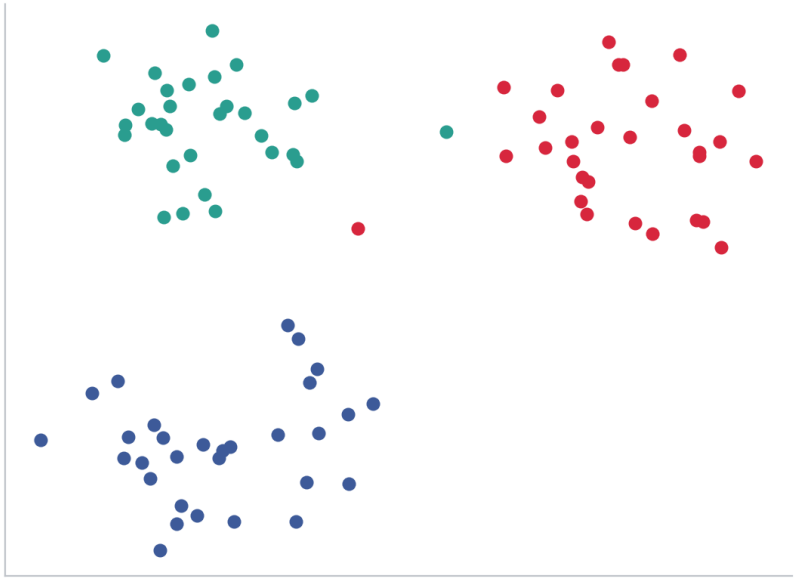
ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Clasificación frente a clustering

Clasificación: ya conocemos la clase (color)



Clustering: no hay colores; hay que descubrir grupos



Clasificación

Los colores (clases) vienen en los datos.

Clustering

Los colores los propone el algoritmo.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Regresión, clasificación y clustering

	Regresión	Clasificación	Clustering
¿Hay variable objetivo?	Sí, un número	Sí, una clase	**No**
Pregunta	¿Cuánto?	¿Cuál clase?	¿Qué grupos de filas parecidas hay?
Cómo se evalúa	MAE, RMSE, R^2	Matriz de confusión, F1	Silhouette, tamaños e interpretación
Línea base	Predecir el promedio	La clase más frecuente	Una segmentación simple
Ejemplo bancario	Monto que transará un cliente	¿Abandonará la tarjeta?	Perfiles de uso de la tarjeta
Algoritmos	Lineal, árbol, bosque, KNN, SVR	Árbol, bosque, KNN, SVM	K-Means, jerárquico

Pista: si nadie puede decirte cuál es la respuesta correcta de cada fila, el problema es de clustering.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Para qué sirve agrupar en un banco?

Segmentar clientes

productos y campañas para cada perfil de uso

Perfiles de riesgo

clientes con patrones de pago parecidos

Economías parecidas

países, provincias o sectores con indicadores similares

Casos raros

filas que no se parecen a ningún grupo

Hoy: segmentar 8 950 clientes de tarjeta de crédito según cómo usan la tarjeta.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Vocabulario del día

Cluster

un grupo propuesto por el algoritmo

Centroide

el punto promedio de un grupo

Distancia

qué tan diferentes son dos filas

Inercia

suma de distancias² de cada fila a su centroide

Silhouette

¿cada fila está más cerca de su grupo que del vecino?

Perfil

cómo es un grupo, en unidades originales

Advertencia central: un algoritmo de clustering siempre entrega grupos, aunque los datos no tengan grupos reales.

Dos familias de clustering: por centros y jerárquico

K-Means: grupos alrededor de centros

- Se elige k antes de empezar.
- Ubica k centros (promedios).
- Cada fila va al centro más cercano.
- Rápido: sirve para millones de filas.

resultado: k grupos y sus centros

Jerárquico: un árbol de uniones

- Cada fila empieza sola.
- Une, paso a paso, los grupos más parecidos.
- El árbol (dendrograma) muestra todas las uniones.
- k se elige al cortar el árbol.

resultado: un dendrograma

Lo común: ambos miden distancias entre filas; por eso limpiar, transformar y escalar es igual de importante en los dos.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

3

Conocer y preparar los datos

Credit Card Dataset for Clustering: 8 950 clientes y 6 meses de comportamiento

En esta sección

- El dataset
- Limpieza
- Logaritmo
- Escala

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

El dataset: 8 950 clientes de tarjeta de crédito

Variable	Qué mide
BALANCE	saldo adeudado
PURCHASES	compras totales en 6 meses
ONEOFF / INSTALLMENTS_PURCHASES	compras de un solo pago / en cuotas
CASH_ADVANCE	avances en efectivo con la tarjeta
PURCHASES_FREQUENCY	qué tan seguido compra (0 a 1)
CREDIT_LIMIT	límite de crédito
PAYMENTS	total pagado
PRC_FULL_PAYMENT	% de meses en que pagó el total

Clientes
8 950

Variables
17 + ID

Etiqueta de grupo
ninguna

Una fila = un cliente. Usaremos 9 de las 17 variables: las que describen cómo se usa la tarjeta.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Limpieza: decisiones declaradas

Problema	Filas afectadas	Decisión	Por qué
CUST_ID	todas	fuera	es un identificador
CREDIT_LIMIT faltante	1	eliminar la fila	es un solo cliente
MINIMUM_PAYMENTS faltante	313	imputar la mediana	eliminar perdería el 3,5 %
Variables que repiten información	—	elegir 9 de 17	frecuencia y número de compras miden casi lo mismo

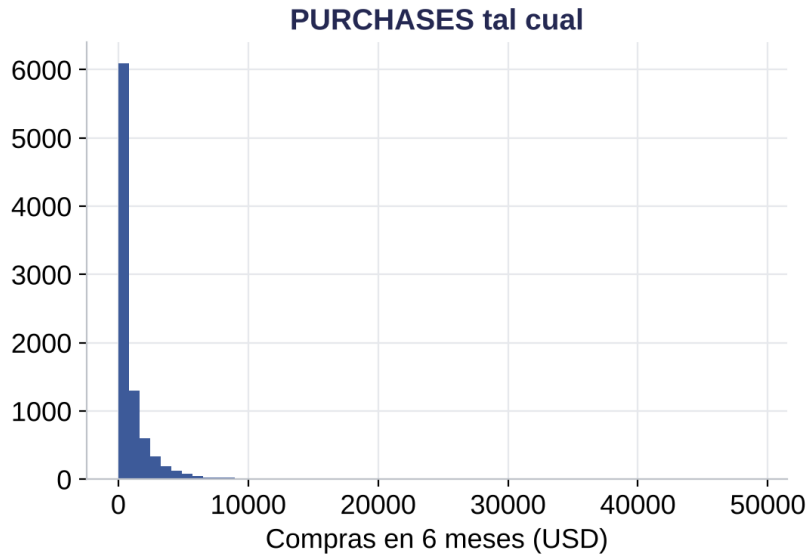
Clientes después de limpiar

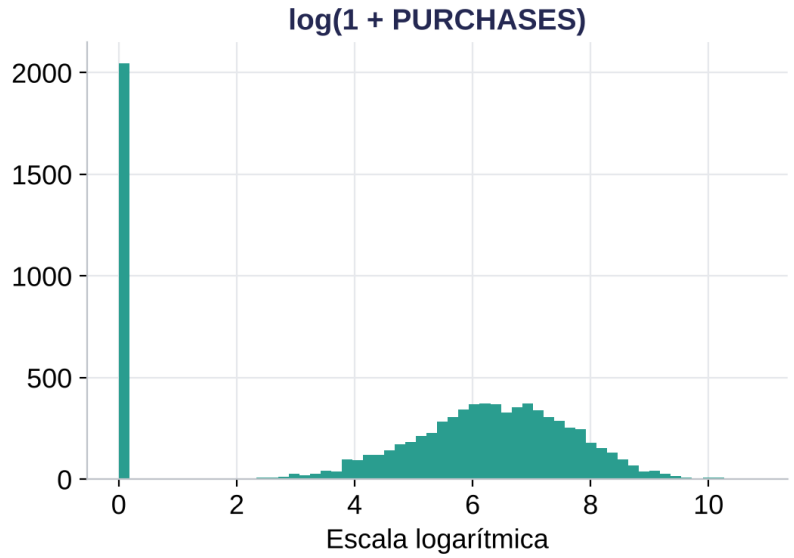
8 949

Igual en el proyecto final:

problema, filas afectadas, decisión y motivo

Montos muy asimétricos: el logaritmo





Compras: promedio / mediana	Clientes sin compras	Clientes sin avances
1 003 / 361	**22,8 %**	**51,7 %**

log(1 + x): pasar de 100 a 1 000 USD pesa parecido a pasar de 1 000 a 10 000: importa la proporción.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Escalar antes de medir distancias

	Cliente A	Cliente B	Diferencia cruda	En desviaciones
Compras (USD)	1 000	1 100	100	0,05
Límite de crédito (USD)	3 000	9 000	**6 000**	1,65
Frecuencia de compras	0,9	0,1	0,8	**1,99**

Sin escalar

El límite domina: A y B parecen distintos solo por el límite.

Estandarizado: z = (x − media) / desv.

Cada variable aporta en su propia escala; la frecuencia vuelve a contar.

Orden de preparación: 1) limpiar faltantes · 2) log a los montos · 3) estandarizar las 9 variables.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

4 K-Means

Qué es, cómo funciona paso a paso, sus hiperparámetros y sus límites

En esta sección

- Qué es
- Una variable
- Paso a paso
- Hiperparámetros
- Límites

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Qué es K-Means?

K-Means: divide los datos en k grupos; cada grupo es un centro (promedio) y cada fila va al centro más cercano.

K

número de grupos (lo elegimos)

Means

medias: los centros son promedios

Entrega

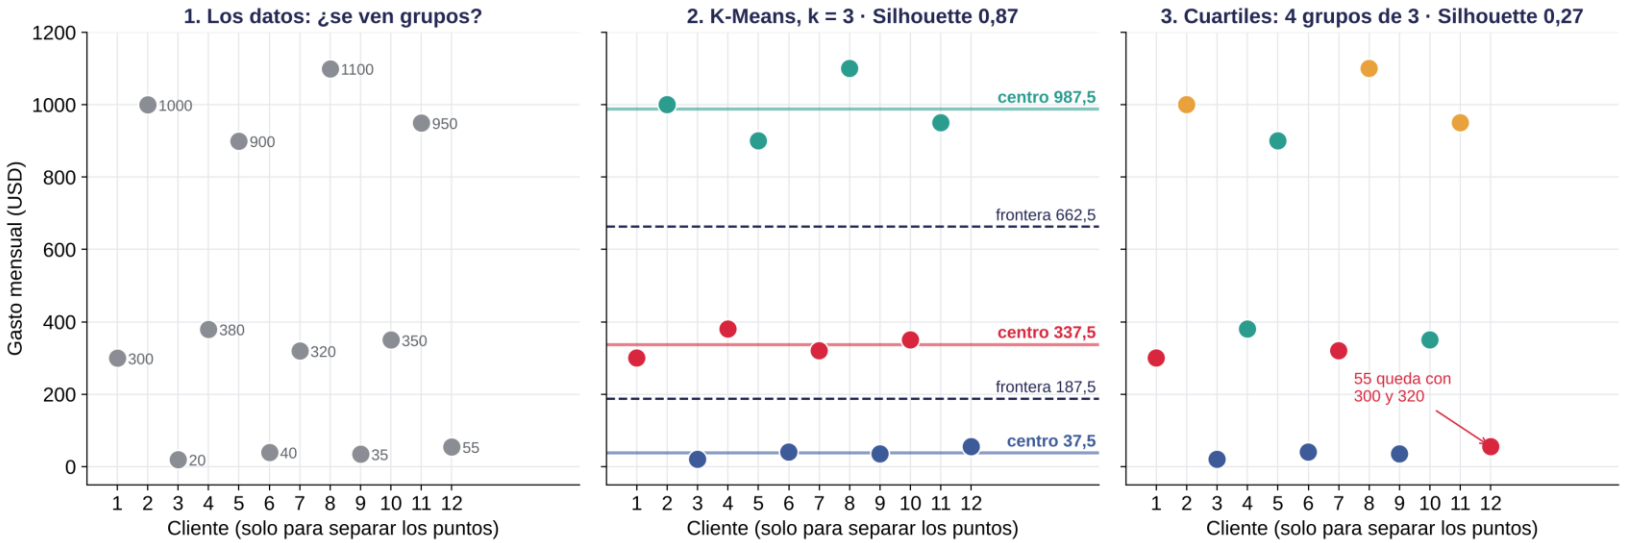
una etiqueta de grupo por fila y k centroides

Analogía: abrir k agencias

1. Ubicar k agencias en la ciudad.
2. Cada cliente va a la más cercana.
3. Mover cada agencia al centro de sus clientes.
4. Repetir hasta que ya no convenga moverlas.

Qué busca: grupos compactos, es decir, la menor inercia: la suma de distancias² de cada fila a su centro.

Ejemplo visual: 12 clientes, una sola variable



Grupo	Clientes (USD)	Centro = promedio
1	20 · 35 · 40 · 55	37,5
2	300 · 320 · 350 · 380	337,5
3	900 · 950 · 1 000 · 1 100	987,5

Fronteras

(37,5 + 337,5) / 2 = 187,5

(337,5 + 987,5) / 2 = 662,5

cliente nuevo de 500 → grupo 2

K-Means sigue los huecos de los datos (Silhouette 0,87); los cuartiles cortan por cantidad de clientes, no por parecido (0,27).

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cuartiles frente a K-Means, punto por punto

Cliente que gasta 55	K-Means	Cuartiles
Su grupo	20 · 35 · 40	300 · 320
a = distancia media a su grupo	(35 + 20 + 15) / 3 = 23,3	(245 + 265) / 2 = 255
b = distancia media al grupo vecino	a 300–380: 282,5	a 20–40: 23,3
s = (b − a) / máx(a, b)	**0,92**	**−0,91**

Clientes con Silhouette negativo · K-Means

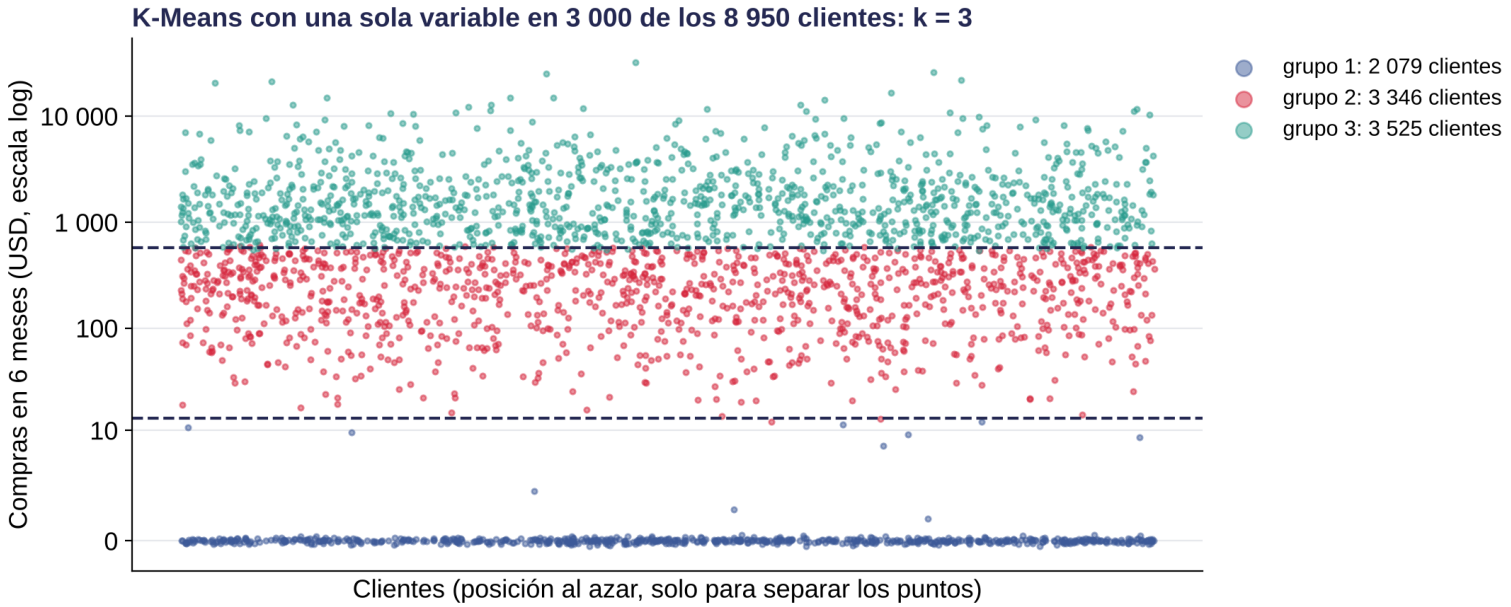
0 de 12

Clientes con Silhouette negativo · cuartiles

4 de 12

Por eso los cuartiles son una línea base: agrupan sin mirar el parecido. Si K-Means no les gana, no aporta nada.

Lo mismo con los 8 950 clientes: solo compras



Grupo 1 · no compran	Grupo 2 · 13 a 574 USD	Grupo 3 · más de 574 USD
2 079	**3 346**	**3 525**

Una variable ayuda a ver; nueve ayudan a entender: con más variables ya no se puede dibujar, pero la idea es la misma.

K-Means paso a paso: centros que se mueven

0. Elegir k
y ubicar k centros iniciales

→

1. Asignar
cada punto al centro más cercano

→

2. Actualizar
cada centro al promedio de sus puntos

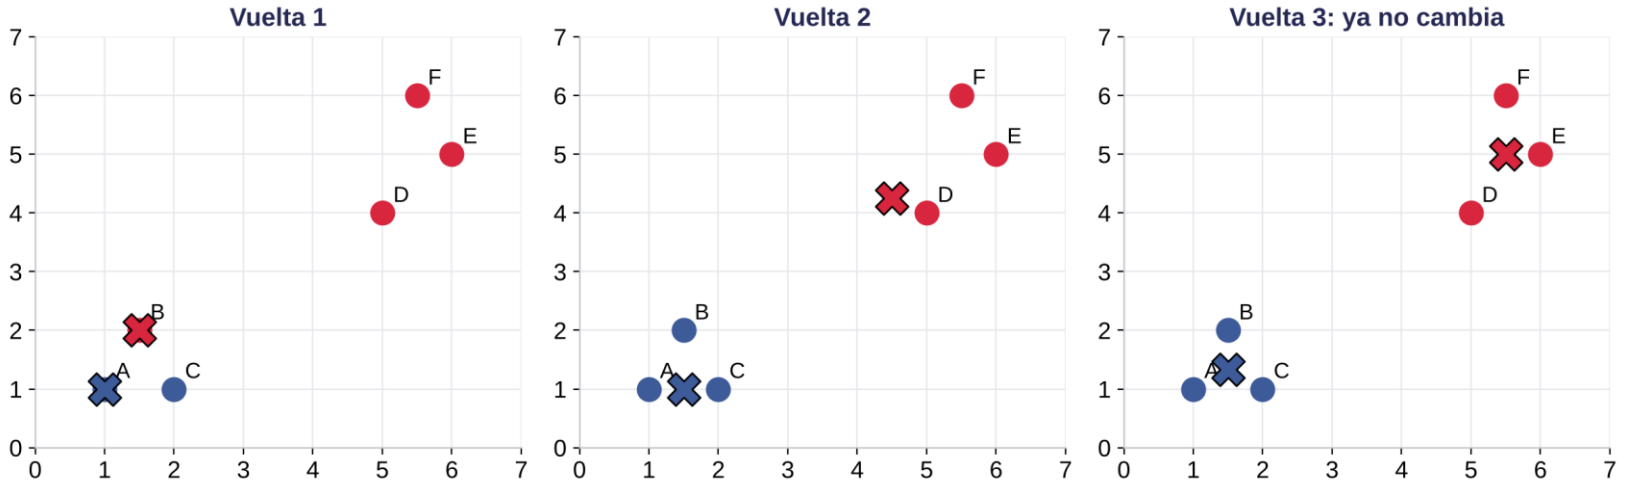
→

3. Repetir
hasta que nada cambie

Inercia = Σ distancia² de cada punto a su centroide · K-Means intenta hacerla lo más pequeña posible

«Means» = medias: los centros son promedios. Por eso los valores extremos los arrastran y conviene el logaritmo.

K-Means a mano: seis puntos, dos grupos



	Centro azul	Centro rojo	Grupo azul	Grupo rojo
Vuelta 1	A (1; 1)	B (1,5; 2)	A, C	B, D, E, F
Vuelta 2	(1,5; 1)	(4,5; 4,25)	A, B, C	D, E, F
Vuelta 3	(1,5; 1,33)	(5,5; 5)	A, B, C	D, E, F ✓

Lección: el punto de partida importa. Por eso K-Means se repite desde varios inicios.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

La primera vuelta con números

Punto	Coordenadas	Distancia al azul (1; 1)	Distancia al rojo (1,5; 2)	Va al
A	(1; 1)	0,00	1,12	**azul**
B	(1,5; 2)	1,12	0,00	**rojo**
C	(2; 1)	1,00	1,12	**azul**
D	(5; 4)	5,00	4,03	**rojo**
E	(6; 5)	6,40	5,41	**rojo**
F	(5,5; 6)	6,73	5,66	**rojo**

Nuevo centro azul

promedio de A y C = ((1 + 2) / 2; (1 + 1) / 2) = (1,5; 1)

Nuevo centro rojo

promedio de B, D, E y F = (4,5; 4,25)

Distancia euclidiana: de C a A = $\sqrt{((2 - 1)^2 + (1 - 1)^2)}$ = 1,00. La misma del KNN del Día 3.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Los hiperparámetros de K-Means

n_clusters (k) hoy: **4**

Número de grupos

Se elige con codo, Silhouette e interpretación

n_init hoy: **20**

Inicios distintos

Evita quedarse con un mal punto de partida

random_state hoy: **42**

Semilla del sorteo

Resultados repetibles

Preparación hoy: **9, log, z**

Variables y transformación

Cambia los grupos tanto como k

Para el proyecto final: comparar al menos tres configuraciones (por ejemplo, varios k, con y sin logaritmo).

n_init: no confiar en un solo punto de partida

Semilla	0	1	2	3	4	5
Inercia con n_init = 1	41 171	**41 825**	41 172	**41 825**	**41 825**	**41 825**
ARI frente a la referencia	1,00	0,51	0,98	0,50	0,50	0,50
Inercia con n_init = 20	41 171	41 172	41 171	41 172	41 171	41 171

Un solo inicio

4 de 6 veces cae en una solución peor: los grupos cambian según la suerte.

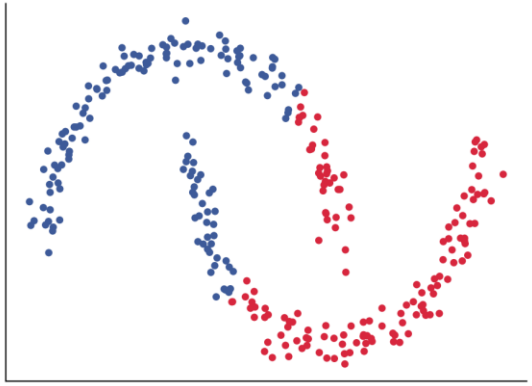
Veinte inicios

Siempre la misma solución: el resultado es estable y repetible.

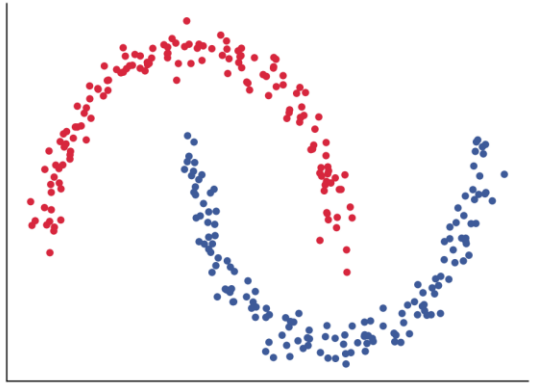
ARI (Adjusted Rand Index): 1 = mismos grupos, 0 = parecido al azar. Sirve para medir estabilidad.

Qué hace bien K-Means y dónde falla

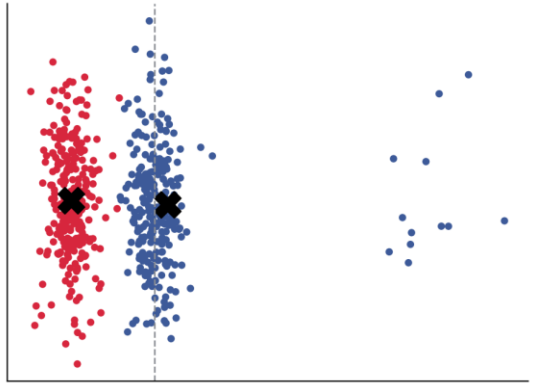
K-Means con grupos curvos: corta las lunas por la mitad



Jerárquico (single) sigue la forma: una luna por grupo



12 valores extremos arrastran el centro azul de 3,0 a 3,5



Fortalezas

Rápido, simple, escala a millones de filas; centros fáciles de leer como perfiles.

Limitaciones

Hay que elegir k; sensible a escala, inicio y extremos; supone grupos redondos; solo numéricas.

Por eso hoy: logaritmo para los extremos, escalado para las unidades y n_init alto para el punto de partida.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

5

Elegir k y describir los grupos

Codo, Silhouette, tamaños y, sobre todo, perfiles que se puedan explicar

En esta sección

- **Codo**
- **Silhouette**
- **Una trampa**
- **Perfiles**

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Silhouette a mano

s = (b − a) / máx(a, b)

a = distancia media a su grupo · b = distancia media al grupo vecino



Punto 3	Cálculo
a (su grupo: 1 y 2)	(2 + 1) / 2 = 1,5
b (grupo B: 8 y 9)	(5 + 6) / 2 = 5,5
s	**(5,5 − 1,5) / 5,5 = 0,73**

≈ 1 bien separado

≈ 0 en la frontera

< 0 grupo equivocado

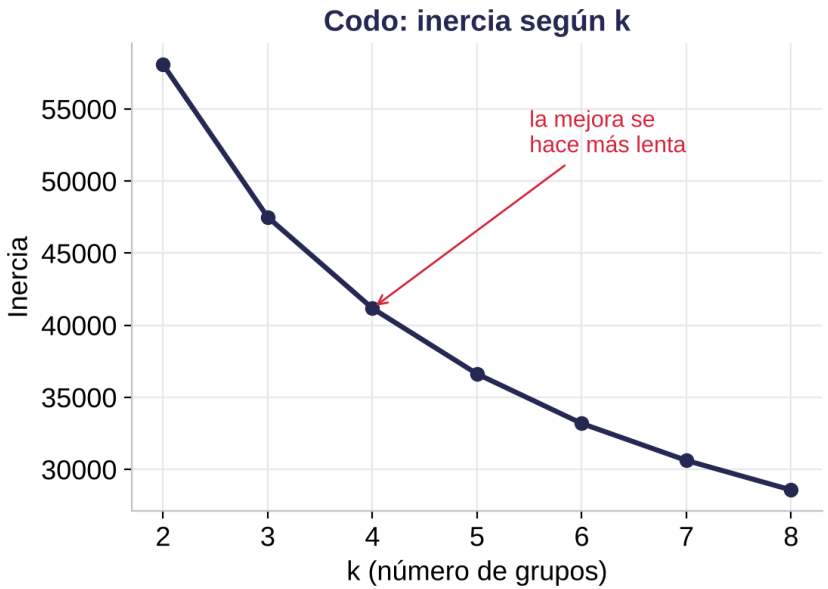
Silhouette no es Accuracy: no hay respuestas correctas; solo mide separación geométrica.

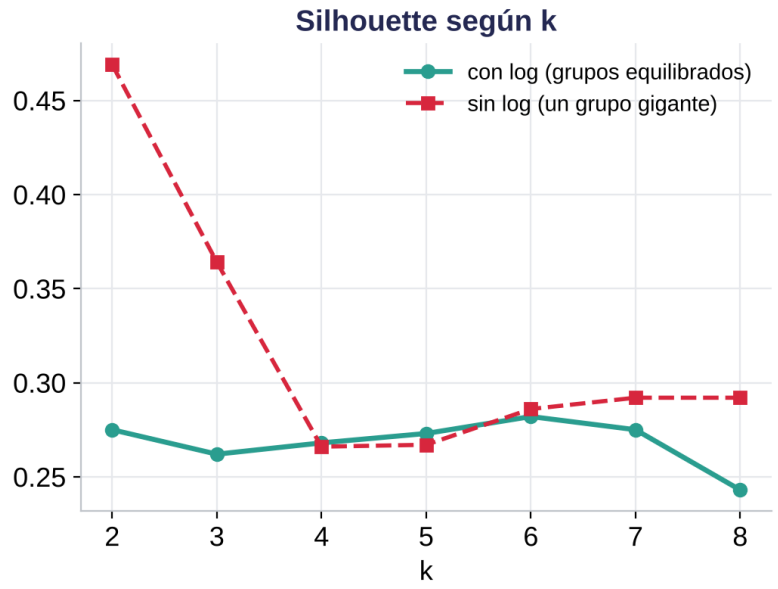
ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Codo y Silhouette con los clientes





Codo

La inercia baja mucho hasta k = 4; después, cada grupo extra aporta menos.

Silhouette con log

Entre 0,26 y 0,28: ningún k separa claramente mejor.

La trampa: el Silhouette más alto no es el mejor

Sin log, k = 2 (medianas)	Grupo grande	Grupo pequeño
Clientes	7 699	1 250
Saldo (USD)	661	4 227
Compras (USD)	297	2 544
Límite (USD)	3 000	9 450
Pagos (USD)	692	3 923

Silhouette sin log, k = 2

0,47

Silhouette con log, k = 4

0,27

Lo mismo que en clasificación: un número alto (Accuracy, Silhouette) puede esconder un resultado inútil. Siempre mira los tamaños.

Recuerda: el clustering siempre entrega grupos; aquí entregó «grandes contra el resto».

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Nuestra decisión: k = 4, con argumentos

1. Codo

la inercia empieza a mejorar poco desde k = 4

2. Silhouette

0,27, similar al resto: no penaliza

3. Tamaños

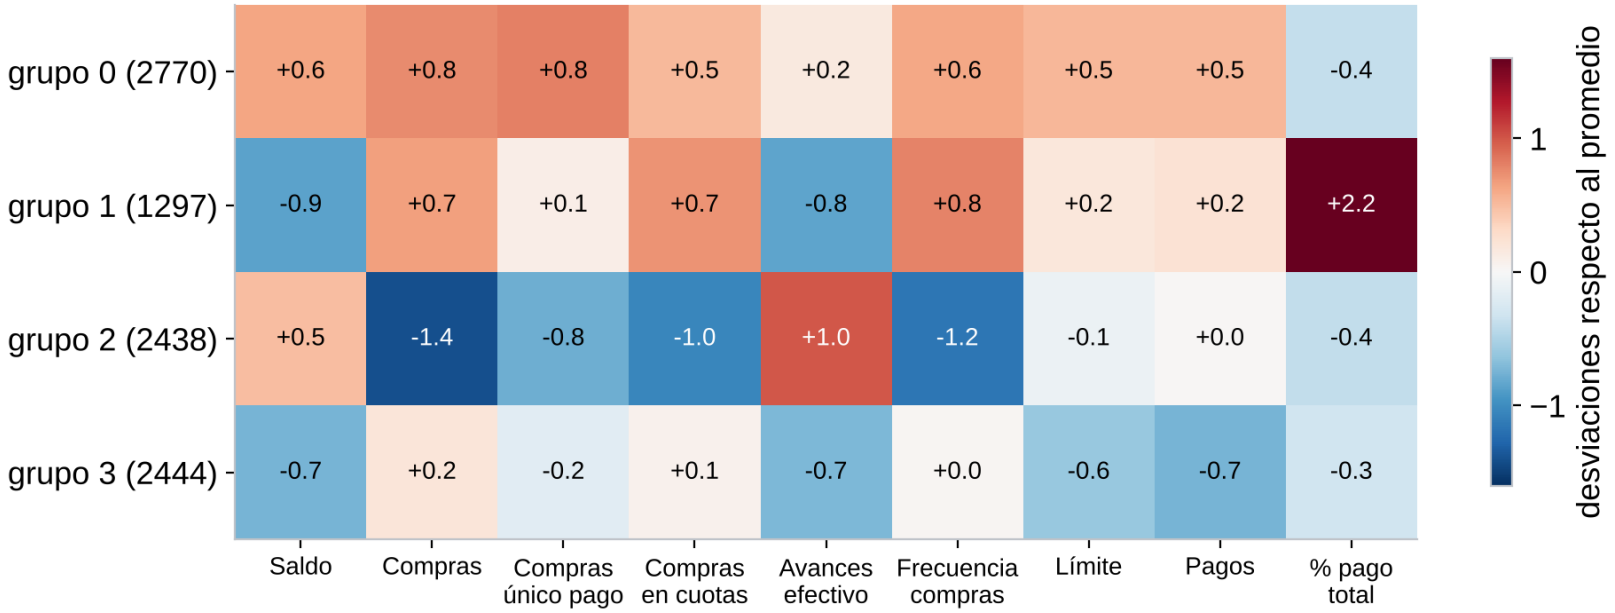
entre 1 297 y 2 770 clientes por grupo

4. Interpretación

cuatro perfiles claros y con acciones posibles

Válido también: «no encontré una separación convincente». Mejor eso que inventar grupos.

Del número al perfil: el mapa de calor



Cómo leerlo: recorre cada fila y busca sus colores más intensos; eso es lo que distingue al segmento.

Los números 0 a 3 son nombres arbitrarios: el segmento 3 no es «peor» que el 0.

Cuatro segmentos con nombre

Compradores que financian — 2 770

Saldo 1 865 · compras 1 271 · límite 5 950 · paga el total casi nunca

Totaleros — 1 297

Saldo 84 · compra el 92 % de los meses · paga el total el 83 % de los meses

Usuarios de avances en efectivo — 2 438

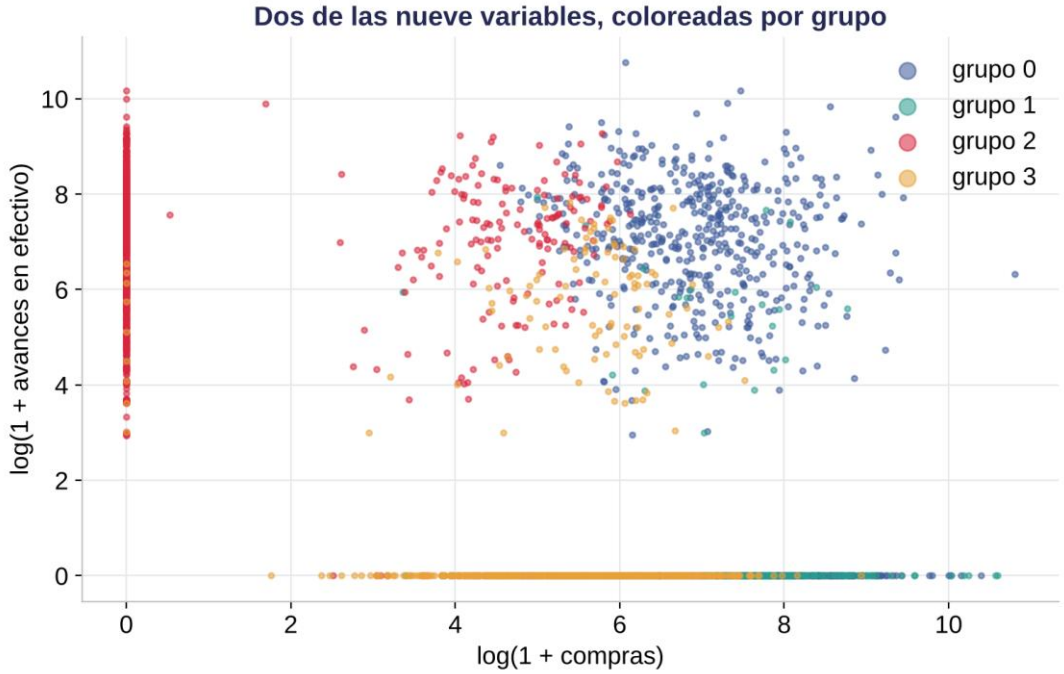
82 % sin compras · 99 % usa avances (mediana 1 272) · saldo 1 528

Poco activos — 2 444

Saldo 127 · compras 282 · pagos 338 · límite 1 800

Medianas, no promedios: con montos asimétricos la mediana describe mejor al cliente típico de cada segmento.

Dos de las nueve variables, por segmento



Columna en compras = 0

usuarios de avances (grupo 2)

Franja en avances = 0

totaleros y poco activos (1 y 3)

Nube central

compradores que financian (0)

Una vista 2D no es todo el modelo: grupos que se mezclan aquí pueden separarse en las otras siete variables.

De los segmentos a las decisiones

Segmento	Idea de acción	Antes de actuar, revisar…
Compradores que financian	Ofertas de cuotas; vigilar endeudamiento	mora e ingresos
Totaleros	Programas de recompensas	rentabilidad del cliente
Usuarios de avances	Ofrecer un crédito más barato; revisar riesgo	historial de pagos y mora
Poco activos	Campañas de activación	si tienen otra tarjeta principal

Lo que el clustering NO dice: por qué un cliente se comporta así, ni que el grupo sea permanente. Con otras variables saldrían otros grupos.

Siguiente paso real: validar cada segmento con el área de negocio y con datos que no se usaron para agrupar.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

6

Validar y clustering jerárquico

Comparar con una línea base, con otras configuraciones y con otro método

En esta sección

- Línea base
- Qué es el jerárquico
- A mano
- Dendrograma
- Linkage

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Línea base y configuraciones

Configuración	Silhouette	Grupo más chico	Grupo más grande	¿Útil?
Línea base: cuartiles de compras	0,135	2 237	2 238	referencia
K-Means con log, k = 3	0,262	2 736	3 443	sí
K-Means con log, k = 4	**0,268**	1 297	2 770	**elegida**
K-Means con log, k = 5	0,273	1 154	2 148	sí
K-Means con log, k = 6	0,282	365	2 067	un grupo pequeño
K-Means sin log, k = 2	**0,469**	1 250	7 699	**no: grandes contra el resto**

Así se ve la tabla del proyecto final: línea base, al menos tres configuraciones y una justificación que no se quede en la métrica.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Qué es el clustering jerárquico?

Jerárquico: construye un árbol de uniones; los grupos se eligen al cortar el árbol a cierta altura.

Aglomerativo (el que usaremos)

De abajo hacia arriba: cada fila empieza sola y se van uniendo las más parecidas.

Divisivo

De arriba hacia abajo: todo empieza junto y se va partiendo. Es menos común.

Sin k al inicio
se decide al cortar

Se ve el proceso
el dendrograma muestra cada unión

Lento con muchos datos
compara todos los pares

Analogía: un árbol genealógico al revés: primero se juntan los hermanos, luego los primos, luego las familias.

Jerárquico a mano: la matriz de distancias

	A = 1	B = 2	C = 6	D = 7	E = 15
A	—	**1**	5	6	14
B		—	4	5	13
C			—	**1**	9
D				—	8

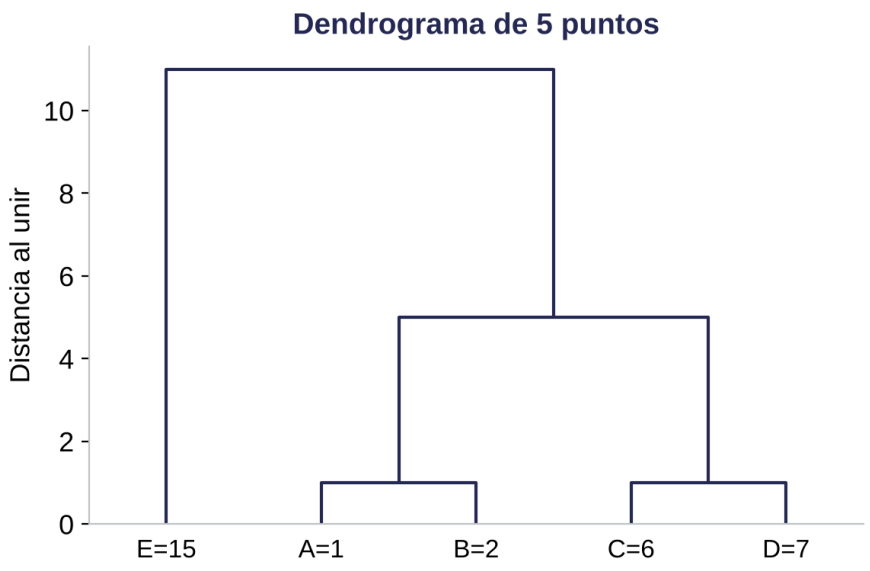
Paso	Distancia menor	Se unen	Nuevo centro
1	1 (A-B)	A y B	1,5
2	1 (C-D)	C y D	6,5
3	6,5 − 1,5 = 5	{A, B} y {C, D}	4
4	15 − 4 = 11	{A, B, C, D} y E	—

Matriz inicial: distancia entre cada par de puntos

Regla de cada paso: buscar la menor distancia de la tabla, unir esos dos grupos, recalcular las distancias del grupo nuevo y repetir.

Aquí medimos entre grupos por sus centros. Esa elección se llama linkage; Ward, complete, average y single son otras formas.

Leer y cortar un dendrograma



Cortar a altura…	Grupos	Cuáles
0,5	5	cada punto solo
3	3	{A, B} · {C, D} · {E}
8	2	{A, B, C, D} · {E}
12	1	todos juntos

Buen corte:
justo antes de un salto grande de altura

La altura = qué tan distintos eran los grupos al unirse. Uniones bajas: grupos parecidos. Uniones altas: grupos muy distintos.

No es el árbol de decisión del Día 3: aquí las ramas son uniones de puntos, no preguntas para predecir.

Reglas de unión: el linkage

Ward

la unión que menos aumenta la variación interna

Complete

distancia entre los puntos más lejanos

Average

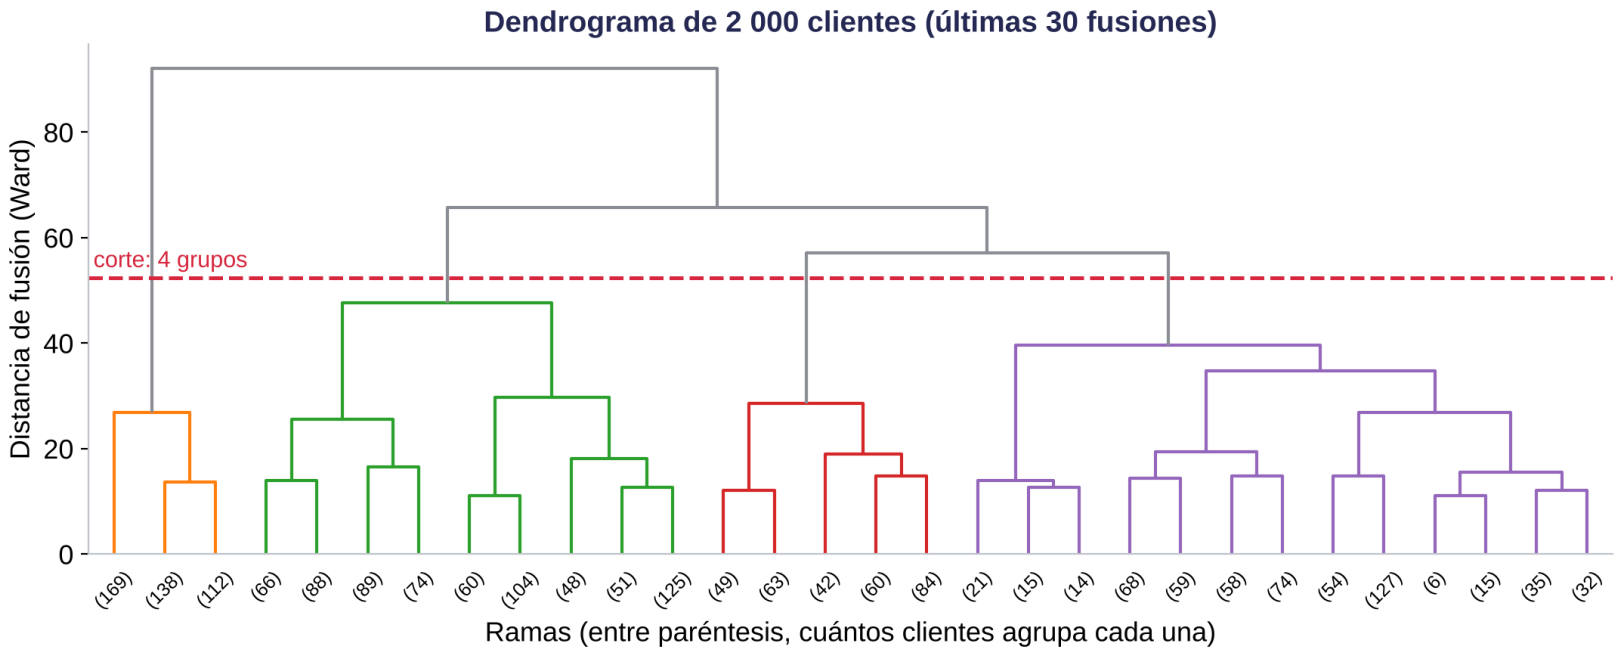
promedio de todas las distancias

Single

distancia entre los puntos más cercanos

Hoy usamos Ward porque, como K-Means, busca grupos compactos. Las otras reglas sirven para otros problemas, como detectar casos aislados.

Dendrograma de 2 000 clientes



Lectura: uniones bajas = grupos parecidos; un salto grande en la altura sugiere un buen lugar para cortar.

La altura no es una probabilidad ni una prueba estadística: es la distancia de fusión de Ward.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ward, complete, average y single: el mismo engaño

Linkage	Tamaños de los 4 grupos	Silhouette	ARI frente a K-Means
Ward	705 · 578 · 419 · 298	0,233	**0,53**
Complete	928 · 588 · 434 · 50	0,182	0,28
Average	**1 942 · 51 · 6 · 1**	**0,248**	0,00
Single	**1 997 · 1 · 1 · 1**	0,224	0,00

K-Means

Muchos datos; grupos compactos; hay que fijar k antes.

Jerárquico

Cientos o pocos miles de filas; permite ver las uniones antes de elegir k.

Igual que con k = 2 sin log: un Silhouette alto con un grupo gigante no es una buena segmentación.

K-Means o jerárquico: ¿cuándo usar cada uno?

	K-Means	Jerárquico (aglomerativo)
¿Cómo agrupa?	Alrededor de k centros	Uniendo los grupos más cercanos
¿Cuándo se elige k?	Antes de empezar	Después, al cortar el árbol
Tamaño de datos	Millones de filas	Cientos o pocos miles
¿Mismo resultado siempre?	Depende del inicio (usar n_init)	Sí, es determinista
Forma de los grupos	Redondos y de tamaño parecido	Depende del linkage
Qué entrega	Grupos y centros	Dendrograma y grupos al cortar
Ejemplo	Segmentar 8 950 clientes	Agrupar 24 provincias o 30 países

Hoy: K-Means para los 8 950 clientes; jerárquico en una muestra de 2 000 para comparar.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

7

Cierre

Cómo defender un clustering y llevarlo al proyecto final

En esta sección

- **Checklist**
- **Proyecto final**
- **Ideas clave**

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cómo defender un clustering

1 Pregunta

¿para qué quiero los grupos?

2 Preparación

variables, faltantes, log, escala

3 Elegir k

codo, Silhouette, tamaños, sentido

4 Comparar

línea base y otras configuraciones

5 Estabilidad

n_init alto, otras semillas

6 Perfiles

unidades originales y nombres

7 Limitaciones

no prueban causas

Resultado

grupos que se pueden explicar y usar

Válido: concluir que no hay grupos claros. Lo inválido es esconderlo detrás de un número.

Clustering en el proyecto final

Lo que vimos hoy	En su proyecto
Tabla de limpieza con decisiones	Sección 2 del informe
Logaritmo y escala, con su motivo	Secciones 2 y 4
Línea base: cuartiles de una variable	Obligatoria: por ejemplo, cuartiles o Channel (Wholesale)
Tabla de configuraciones con Silhouette y tamaños	Sección 5: al menos tres configuraciones
Perfiles en medianas y nombres	Secciones 6 y 7: elección y conclusiones

Recuerden: no gana el Silhouette más alto; gana el grupo mejor explicado y mejor justificado.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ideas clave del día

1

Sin respuesta

Clustering no tiene y: propone grupos según nuestras variables.

2

Preparar

Faltantes, logaritmo en montos asimétricos y escalado antes de medir distancias.

3

K-Means

Asignar al centro más cercano y promediar; usar n_init alto.

4

Elegir k

Codo, Silhouette, tamaños e interpretación, juntos.

5

La trampa

Un Silhouette alto con un grupo gigante no sirve.

6

Perfiles

Medianas en unidades originales, nombres y acciones; no prueban causas.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Del papel al notebook

Lo que hicimos a mano	Lo que verán en el notebook	Debe dar…
Escalar dos clientes	Diferencias en desviaciones	0,05 · 1,65 · 1,99
K-Means con seis puntos	Tres vueltas impresas	centros (1,5; 1,33) y (5,5; 5)
n_init con seis semillas	Tabla de inercias y ARI	41 171 frente a 41 825
Silhouette del punto 3	silhouette_samples	0,73
Codo y Silhouette	Tabla con y sin log, k = 2 a 8	0,469 sin log; 0,27 con log
Cuatro segmentos	Medianas y mapa de calor	2 770 · 1 297 · 2 438 · 2 444
Línea base y linkage	Dos tablas de comparación	0,135 · Ward ARI 0,53

Su rol con el agente de IA

Pidan que explique cada línea y verifiquen los números. Si un resultado no coincide con lo calculado a mano, pregunten por qué.