ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Día 5 — PCA, selección e ingeniería de variables



Módulo 3: Machine Learning Aplicado

Jonathan Rosero Soto

Edificio Aulas y Relación con el Medio Externo, Av. Toledo N23-55 y Madrid
Telf.: +593 2 2525766 - Ext: 102 / 125 / 143 / 120 / 127 - www.cec-epn.edu.ec

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ruta de la jornada

1	**Más variables no siempre es mejor**	Información repetida, columnas que estorban y la que falta
2	**PCA a mano**	Cinco pasos con seis clientes
3	**PCA con 8 949 clientes de tarjeta**	Varianza, cargas, mapa y la trampa del Silhouette
4	**Selección de variables**	Filtro, envoltura y embebido; ¿cuántas dejar?
5	**Ingeniería de características**	Crear columnas con sentido económico
6	**Comparación final y cierre**	Qué preparación gana en cada dataset

Regla del día: *antes de cambiar de modelo, revisa las variables que le das.*

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

1

Más variables no siempre es mejor

Tres problemas de las variables y tres herramientas para resolverlos

En esta sección

- **Tres problemas**
- **Tres herramientas**
- **Maldición de la dimensión**

Tres problemas con las variables

Información repetida

Compras totales y compras de un pago: correlación 0,92. Dicen casi lo mismo.

Columnas que estorban

Sexo, educación o tipo de tarjeta casi no se relacionan con el abandono, pero KNN las cuenta igual.

Información escondida

El gasto promedio por compra no viene en los datos: hay que calcularlo (monto ÷ n.º de compras).

Solución

PCA: resumir

Selección: quitar

Ingeniería: crear

Hoy: trabajamos sobre las columnas, no sobre el algoritmo.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Tres herramientas, tres preguntas

	PCA	Selección	Ingeniería
Pregunta	¿Puedo resumir muchas variables en pocas?	¿Cuáles ayudan a predecir?	¿Qué variable falta?
¿Mira la respuesta y?	**No**	**Sí**	No necesariamente
Entrega	Componentes: mezclas de todas	Un subconjunto de las originales	Columnas nuevas hechas por nosotros
Se interpreta…	Con las cargas	Directamente	Directamente
Típico en	Clustering y visualización	Modelos de distancia (KNN, SVM)	Cualquier modelo
Ejemplo de hoy	17 variables de tarjeta → 2 ejes	37 columnas → 4 o 5	Gasto promedio por compra

No son sinónimos: PCA crea columnas que nadie eligió; la selección conserva columnas que sí entendemos.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

La maldición de la dimensionalidad

Solo la columna que importa

Transacciones: A y B difieren 1,5 desviaciones.

distancia = 1,5

100 % viene de lo que importa

+ 20 columnas irrelevantes de 0/1

A y B difieren en 8 de ellas.

distancia = $\sqrt{(1{,}5^2 + 8)} \approx 3{,}2$

78 % viene de lo que NO importa

KNN con las 37 columnas de BankChurners

F1 = 0,24

KNN con 5 columnas bien elegidas

F1 = 0,75

Con muchas columnas, todos los clientes quedan «igual de lejos» y los vecinos dejan de significar algo.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

2

PCA a mano

Encontrar la dirección en la que los datos más se estiran

En esta sección

- La idea
- Covarianza
- Direcciones
- Coordenadas
- Reconstruir

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

La idea de PCA: la sombra que más dice

1.er componente (PC1)

La dirección en la que los datos más varían.

2.º componente (PC2)

Perpendicular a PC1: la que más varía de lo que queda.

Coordenada

Dónde cae cada cliente sobre esa dirección: su nuevo valor.

Varianza explicada

Qué parte del total de la variación recoge cada componente.

Analogía: una buena foto de perfil no muestra todo, pero casi todo lo importante en dos dimensiones.

Lo esencial: PCA no usa ninguna respuesta y; solo mira cómo varían las variables.

Paso 0: estandarizar, siempre

Variable	Varianza	Peso en PC1 sin escalar
N.º de compras	609,9	**0,99**
Avances (log)	12,7	0,03
Compras de un pago (log)	10,5	0,06
Compras (log)	8,5	0,06
Frecuencia de compras	≈ 0,1	≈ 0

Con estandarización

z = (x − media) / desviación

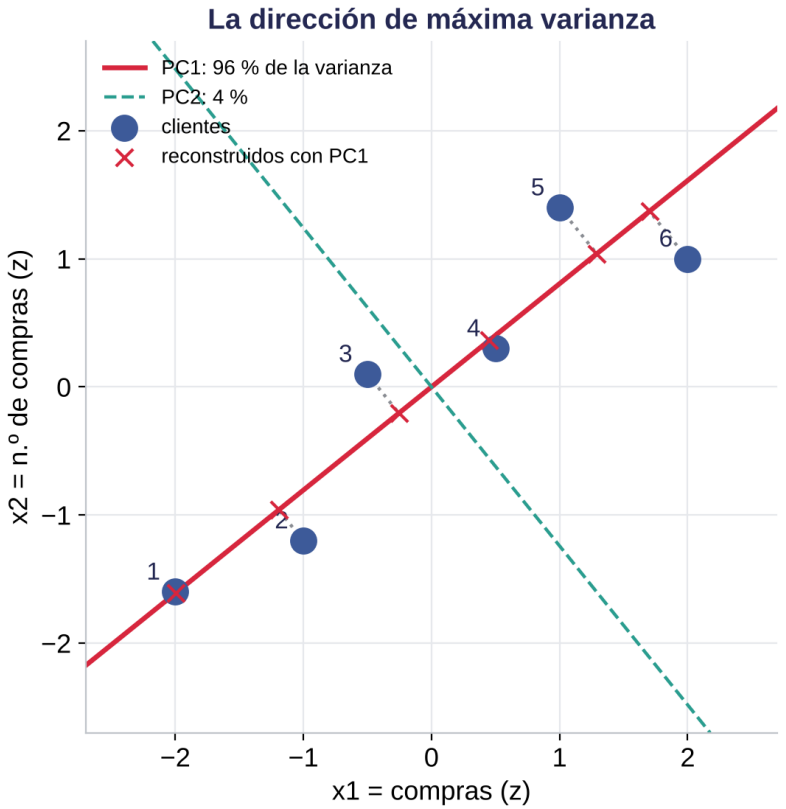
todas las variables: varianza 1

PC1 mezcla compras, frecuencias y avances

Regla: estandarizar antes de PCA, igual que antes de KNN o K-Means. Y aprender medias y desviaciones solo con Train.

Seis clientes, dos variables

Cliente	x1 (compras)	x2 (n.º compras)
1	−2,0	−1,6
2	−1,0	−1,2
3	−0,5	0,1
4	0,5	0,3
5	1,0	1,4
6	2,0	1,0
Media	**0**	**0**



Lo que vemos: una nube alargada. Un solo eje diagonal la describe casi por completo.

Paso 1: la matriz de covarianzas

Varianza de x1

(4 + 1 + 0,25 + 0,25 + 1 + 4) / 5 = 2,10

Covarianza x1·x2

(3,2 + 1,2 − 0,05 + 0,15 + 1,4 + 2,0) / 5 = 1,58

Varianza de x2

(2,56 + 1,44 + 0,01 + 0,09 + 1,96 + 1) / 5 = 1,41

	x1	x2
x1	2,10	1,58
x2	1,58	1,41

azul: varianzas · rojo: covarianza

Lectura: covarianza positiva y grande = las dos variables se mueven juntas: hay información repetida.

Paso 2 y 3: direcciones y varianza explicada

	Dirección (x1, x2)	Varianza	Varianza explicada
PC1	(0,78; 0,63)	3,37	**96 %**
PC2	(−0,63; 0,78)	0,14	4 %
Total		3,51	100 %

Varianza total = 2,10 + 1,41 = 3,51
PCA no la cambia: la reparte entre componentes.

96 % en una sola dirección
las dos variables casi son una: «nivel de compra».

Nota: el signo de una dirección es arbitrario. (0,78; 0,63) y (−0,78; −0,63) son la misma recta.

Paso 4: la nueva coordenada de cada cliente

Cliente	x1	x2	PC1 = 0,78·x1 + 0,63·x2
1	−2,0	−1,6	**−2,56**
2	−1,0	−1,2	−1,53
3	−0,5	0,1	−0,33
4	0,5	0,3	0,58
5	1,0	1,4	1,66
6	2,0	1,0	**2,18**

Cliente 1, a mano

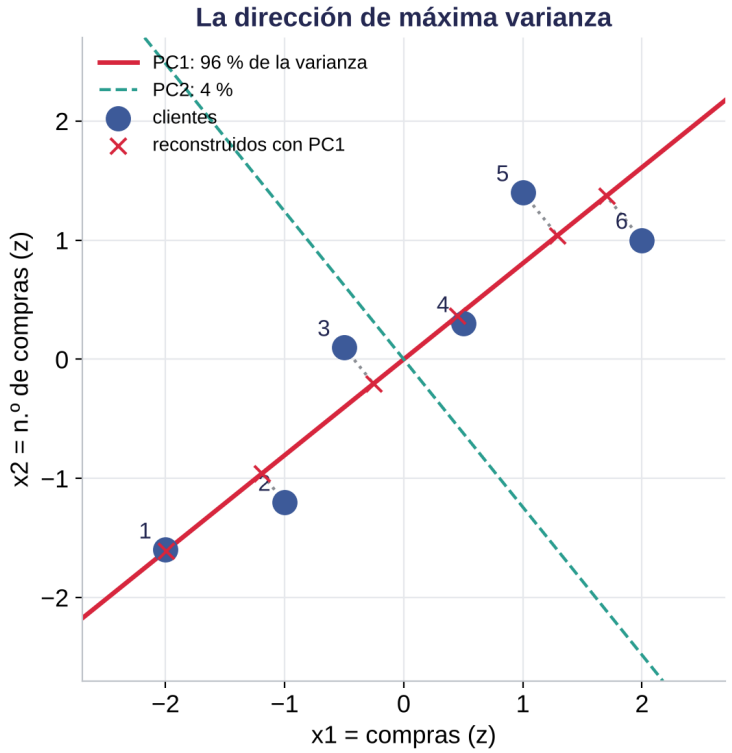
(−2,0)·0,78 + (−1,6)·0,63

= −1,56 − 1,00

= −2,56

De 2 columnas a 1: la coordenada PC1 ordena a los clientes de menos a más compra.

Paso 5: reconstruir y medir lo que se pierde



Reconstruir

$\hat{x}$ = coordenada × dirección

cliente 1: (−2,0; −1,6) → (−2,0; −1,6)

Error con 1 componente

0,06

Error sin componentes: 1,46

decir «todos son el promedio»

Métrica de PCA: error de reconstrucción bajo con pocos componentes.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

PCA a mano: los cinco pasos

1	**Estandarizar**	Todas las variables con media 0 y varianza 1, con las medias de Train.
2	**Covarianzas**	Cuánto varía cada variable y cuánto varían juntas.
3	**Direcciones**	Las direcciones de máxima varianza y cuánta varianza tiene cada una.
4	**Coordenadas**	Nuevo valor de cada cliente: suma ponderada de sus variables.
5	**Reconstruir**	Volver a las variables originales y medir el error.

En el notebook: los cinco pasos a mano con numpy y luego PCA(n_components=2) de scikit-learn: dan lo mismo.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

3

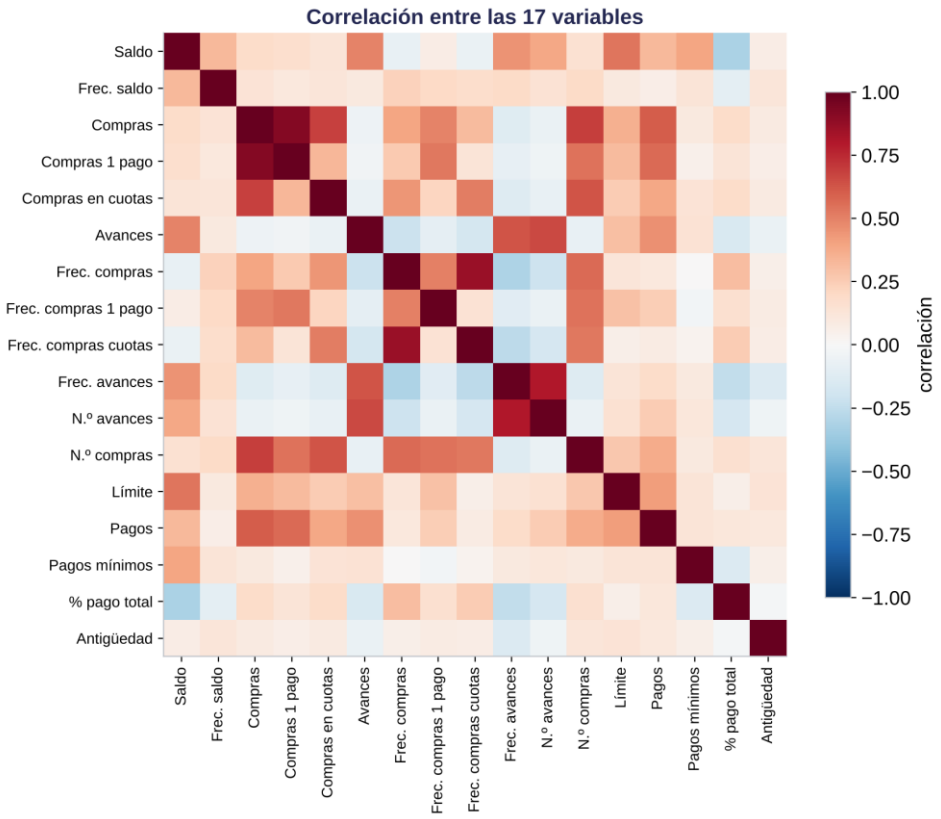
PCA con 8 949 clientes de tarjeta

17 variables de comportamiento resumidas en pocos componentes

En esta sección

Repetición | Varianza | Cargas | Mapa | La trampa

¿Cuánto se repiten las 17 variables?

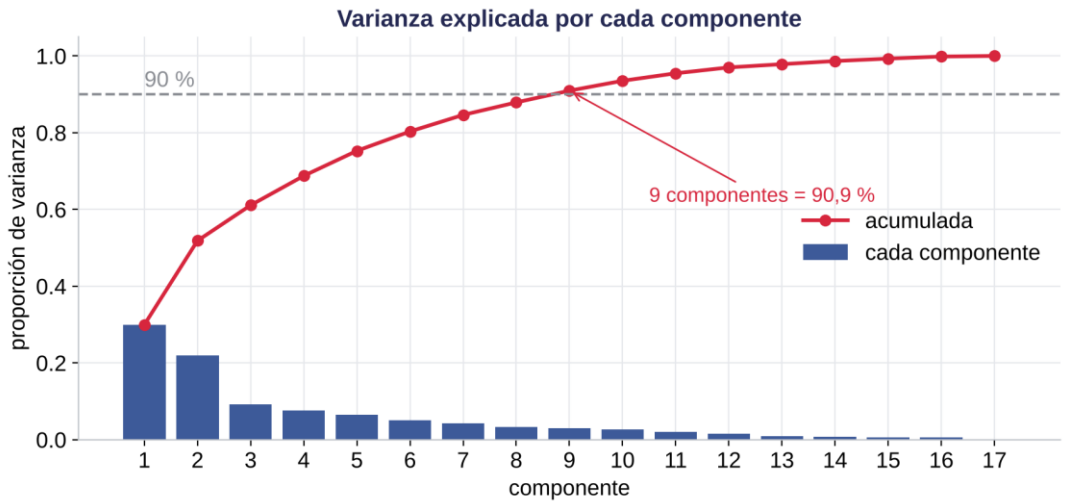


Pareja	r
Compras · compras 1 pago	0,92
Frec. compras · frec. cuotas	0,86
Frec. avances · n.º avances	0,80
Compras · n.º compras	0,69

9 parejas con r > 0,6
dos familias: compra y efectivo

Preparación: la misma del Día 4: faltantes, logaritmo de los 8 montos, Train/Validation 70/30 y estandarización.

Varianza explicada: ¿cuántos componentes?

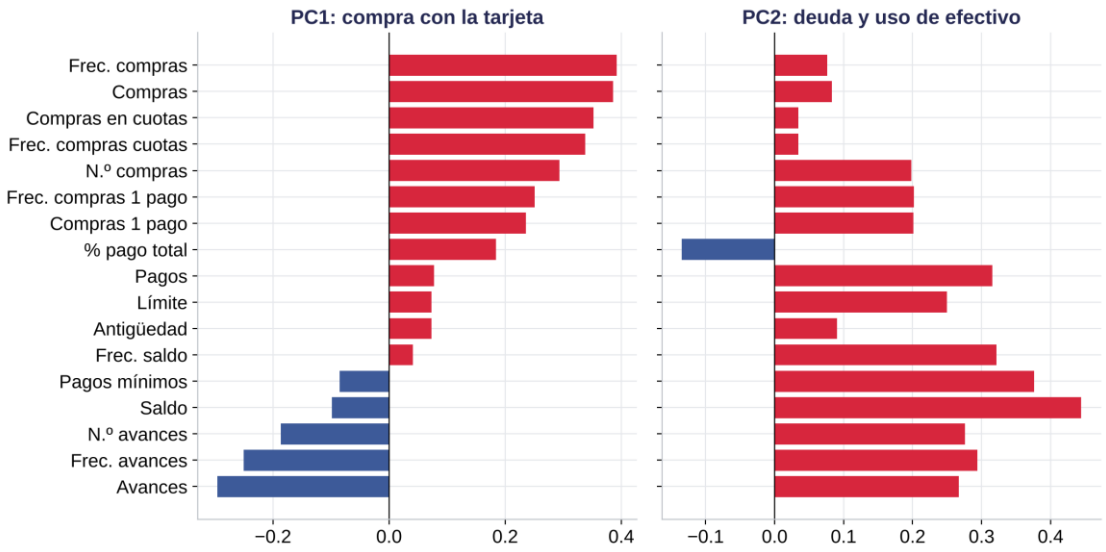


Train ≈ Validation

PCA no memoriza: las direcciones sirven igual para clientes nuevos.

Componentes	Varianza acum.	Error Train	Error Validation
0 (línea base)	0 %	1,00	1,00
1	30 %	0,70	0,71
2	52 %	0,48	0,49
9	**91 %**	**0,09**	**0,09**
17	100 %	0	0

Cargas: ¿qué significa cada componente?



PC1

compra con la tarjeta

+ compras, frecuencia · − avances

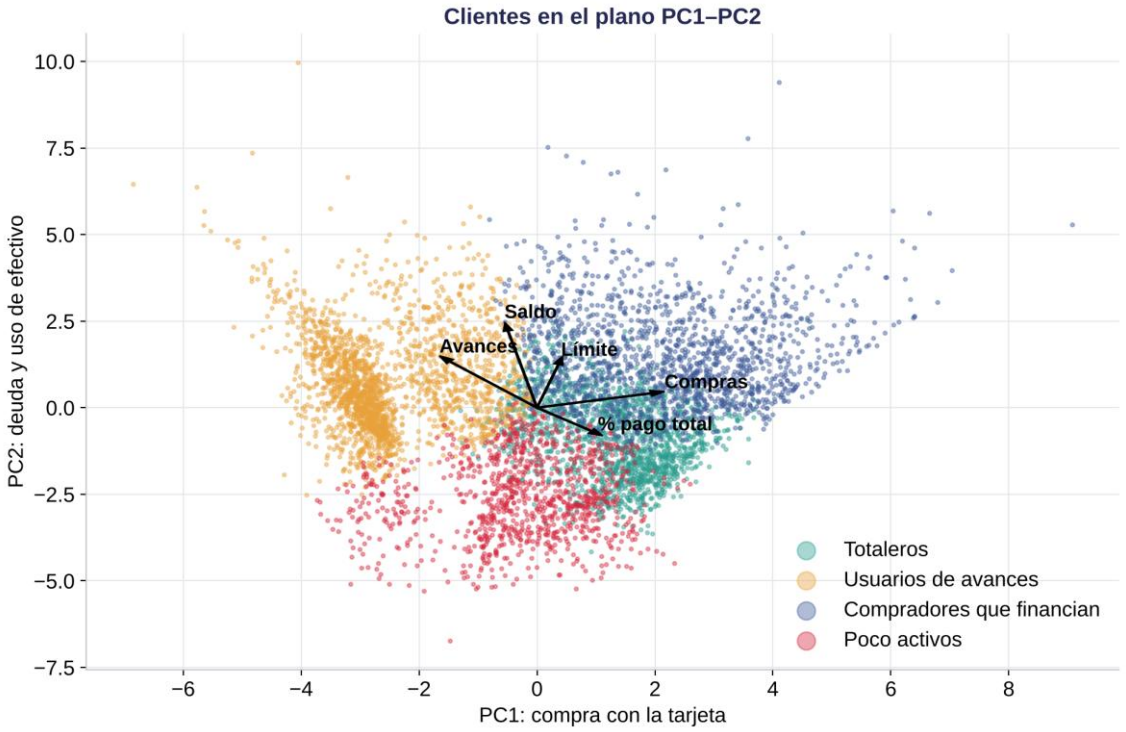
PC2

deuda y uso de efectivo

+ saldo, mínimos, pagos, avances

Cuidado: las cargas no son coeficientes de regresión. Dicen cómo se arma el eje, no qué causa qué.

El mapa de los clientes: biplot



Cómo leerlo

punto = cliente

flecha = hacia dónde crece la variable

color = segmento de K-Means

PCA encontró los dos ejes que separan los segmentos, sin saber de ellos.

Cliente nuevo: logaritmo → estandarizar con Train → transform de PCA, y aparece en el mapa.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

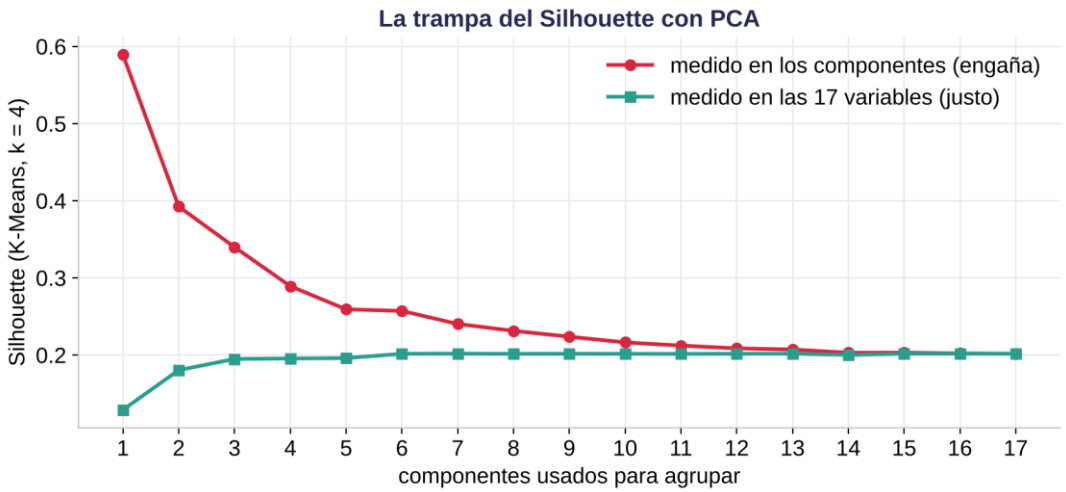
cec·epn U.C.C. Unidad de Capacitación y Certificación

Los hiperparámetros de PCA

Hiperparámetro	Qué controla	Ejemplo de hoy
n_components	Cuántos componentes guardar: entero, decimal (% de varianza) o None	0,90 → 9 componentes (90,9 %)
whiten	Reescalar cada componente a varianza 1	varianzas 5,09 · 3,72 · 1,57 → 1 · 1 · 1
svd_solver	Método de cálculo: auto, full, randomized	randomized da 0,299 y 0,219, igual
random_state	Semilla del método aleatorio	42

El más importante es n_components. Se elige mirando la varianza acumulada y el error en Validation, y según para qué lo quiero.

La trampa del Silhouette con PCA



Regla

Para comparar representaciones, mide siempre en el mismo espacio.

Componentes	Silhouette en componentes	Silhouette en 17 variables
1	**0,59**	0,13
2	**0,39**	0,18
6	0,26	0,20
17	0,20	0,20

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Cuándo usar PCA y cuándo no?

Sí

- Visualizar muchas variables en 2 o 3 ejes
- Resumir variables muy correlacionadas
- Acelerar modelos con cientos de columnas
- Construir índices (actividad, desarrollo)

Con cuidado o no

- Cuando hay que explicar cada variable
- Con pocas variables poco correlacionadas
- Para predecir: no mira y. Hoy, en BankChurners, PCA bajó el F1 del bosque de 0,83 a 0,45

Recuerda: PCA resume lo que más varía, no lo que más predice.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

4

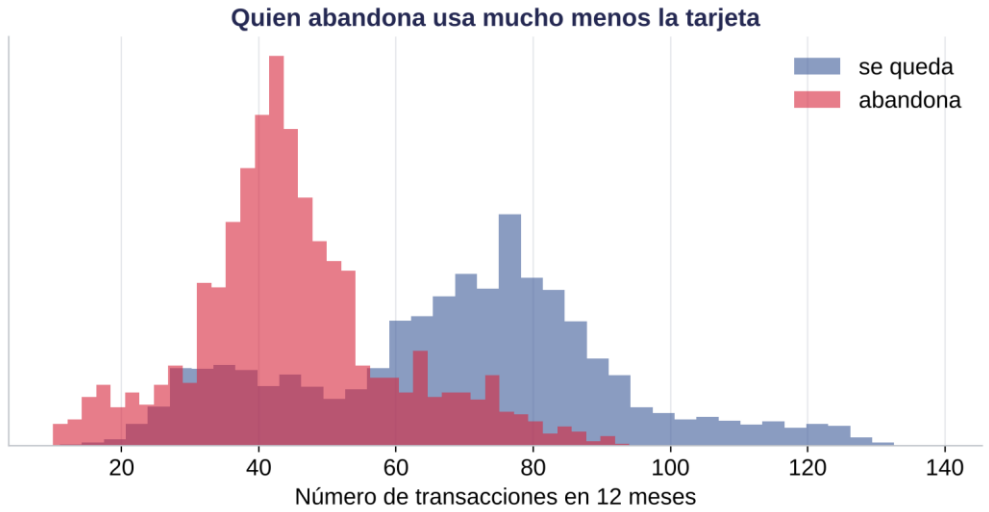
Selección de variables

Quedarse con las columnas que ayudan a predecir

En esta sección

- El problema
- Tres familias
- A mano
- ¿Cuántas?
- Fuga

BankChurners: 37 columnas para predecir el abandono



Paso	Columnas
Original	23
− CLIENTNUM y respuesta	21
− 2 columnas Naive Bayes (fuga)	19
+ One-Hot de 5 categorías	**37**

Clientes	Abandonan	Train · Val · Test
10 127	**16,1 %**	**7 088 · 1 519 · 1 520**

Con < 50 transacciones abandona el 38 %; con 50 o más, solo el 7 %.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Con todas las columnas: KNN se desploma

Modelo (37 columnas)	F1 Train	F1 Validation	Brecha
Siempre «se queda»	0,000	0,000	0,000
KNN (15 vecinos)	0,392	**0,240**	0,153
Random Forest	0,982	**0,832**	0,150

¿Por qué KNN cae?

Suma diferencias en todas las columnas: las irrelevantes pesan igual que las importantes.

¿Por qué el bosque no?

Cada pregunta elige la mejor variable: ignora las que no sirven.

Pregunta: ¿qué columnas dejar para que KNN vuelva a funcionar?

Tres familias de métodos de selección

Filtro

Cada variable sola frente a y: correlación, prueba F, información mutua.

Rápido · no ve combinaciones.

SelectKBest

Envoltura

Entrena, quita la peor variable, vuelve a entrenar…

Usa el modelo · lento.

RFE

Embebido

El modelo mide la importancia al aprender (árboles, Lasso).

Un entrenamiento · depende del modelo.

SelectFromModel

Todas aprenden de los datos: se ajustan solo con Train, dentro de un Pipeline.

Filtro a mano: la correlación con la respuesta

Total_Trans_Ct frente al abandono

$$r = \Sigma(x-\bar{x})(y-\bar{y}) / \sqrt{\Sigma(x-\bar{x})^2}\ \sqrt{\Sigma(y-\bar{y})^2}$$

$$= -23\,353 / 61\,502$$

$$= -0{,}38$$

Variable	|r|
N.º de transacciones	**0,380**
Cambio de transacciones T4/T1	0,292
Saldo pendiente	0,267
Contactos en 12 meses	0,208
…	…
Antigüedad	0,003
Tarjeta Blue	0,000

Limitación: la correlación solo ve relaciones en línea recta y mira cada variable sola.

Información mutua: ¿cuánto me dice esta variable?

N.º de transacciones

sin saber nada: 16 %

menos de 50 → abandona 38 %

50 o más → abandona 7 %

informa mucho

Sexo

sin saber nada: 16 %

mujer → abandona 17 %

hombre → abandona 15 %

casi no informa

Información mutua (Train)	Valor
Monto de transacciones	0,159
N.º de transacciones	0,115
Cambio de transacciones	0,105
Saldo pendiente	0,089
Uso del cupo	0,049

Envoltura a mano: RFE

1	**Vuelta 1**	Entrenar con 37 → quitar edad y n.º de dependientes → quedan 35
2	**Vuelta 2**	Entrenar con 35 → quitar antigüedad y límite de crédito → quedan 33
3	**Vuelta 3**	Entrenar con 33 → quitar educación College y High School → quedan 31
4	**…**	Repetir hasta dejar las k variables pedidas

Ventaja: considera el modelo y las variables juntas. Costo: un entrenamiento por vuelta.

Resultado: KNN con 5 variables

KNN, 5 variables · Validation

	pred. se queda	pred. abandona
real se queda	VN **1 236**	FP **39**
real abandona	FN **74**	VP **170**

Métricas, a mano

Precision = 170 / (170 + 39) = 0,813

Recall = 170 / (170 + 74) = 0,697

F1 = 340 / (340 + 39 + 74) = 0,751

KNN	F1 Train	F1 Validation	Brecha
37 columnas	0,392	**0,240**	0,153
5 variables	0,771	**0,751**	0,021

Elegidas: monto y n.º de transacciones, cambio de transacciones, saldo y uso del cupo.

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Los métodos eligen lo mismo?

Método (5 variables, KNN)	Familia	F1 Train	F1 Validation
Prueba F	Filtro	0,671	0,635
Información mutua	Filtro	0,771	0,751
RFE con árbol	Envoltura	0,781	**0,759**
Importancia del Random Forest	Embebido	0,771	0,751

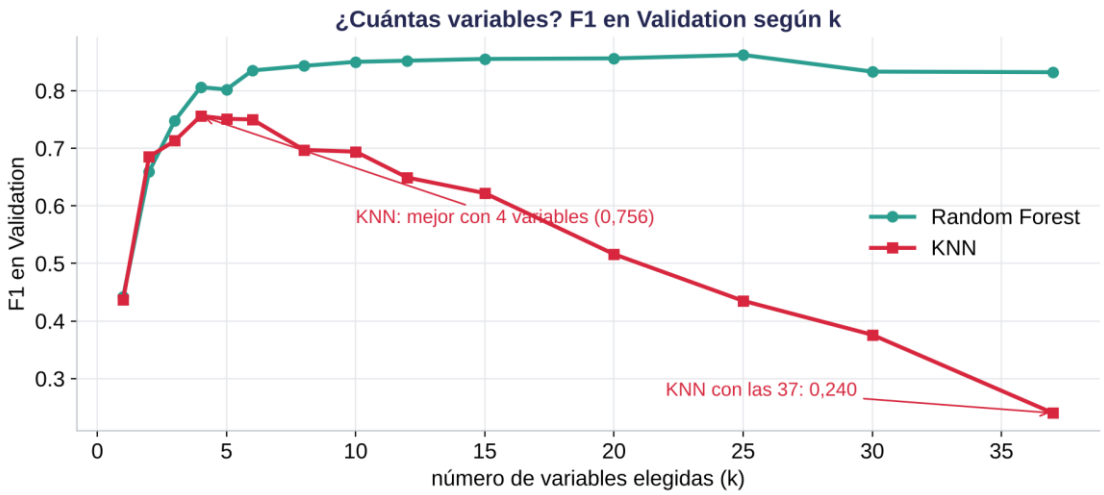
Coinciden en: transacciones (monto y número), cambio de transacciones entre trimestres y saldo pendiente.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Cuántas variables dejar?



Mejor k

KNN: 4 → 0,756

Bosque: 25 → 0,862

seleccionar es clave para KNN y opcional para el bosque

Pocas (1–2)

Se pierde información útil.

Justas

Solo lo que predice.

Muchas

Ruido: KNN se pierde.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

La selección también puede tener fuga

KNN con las columnas Naive Bayes

F1 = 1,00

KNN sin ellas

F1 = 0,75

Alarma

Un F1 casi perfecto no es un éxito: es la señal de que algo trae la respuesta.

Regla

Limpiar la fuga antes de seleccionar y ajustar el selector solo con Train.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Los hiperparámetros de la selección

Herramienta	Hiperparámetro	Qué controla
SelectKBest	score_func	Cómo puntuar: f_classif (lineal), mutual_info_classif (cualquier relación)
	k	Cuántas variables dejar
RFE	estimator	Modelo que mide la importancia en cada vuelta
	n_features_to_select	Cuántas dejar al final
	step	Cuántas quitar por vuelta
SelectFromModel	estimator	Modelo que da las importancias
	threshold / max_features	Umbral de importancia o máximo de variables

Se elige con Validation: nunca con Test y nunca con todos los datos juntos.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

5

Ingeniería de características

Crear las columnas que el modelo no puede ver solo

En esta sección

- Tipos
- A mano
- ¿Mejora?
- Potencias
- Clustering

Tipos de variables que podemos crear

Tipo	Ejemplo	Para qué
Cociente	monto / n.º de transacciones	Comparar clientes de distinto tamaño
Logaritmo	log(1 + monto)	Montos muy asimétricos (Día 4)
Indicador 0/1	¿tiene saldo pendiente?	Separar «nada» de «algo»
Interacción o potencia	tasa × cuota; (transacciones)²	Efectos combinados o curvos
Tramos	edad en rangos	Relaciones por escalones
Fechas	mes, rezagos	Series de tiempo (Día 7)

Regla de oro: solo información disponible al momento de predecir; si aprende un valor (mediana, promedio), solo con Train.

Cuatro variables nuevas para BankChurners, a mano

Variable nueva	Fórmula	Cliente 1
monto_por_transaccion	monto / n.º de transacciones	7 632 / 95 = 80,3
tiene_saldo	1 si saldo > 0	1 839 > 0 → 1
contactos_por_inactividad	contactos / (meses inactivo + 1)	3 / (3 + 1) = 0,75
log_monto	log(1 + monto)	log(7 633) = 8,94

Abandono SIN saldo pendiente

36,4 %

Abandono CON saldo pendiente

9,5 %

Conocimiento del negocio: quien no usa el crédito de la tarjeta tiene menos razones para quedarse.

¿Mejoran los modelos?

Modelo	F1 Train	F1 Validation	Brecha
KNN, 5 elegidas	0,771	0,751	0,021
KNN, 5 elegidas + 4 nuevas	0,794	**0,780**	0,014
Random Forest, 37 columnas	0,982	0,832	0,150
Random Forest, 37 + 4 nuevas	0,984	**0,870**	0,114

Los dos mejoran: una buena variable vale más que cambiar de algoritmo.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Potencias e interacciones automáticas

Grado 2 con a y b

$[a, b] \rightarrow [a, b, a^2, a \cdot b, b^2]$

$95 \rightarrow 95^2 = 9\,025 \cdot 95 \times 0{,}532 = 50{,}5$

Hiperparámetros

degree: grado máximo

interaction_only: solo productos a·b

include_bias: columna de unos

KNN	Grado 1	Grado 2	Grado 3
5 elegidas (columnas)	0,751 (5)	0,750 (20)	0,744 (55)
5 + 4 nuevas (columnas)	**0,780 (9)**	0,748 (54)	**0,740 (219)**

Lección: la ingeniería con sentido le gana a la ingeniería automática en masa.

Ingeniería para clustering: describir mejor los segmentos

Segmento (mediana)	Uso del cupo	Pago / mínimo	Compra promedio
Usuarios de avances	**65 %**	**1,1**	0
Compradores que financian	29 %	4,1	64
Totaleros	9 %	2,1	38
Poco activos	1 %	2,8	50

Uso del cupo

saldo / límite

Pago frente al mínimo

pagos / pago mínimo

Compra promedio

compras / n.º de compras

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

6

Comparación final y cierre

La misma pregunta en tres datasets: ¿qué preparación funciona mejor?

En esta sección

- La tabla
- Ganadores
- Por qué
- Pipeline
- Ideas clave

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cinco preparaciones, tres datasets

F1 en Validation	BankChurners KNN	BankChurners RF	Credit Risk KNN	Credit Risk RF
Todas (línea base)	0,240	0,832	**0,727**	0,831
Selección	0,756	0,860	0,701	0,763
PCA 90 %	**0,215**	**0,446**	**0,662**	**0,712**
Ingeniería	0,349	**0,870**	0,717	**0,833**
Selección + ingeniería	**0,803**	0,868	0,707	0,764

Silhouette (Validation)	Todas	PCA 90 %	PCA 2	Selección	Ingeniería
Clientes de tarjeta, K-Means	**0,206**	**0,206**	0,174	0,176	0,176

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Los ganadores y su examen en Test

BankChurners

Random Forest + ingeniería

0,870

Validation

Test 0,864

Credit Risk

Random Forest + ingeniería

0,833

Validation

Test 0,814

Clientes de tarjeta

Todas = PCA 90 %

0,206

Validation

Silhouette

No compares entre datasets: un F1 de abandono, uno de impago y un Silhouette miden cosas distintas.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Por qué gana algo distinto en cada caso?

BankChurners

37 columnas, muchas irrelevantes → seleccionar y crear variables ayuda mucho (KNN: 0,24 → 0,80).

Credit Risk

Pocas columnas y casi todas útiles → seleccionar quita información (bosque: 0,83 → 0,76).

Clientes de tarjeta

Sin y y con información repetida → PCA 90 % resume 17 en 9 sin perder calidad.

PCA para predecir

La peor opción en los dos supervisados: no mira la respuesta.

Ninguna preparación gana siempre: se compara en Validation, igual que los modelos.

Todo dentro del Pipeline

Preparar
imputar · escalar · One-Hot

→

Reducir o seleccionar
PCA o SelectKBest

→

Modelo
KNN · bosque · K-Means

fit (solo Train)

aprende medias, puntuaciones, direcciones y el modelo

predict / transform

aplica lo aprendido a Validation, Test y clientes nuevos

Día 7: convertiremos este Pipeline en un flujo automático que se guarda y se reutiliza.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ideas clave del día

1

Tres herramientas

PCA resume, la selección quita y la ingeniería crea. Responden preguntas distintas.

2

PCA

Estandarizar, direcciones de máxima varianza, coordenadas; varianza explicada y error de reconstrucción.

3

PCA no mira y

Ideal para visualizar y resumir; arriesgado para predecir.

4

Seleccionar

Clave para modelos de distancia: KNN pasó de 0,24 a 0,75 con 5 de 37 columnas.

5

Crear con sentido

Gasto por compra y tiene saldo mejoraron a los dos modelos; las potencias en masa, no.

6

Comparar en Validation

Ninguna preparación gana siempre; todo dentro del Pipeline.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Del papel al notebook

Lo que hicimos a mano	Lo que verán en el notebook	Debe dar…
PCA de 6 clientes	Cinco pasos con numpy y PCA	96 % · cliente 1 = 2,56
Varianza de 17 variables	Tabla y gráfico de componentes	30 % · 22 % · 9 para el 90 %
Error de reconstrucción	Train frente a Validation	0,482 · 0,490 con 2
La trampa del Silhouette	Dos columnas de Silhouette	0,39 frente a 0,18
Correlación a mano	Total_Trans_Ct con el abandono	−0,38
KNN con 5 variables	Matriz y métricas	F1 0,751
Variables nuevas	Cuatro funciones de una línea	80,3 · 1 · 0,75 · 8,94
Comparación final	Tablas de la Parte D	0,870 · 0,833 · 0,206

Su rol con el agente de IA

Pidan que explique cada línea y verifiquen los números. Si un resultado no coincide con lo calculado a mano, pregunten por qué.