ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Día 6 — Visualización multidimensional y optimización de modelos



Módulo 3: Machine Learning Aplicado

Jonathan Rosero Soto

Edificio Aulas y Relación con el Medio Externo, Av. Toledo N23-55 y Madrid
Telf.: +593 2 2525766 - Ext: 102 / 125 / 143 / 120 / 127 - www.cec-epn.edu.ec

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ruta de la jornada

1	**Ver muchas dimensiones**	Dos variables, matriz de dispersión y coordenadas paralelas
2	**Reducir para ver: PCA y t-SNE**	Varianza frente a vecinos; qué significa cada mapa
3	**¿Qué es optimizar un modelo?**	Parámetros, hiperparámetros y el problema de una Validation
4	**Validación cruzada a mano**	Medir varias veces y promediar
5	**Grid Search y Random Search**	Buscar hiperparámetros de forma automática
6	**Optimizar un clustering**	Elegir k con remuestreo y estabilidad
7	**Comparación final y cierre**	Tres modelos optimizados en dos datasets

Regla del día: *un gráfico y una métrica siempre esconden algo; elige qué perder a conciencia.*

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

1

Ver muchas dimensiones

Los segmentos del Día 4 viven en 9 dimensiones; la pantalla tiene 2

En esta sección

- El problema
- Dos variables
- Matriz
- Paralelas

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Nueve dimensiones, una pantalla plana

Camino 1: varias vistas

Matriz de dispersión, coordenadas paralelas, mapa de calor.

\+ Cada eje es una variable que entendemos.

− Vistas parciales: nunca se ve todo junto.

Camino 2: reducir a 2D

PCA, t-SNE.

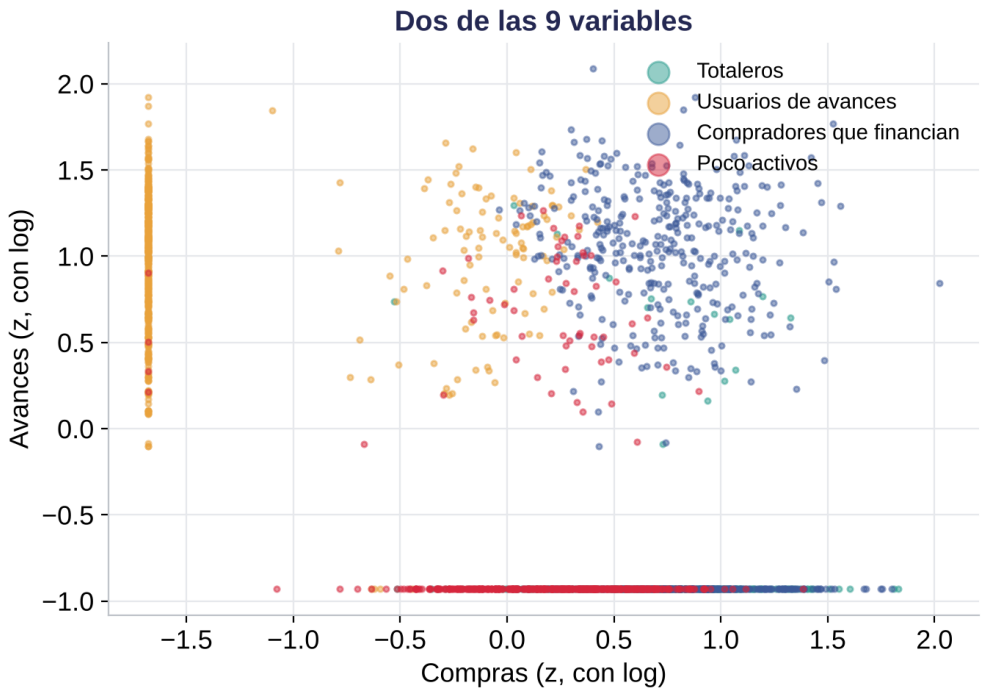
\+ Un solo mapa con todos los clientes.

− Los ejes ya no son variables; algo se pierde.

Clientes	Variables (dimensiones)	Segmentos del Día 4
8 949	**9**	**4**

Pregunta del día: ¿qué vista muestra mejor los 4 segmentos y qué esconde cada una?

Línea base: dos variables a la vez



Se ve

Usuarios de avances: compran poco y sacan efectivo.

No se ve

Qué distingue a los otros tres: está en las otras 7 variables.

Lección: una vista parcial puede mostrar un grupo y esconder los demás.

Matriz de dispersión: todas las parejas

	Saldo	Compras	Avances	Frec.	% pago
Saldo	histograma	·	·	·	·
Compras	·	histograma	avances	·	·
Avances	·	avances	histograma	·	·
Frec.	·	·	·	histograma	totaleros
% pago	·	·	·	totaleros	histograma

Cuántos gráficos

2 variables → 4

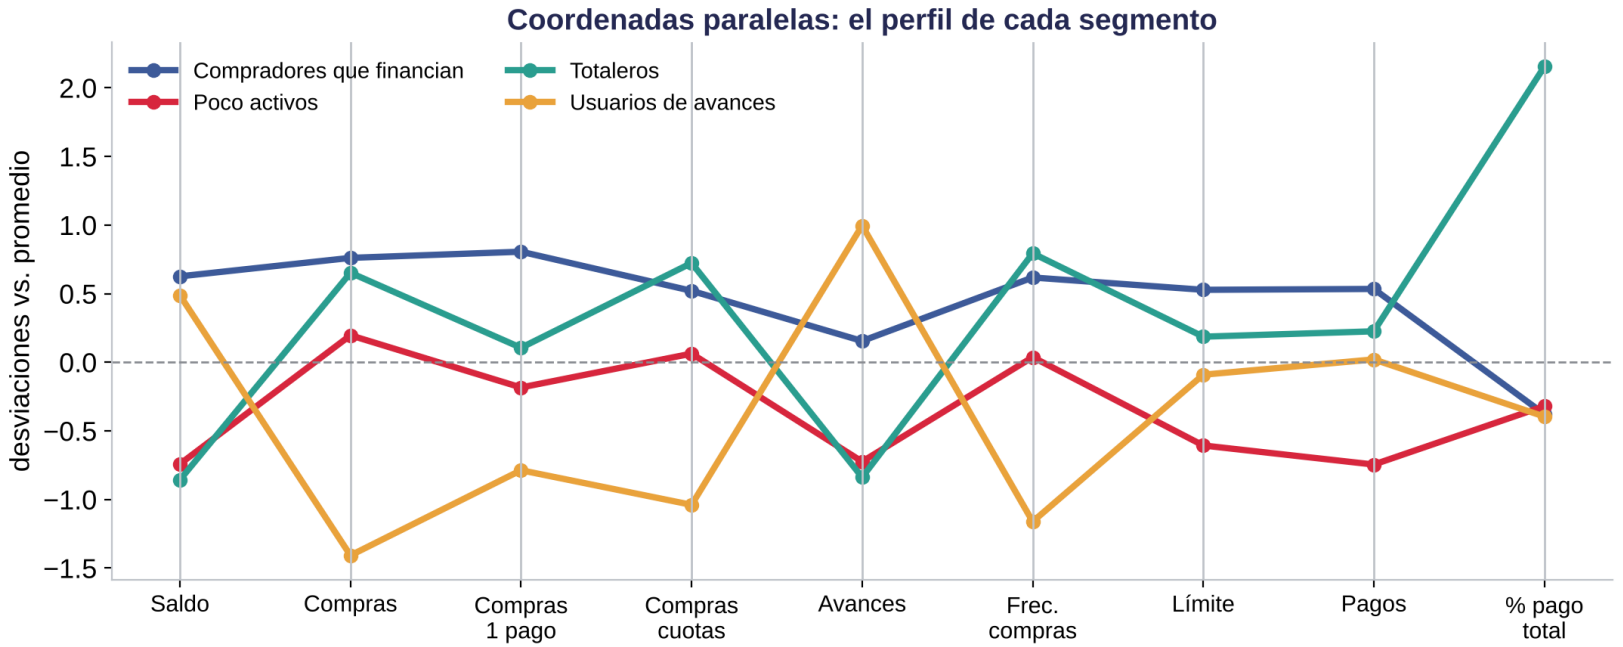
5 variables → 25

9 variables → 81

37 variables → 1 369

Úsala para explorar al inicio, con pocas variables. Con muchas se vuelve ilegible.

Coordenadas paralelas: un cliente es una línea



Cliente	Saldo	Compras	1 pago	Cuotas	Avances	Frec.	Límite	Pagos	% pago
Usuario de avances (z)	0,95	−1,68	−0,99	−1,09	1,53	−1,22	0,93	1,07	0,23

Lectura: la línea naranja baja en compras y sube en avances; la verde se dispara en % de pago total.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

2

Reducir para ver: PCA y t-SNE

Un mapa de dos dimensiones con todos los clientes

En esta sección

- PCA
- t-SNE a mano
- Comparar
- Confiabilidad
- Perplexity

PCA en 2 y 3 dimensiones

Componentes	Varianza explicada	Acumulada
PC1	37 %	37 %
PC2	24 %	**61 %**
PC3	11 %	72 %

Ventaja

Ejes interpretables (cargas) y transform para ubicar clientes nuevos.

Límite

En 2D se pierde ≈ 39 % de la información: puntos que se ven juntos pueden no estarlo.

PCA conserva la varianza: lo que está lejos en 9 dimensiones tiende a quedar lejos en el mapa.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

t-SNE: conservar a los vecinos

1	**Vecinos en 9D**	Para cada cliente: probabilidad de que otro sea su vecino (alta si está cerca).
2	**Puntos en 2D**	Colocar los puntos en el plano (al azar o desde PCA) y calcular las mismas probabilidades.
3	**Acomodar**	Mover los puntos, vuelta tras vuelta, hasta que las dos tablas de probabilidades se parezcan.

perplexity ≈ cuántos vecinos mira cada punto (lo usual: entre 5 y 50).

Diferencia con PCA: a t-SNE no le importa si dos grupos están a 6 o a 60 de distancia; solo quién es vecino de quién.

t-SNE a mano: cuatro clientes en una recta



Probabilidad de ser vecino	A	B	C	D
de A	—	**0,65**	0,35	0
de B	0,41	—	**0,59**	0
de C	0,27	**0,73**	—	0
de D	0	0,09	**0,92**	—

En el mapa 2D

A, B y C juntos

D aparte

cada fila suma 1

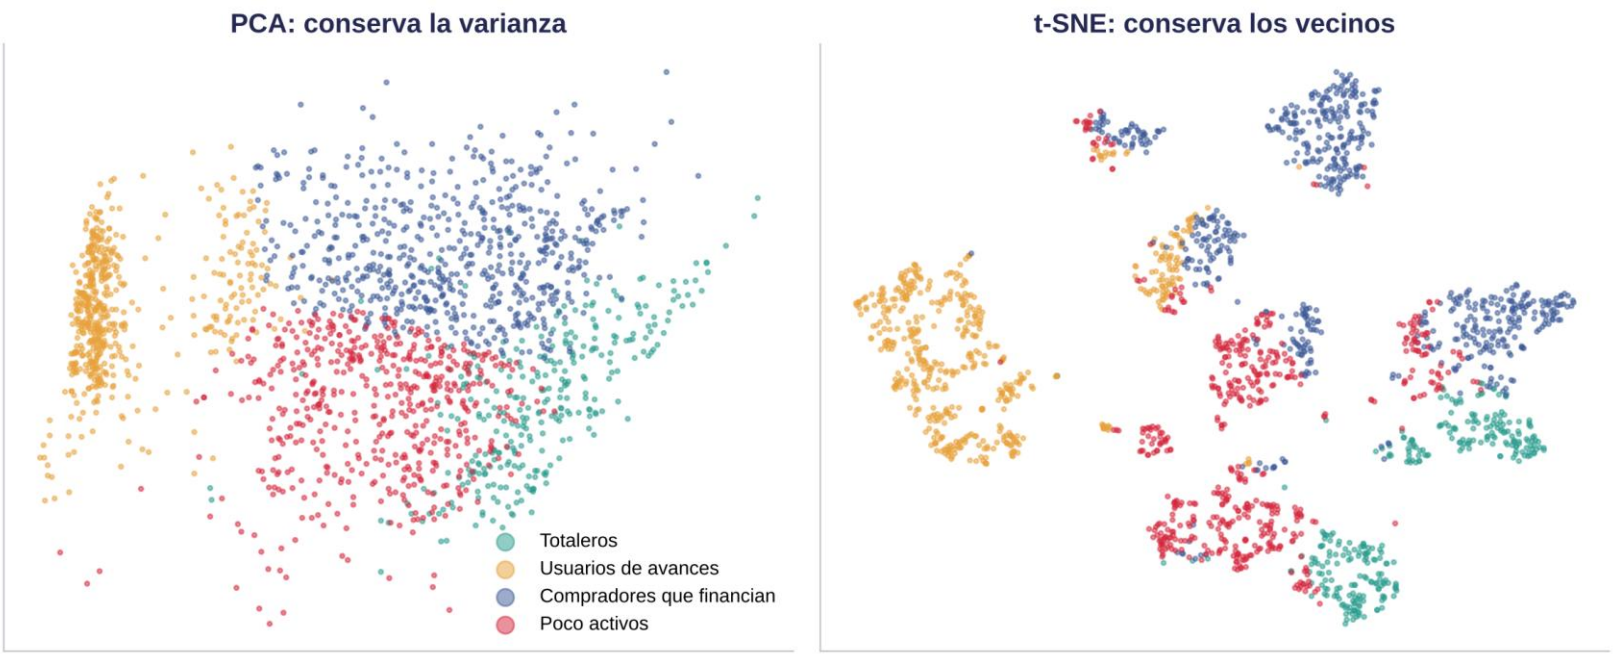
Lo que conserva: quién es vecino de quién. Lo que NO conserva: cuán lejos está D.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

PCA frente a t-SNE con 2 000 clientes



Ojo: que t-SNE muestre islas no prueba que existan grupos separados; agranda los vecindarios.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Lo que NO significa un mapa de t-SNE

Tamaño de las islas

No significa nada: t-SNE expande o comprime grupos.

Distancia entre islas

No significa nada: dos islas lejanas pueden ser parecidas.

Los ejes

No se interpretan (en PCA sí: las cargas).

Clientes nuevos

No tiene transform: hay que rehacer el mapa.

Úsalo para explorar, nunca para medir distancias ni para presentar tamaños de grupos.

Confiabilidad: ¿el mapa junta a quienes son vecinos?

Cliente 0, a mano

10 vecinos en el mapa ∩ 10 vecinos reales

PCA: 1 de 10

t-SNE: 6 de 10

PCA

0,894

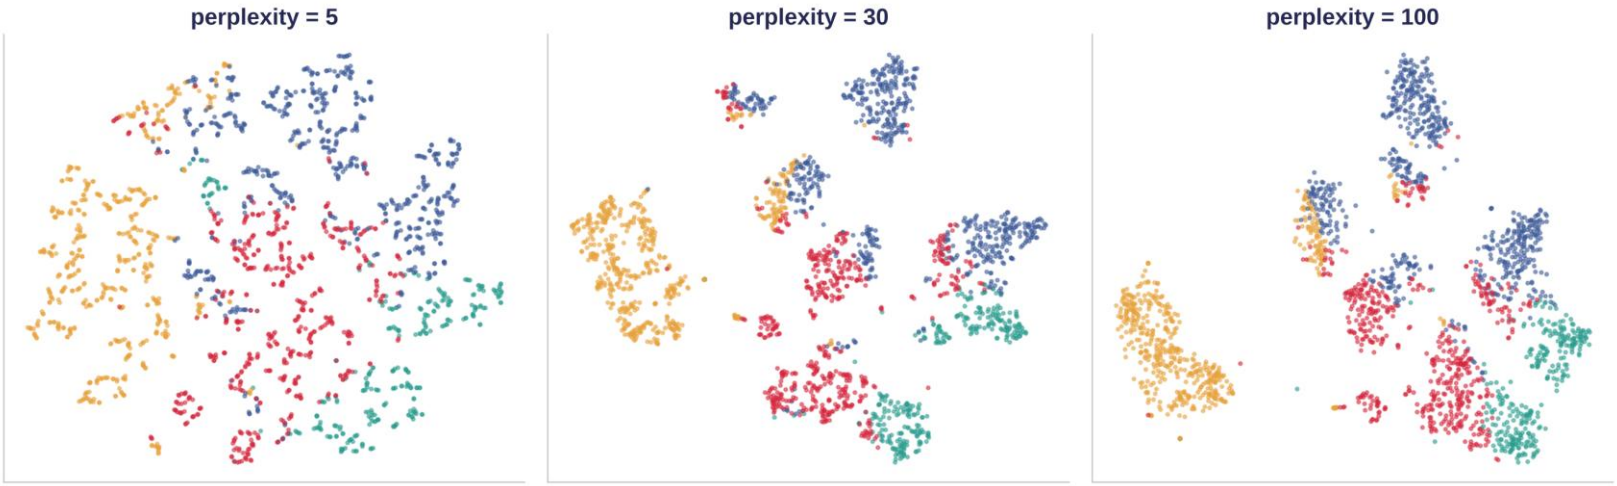
t-SNE

0,995

confiabilidad promedio (10 vecinos)

Vale 1 si el mapa nunca junta a clientes que en realidad estaban lejos.

Perplexity: tres mapas, tres historias



Hiperparámetro	Qué controla	Por defecto
perplexity	Cuántos vecinos mira cada punto	30
init	Inicio al azar o desde PCA (más estable)	pca
max_iter · learning_rate	Cuántas vueltas y qué tan grandes los movimientos	1000 · auto
random_state	Semilla: el mapa cambia mucho con ella	None

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Qué vista usar para qué?

Técnica	Muestra bien	Esconde	Úsala para…
Dispersión 2 variables	Esa relación	Las otras 7	Una pregunta concreta
Matriz de dispersión	Todas las parejas	Combinaciones de 3+	Explorar al inicio
Paralelas / mapa de calor	El perfil de cada grupo	Se satura con muchos clientes	**Explicar segmentos**
PCA 2D	Forma global; ejes con sentido	≈ 39 % de la información	**Ubicar clientes**
t-SNE	Vecindarios; islas	Distancias y tamaños	Explorar si hay grupos

Para un informe: paralelas o mapa de calor para explicar, PCA 2D para ubicar; t-SNE solo como exploración.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

3

¿Qué es optimizar un modelo?

Elegir hiperparámetros con evidencia, sin tocar Test

En esta sección

Parámetros	**Hiperparámetros**	**Una sola Validation**

Parámetros e hiperparámetros

	Parámetros	Hiperparámetros
¿Quién los fija?	El modelo, al entrenar (fit)	**Nosotros, antes de entrenar**
Ejemplos	Preguntas y umbrales de un árbol; centros de K-Means	max_depth, n_estimators, n_neighbors, k
¿Cómo se eligen?	Minimizando el error en Train	**Comparando en datos no vistos**

Optimizar = encontrar los hiperparámetros con mejor resultado en datos no vistos, sin tocar Test.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

El caso: impago en Credit Risk

Préstamos limpios	Para entrenar y validar	Test (se abre al final)
32 409	**8 000**	**4 862**

Preparación

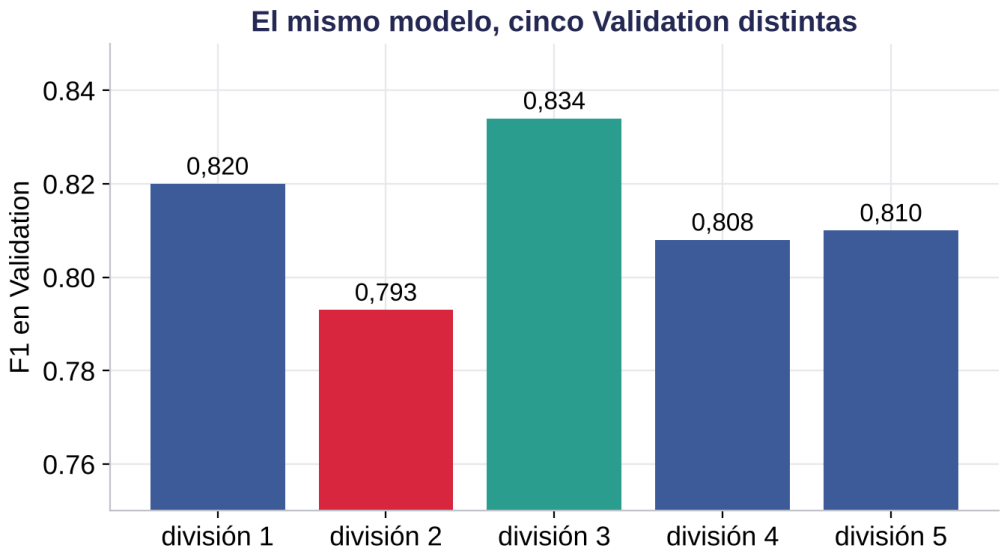
Imputar la mediana (tasa y antigüedad) y One-Hot de las 4 categorías, dentro de un Pipeline.

Modelos a mejorar

La línea base (siempre «paga»: F1 = 0) y un Random Forest con valores por defecto.

Impago: 21,9 % de los préstamos. Métrica: F1 de la clase impago.

El problema de una sola Validation



Mismo modelo

F1 entre

0,793 y 0,834

solo por la suerte de la división

Solución: medir varias veces con divisiones distintas y promediar: validación cruzada.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

4

Validación cruzada a mano

Que cada fila sirva una vez para validar

En esta sección

k pliegues	A mano	Estratificada	Train frente a CV

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Validación cruzada con k pliegues

Vuelta 1	**filas 0–1**	filas 2–3	filas 4–5	filas 6–7	filas 8–9	**validar**
Vuelta 2	filas 0–1	**filas 2–3**	filas 4–5	filas 6–7	filas 8–9	entrenar
Vuelta 3	filas 0–1	filas 2–3	**filas 4–5**	filas 6–7	filas 8–9	
Vuelta 4	filas 0–1	filas 2–3	filas 4–5	**filas 6–7**	filas 8–9	
Vuelta 5	filas 0–1	filas 2–3	filas 4–5	filas 6–7	**filas 8–9**	

Resultado: 5 valores de F1 → promedio (lo esperado) y desviación (qué tan estable).

Costo: entrenar k veces. 5 o 10 pliegues es lo usual.

Validación cruzada a mano con los préstamos

Pliegue	Entrena	Valida	Impago en validación	F1
1	6 400	1 600	21,9 %	0,817
2	6 400	1 600	21,9 %	0,792
3	6 400	1 600	21,9 %	0,788
4	6 400	1 600	21,9 %	0,812
5	6 400	1 600	21,9 %	0,803

Promedio

(0,817 + 0,792 + 0,788 + 0,812 + 0,803) / 5

0,802

desviación 0,011

Estratificada: cada pliegue conserva la proporción de impagos; imprescindible con clases desbalanceadas.

Train frente a validación cruzada

Modelo	F1 Train	F1 validación cruzada	Brecha
Línea base (siempre «paga»)	0,000	0,000	0,000
Random Forest por defecto	**1,000**	**0,802**	**0,198**

Hiperparámetro de la validación	Qué controla
n_splits	Cuántos pliegues (5 o 10)
shuffle · random_state	Barajar antes de dividir, con semilla fija
StratifiedKFold	Mantener la proporción de cada clase

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

5

Grid Search y Random Search

Buscar hiperparámetros de forma automática con validación cruzada

En esta sección

Rejilla	cv_results_	Elegir	Random	Pipeline	Test

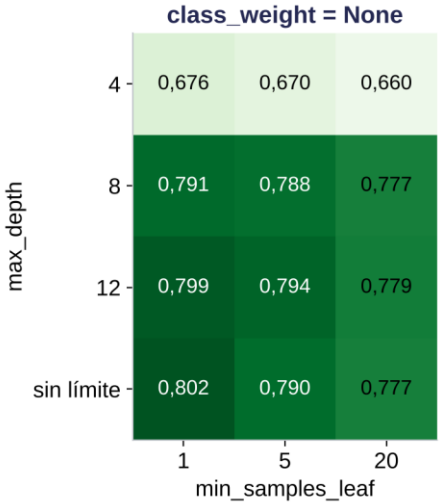
Grid Search: probar todas las combinaciones

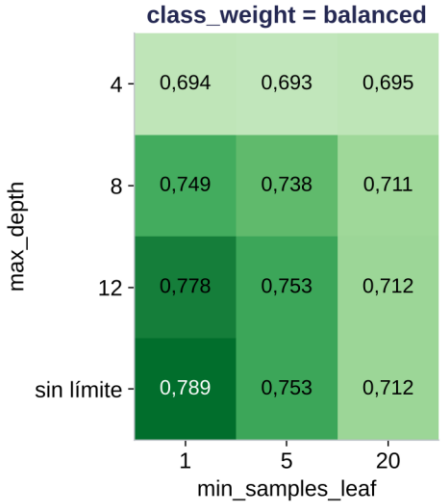
Hiperparámetro	Valores	Cantidad
max_depth	4 · 8 · 12 · sin límite	4
min_samples_leaf	1 · 5 · 20	3
class_weight	ninguno · balanced	2

4 × 3 × 2 = 24 combinaciones
× 5 pliegues
= 120 entrenamientos
≈ 45 segundos

Hiperparámetro de GridSearchCV	Qué controla
param_grid	Los valores a probar (todas las combinaciones)
scoring · cv	La métrica (F1) y la validación cruzada
refit	Reentrenar la mejor con todos los datos de entrenamiento
return_train_score · n_jobs	Guardar F1 de Train · núcleos del procesador

Leer los resultados de la rejilla





Mejor

sin límite · hoja 1 · sin pesos

0,802

= valores por defecto

Nombres en un Pipeline: rf__max_depth = el max_depth del paso llamado «rf» (paso, dos guiones bajos, hiperparámetro).

Profundidad 4: demasiado simple (≈ 0,67). Desde 12, todo ≈ 0,80.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿La mejor siempre es la de mayor F1?

Puesto	max_depth	min_samples_leaf	F1 Train	F1 validación cruzada	Desv.	Brecha
1	sin límite	1	**1,000**	0,802	0,011	**0,198**
2	12	1	0,864	0,799	0,014	0,065
3	12	5	0,831	0,794	0,015	**0,036**
4	8	1	0,828	0,791	0,015	0,037

Regla: si dos combinaciones difieren menos que la desviación entre pliegues, están empatadas: elige la de menor brecha o la más simple.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

La rejilla explota: Random Search

5 hiperparámetros × 5 valores

3 125 combinaciones

Random Search, n_iter = 15

15 combinaciones

	Grid Search	Random Search
Qué prueba	Todas las combinaciones	n_iter combinaciones sorteadas
Hiperparámetros explorados	3	5
Combinaciones	24	15
Mejor F1 (validación cruzada)	**0,802**	0,790
Cuándo usarlo	Pocos hiperparámetros y valores	Muchos, o no sé dónde buscar

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Optimizar un Pipeline: la escala va adentro

Preparar
imputar · One-Hot

→

Escalar
medias de los pliegues de entrenamiento

→

KNN
knn__n_neighbors · knn__weights

KNN	uniform: F1 Train	uniform: F1 CV	distance: F1 CV
5 vecinos	0,744	0,670	**0,676**
15 vecinos	0,672	0,637	0,660
31 vecinos	0,595	0,576	0,609
51 vecinos	0,538	0,529	0,569

Regla: todo lo que aprende de los datos va dentro del Pipeline, para que cada pliegue sea de verdad «no visto».

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Test, una sola vez

Modelo	F1 validación cruzada	F1 Test
Línea base	0,000	0,000
Random Forest (Grid Search = por defecto)	**0,802**	**0,810**
Random Forest (Random Search)	0,790	0,796
KNN (Grid Search)	0,676	0,682

Validación cruzada ≈ Test: la estimación era confiable. Test solo confirma; no se usa para elegir.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

6

Optimizar un clustering

Sin y no hay F1, pero sí podemos medir varias veces

En esta sección

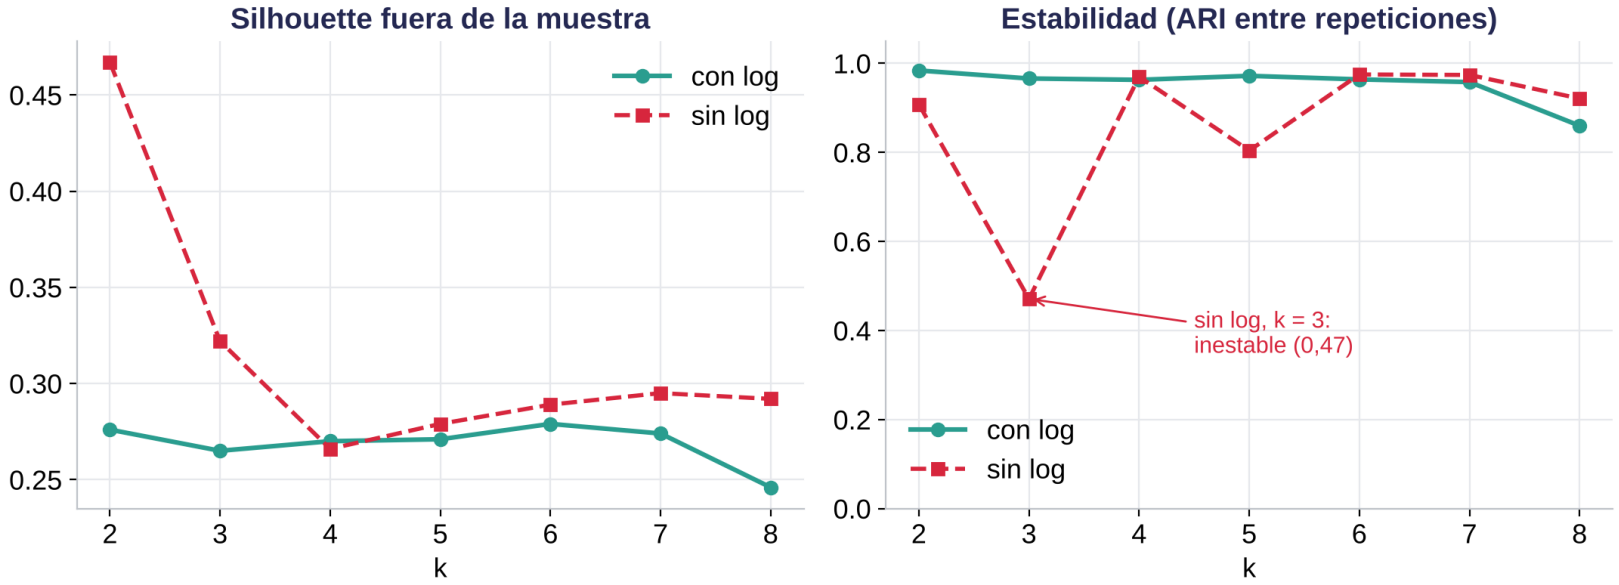
- **Remuestreo**
- **Estabilidad**
- **Elegir k**

Remuestreo y estabilidad, a mano

1	**Muestra**	70 % de los clientes al azar.
2	**Ajustar y medir**	K-Means con la muestra; Silhouette en el 30 % de fuera.
3	**Repetir**	Cinco veces, con muestras distintas.
4	**Estabilidad**	ARI entre las cinco soluciones (1 = idénticas).

k = 4, con log	Silhouette fuera	Desviación	ARI	Grupo más chico
Resultado	0,270	0,002	0,963	14 %

k × preparación: ¿qué es bueno y estable?



Descartar con números: inestables (ARI bajo) y con grupos diminutos (< 5 %).

Decidir con interpretación: entre k = 2 y 5 con log, k = 4 tiene perfiles que se explican.

La regla elige «sin log, k = 2»… y no basta

Válidas (grupo ≥ 5 %, ARI ≥ 0,8)	Silhouette	ARI	Grupo más chico
sin log, k = 2	**0,467**	0,908	13 %
con log, k = 2	0,276	0,984	33 %
con log, k = 5	0,271	0,972	13 %
con log, k = 4	0,270	0,963	14 %
con log, k = 3	0,265	0,966	30 %

Optimizar un clustering = descartar con números lo que no sirve y decidir entre lo que queda con interpretación.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

7

Comparación final y cierre

Tres modelos optimizados en dos datasets

En esta sección

- La tabla
- Por qué
- Ideas clave

Tres modelos optimizados en dos datasets

F1 validación cruzada	Credit Risk (impago)	BankChurners (abandono)
Árbol	0,781	0,813
Random Forest	**0,797**	**0,861**
KNN (con escalado)	**0,653**	**0,451**
Test del ganador	**0,800**	**0,837**

Desviación entre pliegues ≈ 0,02: en Credit Risk, bosque y árbol están casi empatados; el árbol se explica mejor.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Qué nos dice la comparación?

Bosque optimizado

Gana en los dos; Test ≈ validación cruzada.

Árbol optimizado

Casi empata en Credit Risk: reglas simples y explicables.

KNN optimizado

Último en los dos: sus hiperparámetros no arreglan columnas irrelevantes.

Lección

Primero buenas variables (Día 5), después buenos hiperparámetros (hoy).

Día 7: empaquetaremos el modelo elegido en un Pipeline que se guarda y se reutiliza.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ideas clave del día

1

Ver muchas dimensiones

Varias vistas (paralelas, mapa de calor) o un mapa reducido (PCA, t-SNE): cada uno esconde algo.

2

PCA y t-SNE

PCA conserva la forma global y ubica clientes nuevos; t-SNE, los vecindarios. No midas distancias en t-SNE.

3

Una Validation engaña

El mismo modelo dio F1 entre 0,79 y 0,83 según la división.

4

Validación cruzada

Medir k veces y promediar; la desviación dice cuándo hay empate.

5

Grid y Random

Todas las combinaciones o un sorteo; todo dentro del Pipeline; Test al final.

6

Clustering

Elegir k con Silhouette fuera de la muestra, estabilidad y grupos útiles; decidir con interpretación.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Del papel al notebook

Lo que hicimos a mano	Lo que verán en el notebook	Debe dar…
Probabilidades de vecinos	Tabla de 4 clientes	0,65 · 0,35 · 0,92
Confiabilidad	Cliente 0 y promedio	1/10 y 6/10 · 0,894 y 0,995
Cinco Validation	Mismo bosque, 5 divisiones	0,793 a 0,834
Validación cruzada	Bucle de 5 pliegues	0,802 ± 0,011
Grid Search	24 combinaciones, cv_results_	0,802 · brecha 0,198
Random Search	15 combinaciones	0,790
Clustering	k × preparación con remuestreo	k = 4: 0,270 · ARI 0,963
Comparación final	6 búsquedas	0,797 · 0,861 · Test 0,800 y 0,837

Su rol con el agente de IA

Pidan que explique cada línea y verifiquen los números. Si un resultado no coincide con lo calculado a mano, pregunten por qué.