ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Día 7 — Pipelines, automatización y forecasting económico



Módulo 3: Machine Learning Aplicado

Jonathan Rosero Soto

Edificio Aulas y Relación con el Medio Externo, Av. Toledo N23-55 y Madrid
Telf.: +593 2 2525766 - Ext: 102 / 125 / 143 / 120 / 127 - www.cec-epn.edu.ec

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ruta de la jornada

1	**¿Qué es automatizar un análisis?**	Del paso a paso manual al flujo reproducible
2	**El Pipeline, pieza por pieza**	ColumnTransformer, fit, predict e hiperparámetros
3	**Guardar, reutilizar e informar**	joblib, solicitudes nuevas, segmentos y un informe semanal
4	**Series de tiempo**	Tendencia, estacionalidad y ruido
5	**Rezagos y división cronológica**	Construir la tabla sin mirar el futuro
6	**Líneas base y modelo**	Ingenua, estacional, promedio móvil y regresión
7	**Validar en el tiempo y elegir**	TimeSeriesSplit, bosques que no extrapolan y Test
8	**Comparación final y cierre**	Cuatro series, cinco modelos y el recorrido del módulo

Regla del día: *si un paso se hace a mano cada vez, tarde o temprano se hará mal.*

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

1

¿Qué es automatizar un análisis?

Que el mismo procedimiento dé siempre el mismo resultado, sin pasos a mano

En esta sección

- **El problema**
- **La forma manual**
- **El error típico**

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Un análisis que se repite cada semana

1	**Rellenar faltantes**	Tasa de interés y antigüedad laboral, con la mediana de Train.
2	**Codificar categorías**	Tipo de vivienda, propósito, grado y antecedentes: One-Hot con las categorías de Train.
3	**Aplicar el modelo**	Random Forest entrenado con Train.
4	**Informar**	Probabilidad, decisión y resumen por grado de riesgo.

Automatizar = el procedimiento se guarda y se ejecuta igual cada vez, sin pasos a mano.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

La forma manual y el error típico

imputar
fit con Train → transform

→

codificar
fit con Train → transform

→

modelo
fit con Train → predict

Mediana de la tasa en Train
10,99 %

Mediana en el lote nuevo (D a G)
15,65 %

Decisiones que cambian
3 de 759

El problema no es el número: es que el resultado depende de quién y cómo ejecuta los pasos.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

2 El Pipeline, pieza por pieza

Todos los pasos y todo lo aprendido en un solo objeto

En esta sección

- Piezas
- fit y predict
- Mirar dentro
- Hiperparámetros

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Las piezas: ColumnTransformer y Pipeline

Datos crudos
11 columnas
con faltantes y texto

numéricas (7)
imputar mediana

categorías (4)
One-Hot

ColumnTransformer → 26 columnas

Modelo
Random Forest
200 árboles · prof. 12

fit (con Train)

Aprende medianas, categorías y árboles, en orden.

predict (con datos nuevos)

Aplica lo aprendido, sin volver a aprender.

¿Qué guarda un Pipeline entrenado?

Columna	Mediana aprendida
Edad	26
Ingreso	55 000
Antigüedad laboral	4 años
Monto	8 000
Tasa de interés	**10,99 %**
Cuota / ingreso	0,15
Historial crediticio	4 años

Además guarda
las categorías de las 4 variables de texto
y los 200 árboles del bosque

F1 Validation a mano
0,831

F1 Validation Pipeline
0,831

Mismo resultado, una línea y sin posibilidad de mezclar medianas.

Los hiperparámetros de un Pipeline

modelo__max_depth	F1 Train	F1 Validation	Brecha
4	0,692	0,698	−0,006
8	0,814	0,821	−0,007
12	0,848	**0,831**	0,017
20	**0,943**	0,836	**0,107**

Nombres

paso__hiperparámetro

modelo__max_depth

preparar__numericas__strategy

F1 Test (una vez)

0,817

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

3 Guardar, reutilizar e informar

Entrenar una vez, usar muchas

En esta sección

- joblib
- Solicitudes nuevas
- Segmentos
- Informe

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Guardar el flujo en un archivo

Entrenar
fit con Train

Guardar
joblib.dump → modelo_impago.joblib

Cargar
joblib.load, otro día

Usar
predict_proba con solicitudes nuevas

Solicitud	Edad	Ingreso	Grado	Cuota / ingreso	Tasa	Prob. impago	Decisión
1	25	18 000	D	0,50	16,5 %	**0,983**	**revisar**
2	41	85 000	A	0,07	**falta**	**0,040**	**aprobar**

La tasa faltante se rellenó sola con la mediana de Train (10,99 %) que el Pipeline guardó.

El mismo principio para los segmentos del Día 4

Logaritmo
FunctionTransformer(log1p) en los 7 montos

→

Estandarizar
medias y desviaciones

→

K-Means
4 centros

Cliente	Saldo	Compras	Avances	Frec.	% pago total	Segmento
Ana	2 500	0	3 000	0,0	0,0	Usuarios de avances
Beto	50	800	0	1,0	1,0	Totaleros
Carla	150	100	0	0,3	0,0	Poco activos

Clientes por segmento: 2 770 compradores que financian · 2 444 poco activos · 2 438 avances · 1 297 totaleros.

Un informe semanal en una función

1	**Cargar**	modelo guardado + archivo de la semana
2	**Puntuar**	predict_proba: el Pipeline hace toda la preparación
3	**Decidir y guardar**	umbral 0,5 → revisar / aprobar; CSV con el detalle
4	**Resumir**	solicitudes, a revisar y probabilidad promedio por grado

Grado	A	B	C	D	E	F
Solicitudes	164	168	97	52	16	3
A revisar	18	22	6	19	9	1
Prob. promedio	0,14	0,20	0,18	**0,49**	**0,63**	**0,50**

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Lista de control de un análisis automatizado

Reproducible

Mismo archivo → mismo resultado; semillas fijas.

Sin fugas

Todo lo que aprende, dentro del Pipeline y solo con Train.

Guardado

Modelo en un archivo, con fecha y versión.

Documentado

Datos, preparación, métrica y umbral, por escrito.

Vigilado

Medir el desempeño con datos nuevos cada cierto tiempo.

Revisable

El modelo sugiere; una persona decide.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

4 Series de tiempo

Cuando el orden de las filas es la información

En esta sección

- **Qué cambia**
- **Los datos**
- **Componentes**
- **Frecuencia**

Serie de tiempo frente a tabla transversal

	Tabla transversal (Credit Risk)	Serie de tiempo (actividad)
Una fila es…	Un préstamo	Un mes
¿Importa el orden?	No	**Sí: es la información**
Predictores	Características del préstamo	El pasado de la serie (rezagos) y el calendario
División	Al azar, estratificada	**Cronológica: pasado → futuro**
Validación cruzada	KFold, StratifiedKFold	**TimeSeriesSplit**

Es una regresión (la respuesta es un número), pero con la regla de oro: el futuro no se usa para predecir.

Los datos: 144 meses de cuatro indicadores

Columna	Qué es (en la simulación)	Rango
indice_actividad	**Índice de actividad: nuestro objetivo**	87 a 126
exportaciones_mill	Exportaciones del mes, millones de USD	≈ 760 a 1 290
precio_petroleo_usd	Precio del barril, USD	≈ 37 a 88
inflacion_interanual_pct	Inflación de los últimos 12 meses, %	≈ 0,4 a 3,8

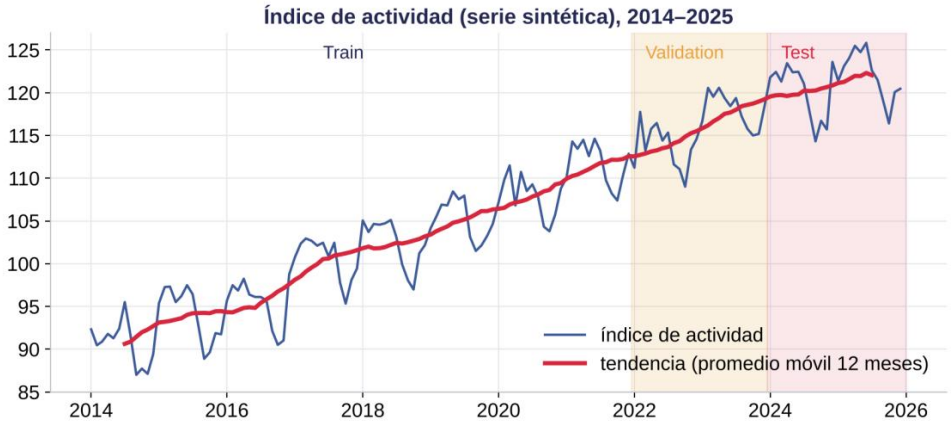
Meses

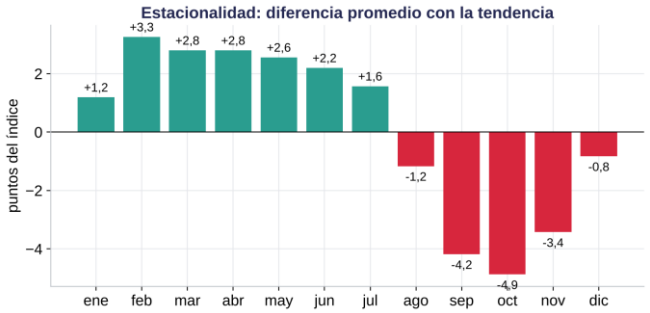
144 · 2014–2025

Tipo de dato

SINTÉTICO DIDÁCTICO

Tendencia, estacionalidad y ruido





Tendencia

Dirección de largo plazo: promedio móvil de 12 meses.

Estacionalidad

Patrón anual: octubre −4,9; febrero +3,3.

Ruido

Lo que queda: no se puede pronosticar.

Control previo: 144 meses esperados, 144 en el archivo, 0 faltantes. Si faltara uno, «el mes anterior» sería falso.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

5

Rezagos y división cronológica

Convertir una serie en una tabla sin mirar el futuro

En esta sección

- **Rezagos**
- **Verificar**
- **Fuga**
- **División**

Construir la tabla: rezagos y objetivo

Origen (mes t)	rezago_1	rezago_2	rezago_3	rezago_12	mes a pronosticar	objetivo
oct-2014	87,73	87,00	91,58	—	nov	87,12
nov-2014	87,12	87,73	87,00	—	dic	89,43
dic-2014	89,43	87,12	87,73	92,32	ene	95,39
ene-2015	95,39	89,43	87,12	90,46	feb	**97,27**

Columna	Se construye con	Significado
rezago_k	serie.shift(k − 1)	valor conocido hace k − 1 meses
mes_m	calendario	1 si el mes a pronosticar es m
objetivo	**serie.shift(−1)**	el mes siguiente (solo la respuesta)

Verificar una fila a mano

Columna	Mes de la serie	Valor
rezago_1	ene-2015 (el último conocido)	95,39
rezago_2	dic-2014	89,43
rezago_3	nov-2014	87,12
rezago_12	feb-2014 (mismo mes, un año antes)	90,46
mes_2	pronosticamos febrero	1
objetivo	**feb-2015**	**97,27**

Filas útiles

132

144 − 11 sin historia − 1 sin objetivo

Si una fila no coincide con la serie, hay un error de desplazamiento: se corrige antes de modelar.

La fuga temporal: el error más caro

Predictor del futuro

shift(−1) en una X, o un dato publicado después del mes t.

Preparar con toda la serie

Escalar o imputar con Validation y Test incluidos.

Mezclar meses al azar

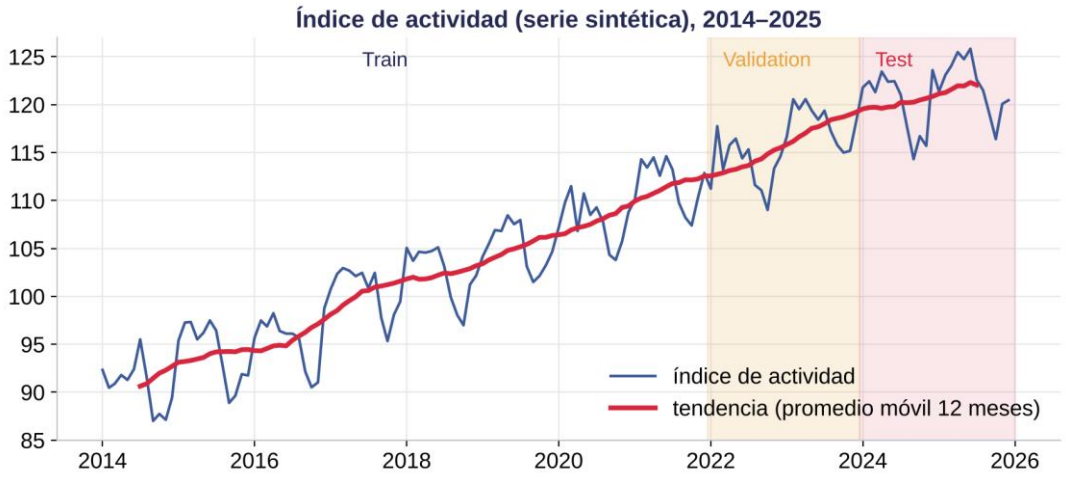
Entrenar con 2023 y validar con 2019.

Señal de alarma

Un pronóstico «demasiado bueno»: revisa los desplazamientos.

Pregunta de control: «¿tendría este dato el último día del mes t?» Si la respuesta es no, no puede ser predictor.

División cronológica



Parte	Pronostica	Meses
Train	feb-2015 a dic-2021	84
Validation	ene-2022 a dic-2023	24
Test	ene-2024 a dic-2025	24

Siempre: entrenar con el pasado, validar con lo que viene después. Igual que en la vida real.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

6

Líneas base y modelo

Reglas simples que un modelo debe superar

En esta sección

- Tres líneas base
- Regresión a mano
- Rezagos + mes
- Métricas

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Tres líneas base temporales, a mano

Línea base	Regla	Enero 2022	Error	MAE Validation (24 meses)
Ingenua	último valor	112,87	1,64	**2,07**
Estacional ingenua	mismo mes, un año antes	110,08	1,15	**3,15**
Promedio móvil 3	(112,87 + 110,36 + 107,39) / 3	110,21	1,02	2,29

Real de enero 2022

111,23

Un mes no basta: en enero ganó el promedio móvil; en los 24 meses, la ingenua.

La estacional pierde porque ignora la tendencia: hace un año el índice estaba más abajo.

Regresión a mano: un rezago

Mínimos cuadrados

$b = \Sigma(x - \bar{x})(y - \bar{y}) / \Sigma(x - \bar{x})^2$

b = 0,923

$a = \bar{y} - b \cdot \bar{x}$

a = 8,11

Enero 2022

8,11 + 0,923 × 112,87

= 112,33

real: 111,23

Con un solo rezago el modelo ≈ la ingenua. Para la estacionalidad agregamos el rezago 12 y el mes.

Regresión con rezagos y calendario

Rezago	1	2	3	12
Coeficiente	0,363	0,312	0,249	0,071

Mes	ene	feb	mar	abr	may	jun	jul	ago	sep	oct	nov	dic
Efecto	+4,3	+3,6	+1,8	−0,4	−0,4	−0,4	−1,0	−2,9	**−4,6**	**−3,4**	+0,5	+2,9

Lectura: los rezagos dan el nivel (tendencia); el mes, la estacionalidad.

Métricas de pronóstico: MAE, RMSE y MAPE

Métrica	Fórmula	Se lee como…
MAE	promedio de |real − pronóstico|	error típico, en puntos
RMSE	√ promedio de (real − pronóstico)²	castiga los errores grandes
MAPE	promedio de |real − pronóstico| / real	error en %

Modelo	MAE Train	MAE Validation	RMSE Validation
Ingenua	1,90	2,07	2,57
Estacional ingenua	3,18	3,15	3,59
Promedio móvil 3	2,74	2,29	2,80
Regresión (rezagos + mes)	1,05	**1,29**	**1,58**

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

7 Validar en el tiempo y elegir

Validación cruzada que no mira el futuro

En esta sección

- TimeSeriesSplit
- Rezagos × modelo
- Bosques
- Test
- Comunicar

TimeSeriesSplit: validación cruzada en orden



→ el tiempo avanza hacia la derecha; Test (2024–2025) sigue aparte

Hiperparámetro	Qué controla
n_splits	Cuántas vueltas
test_size · gap	Meses que valida cada vuelta · meses que se saltan

Rezagos × modelo: ¿qué historia mirar?

Variables	Regresión lineal	Random Forest
1 rezago	2,10	3,15
3 rezagos	2,19	3,29
3 rezagos + 12	1,63	2,44
3 rezagos + 12 + mes	**1,30**	2,44
Línea base ingenua	2,14	2,14

MAE promedio de 4 vueltas de TimeSeriesSplit. Elegimos la regresión con 3 rezagos + 12 + mes.

¿Por qué el bosque pierde? No puede extrapolar

Árbol / bosque

Pronostica promedios de valores ya vistos.

Techo: el máximo de Train.

Con tendencia creciente, se queda corto.

Regresión lineal

a + b·x: puede seguir la tendencia más allá de lo visto.

Captura la estacionalidad con el mes.

Mejor bosque optimizado (MAE)

2,40

Regresión con rezagos + mes (MAE)

1,30

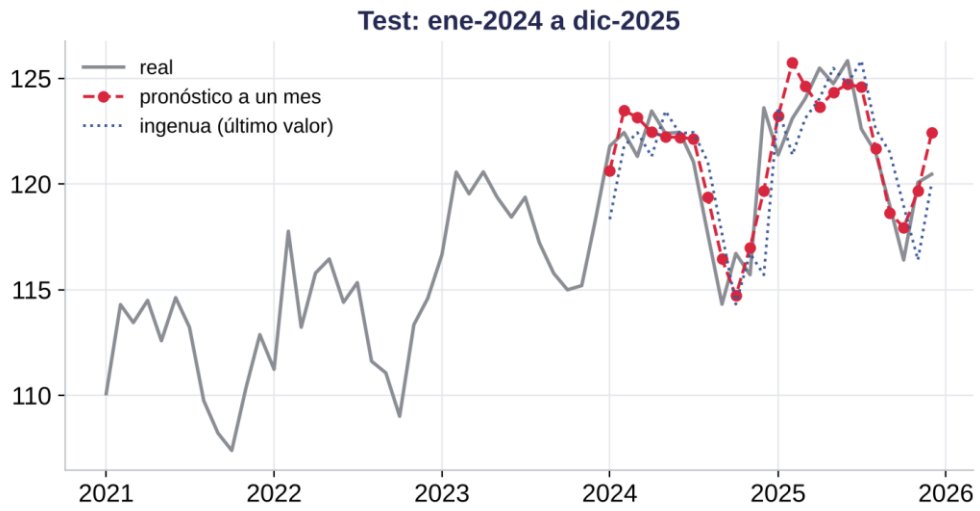
Lección: el mejor modelo depende de la forma de los datos, no de su complejidad.

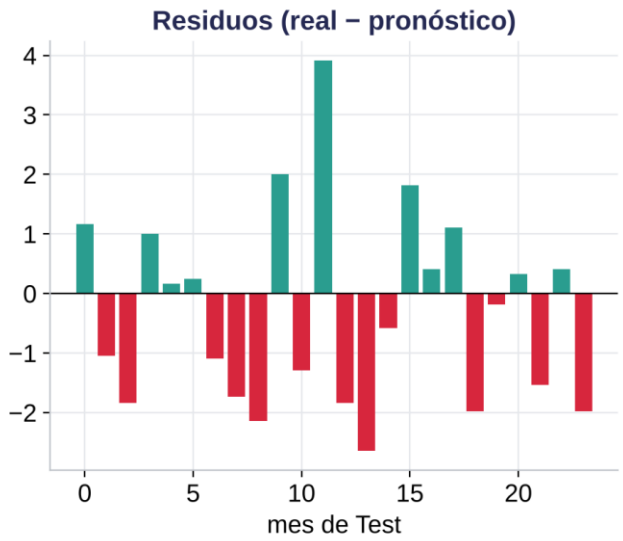
ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Test, una sola vez: 2024 y 2025





MAE Test	MAPE Test	Ingenua (MAE)	Residuo promedio
1,35	1,12 %	2,07	−0,30

Comunicar un pronóstico

«Con la información disponible a fin de cada mes, el modelo pronostica el índice de actividad del mes siguiente con un error típico de 1,35 puntos (≈ 1,1 %), un 35 % menos que repetir el último valor. No muestra un sesgo sistemático. Es un pronóstico a un mes: para horizontes más largos el error crece. Datos simulados con fines didácticos.»

Parte del mensaje	En este caso
Qué y cuándo	Índice de actividad, un mes adelante
Con qué error	MAE 1,35 puntos · MAPE 1,1 %
Frente a qué	35 % menos que la línea base ingenua
Sesgo	No: residuo promedio −0,30
Limitaciones	Horizonte de un mes; datos sintéticos

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

8

Comparación final y cierre

Cuatro series, cinco modelos y el recorrido del módulo

En esta sección

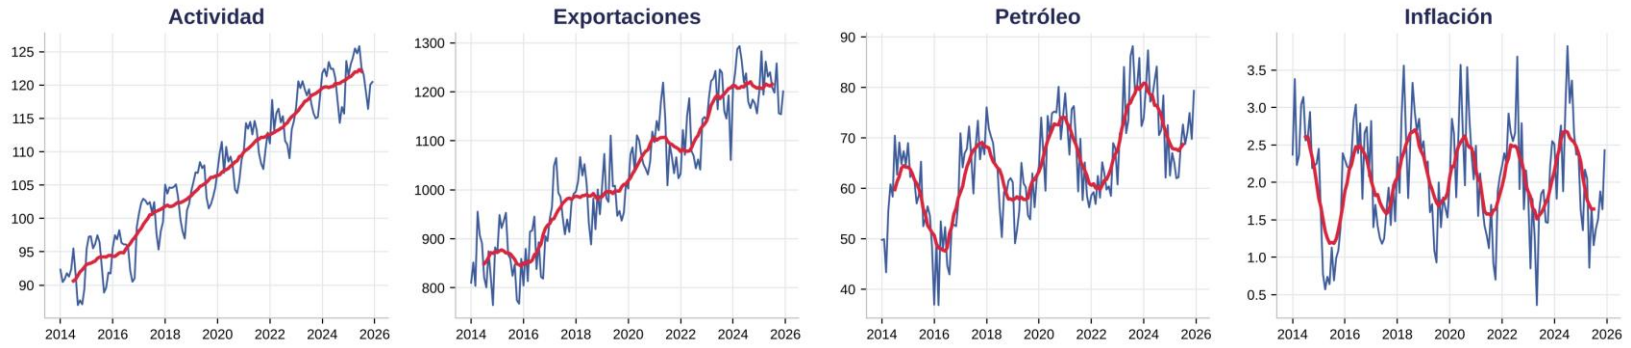
- Cuatro series
- Ganadores
- Por qué
- El módulo

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

El mismo flujo en cuatro series



MAE / MAE ingenua (Validation)	Actividad	Exportaciones	Petróleo	Inflación
Ingenua	1,00	1,00	1,00	1,00
Estacional ingenua	1,52	1,67	2,34	1,80
Promedio móvil 3	1,11	1,09	**0,89**	0,87
Regresión lineal	**0,62**	**0,85**	1,18	**0,86**
Random Forest	**1,57**	**1,33**	0,98	0,90

Un ganador distinto según la forma de la serie

Serie	Forma	Ganador	MAE Val.	MAE Test	Ingenua Test
Actividad	tendencia + estacionalidad	**Regresión lineal**	1,29	1,35	2,07
Exportaciones	tendencia + estacionalidad	**Regresión lineal**	39,2	36,2	42,4
Petróleo	paseo aleatorio	**Promedio móvil 3**	4,87	4,72	5,64
Inflación	muy ruidosa	**Regresión lineal**	0,49	0,50	0,53

Con tendencia

La regresión extrapola y capta la estacionalidad.

Sin patrón

Una regla simple puede ganar: el petróleo.

Bosques

Peores que la ingenua si la serie crece.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ideas clave del día

1

Pipeline

Guarda pasos y todo lo aprendido; fit con Train, predict con lo demás.

2

Automatizar

joblib guarda el flujo; una función produce el informe. Reproducible y sin fugas.

3

Rezagos

shift(k) trae el pasado; shift(−1) solo para el objetivo. Verifica una fila a mano.

4

El tiempo manda

División cronológica y TimeSeriesSplit: entrenar con el pasado, validar con lo que sigue.

5

Líneas base

Ingenua, estacional y promedio móvil. A veces una regla simple gana.

6

Forma de la serie

Con tendencia, la regresión extrapola; los bosques no.

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

El recorrido del módulo

1 Regresión lineal y limpieza

2 Árboles y bosques de regresión

3 Clasificación: árbol, bosque, KNN, SVM

4 Clustering: K-Means y jerárquico

5 PCA, selección e ingeniería

6 Visualización y optimización

7 Pipelines y forecasting

Siempre
línea base · validar · Test una vez · explicar

La pregunta que se lleva: ¿mi modelo le gana a una regla simple, con datos que no vio, y puedo explicar por qué?

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Del papel al notebook

Lo que hicimos a mano	Lo que verán en el notebook	Debe dar…
La mediana equivocada	Imputador ajustado con el lote nuevo	10,99 frente a 15,65 · 3 cambian
Pipeline	fit y predict en una línea	F1 Validation 0,831 · Test 0,817
Solicitudes nuevas	joblib.load + predict_proba	0,983 revisar · 0,040 aprobar
Fila de enero 2015	Tabla de rezagos	95,39 · 89,43 · 87,12 · 90,46 → 97,27
Líneas base	MAE en Validation	2,07 · 3,15 · 2,29
Regresión a mano	a y b con mínimos cuadrados	8,11 + 0,923·x
Test	Pronóstico 2024–2025	MAE 1,35 · ingenua 2,07
Cuatro series	MAE relativo a la ingenua	0,62 · 0,85 · 0,89 · 0,86

Su rol con el agente de IA

Pidan que explique cada línea y verifiquen los números. Si un resultado no coincide con lo calculado a mano, pregunten por qué.