ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Día 1 — Datos, Visualización y Regresión Lineal



Módulo 3: Machine Learning Aplicado

13-10-2026 · Jonathan Rosero Soto

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Ruta de la jornada



El ciclo de trabajo que repetiremos en cada problema de Machine Learning

1 Herramientas
NumPy, Pandas y Matplotlib: representar, resumir y ver los datos

2 Dataset y calidad
Qué contiene el archivo, por qué limpiarlo y cómo hacerlo

3 Relación entre variables
Correlación de Pearson y lectura de gráficos de dispersión

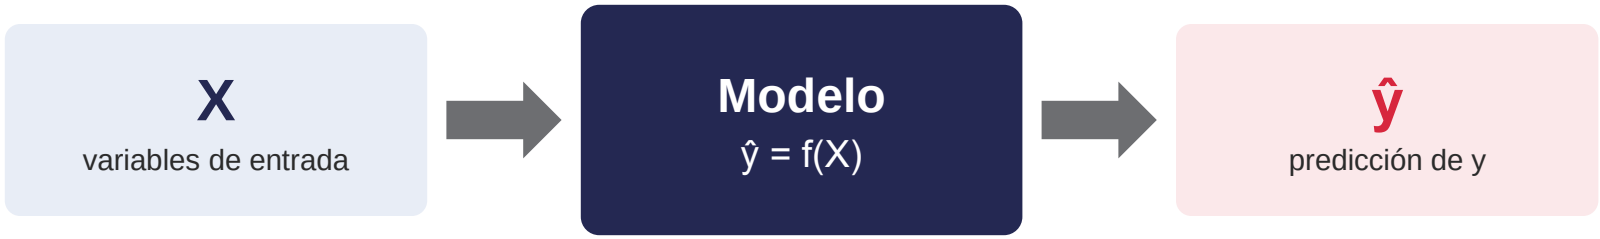
4 Regresión lineal simple
La recta, los residuos y los mínimos cuadrados

5 Medir errores
MAE, MSE, RMSE, Bias y R^2: qué pregunta responde cada una

6 Train / Validation / Test
Cómo saber si el modelo funciona con datos nuevos

7 Regresión múltiple
Del plano al hiperplano y variables categóricas (One-Hot)

Estadística y ML: mismo problema, otro vocabulario



Aprendizaje supervisado: **aprendemos f a partir de ejemplos donde conocemos X y también la respuesta real y**

En estadística decimos…	En Machine Learning decimos…
Variable dependiente / respuesta	Target, etiqueta, variable objetivo (y)
Variables independientes / regresoras	Features, atributos, predictores (X)
Observación / unidad muestral	Fila, ejemplo, instancia
Estimar los parámetros	Entrenar o ajustar el modelo (fit)
Valor ajustado / pronóstico	Predicción (predict)
Muestra de estimación	Conjunto de entrenamiento (Train)
Validación fuera de muestra	Validation y Test

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

1

Herramientas antes del modelo

NumPy, Pandas y Matplotlib: cómo Python representa, resume y muestra los datos

En esta sección

- **NumPy: vectores y matrices**
- **Pandas: tablas y diagnóstico**
- **Matplotlib: 4 gráficos básicos**

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cuatro herramientas, cuatro tareas

np

NumPy · Calcula

Vectores y matrices. Operaciones sobre todos los datos a la vez.

Como una calculadora matricial

pd

Pandas · Organiza

Tablas (DataFrame) con nombres, tipos, fechas y herramientas de limpieza.

Como una hoja de datos de SPSS o Excel

plt

Matplotlib · Muestra

Gráficos: línea, histograma, dispersión, boxplot, 3D…

Como el papel milimetrado del analista

sklearn

Scikit-learn · Modela

Algoritmos (LinearRegression…), particiones y métricas.

La caja de herramientas de modelos

+ statsmodels: inferencia estadística (errores estándar, intervalos, p-valores) para complementar.

NumPy: pensar en vectores, no en bucles

ventas (vector de 5 elementos)

105	112	118	109	125

+ 10

115	122	128	119	135

Una sola instrucción, ventas + 10, transforma los 5 valores (vectorización).

113.8
Media
`ventas.mean()`

7.03
Desv. estándar
`ventas.std()` · divide para n

(5,)
Forma
`ventas.shape` · 1 dimensión

Ojo estadístico: NumPy calcula la desviación estándar poblacional (divide para n). Pandas usa la muestral (divide para n − 1).

La matriz de datos X: n filas × p columnas

	x_1	x_2
observación 1	100	60
observación 2	120	65
observación 3	140	70

n = 3 filas

p = 2 columnas (variables)

```
X_demo.shape  →  (3, 2)
```

En estadística

Es la **matriz de diseño** X de tamaño n × p.

y es un vector n × 1 con la respuesta.

En scikit-learn

X siempre es **2D** (aunque tenga una sola variable):

`df[['inversion_mill']]`

y es 1D: `df['crecimiento']`

Pandas: el DataFrame, una tabla con significado

Índice (etiqueta de fila)

Nombres de columnas = variables

	mes	inversion_mill	crecimiento_pct
0	ene	100	1.1
1	feb	120	1.6
2	mar	140	2.0

Una fila = una observación

object (texto) int64 (entero) float64 (decimal)

dtypes: Pandas asigna un tipo a cada columna

NumPy → solo números en posiciones. **Pandas** → números + nombres + tipos + fechas + categorías.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

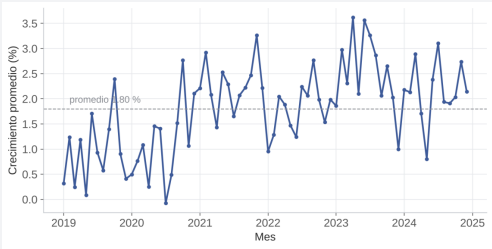
Pandas como herramienta de diagnóstico

Función	Pregunta que responde	En nuestro dataset
`df.shape`	¿Cuál es el tamaño de la muestra (n, p)?	(289, 11)
`df.dtypes / df.info()`	¿Qué tipo de variable es cada columna? ¿Cuántos datos no nulos hay?	fecha llega como texto
`df.describe()`	Estadísticos descriptivos: media, desviación, mínimo, cuartiles, máximo	máx. crecimiento = 15 %
`value_counts()`	Tabla de frecuencias de una variable categórica	Agro: solo 34 filas
`isna().sum()`	¿Cuántos valores faltan por columna?	8 celdas vacías
`duplicated()`	¿Hay filas repetidas exactamente?	1 duplicado
`corr()`	Matriz de correlación de Pearson	inversión: r = 0.41

Si max está muy lejos del percentil 75 % → posible atípico: una señal para investigar, no una orden para borrar.

Matplotlib: cada gráfico responde una pregunta

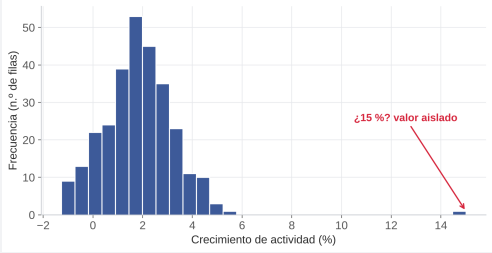
Línea



`plt.plot()`

¿Cómo cambia en el tiempo?

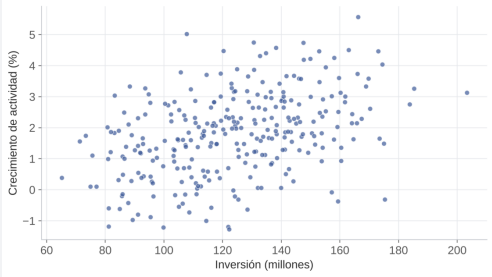
Histograma



`plt.hist()`

¿Cómo se distribuye una variable?

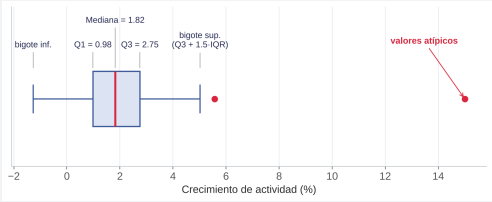
Dispersión



`plt.scatter()`

¿Cómo se relacionan dos variables?

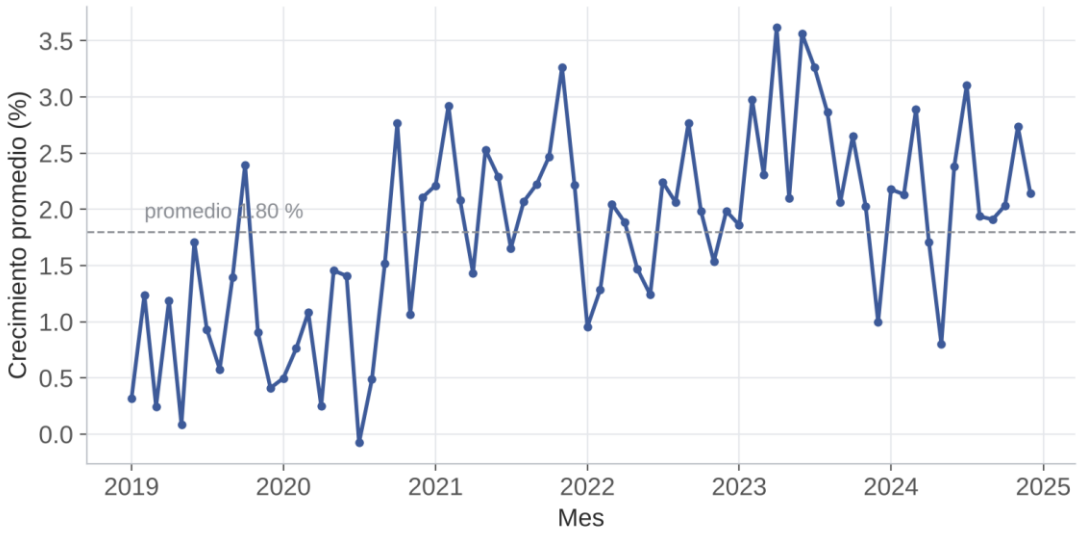
Boxplot



`plt.boxplot()`

¿Dónde está el centro, la dispersión y los atípicos?

Gráfico de línea: ¿cómo cambia en el tiempo?



Promedio mensual del crecimiento de actividad (dataset limpio, 2019–2024)

Tendencia

¿Sube, baja o se mantiene a largo plazo?

Variabilidad

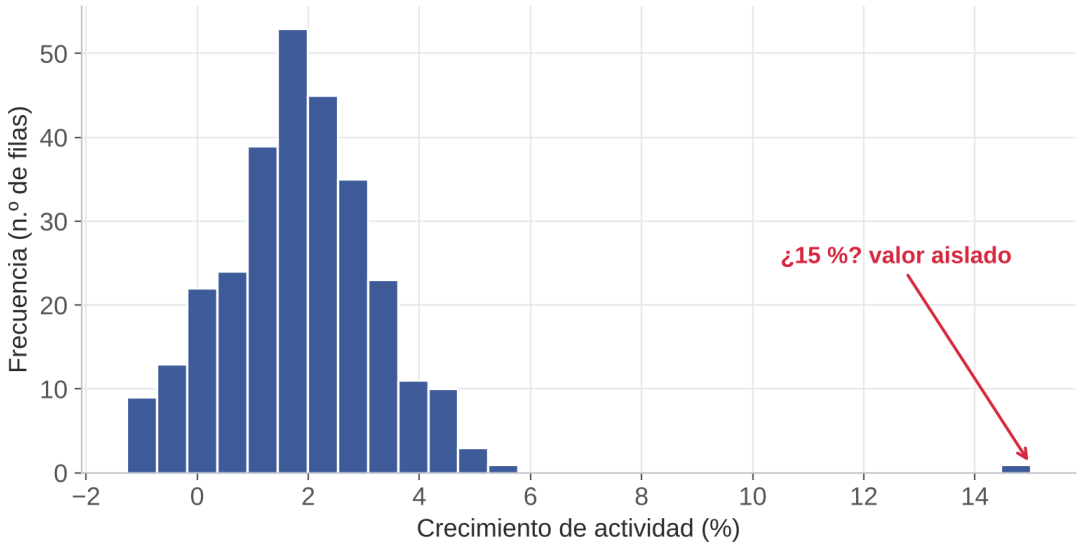
¿Los picos y valles son grandes o pequeños?

Cambios

¿Hay saltos, rupturas o estacionalidad?

Lectura: el crecimiento promedio oscila alrededor de 1.8 % sin una tendencia clara; la variación mes a mes es grande.

Histograma: ¿cómo se distribuye una variable?



Crecimiento de actividad, dataset original (289 filas, 30 intervalos)

Centro

La mayoría de valores entre 0 % y 4 %

Forma

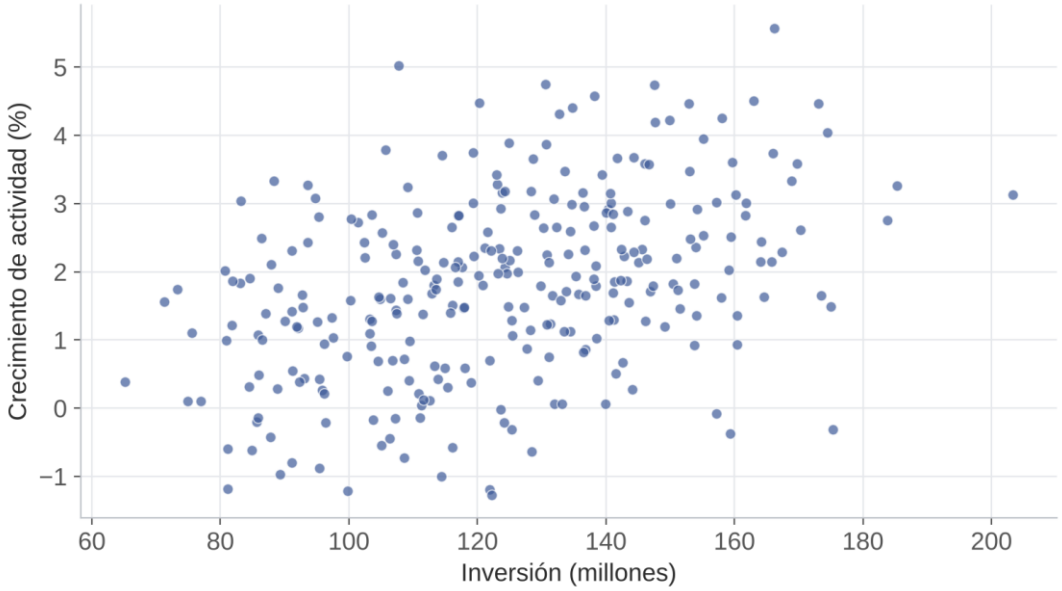
Aproximadamente simétrica, en campana

Aislados

Un valor de 15 %, muy lejos del resto

Clave: el número de intervalos (bins) cambia la apariencia; pruebe varios antes de concluir sobre la forma.

Diagrama de dispersión: ¿se relacionan dos variables?



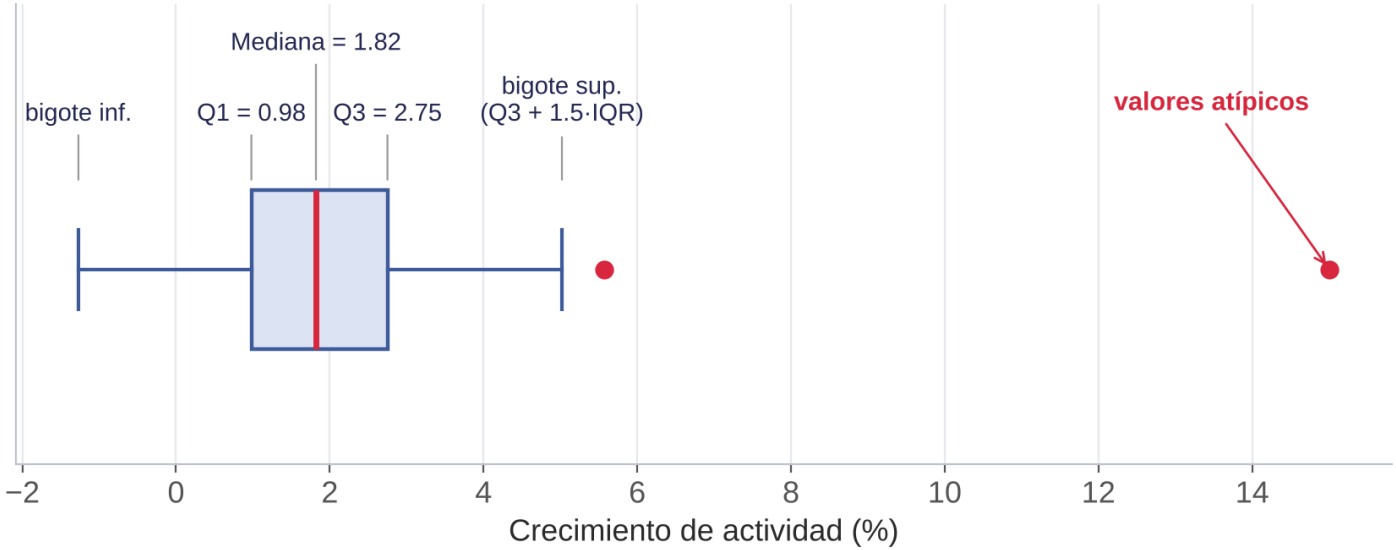
Inversión vs crecimiento de actividad (dataset limpio, 287 puntos)

Preguntas al mirarlo

1. ¿La nube sube, baja o no tiene dirección?
2. ¿Parece una recta o una curva?
3. ¿Hay grupos separados?
4. ¿La dispersión crece con X?
5. ¿Hay puntos aislados?

Lectura: la nube sube suavemente: más inversión se asocia con más crecimiento, pero con mucha dispersión.

Boxplot: el resumen de cinco números



Estadístico	Valor	Cómo se obtiene
Q1 (percentil 25)	0.98	25 % de los datos está por debajo
Mediana (Q2)	1.82	Divide los datos en dos mitades
Q3 (percentil 75)	2.75	75 % de los datos está por debajo
IQR = Q3 − Q1	1.77	Ancho de la caja: dispersión robusta
Límite superior	5.41	Q3 + 1.5 × IQR → 2 valores lo superan

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

2

El dataset y la calidad de los datos

Qué contiene el archivo, qué representa cada fila y por qué debemos limpiarlo antes de modelar

En esta sección

- **Estructura y variables**
- **Dimensiones de calidad**
- **Faltantes, atípicos y duplicados**
- **Flujo de limpieza**

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

El dataset conductor: actividad_economica_demo.csv

289	11	72	4 × 4
filas observaciones	**columnas** variables	**meses** ene-2019 a dic-2024	**grupos** regiones × sectores

¿Qué queremos predecir?

La variable objetivo **y = crecimiento_actividad_pct**

a partir de indicadores económicos, la región y el sector.

¿Para qué lo usamos?

Para **practicar el método**, no para obtener conclusiones económicas reales sobre Ecuador.

Sintético: contiene errores insertados a propósito (faltantes, duplicados, un atípico) para aprender a detectarlos.

Unidad de observación: ¿qué representa una fila?

Mes enero 2019 + **Región** Costa + **Sector** Servicios = **1** fila

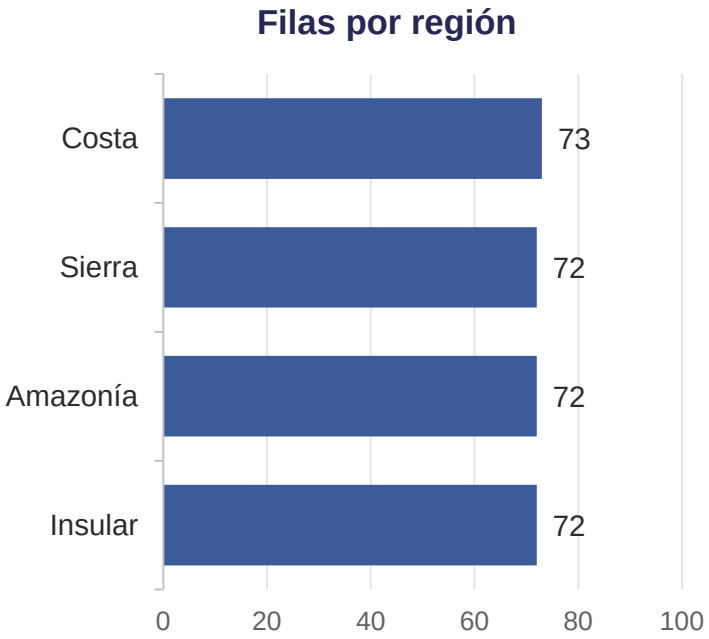
Variable	Valor (fila 0)	Variable	Valor (fila 0)
fecha	2019-01-01	inversion_mill	74.86
region	Costa	precio_petroleo_usd	42.80
sector	Servicios	indice_confianza	42.42
inflacion_pct	2.33	tipo_dato	SINTETICO_DIDACTICO
desempleo_pct	6.75	**crecimiento_actividad_pct**	**0.10**
exportaciones_mill	231.63		

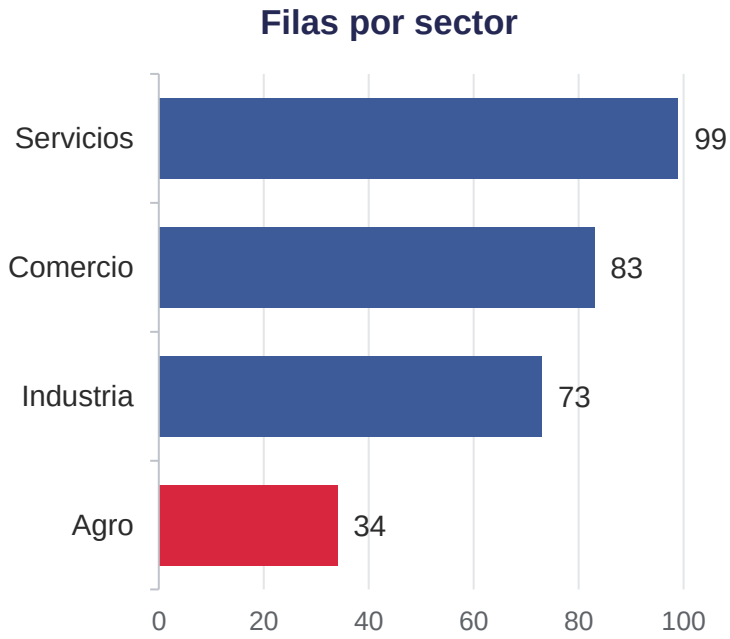
Se lee así: **“En enero de 2019, el sector Servicios de la Costa creció 0.10 %, con inversión de 74.86 millones…”**

Diccionario de variables: tipo y rol de cada columna

Variable	Tipo estadístico	Rol en el modelo	Unidad
crecimiento_actividad_pct	Cuantitativa continua	**Objetivo (y)**	%
inversion_mill	Cuantitativa continua	Predictora (X)	millones USD
exportaciones_mill	Cuantitativa continua	Predictora (X)	millones USD
precio_petroleo_usd	Cuantitativa continua	Predictora (X)	USD / barril
inflacion_pct · desempleo_pct	Cuantitativa continua	Predictora (X)	%
indice_confianza	Cuantitativa (índice)	Predictora (X)	puntos
region · sector	Cualitativa nominal	Predictora (requiere One-Hot)	categoría
fecha	Temporal	Identifica el periodo	mes
tipo_dato	Constante (1 valor)	**Se elimina**	texto

¿Cuántas observaciones tiene cada grupo?





Balanceado

Cada región aporta información similar.

Desbalanceado

Pocas filas → estimaciones más inestables.

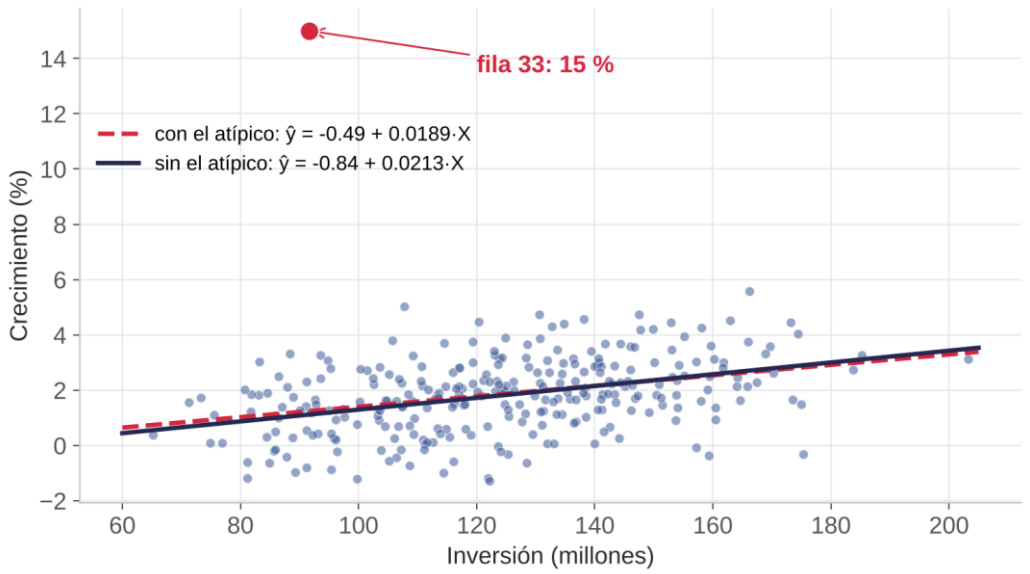
ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Por qué limpiar?

Datos con errores → **Modelo** → **Conclusiones sesgadas**



Pendiente sin el atípico

0.0213

Pendiente con el atípico

0.0189

1 fila de 289 (0.3 % de los datos) mueve la recta y también infla la media, la varianza y el RMSE.

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Las dimensiones de la calidad de datos

C Completitud

¿Faltan valores?

Aquí: **8 celdas vacías**

U Unicidad

¿Hay filas repetidas?

Aquí: **1 fila duplicada**

V Validez

¿Los valores son posibles?

Aquí: **desempleo entre 0 y 100 %**

E Exactitud

¿El valor es real o un error?

Aquí: **crecimiento de 15 %**

C Consistencia

¿Tipos y formatos correctos?

Aquí: **fecha llegó como texto**

P Pertinencia

¿La columna aporta información?

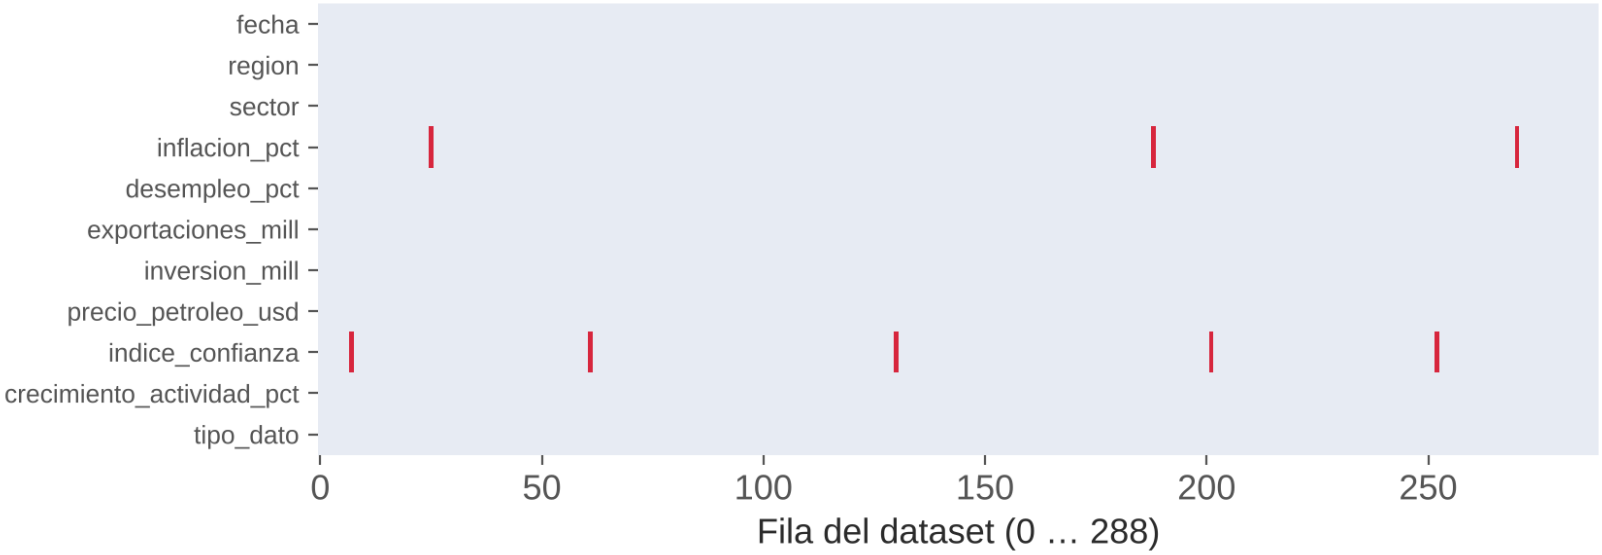
Aquí: **tipo_dato es constante**

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Radiografía de los valores faltantes



3

faltantes en inflacion_pct

5

faltantes en indice_confianza

0.25 %

de las 3 179 celdas

¿Por qué falta un dato? Y ¿qué hacemos con él?

MCAR

Completamente al azar

Ej.: *Se perdió una hoja del registro*

MAR

Depende de otra variable observada

Ej.: *Una región reporta menos la confianza*

MNAR

Depende del propio valor

Ej.: *Las empresas con malos resultados no reportan*

Estrategia	Ventaja	Riesgo
Eliminar filas	Simple	Perdemos información y podemos sesgar la muestra
Imputar con la media	Conserva n	Sensible a atípicos; reduce la varianza
Imputar con la mediana (elegida)	Robusta a atípicos	También reduce la varianza
Imputar con un modelo	Usa otras variables	Más complejo; riesgo de fuga de datos

inflacion_pct: media 1.91 · mediana 1.97 *indice_confianza: media 44.54 · mediana 44.92*

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Valores atípicos: detectar, investigar, decidir

Regla del IQR

Atípico si $x > Q3 + 1.5 \cdot IQR$ o $x < Q1 - 1.5 \cdot IQR$

Aquí: límite superior = $2.75 + 1.5 \cdot 1.77 =$ **5.41**

Regla del z-score

$z = (x - \text{media}) / \text{desviación}$

Atípico si $|z| > 3$. Sensible al propio atípico, que infla la media y la desviación.

1 Detectar
boxplot, IQR, describe(), nlargest()

→

2 Investigar
¿plausible? ¿error de captura? ¿qué fila?

→

3 Decidir
corregir, eliminar o conservar y documentar

Caso en el dataset	Valor	Decisión
Fila 33: Sierra · Comercio · sep-2019	crecimiento = 15 %	**Eliminar (error insertado)**
Fila 199: Insular · Comercio · feb-2023	exportaciones = 1300	Investigar (¡queda como ejercicio!)

Duplicados y columnas sin información

Duplicado exacto: las filas 20 y 288 son idénticas

Fila	fecha	region	sector	inflación	inversión	crecimiento
20	2019-06-01	Costa	Comercio	4.07	71.28	1.56
288	2019-06-01	Costa	Comercio	4.07	71.28	1.56

Consecuencia

la observación pesa el doble y puede aparecer a la vez en Train y en Test.

Solución

drop_duplicates() conserva solo la primera aparición.

Columna sin aporte: tipo_dato vale “SINTETICO_DIDACTICO” en las 289 filas

SINTÉTICO	SINTÉTICO	SINTÉTICO	SINTÉTICO	SINTÉTICO

Varianza = 0

→ no explica nada; se elimina con drop(columns=…)

El flujo de limpieza aplicado



filas × columnas en cada paso

Lo que ganamos

- Cada observación cuenta una sola vez
- Sin valores imposibles que distorsionen la recta
- Todas las filas utilizables por el modelo

Evitar la fuga de datos

Calcule la mediana **solo con Train** y aplíquela después a Validation y Test. Así el modelo no “ve” información de los datos de evaluación.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

3

Relación entre variables

Correlación de Pearson: medir la fuerza y la dirección de una relación lineal

En esta sección

- **Fórmula e intensidad de r**
- **Correlaciones del dataset**
- **Correlación ≠ causalidad**

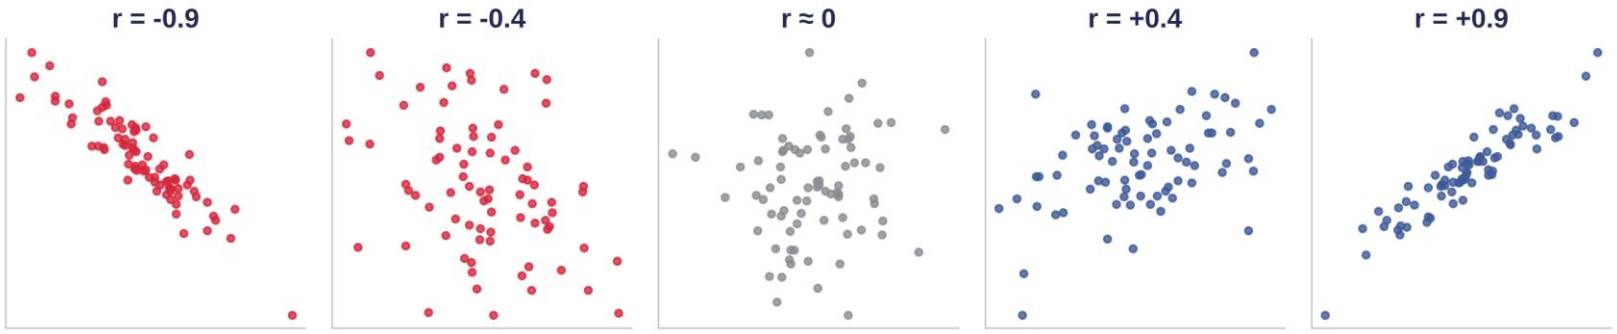
ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Coeficiente de correlación de Pearson

$$r = \Sigma (x_i - \bar{x})(y_i - \bar{y}) \;/\; \sqrt{[\,\Sigma(x_i - \bar{x})^2 \cdot \Sigma(y_i - \bar{y})^2\,]} \qquad -1 \le r \le 1$$

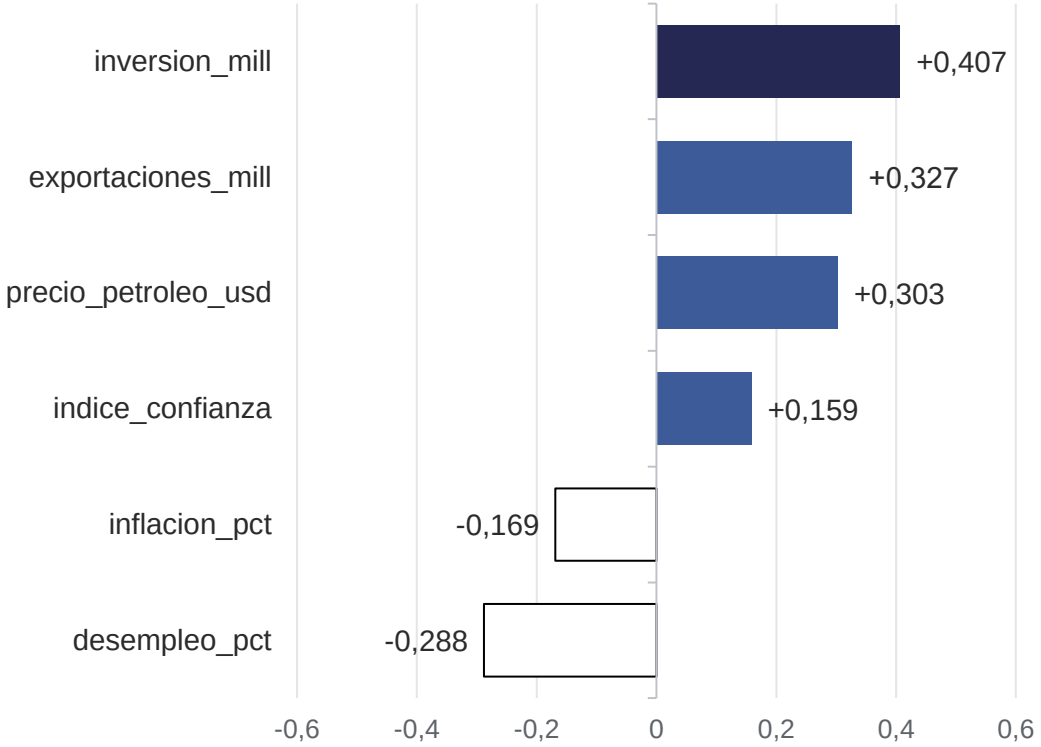


relación negativa ← *sin relación lineal* *→ relación positiva*

|r| 0 – 0.19	|r| 0.20 – 0.39	|r| 0.40 – 0.59	|r| 0.60 – 0.79	|r| 0.80 – 1
muy débil	débil	moderada	fuerte	muy fuerte

r ≈ 0 no significa "sin relación": puede existir una relación curva que Pearson no detecta.

¿Qué variable se relaciona más con el crecimiento?



Correlación de Pearson con crecimiento_actividad_pct

Positiva moderada

inversion_mill r = 0.41
más inversión, más crecimiento

Negativa débil

desempleo_pct r = −0.29
más desempleo, menos crecimiento

Correlación ≠ causalidad
Indica asociación; no prueba que una variable provoque a la otra.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

4

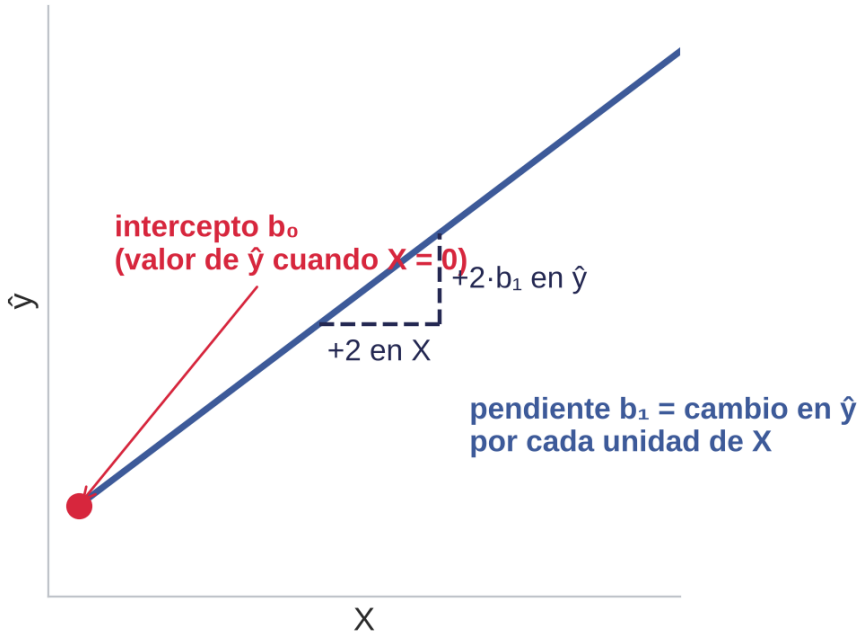
Regresión lineal simple

Una variable explicativa, una recta y el criterio de mínimos cuadrados

En esta sección

- **Ecuación y residuos**
- **Mínimos cuadrados (SSE)**
- **Interpretación de b_0 y b_1**
- **Supuestos LINE**

La idea: una recta que resume la nube de puntos

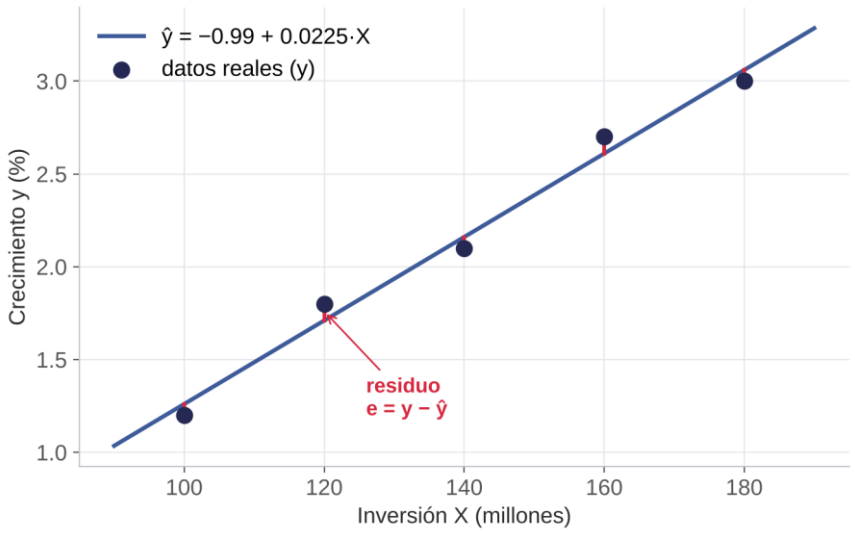


$$\hat{y} = b_0 + b_1 \cdot X$$

$\hat{y}$	valor predicho de y (crecimiento %)
b_0	intercepto: ŷ cuando X = 0
b_1	pendiente: cambio de ŷ por cada unidad de X
X	variable de entrada (inversión, millones)

Diferencia clave: y es el valor real observado; ŷ (“y sombrero”) es lo que predice el modelo. Nunca coinciden exactamente.

Residuo: la distancia entre lo real y lo predicho

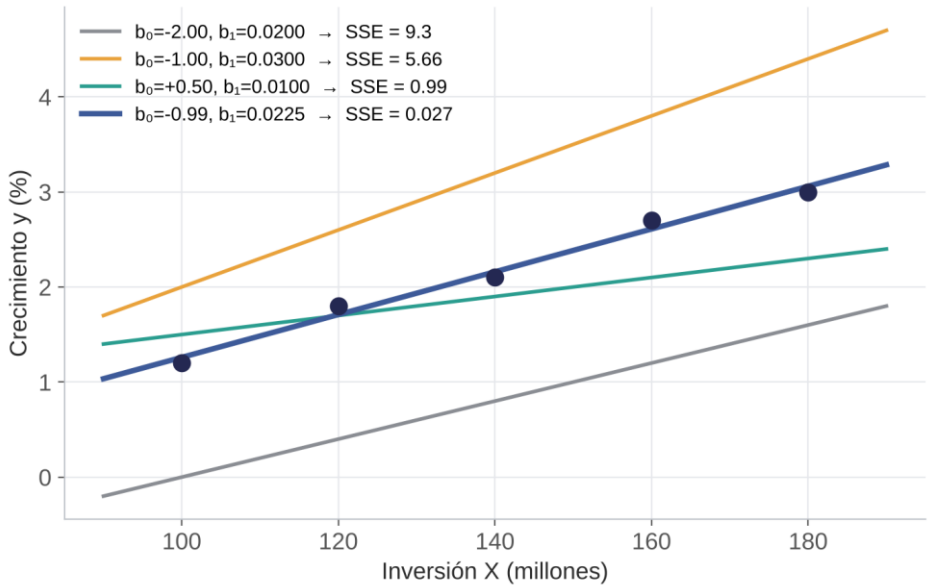


X	y real	ŷ	e = y − ŷ	e²
100	1.2	1.26	−0.06	0.0036
120	1.8	1.71	+0.09	0.0081
140	2.1	2.16	−0.06	0.0036
160	2.7	2.61	+0.09	0.0081
180	3.0	3.06	−0.06	0.0036
Suma			**0.00**	**0.0270**

e > 0
real mayor que predicho: el modelo subestimó

e < 0
real menor que predicho: el modelo sobreestimó

¿Qué recta es la mejor? Mínimos cuadrados



$$SSE = \Sigma (y_i - \hat{y}_i)^2$$

Mínimos cuadrados elige b_0 y b_1 que hacen el SSE lo más pequeño posible.

¿Por qué al cuadrado?

Sumando errores

2 + (−2) = 0

¡parece perfecto!

Al cuadrado

4 + 4 = 8

todo error suma

Además: al elevar al cuadrado, los errores grandes pesan mucho más (un error de 3 aporta 9; uno de 1 aporta 1). Por eso un atípico puede “jalar” la recta.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cálculo de b_1 y b_0 paso a paso

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
100	1.2	−40	−0.96	38.4	1600
120	1.8	−20	−0.36	7.2	400
140	2.1	0	−0.06	0	0
160	2.7	20	0.54	10.8	400
180	3.0	40	0.84	33.6	1600
$\bar{x} = 140$	**$\bar{y} = 2.16$**		**Σ**	**90**	**4000**

1 Medias

$\bar{x} = 700/5 = 140$
$\bar{y} = 10.8/5 = 2.16$

2 Pendiente

$b_1 = 90 / 4000$
$= 0.0225$

3 Intercepto

$b_0 = 2.16 - 0.0225 \cdot 140$
$= -0.99$

Recta resultante: $\hat{y} = -0.99 + 0.0225 \cdot X$ Para $X = 160 \rightarrow \hat{y} = 2.61$

Interpretar la pendiente y el intercepto

Pendiente $b_1 = 0.0225$

Por cada **1 millón más** de inversión, la predicción de crecimiento sube **0.0225 puntos porcentuales**.

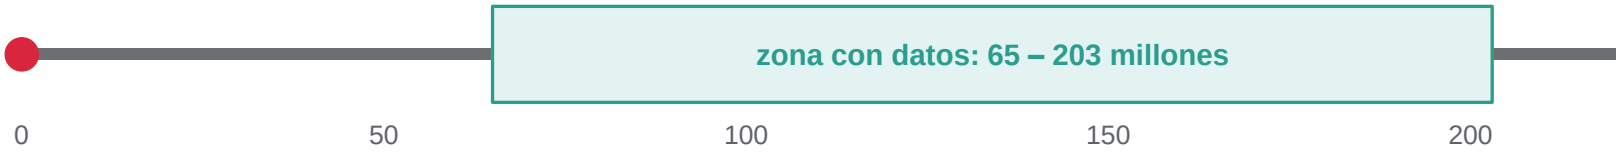
Es asociación, no causalidad.

Intercepto $b_0 = -0.99$

Valor de ŷ cuando la inversión es **0**.

Pero nunca observamos inversión 0: aquí es solo una pieza para ubicar la recta.

Rango de inversión observado en el dataset



X = 0 → extrapolación

Extrapolar (predecir fuera del rango observado) es arriesgado: no hay evidencia de que la recta siga siendo válida.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Supuestos del modelo lineal clásico: LINE

L

Linealidad

La relación media entre X e y es una recta.

Cómo revisarlo: *Residuos vs predicción sin curvas*

I

Independencia

Los errores de una fila no dependen de otra.

Cómo revisarlo: *Cuidado con series de tiempo*

N

Normalidad

Los errores siguen una distribución normal.

Cómo revisarlo: *Histograma o QQ-plot de residuos*

E

Igual varianza

La dispersión de los errores es constante (homocedasticidad).

Cómo revisarlo: *Sin forma de embudo*

En ML: el criterio principal es cuánto se equivoca el modelo con datos que no vio. Los supuestos nos ayudan a entender por qué.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

5 Medir los errores

MAE, MSE, RMSE, Bias y R^2: no hay una métrica única; cada una responde una pregunta distinta

En esta sección

- Cinco métricas
- Cálculo a mano
- R^2 frente a la media
- MAE vs RMSE

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Cinco métricas, cinco preguntas

MAE	$(1/n)\ \Sigma\ \lvert y - \hat{y} \rvert$	¿Cuánto me equivoco normalmente?	**ideal = 0** unidades de y
MSE	$(1/n)\ \Sigma\ (y - \hat{y})^2$	Error cuadrático medio	**ideal = 0** unidades²
RMSE	$\sqrt{MSE}$	¿Qué tan grandes son los errores grandes?	**ideal = 0** unidades de y
Bias	$(1/n)\ \Sigma\ (\hat{y} - y)$	¿Sobreestimo o subestimo sistemáticamente?	**ideal = 0** + sobre / − sub
R^2	$1 - SSE / SST$	¿Cuánto mejoro frente a predecir siempre la media?	**ideal = 1** sin unidades

Las métricas calculadas a mano

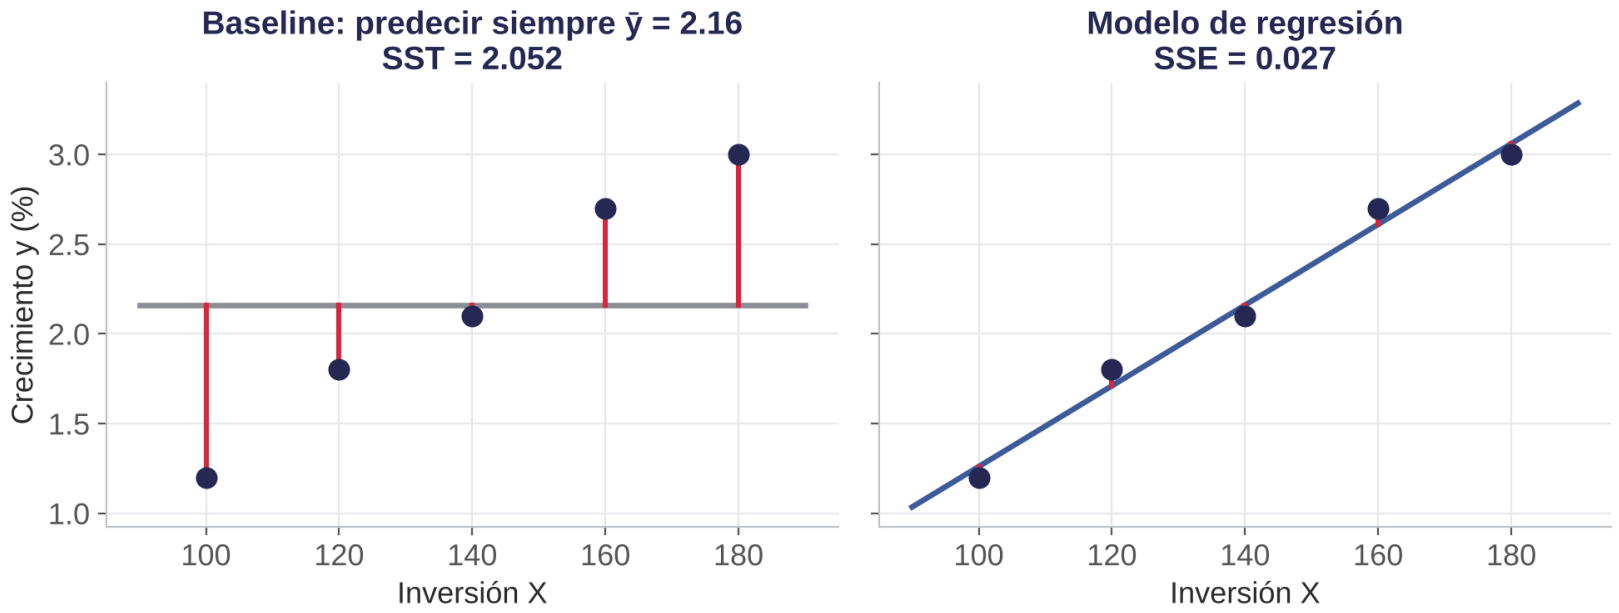
y	ŷ	e = y − ŷ	|e|	e²
1.2	1.26	−0.06	0.06	0.0036
1.8	1.71	+0.09	0.09	0.0081
2.1	2.16	−0.06	0.06	0.0036
2.7	2.61	+0.09	0.09	0.0081
3.0	3.06	−0.06	0.06	0.0036
Suma		**0.00**	**0.36**	**0.027**

MAE	0.36 / 5	**0.072**
MSE	0.027 / 5	**0.0054**
RMSE	√0.0054	**0.073**
Bias	0.00 / 5	**0.000**
R^2	1 − 0.027 / 2.052	**0.987**

Interpretación: el modelo se equivoca en promedio 0.07 puntos porcentuales y explica el 98.7 % de la variación respecto a la media.

Pero… lo medimos con los mismos datos con los que aprendió. ¿Funcionará con datos nuevos?

R^2: ¿cuánto mejora el modelo frente a la media?



$R^2 = 1 - SSE / SST$

$= 1 - 0.027 / 2.052 = 0.987$

$R^2 < 0$ es posible

en datos nuevos, si el modelo predice peor que la simple media.

ESCUELA POLITÉCNICA NACIONAL

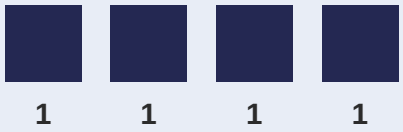
CENTRO DE EDUCACIÓN CONTINUA

Unidad de Capacitación y Certificación

MAE vs RMSE, y la trampa del Bias

Modelo A: errores parejos

|errores| de 4 predicciones:

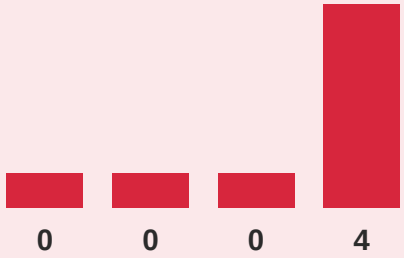


MAE = **1.0**

RMSE = **1.0**

Modelo B: un error grande

|errores| de 4 predicciones:



MAE = **1.0**

RMSE = **2.0**

La trampa del Bias

errores: **+3 y −3**

Bias = (+3 − 3)/2 = **0**

Bias ≈ 0 no significa modelo bueno.

Solo dice que no hay tendencia sistemática a sobreestimar o subestimar. Siempre acompañarlo de MAE o RMSE.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

6

Train, Validation y Test

Cómo saber si un modelo funciona con datos que nunca vio

En esta sección

- Para qué sirve cada conjunto
- Sub y sobreajuste
- Primer modelo real
- Gráfico de residuos

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

¿Por qué separar los datos en tres conjuntos?

Train 70 %	Validation 15 %	Test 15 %
200 filas	43 filas	44 filas

287 filas limpias → train_test_split dos veces (70 / 30, luego 30 → 15 / 15), random_state = 42

Train

Los apuntes con los que se estudia

El modelo aprende b_0, b_1, …

fit()

Validation

El examen de práctica

Nosotros elegimos variables y modelos. Se puede consultar varias veces.

comparar

Test

El examen final

Se mira una sola vez, al final, para estimar el error real.

una sola vez

Regla de oro: si usamos Test para decidir, deja de ser un examen final y el error reportado será optimista.

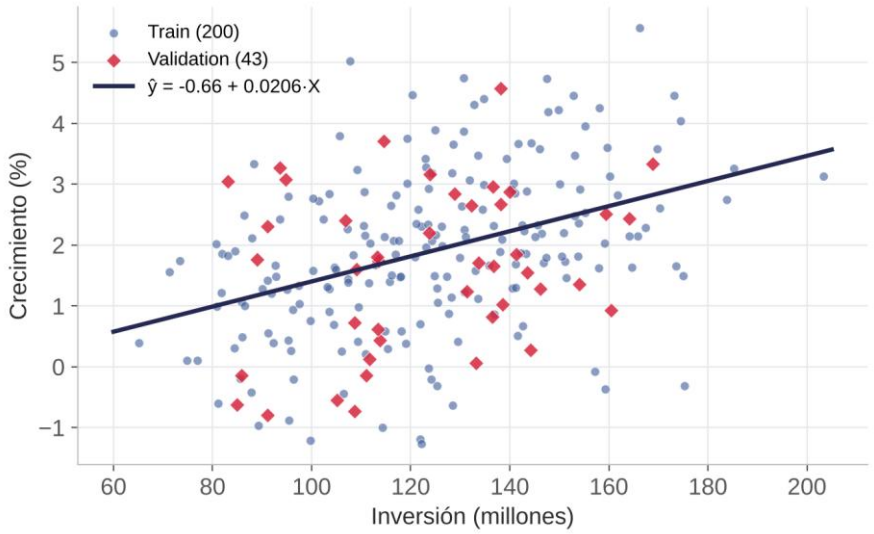
Subajuste y sobreajuste: el equilibrio



	Error en Train	Error en Validation	Diagnóstico
Subajuste	alto	alto	Modelo demasiado simple
Buen ajuste	bajo	bajo y parecido	Generaliza bien
Sobreajuste	muy bajo	alto	Memorizó el ruido

La señal de alerta es la brecha entre Train y Validation, no el valor aislado.

Primer modelo real: inversión → crecimiento



	MAE	RMSE	R^2	Bias
Train	0.947	1.220	0.165	0.000
Validation	1.115	1.305	0.012	+0.262

Baseline (media de Train)

$\hat{y} = 1.90$ siempre

Validation: RMSE 1.343 · R^2 −0.045

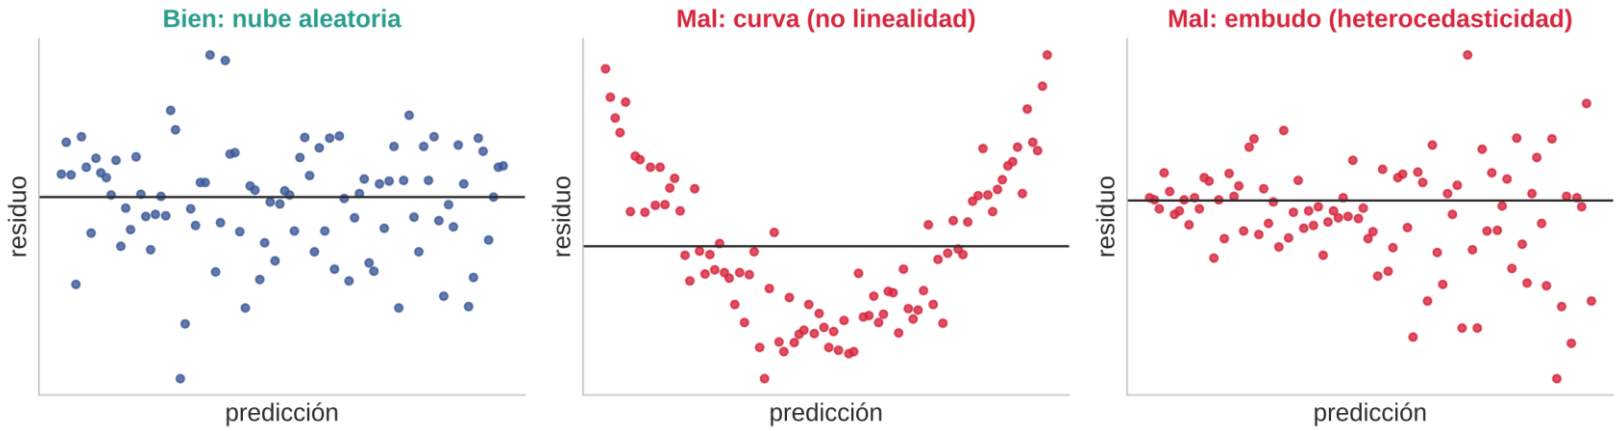
Lo bueno

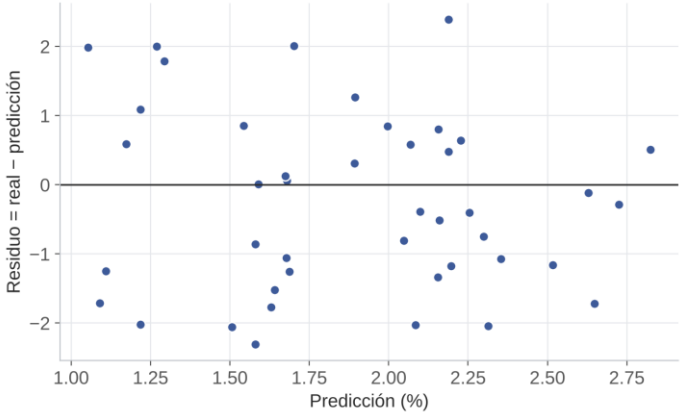
Train y Validation no son muy distintos: no hay sobreajuste fuerte.

Lo malo

En Validation explica solo 1.2 %: la inversión sola no basta.

Leer el gráfico de residuos





Nuestro modelo simple (Validation)

- Residuos arriba y abajo de 0: **sin curva clara**
- Pero muchos errores de **±2 puntos**
- Coincide con $R^2 \approx 0$: predice con poca precisión

ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

7

Regresión múltiple y variables categóricas

Más de una X: del plano al hiperplano, y cómo incluir región y sector sin inventar un orden

En esta sección

- Plano e hiperplano
- Ceteris paribus
- One-Hot Encoding
- Evaluación final

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

De la recta al plano y al hiperplano

1 X — **Recta** (2D)

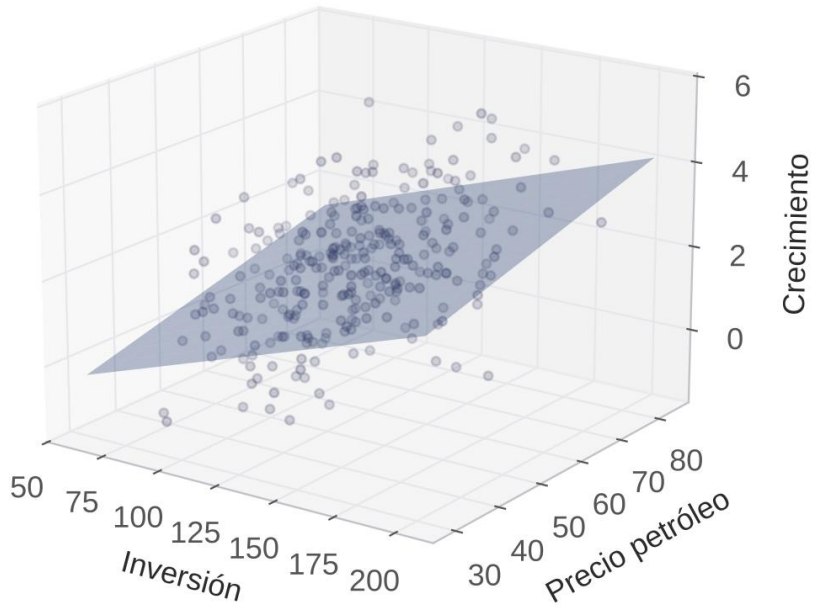
$\hat{y} = b_0 + b_1 x_1$

2 X — **Plano** (3D)

$\hat{y} = b_0 + b_1 x_1 + b_2 x_2$

p X — **Hiperplano** (p+1 D)

$\hat{y} = b_0 + b_1 x_1 + \ldots + b_p x_p$



ŷ = −2.24 + 0.0189·inversión + 0.0300·petróleo

Puntos: datos reales · Plano: predicción

Coeficientes: “manteniendo lo demás constante”

Variable	Coeficiente	Lectura (manteniendo constante lo demás)
inflacion_pct	−0.163	+1 punto de inflación → −0.16 pp de crecimiento
desempleo_pct	−0.157	+1 punto de desempleo → −0.16 pp
precio_petroleo_usd	+0.024	+1 USD por barril → +0.024 pp
inversion_mill	+0.015	+1 millón de inversión → +0.015 pp
indice_confianza	+0.004	+1 punto del índice → +0.004 pp
exportaciones_mill	+0.001	+1 millón exportado → +0.001 pp

Ojo con las escalas

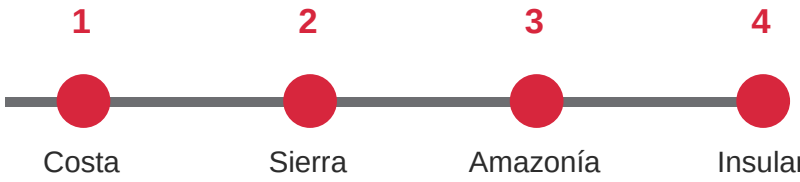
inflación se mide en unidades pequeñas (0–5); exportaciones en cientos de millones. Un coeficiente pequeño **no** implica una variable poco importante.

Multicolinealidad

Si dos X se mueven juntas, el modelo no sabe a cuál atribuir el efecto y los coeficientes se vuelven inestables.

Variables categóricas: el texto no es una magnitud

Codificación con números



Inventa un orden y distancias

¿Sierra está “entre” Costa y Amazonía? ¿Insular vale 4 veces Costa?

One-Hot Encoding (dummies)

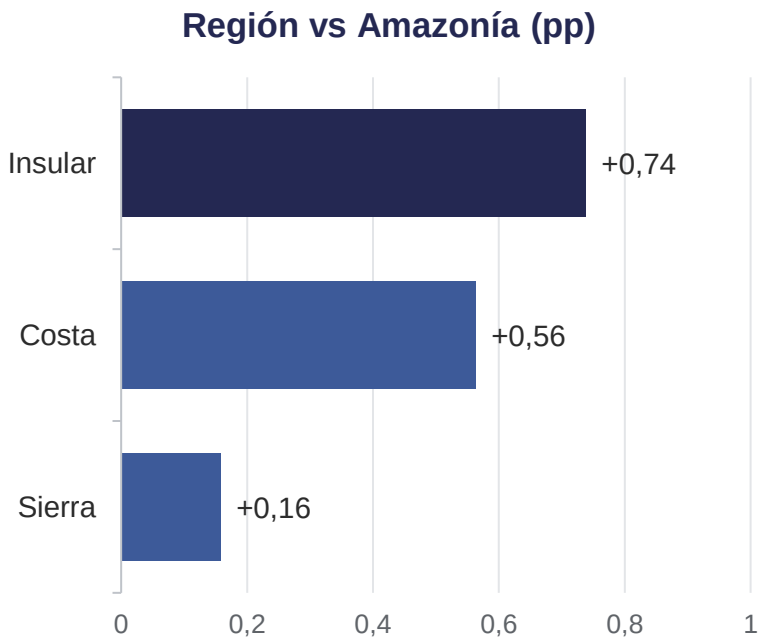
region	Costa	Insular	Sierra
Amazonía	0	0	0
Costa	1	0	0
Insular	0	1	0
Sierra	0	0	1

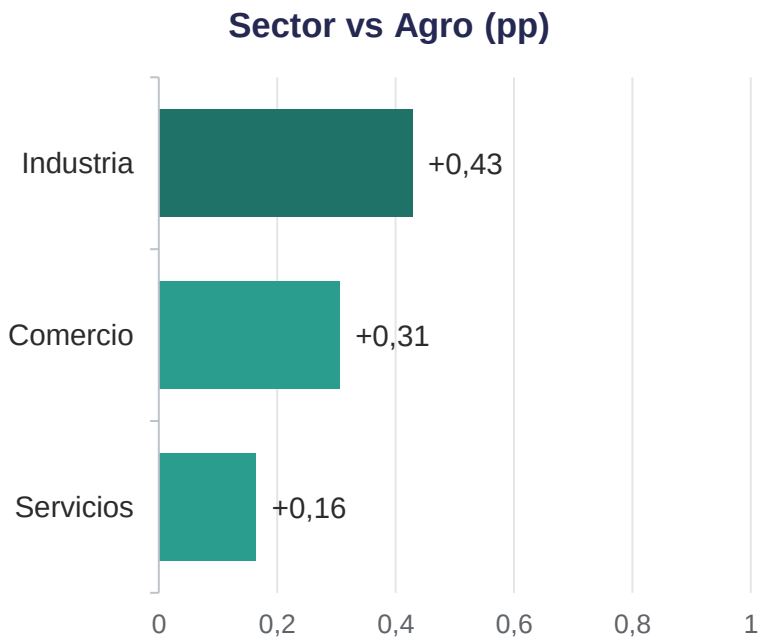
Amazonía = categoría de referencia (todo en 0)

¿Por qué eliminar una columna? (drop_first=True)

Con 4 dummies, siempre suman 1 y repiten la información del intercepto (colinealidad perfecta: la “trampa de las dummies”). Con k categorías se usan k − 1 columnas.

Leer el coeficiente de una dummy

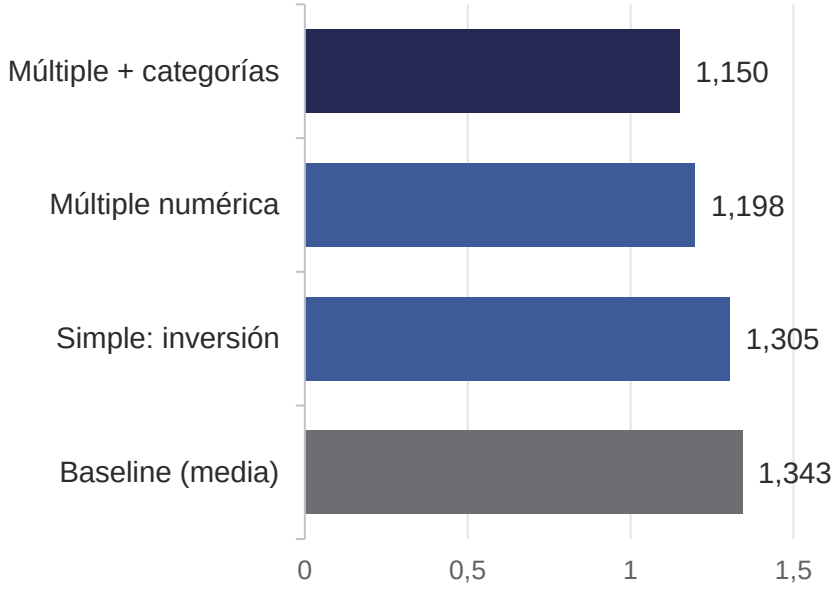




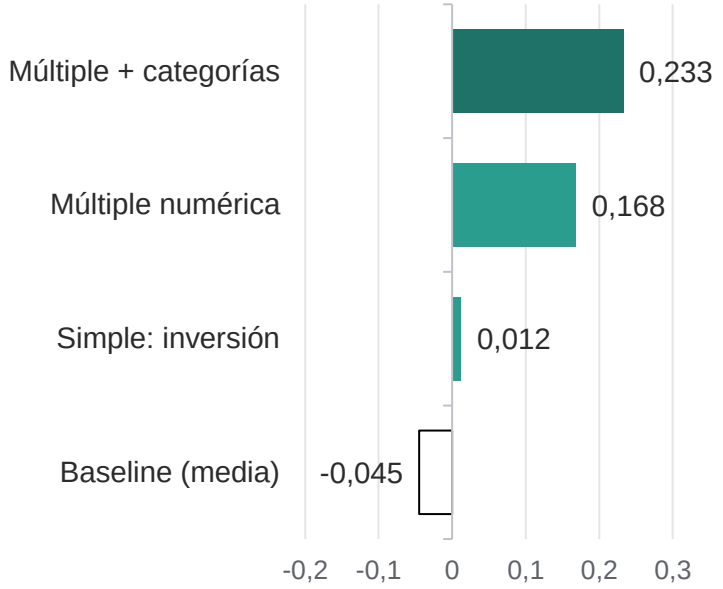
Lectura: con la misma inversión, inflación, desempleo, etc., una fila de la región Insular tiene una predicción 0.74 puntos porcentuales mayor que una de Amazonía.

Comparar modelos en Validation

RMSE en Validation (menor es mejor)



R^2 en Validation (mayor es mejor)



Ganador: regresión múltiple + región y sector

RMSE 1.150 y R^2 0.233: mejora frente al baseline y a los modelos más simples.

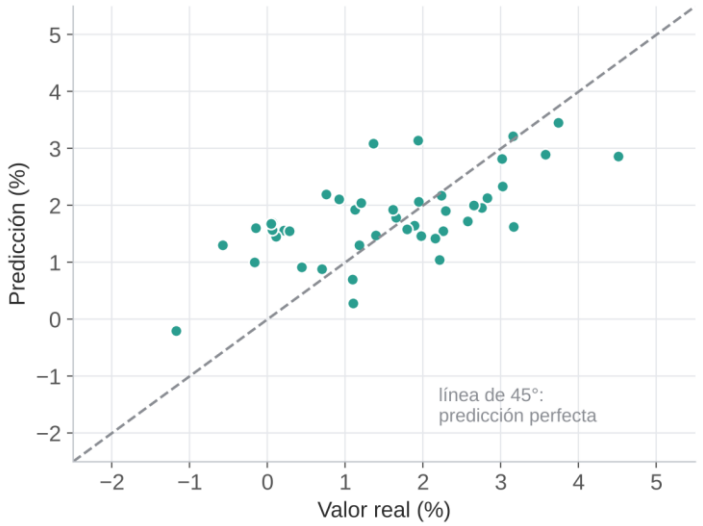
Evaluación final: Train, Validation y Test

Conjunto	MAE	RMSE	R^2	Bias
Train	0.859	1.107	0.312	0.000
Validation	0.979	1.150	0.233	+0.364
Test	**0.830**	**0.997**	**0.369**	**+0.230**

Consistente
Errores similares en los tres conjuntos → sin sobreajuste fuerte

Ligera sobreestimación
Bias +0.23 a +0.36 en datos nuevos

Margen de mejora
$R^2 \approx 0.37$: queda mucha variación sin explicar



Test: real vs predicho

Error típico esperado con datos nuevos

≈ 1 punto porcentual

RMSE en Test = 0.997

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Usar el modelo: una predicción nueva

Entrada	Valor	Rango en datos
inversion_mill	180	65 – 203
exportaciones_mill	500	187 – 1300
precio_petroleo_usd	70	29 – 84
indice_confianza	**60**	**28 – 57**
inflacion_pct	2.5	−0.7 – 4.7
desempleo_pct	4.5	2.9 – 8.0
region · sector	Costa · Industria	20 casos

Alerta de extrapolación

índice de confianza = 60 está fuera del rango observado (máx. 57.1).

Crecimiento estimado

3.57 %

modelo múltiple + categorías

Casos reales Costa · Industria

media 2.07 % · rango −1.2 a 4.5

Categoría nueva (no vista en Train) → el modelo no sabe tratarla.