Proyecto Integrador · Tarea 1

Formativa · práctica guiada · Día 4 · 20 puntos

Descripción de la actividad

Inicio del Proyecto Integrador: elige un dataset local y define un problema que se pueda responder con sus filas. Esta primera entrega audita los datos y decide el protocolo; aún no se califica el rendimiento de un modelo.

Objetivo de aprendizaje

Distinguir regresión, clasificación y clustering a partir de la respuesta buscada y justificar la pertinencia y calidad inicial del archivo elegido.

Resultado esperado

Ficha y primeras celdas ejecutables de un único notebook que continuará durante las Tareas 2 y 3 y la práctica final. Debe existir una pregunta precisa, un tipo justificado, un diccionario breve y un plan de evaluación sin abrir Test.

Cómo se trabajará

Paso 1. En equipo pequeño o individualmente, escoge uno de los cinco CSV ya guardados en datos/ y mantén ese problema en las entregas sucesivas.

Paso 2. Carga el archivo y explica qué representa una fila, su fuente, periodo, carácter público o sintético y si existe una variable objetivo.

Paso 3. Muestra shape, head, dtypes, nulos, duplicados, categorías e identificadores; registra un extremo relevante y su posible efecto.

Paso 4. Construye un primer gráfico con título, ejes y lectura; propón otros dos para la siguiente tarea.

Paso 5. Esboza Train/Validation/Test conforme al objetivo y una referencia simple; no modeles todavía.

Una elección, cinco datasets disponibles

Tipo orientativo	Archivo en datos/	Pregunta inicial
A. Regresión	actividad_economica_reto.csv	Estimar crecimiento de actividad por fecha, región y sector.
B. Clasificación	bank_marketing_uci.csv	Predecir yes/no antes de llamar; excluir duration.
C. Clasificación	telco_churn_fallback.csv	Identificar Churn=Yes/No en clientes sintéticos.
D. Clustering	world_bank_latam_ml.csv	Agrupar país-años por indicadores, sin etiqueta de grupo.
E. Regresión temporal	macro_mensual_demo.csv	Pronosticar índice de actividad del mes siguiente con rezagos.

La elección se justifica según la respuesta buscada: cantidad numérica → regresión; etiqueta conocida → clasificación; sin grupo correcto conocido → clustering. No convertir identificadores como customerID o pais a números arbitrarios.

Rúbrica de evaluación — 20 puntos

Por cada criterio marque Logrado (puntaje completo), En desarrollo (mitad) o No logrado (0). Se admiten medios puntos. Registre el puntaje real y una observación específica cuando falte evidencia.

Criterio	Niveles de desempeño y evidencia observable	Puntos
Pregunta y tipo	**Logrado (4):** Pregunta y decisión claras; explica el tipo según y numérica, categórica o ausencia de grupo conocido. **En desarrollo (2):** Identifica el tipo, pero la pregunta o el motivo es impreciso. **No logrado (0):** No define problema o confunde tipo y respuesta.	___ / 4
Fuente y fila	**Logrado (4):** Archivo local, fuente pública/sintética, periodo, población, unidad de fila y target si aplica. **En desarrollo (2):** Identifica archivo y fila, pero omite contexto importante. **No logrado (0):** No identifica origen ni unidad de observación.	___ / 4
Auditoría inicial	**Logrado (5):** Tamaño, columnas, tipos, nulos, duplicados, categorías especiales y extremos explicados. **En desarrollo (2.5):** Revisa solo parte de los datos o no interpreta hallazgos. **No logrado (0):** No revisa datos o imprime filas sin explicación.	___ / 5
Primer gráfico	**Logrado (3):** Figura legible con interpretación y dos gráficos futuros pertinentes propuestos. **En desarrollo (1.5):** Figura sin lectura o plan de visualización incompleto. **No logrado (0):** No hay figura útil.	___ / 3
Plan de evaluación	**Logrado (4):** Partición apropiada, predictor disponible al decidir y baseline o criterio de agrupación. **En desarrollo (2):** Hay split propuesto sin justificación o sin referencia. **No logrado (0):** No hay protocolo o ya usa Test para decidir.	___ / 4
TOTAL	Ficha y notebook inicial; Test aún reservado.	___ **/ 20**