Proyecto Integrador · Tarea 2

Formativa · práctica guiada · Día 5 · 20 puntos

Descripción de la actividad

Continúa el mismo dataset y la pregunta de la Tarea 1. Esta entrega prepara filas y columnas de manera reproducible y permite entender qué información se modelará. PCA es una opción cuando aporta a la pregunta, no un requisito universal.

Objetivo de aprendizaje

Limpiar y visualizar los datos sin perder trazabilidad; dividirlos según la pregunta y convertir variables cualitativas pertinentes a entradas numéricas sin fuga de información.

Resultado esperado

Notebook ampliado con tabla de decisiones de calidad, al menos tres figuras interpretadas, particiones Train/Validation/Test verificadas y preprocesamiento ajustado solo en Train.

Cómo se trabajará

Paso 1. Justifica nulos, duplicados, valores extremos y columnas indisponibles en el momento de predicción; indica cuántas filas se conservan.

Paso 2. Presenta tres figuras distintas con título, ejes y una oración que responda qué muestran; no deduzcas causalidad.

Paso 3. Divide antes de calcular medianas, escalas o categorías: estratifica clases si procede; respeta fechas en pronóstico y países completos si buscas generalizar a ellos.

Paso 4. Identifica cualitativas desde el principio, pero ajusta OneHotEncoder/imputación/escalado dentro de Pipeline usando solo Train; aplica las reglas aprendidas a Validation y Test.

Paso 5. En clustering no inventes y: separa datos para comprobar estabilidad/perfiles y escala usando solo Train. Si no hay categorías sustantivas, explica por qué One-Hot no aplica.

Ejemplo de una decisión correcta

En telco_churn_fallback.csv, Contract es una categoría y customerID un identificador. Separa clientes en Train/Validation/Test; luego aprende en Train columnas 0/1 para las categorías Contract con One-Hot. No asignes Month-to-month=1 y One year=2 como si fuesen magnitudes ni incluyas customerID por rutina.

Rúbrica de evaluación — 20 puntos

Por cada criterio marque Logrado (puntaje completo), En desarrollo (mitad) o No logrado (0). Se admiten medios puntos.

Criterio	Niveles de desempeño y evidencia observable	Puntos
Limpieza	**Logrado (5):** Trata nulos/duplicados/extremos, excluye IDs y variables futuras y cuantifica pérdida de filas. **En desarrollo (2.5):** Limpia, pero sin justificar una decisión importante. **No logrado (0):** No limpia o introduce target/futuro como predictor.	___ / 5
Tres gráficos	**Logrado (5):** Tres figuras distintas con título, ejes y conclusión pertinente por figura. **En desarrollo (2.5):** Una figura falta o las interpretaciones son parciales. **No logrado (0):** No hay exploración útil.	___ / 5
Particiones	**Logrado (5):** Train/Validation/Test reproducibles según clases, tiempo, país o estabilidad; comprueba tamaños. **En desarrollo (2.5):** Divide pero no justifica ni revisa composición. **No logrado (0):** No divide o mezcla Test con Train.	___ / 5
Sin fuga	**Logrado (5):** Categorías relevantes con One-Hot y transformaciones aprendidas solo en Train; aplica al resto sin reajuste. **En desarrollo (2.5):** Algunas transformaciones son correctas pero falta justificar o aislar un paso. **No logrado (0):** Codifica usando toda la muestra antes del split o trata IDs como magnitudes.	___ / 5
TOTAL	Mismo notebook, ahora con preparación y tres gráficos.	___ **/ 20**