Proyecto final

Del dato a la decisión: un modelo defendible

Módulo 3 · Machine Learning Aplicado · Diplomado en Big Data e Inteligencia Artificial

Modalidad	Tipo de problema	Entrega	Calificación
Individual	Regresión, clasificación o clustering	Un solo archivo PDF	10 puntos

1. Objetivo

Usted escogerá **uno** de los ocho datasets de este catálogo y lo llevará desde el archivo crudo hasta un modelo que pueda defender: cargar, limpiar, visualizar y entender los datos; escoger las variables de entrada; elegir un modelo y sus hiperparámetros; compararlo con una línea base y con otras configuraciones del mismo modelo; y justificar cuál es el mejor. No gana quien obtenga el R^2, el F1 o el Silhouette más alto: se evalúa la calidad del planteamiento, la elección del procedimiento, la interpretación de los resultados y la capacidad de reconocer sus limitaciones.

2. Qué está definido y qué decide usted

Lo define el docente	Lo decide usted
El dataset (usted escoge uno del catálogo)	Cómo limpiar los datos y por qué
La variable objetivo de cada dataset (lo que se predice)	Las variables de entrada (X) y su justificación
El tipo de problema de cada dataset	El modelo, la configuración de hiperparámetros y la forma de validar
Las métricas mínimas que debe reportar	Cuál es el mejor modelo y por qué

3. Catálogo de datasets

Cada ficha indica la variable objetivo y los puntos de cuidado. Los datos no describen al Ecuador ni al Banco Central: no extrapole sus conclusiones sin advertirlo.

Regresión: predecir una cantidad

R1. California Housing

housing.csv · 20 640 zonas de California · censo de 1990 · dificultad baja–media

Una fila es	Un grupo de manzanas (zona censal) de California.
Variable objetivo	**median_house_value**: valor mediano de las viviendas de la zona (USD de 1990).
Puntos de cuidado	El valor está topado en 500 001 (965 zonas): el modelo no puede predecir más que eso. total_bedrooms tiene 207 faltantes. ocean_proximity es categórica y la categoría ISLAND tiene solo 5 filas. total_rooms y population son totales de la zona: considere convertirlos en promedios por hogar. No son precios actuales.

R2. Indicadores de desarrollo mundial 2000–2023

5 archivos (countries, gdp_economy, population_health, education_technology, environment_energy) · 217 economías × 24 años = 5 208 filas · dificultad media–alta

Una fila es	Un país en un año, después de unir los archivos por country_id y year.
Variable objetivo	**gdp_growth_pct**: crecimiento anual del PIB (%).
Puntos de cuidado	Debe unir los archivos y decidir cómo tratar faltantes (por ejemplo, el desempleo falta en 14 % de las filas). Cada país aparece 24 veces: una división al azar pone al mismo país en Train y Validation y el modelo lo «reconoce». Divida por país o por años, y explique cuál. No use gdp_usd ni gdp_per_capita_usd de forma que reconstruyan el crecimiento. Variables del mismo año explican el crecimiento, no lo pronostican. Espere un R^2 modesto: el crecimiento tiene mucho ruido y choques (2009, 2020).

R3. World Happiness Report 2015–2019

5 archivos (uno por año) · unos 155 países por año · dificultad baja–media

Una fila es	Un país en un año de la encuesta.
Variable objetivo	**Happiness Score** (llamado Score o Happiness.Score según el año): puntaje de bienestar de 0 a 10.
Puntos de cuidado	Los nombres de columnas cambian entre años: debe armonizarlos si une varios archivos. No use Happiness Rank, Standard Error, los intervalos ni Dystopia Residual: el puntaje se construye sumando los factores y ese residuo, así que serían una fuga. Con varios años, divida por país. Son pocas filas: K-Fold es buena idea.

Clasificación: predecir una clase

C1. Bank Marketing

bank-additional-full.csv (separador ;) · 41 188 llamadas · campaña de un banco portugués · dificultad baja–media

Una fila es	Un contacto telefónico a un cliente durante una campaña.
Variable objetivo	**y**: ¿el cliente contrató el depósito a plazo? (yes / no; clase positiva yes, 11,3 %).
Puntos de cuidado	Excluya **duration**: dura la llamada que ya ocurrió y solo se conoce después; es una fuga. pdays = 999 significa «nunca contactado antes», no 999 días. Hay muchos «unknown» en las categóricas. Datos desbalanceados: reporte Precision, Recall y F1, no solo Accuracy.

C2. Default of Credit Card Clients

UCI_Credit_Card.csv · 30 000 clientes · Taiwán, 2005 · dificultad baja–media

Una fila es	Un cliente de tarjeta de crédito con seis meses de historial.
Variable objetivo	**default.payment.next.month**: ¿incumplió el pago del mes siguiente? (0 / 1; clase positiva 1, 22,1 %).
Puntos de cuidado	Elimine ID. PAY_0 a PAY_6 son el estado de pago de cada mes: −2 y −1 indican pago al día o sin consumo, 0 uso de crédito rotativo y 1 a 8 meses de atraso; lea la documentación antes de interpretarlas. EDUCATION tiene códigos 0, 5 y 6 sin definir. Montos en dólares taiwaneses.

Clustering: descubrir grupos (no hay variable objetivo)

K1. Unsupervised Learning on Country Data

Country-data.csv y data-dictionary.csv · 167 países · dificultad baja

Una fila es	Un país con 9 indicadores socioeconómicos y de salud.
Objetivo	Identificar grupos de países con condiciones parecidas; por ejemplo, para priorizar ayuda internacional.
Puntos de cuidado	Las escalas son muy distintas (gdpp en miles de USD, health en %): normalice. income y gdpp están muy correlacionadas. Interprete cada grupo con sus promedios y nombre los países típicos de cada uno.

K2. Wholesale Customers

Wholesale customers data.csv · 440 clientes de un distribuidor mayorista · dificultad baja

Una fila es	Un cliente con su gasto anual en seis categorías de productos.
Objetivo	Encontrar perfiles de clientes según sus patrones de gasto.
Puntos de cuidado	Los gastos son muy asimétricos y hay valores extremos: considere una transformación logarítmica antes de normalizar. Deje fuera Channel (1 = hoteles, restaurantes y cafés; 2 = minoristas) y Region al agrupar; úselas después para interpretar si los grupos coinciden con el canal.

K3. Online Retail (E-Commerce Data)

data.csv · 541 909 líneas de factura · tienda en línea del Reino Unido, dic. 2010 a dic. 2011 · dificultad media–alta

Una fila es	Una línea de una factura (un producto comprado), no un cliente.
Objetivo	Segmentar a los clientes según sus hábitos de compra.
Puntos de cuidado	Debe construir una tabla de clientes: agrupe por CustomerID y calcule, por ejemplo, recencia (días desde la última compra), frecuencia (número de facturas) y monto total (Quantity × UnitPrice). Elimine las líneas sin CustomerID (unas 135 000) y trate las cancelaciones (InvoiceNo que empieza con C) y cantidades negativas. Codificación latin-1. El 91 % de las líneas es del Reino Unido.

4. Qué debe hacer

- **Carga y limpieza.** Cargue el archivo, revise tipos, faltantes, duplicados y valores extraños. Cada decisión (eliminar, imputar, transformar) debe quedar escrita con su motivo.
- **Visualización y entendimiento.** Al menos tres gráficas que ayuden a entender los datos: distribución de la variable objetivo, relación de las variables con ella (o entre sí, en clustering) y algún problema de calidad. Cada gráfica con su interpretación.

- **Variables de entrada.** Escoja usted las variables X y justifique cada una. Indique cuáles descartó y por qué, y verifique que ninguna sea una fuga de información (que solo se conozca después o que contenga la respuesta).
- **Modelo e hiperparámetros.** Escoja un modelo estudiado en el módulo. Regresión: regresión lineal (o Ridge / Lasso), árbol de regresión, Random Forest, KNN o SVR. Clasificación: árbol, Random Forest, KNN o SVM. Clustering: K-Means o clustering jerárquico. Si investigó otro modelo, puede usarlo explicando cómo funciona y citando la fuente.
- **Validación.** Divida en Train, Validation y Test (o use K-Fold sobre Train y Validation) y explique por qué. Compare su modelo con una **línea base** y con **al menos tres configuraciones de hiperparámetros** del mismo modelo, todas sobre los mismos datos de Validation. Abra Test una sola vez, al final, con el modelo elegido.
- **Elección y justificación.** Diga cuál configuración es la mejor y por qué: no solo por la métrica, también por la brecha entre Train y Validation, la estabilidad y la facilidad para explicarla.

Tipo	Línea base mínima	Métricas mínimas	Hiperparámetros a explorar (ejemplos)
Regresión	Predecir siempre el promedio de Train	MAE, RMSE y R^2 en Train y Validation	max_depth, min_samples_leaf, n_estimators, k, C, alpha. Si usa regresión lineal sin hiperparámetros, compare al menos tres conjuntos de variables o Ridge / Lasso con varios alpha.
Clasificación	Predecir siempre la clase más frecuente	Matriz de confusión, Precision, Recall y F1 de la clase positiva	max_depth, min_samples_leaf, class_weight, k, C, kernel, umbral de decisión
Clustering	Una segmentación simple, por ejemplo por cuartiles de una variable clave o por Channel	Silhouette, tamaño y perfil promedio de cada grupo	Número de grupos k, método de enlace, escalado o transformación de variables

5. Informe en PDF

Suba **un solo archivo PDF** de entre 6 y 10 páginas. Presente resultados e interpretación; no pegue código. Si usó un agente de IA, debe poder explicar y defender cada decisión del notebook. Organícelo así:

Sección	Qué debe incluir
1. Problema y dataset	Dataset elegido, qué representa una fila, variable objetivo (o propósito del clustering) y por qué el problema es relevante.
2. Carga y limpieza	Tabla con cada problema encontrado, la decisión tomada y cuántas filas o columnas afectó.
3. Visualización y entendimiento	Tres o más gráficas con su interpretación.
4. Variables de entrada	Variables escogidas y descartadas con su justificación; revisión de fugas.
5. Modelo y configuraciones	Modelo elegido y por qué; tabla con la línea base y al menos tres configuraciones de hiperparámetros con sus métricas en Train y Validation.
6. Mejor modelo	Configuración elegida, justificación y resultado en Test.
7. Conclusiones y limitaciones	Qué se puede afirmar con estos resultados, qué no, y qué haría con más tiempo o datos.

6. Evaluación

Criterio	Puntos
Planteamiento del problema y descripción del dataset	1
Carga y limpieza con decisiones justificadas	1,5
Visualización y entendimiento de los datos	1,5
Selección y justificación de las variables de entrada, sin fugas	1
Modelo y configuraciones de hiperparámetros	1,5
Validación frente a la línea base con métricas adecuadas	1,5
Elección y justificación del mejor modelo	1
Conclusiones y limitaciones	1
Total	10

Trabajo individual. Si consulta fuentes externas, cítelas al final del informe. Si tiene dudas, puede escribir o llamar al 0987307747.