Tarea práctica

¿Qué tan confiable es nuestra regresión lineal?

Módulo 3 · Machine Learning Aplicado · Diplomado en Big Data e Inteligencia Artificial

Tiempo sugerido	Modalidad	Dataset	Entrega
90 minutos	Individual	Countries of the World (Kaggle)	Solo un informe en PDF de 2 a 3 páginas

1. Objetivo

Usted va a construir un modelo de regresión lineal con un solo predictor, a probarlo con distintas divisiones de datos y a compararlo con la estrategia más simple posible: predecir siempre el promedio. El resultado que nos interesa no es un R^2 alto, sino una decisión justificada: ¿este modelo es confiable y mejor que el promedio, o no?

2. Qué debe decidir usted

El notebook ya carga y limpia el dataset. Usted debe elegir **la variable objetivo y** (lo que quiere predecir) y **las variables de entrada X** (lo que usa para predecir). X puede tener **una sola columna o varias**. Puede escoger cualquier columna numérica del dataset; si quiere usar la columna Region, debe convertirla en variables binarias y explicarlo. Cada variable de X debe justificarse en su informe: qué relación económica espera encontrar y por qué cree que sirve para explicar y. Si usa varias, debe evitar columnas que midan prácticamente lo mismo (por ejemplo, los tres sectores productivos suman casi 1 y no deberían entrar juntos sin cuidado). Una elección sin justificación no se evalúa.

3. Conjunto de datos

El archivo tiene 227 países con 20 variables: población, área, PIB per cápita, alfabetización, teléfonos por cada 1 000 habitantes, sectores productivos y otros. Los datos provienen de una fuente histórica (World Factbook), no de estadísticas del año actual. Cada fila es un país y todas las observaciones corresponden a la misma fecha, así que la tarea estima una relación entre variables y no hace pronósticos. Al elegir X e y, algunos países quedarán fuera por tener valores faltantes: debe indicar cuántos.

4. Experimento 1: mover los cortes de Train y Validation

Reserve el 20 % de los datos como **Test** y no lo use para decidir nada. Con el 80 % restante haga tres experimentos y, en cada uno, compare la regresión lineal (con las variables de X que haya elegido) con la línea base del promedio (que predice el promedio de y en Train).

Experimento	Train	Validation	Test (reservado)
A	70 %	10 %	20 %
B	60 %	20 %	20 %
C	50 %	30 %	20 %

Use siempre random_state = 42. Registre MAE, RMSE y R^2 de Train y de Validation para ambos modelos.

5. Experimento 2: K-Fold frente a una sola división

Con los datos de desarrollo (el 80 % sin Test), aplique K-Fold con 5 folds (shuffle = True, random_state = 42) al modelo lineal y a la línea base. Obtenga el MAE de cada fold, su promedio y su desviación estándar. Compare ese resultado con el MAE de una sola división de Validation del experimento que usted considere más adecuado.

6. Decisión final

Responda con los resultados: ¿cuál es la mejor opción entre los modelos y las divisiones que probó? ¿El modelo lineal es mejor que predecir siempre el promedio? Si lo es, explique por qué; si no lo es, explique por qué no. Esta pregunta es el centro de la tarea.

7. Informe en PDF (2 a 3 páginas)

El informe presenta resultados e interpretación; no describa el proceso paso a paso ni pegue código. Organícelo en estas secciones:

Sección	Qué debe incluir
1. Datos y variables	Descripción del dataset, elección de y y de cada variable de X con su justificación, cuántos países se eliminaron y por qué. Gráfica de dispersión de y contra X con su interpretación.
2. Cortes de Train y Validation	Tabla de los experimentos A, B y C con MAE, RMSE y R^2 para ambos modelos. Interpretación de qué cambia al mover los cortes.
3. K-Fold frente a una sola división	MAE por fold, promedio y desviación estándar. Comparación con una sola división y su lectura.
4. Modelo frente al promedio	Tabla de comparación con la línea base. Respuesta explícita: sí o no, y por qué. Gráfica de valores reales contra predichos o de MAE, con su interpretación.
5. Mejor opción y conclusión	Conclusión de 150 a 250 palabras sobre cuál opción elegiría y si usaría este modelo en un análisis económico real, y por qué.

Cada gráfica debe pegarse en el informe con un comentario debajo. Recuerde: un R^2 alto no basta si no se entiende de dónde sale, y una relación entre telefonía y PIB no demuestra causalidad.

8. Evaluación

Criterio	Puntos
Elección de y y de las variables de X, con justificación económica y descripción del dataset	2
Experimentos de cortes Train / Validation e interpretación de las métricas	2
K-Fold frente a una sola división, con análisis de estabilidad	2
Comparación con la línea base del promedio y respuesta fundamentada	2

Gráficas pegadas con interpretación y conclusión sobre el uso del modelo	2

La evaluación prioriza la interpretación económica y estadística, no la cantidad ni la complejidad del código.