Actividad 3

Del problema económico al modelo predictivo

Módulo 3 · Machine Learning Aplicado · Diplomado en Big Data e Inteligencia Artificial

Modalidad	Tiempo estimado	Calificación	Entrega
Individual	30 a 45 minutos	10 puntos	Un PDF de máximo dos páginas

Contexto

El Banco Central necesita analizar información económica y financiera para apoyar la toma de decisiones. Un equipo propone utilizar Machine Learning en tres casos. Antes de escribir una sola línea de código, el equipo debe responder preguntas que usted ya puede contestar con lo visto en el módulo: qué tipo de problema es, qué datos hacen falta, qué modelo conviene y cómo sabremos si funciona.

Los tres casos

Caso A. Monto total diario de transacciones de un sistema de pagos. Se quiere estimar cuántos dólares procesará el sistema cada día, para planificar la liquidez y la capacidad operativa. Se dispone de registros diarios de varios años. El monto cambia según el día de la semana, los fines y mediados de mes (pago de sueldos), los feriados, la temporada de diciembre y otras fechas de pago. Las observaciones están ordenadas en el tiempo: el día de mañana depende en parte de lo que ocurrió los días anteriores.

Caso B. Transacciones con características asociadas a posibles fraudes. Cada fila es una transacción individual: tipo de operación, monto, hora, canal, cuenta de origen y de destino. La decisión debe tomarse en segundos, al momento de autorizar la operación. Los fraudes son muy pocos (en datos como los de clase, menos de 1 de cada 1 000 transacciones) y los dos errores posibles tienen costos distintos: dejar pasar un fraude cuesta dinero; bloquear una transacción legítima molesta al cliente y genera trabajo de revisión.

Caso C. Crecimiento de la actividad económica. Se quiere estimar la tasa de crecimiento de la actividad económica (por ejemplo, la variación trimestral del PIB) con indicadores de inversión, inflación y exportaciones. Las series trimestrales de un país rara vez superan unas pocas decenas de años, así que hay relativamente pocas observaciones (alrededor de un centenar). Además, la economía atraviesa cambios estructurales y choques (por ejemplo, la dolarización o la pandemia de 2020), y algunos efectos llegan con rezago: la inversión de hoy puede influir en el crecimiento de trimestres posteriores.

Modelos que puede considerar

Modelo	Idea central (recordatorio)
Regresión lineal	Una recta o un plano: cada variable suma o resta en proporción fija. Fácil de interpretar.
Árbol de regresión / de clasificación	Preguntas de sí o no; cada hoja entrega un promedio (regresión) o una clase (clasificación). Se controla con max_depth, min_samples_leaf y min_samples_split.
Random Forest	Muchos árboles entrenados con muestras distintas; promedia (regresión) o vota (clasificación).
KNN	Predice mirando los k casos más parecidos de Train. Necesita normalizar las variables.
SVM	Busca la frontera con mayor margen; C regula la multa por errores y el kernel permite fronteras curvas.
Otros que usted haya investigado	Por ejemplo, XGBoost u otro boosting, regresión polinomial, regresión logística, Ridge o Lasso, modelos de series de tiempo.

Preguntas abiertas

1. Identificación del problema (2 puntos). Para cada caso, determine si utilizaría un modelo de regresión o de clasificación. Explique por qué, cuál sería la variable objetivo y en qué unidad se mide (dólares, porcentaje, 0/1). En el caso de clasificación, indique cuál sería la clase positiva.

2. Selección de información (1,5 puntos). Escoja uno de los tres casos. ¿Qué información necesitaría recopilar para construir el modelo? Mencione al menos cuatro variables y explique por qué podrían ser útiles. Para cada una, indique si estaría disponible en el momento de hacer la predicción: una variable que solo se conoce después sería una fuga de información.

3. Selección del modelo (2 puntos). Para el caso seleccionado, ¿qué modelo utilizaría entre regresión lineal, árbol de regresión o de clasificación, Random Forest, KNN y SVM? Justifique su elección considerando las características del problema (tipo de respuesta, cantidad de datos, relaciones lineales o con saltos, necesidad de explicar la decisión, escalas de las variables, desbalance de clases) y cómo funcionan los modelos estudiados. Indique también qué modelo descartaría y por qué. Si ha investigado otros modelos de Machine Learning (por ejemplo, XGBoost o regresión polinomial), puede proponerlo: explique brevemente cómo funciona, por qué le parecería mejor para este caso y cite la fuente que consultó.

4. Evaluación de resultados (2 puntos). ¿Cómo comprobaría que el modelo funciona correctamente? Indique cómo dividiría los datos (Train, Validation y Test, K-Fold o una división en el tiempo), qué métricas usaría (MAE, RMSE, R^2; o matriz de confusión, Precision, Recall y F1) y contra qué modelo de referencia lo compararía (el promedio o la clase más frecuente). Mencione qué resultados le harían desconfiar de sus predicciones.

5. Análisis crítico (1,5 puntos). Imagine que el modelo obtiene resultados excelentes durante el entrenamiento, pero considerablemente peores con datos que nunca

había visto. ¿Qué podría estar ocurriendo y qué recomendaría revisar antes de utilizarlo? Piense en el sobreajuste, en los hiperparámetros, en posibles fugas de información y en si los datos nuevos se parecen a los de entrenamiento.

6. Reflexión profesional (1 punto). Un compañero afirma: «Si el modelo obtiene un porcentaje elevado de aciertos, podemos confiar en sus resultados sin necesidad de analizarlos más». ¿Está de acuerdo? Explique su respuesta con lo aprendido durante el módulo; puede apoyarse en un ejemplo numérico propio.

Entrega

- Responda las seis preguntas con argumentos propios, numeradas como en este enunciado. No se requiere programación.
- Extensión: máximo dos páginas en PDF, con su nombre en la primera línea. Puede usar tablas si le ayudan a ordenar sus ideas.
- Si consulta fuentes externas o investiga otros modelos, cítelas al final (no cuentan para la extensión).
- Trabajo individual. Se evaluará la capacidad de identificar problemas, seleccionar modelos, interpretar resultados y justificar decisiones, no la complejidad técnica de las respuestas.

Evaluación

Criterio	Puntos
1. Clasifica correctamente los tres casos y define la variable objetivo de cada uno	2
2. Propone al menos cuatro variables pertinentes y cuida que estén disponibles al predecir	1,5
3. Elige y descarta modelos con argumentos ligados al problema y a cómo funcionan	2
4. Propone una forma de dividir los datos, métricas adecuadas y un modelo de referencia	2
5. Identifica causas del mal desempeño con datos nuevos y qué revisar	1,5
6. Argumenta con criterio por qué un porcentaje de aciertos no basta	1
Total	10